

베이지안 계량경제학

강의노트 — 베이지안 통계, MCMC, 그리고 응용 계량경제 모형

Jin Gyu Song

Department of Economics, Texas A&M University

jgsong@tamu.edu

안내: 본 강의노트는 강규호 교수님의 저서 『베이지안 계량경제학』 (제2판, 박영사)을 바탕으로 혼자 공부하기 위해 정리한 것입니다. 내용에 오류가 있을 수 있으니, 오타나 잘못된 부분을 발견하시면 jgsong@tamu.edu로 알려 주시기 바랍니다. 표기법은 절에 따라 다소 다를 수 있으므로 문맥에 따라 이해하시기 바랍니다. 본 자료의 무단 복제 및 배포를 전부 또는 일부를 막론하고 어떠한 형태로든 엄격히 금지합니다.

목차

1	베이저안 통계 분석의 기초	4
1.1	베이즈 정리	4
1.2	컬레사전분포: 정규평균	5
1.3	점추정, 구간추정, 가설검정	7
1.4	예측분포	8
1.5	계산이 어려운 이유	8
2	베이저안 방법론의 경제적 의의	9
2.1	짧은 표본과 축소추정	9
2.2	모형 불확실성과 베이저안 모형평균	10
2.3	경제이론을 사전분포로 부호화하기	10
2.4	의사결정이론적 관점	11
2.5	계산 방법의 발전과 실무적 확산	11
3	MCMC 알고리즘의 기초	12
3.1	마르코프 연쇄	12
3.2	세부균형조건과 가역성	13
3.3	에르고딕 정리와 몬테카를로 근사	14
3.4	베이저안 계산에서 MCMC의 일반적 사용	15
4	표본추출 기법	15
4.1	합성법(Method of Composition)	16
4.2	확률적분변환	16
4.3	수락-기각 표본추출	17
4.4	중요도 표본추출	18
4.5	메트로폴리스-헤이스팅스 표본추출	19
4.6	다중블록 메트로폴리스-헤이스팅스	21
4.7	깁스 샘플링	22
4.8	슬라이스 샘플링	24
5	수렴 진단(Convergence Diagnostics)	26
5.1	트레이스 플롯과 자기상관함수	26
5.2	비효율성 계수	28
5.3	게웨키의 수렴 진단	28
5.4	겔먼-루빈 통계량	30
6	다중회귀(Multiple Regression)	31
6.1	모형과 컬레 사전분포	32
6.2	사후분포 유도	32
6.3	깁스 표본추출 알고리즘	34
6.4	실증 예제: 미국 경제에 대한 축약형 산출량 방정식	34
6.5	Rudebusch and Svensson (1999)	35

6.6	사전분포 민감도: 무정보적 사전분포 대 축소 사전분포	38
6.7	스튜던트- t 오차를 이용한 강건한 회귀	38
7	프로빗 모형(The Probit Model)	44
7.1	잠재변수 프로빗 모형	44
7.2	사후분포 유도	44
7.3	자료증강(앨버트-치브) 깁스 샘플러	45
7.4	실증 예제: 미국 경기침체 분기 예측	46
7.5	Estrella and Mishkin (1998)	50
8	베이저안 변수선택(Bayesian Variable Selection)	54
8.1	위계적 스파이크-슬래브 사전분포	54
8.2	사후분포 유도	54
8.3	SSVS 깁스 샘플러	57
8.4	실증 예제: CPI 인플레이션의 예측변수 선택	58
8.5	치브의 방법을 통한 주변우도	60
9	토빗 모형(Tobit Model)	63
9.1	검열된 결과변수와 잠재변수 토빗 모형	63
9.2	사후분포 유도	64
9.3	자료증강 깁스 샘플러	65
9.4	실증 예제: 영 하한에서의 연방기금금리	65
10	외견상 무관한 회귀(Seemingly Unrelated Regressions, SUR)	68
10.1	SUR 모형	69
10.2	사후분포 유도	69
10.3	깁스 샘플러	71
10.4	실증 예제: 두 방정식으로 이루어진 거시 예측 체계	72
10.5	실증 예제: SUR이 실제로 도움이 되는 대응 체계	73
11	벡터자기회귀(Vector Autoregression, VAR)	76
11.1	$VAR(p)$ 모형과 그 컴패니언 형태	76
11.2	사후분포 유도	77
11.3	SUR의 특수한 경우로서의 VAR	78
11.4	Stock and Watson (2001)	78
11.5	SW 표본의 끝에서 2001-2026년을 예측하기	81
12	구조적 VAR과 충격반응함수 분석	82
12.1	식별 문제	83
12.2	사후분포 유도	83
12.3	공통난수 몬테카를로를 통한 충격반응	85
12.4	재귀적 식별 아래의 SW 체계	86
12.5	고정된 순서를 넘어서: 부호제약과 영제약	88
12.6	Uhlig (2005)	90
13	대형 베이저안 VAR와 미네소타 사전분포	93

13.1 VAR에서의 차원의 저주	94
13.2 미네소타(Litterman) 사전분포	94
13.3 사후분포 유도	95
13.4 고정된 소규모 시스템: 축소가 정말로 중요한가?	95
13.5 더미 관측치 구현과 적합도에 맞춘 축소	97
13.6 전체 비교: $n = 3, 20, 131$ 에 걸친 적합도-맞춤 축소	99
13.7 확장: 저자 자신의 코드로부터 추정된 위계적 사전분포	103
13.8 확장: 말편자(horseshoe) 사전분포	108
13.9 어느 사전분포가 이기는가? 3자 비교	110
14 GARCH 모형과 맞춤형 독립 메트로폴리스-헤이스팅스	113
14.1 GARCH(1,1) 모형	114
14.2 사후분포 유도	114
14.3 맞춤형 독립 메트로폴리스-헤이스팅스	116
14.4 실증 예제: S&P 500 일별 수익률에 대한 GARCH(1,1) 적합	117
14.5 두 번째 구간: 코로나19 폭락과 회복, 2019-2021년	119
14.6 Bollerslev (1986)	122
15 상태공간모형과 칼만필터	124
15.1 사후분포 유도: 잠재경로에 대한 정밀도-표본추출 완전조건부분포	126
15.2 모형 1: 미국 실질 PCE 성장률에 대한 국소수준모형	127
15.3 모형 2: 미국 실질 GDP의 추세와 순환	130
15.4 Clark (1987)	135
16 확률적 변동성을 갖는 VAR	138
16.1 사후분포 유도	140
16.2 실증 예제: 25개 변수 LVAR-SV, 1979-2026	143
16.3 LVAR 대 LVAR-SV: 점 예측과 밀도 예측	146
17 시변모수 VAR (Time-Varying Parameter VAR, TVP-VAR)	149
17.1 사후분포 유도: 순방향 필터링, 역방향 샘플링	151
17.2 실증 예제: 통화정책의 전달은 변했는가	154
17.3 Cogley and Sargent (2001)	157
18 마르코프 국면전환 모형 (Markov-Switching Regime Model)	160
18.1 사후분포 유도	162
18.2 실증 예제: 미국 GDP 성장률의 경기침체 및 확장 국면, 1959-2026년	164
18.3 Hamilton (1989)	167
19 비모수 모형: 회귀나무와 BART (Bayesian Additive Regression Trees)	170
참고문헌	176

1. 베이저안 통계 분석의 기초

로드맵

이 강의노트의 모든 모형은(6장의 회귀모형부터 18장의 국면전환모형에 이르기까지) 모두 동일한 질문에 답한다: 자료는 미지의 모수 θ 에 대해 무엇을 말해주는가? 이 장은 베이저안적 답을 구성한다(θ 를 확률변수로 취급하고, 사전 믿음을 사후 믿음으로 갱신한다) 그리고 산술이 단순하게 유지되는 하나의 경우, 즉 정규분포 사전을 갖는 정규평균의 경우에 대해 이를 직접 손으로 풀어 보인다. 이 예제는 단순한 장식이 아니다: 동일한 완전제곱식 만들기 단계가 스칼라 대신 행렬을 사용하는 형태로 6장 이후 거의 모든 proofbox에서 다시 등장한다. 모형이 이렇게 단순하지 않게 되는 순간부터(이는 7장부터 사실상 그러하다) 사후분포는 더 이상 닫힌 형태로 표현될 수 없으며, 3-4장은 이 경우를 다루는 계산 도구인 MCMC를 제공한다.

계량경제학에서 모수 θ 를 추정하는 것은 근본적으로 결코 직접 관측되지 않는 대상에 관한 확률적 진술을 만드는 작업이다. 빈도주의 접근법은 θ 를 고정된 미지의 상수로 취급하고, 가상적으로 반복되는 표본에 걸친 추정량 $\hat{\theta}$ 의 표본분포(불편성, 일치성, 점근분산 등)를 통해 불확실성을 표현한다. 반면 베이저안 접근법은 θ 자체를 확률변수로 취급하여, 자료를 관측하기 전에 θ 에 대해 가지고 있던 믿음(사전)과 자료가 제공하는 정보(우도)를 결합함으로써 자료를 관측한 후의 갱신된 믿음(사후)을 얻는다.

두 관점의 핵심적 차이

- 빈도주의: θ 는 고정되어 있고, 자료 y 가 확률적이다. 신뢰구간은 “이 절차를 무한히 반복했을 때 참값을 포함하는 구간의 비율”로 해석된다.
- 베이저안: θ 와 y 모두 확률적이다. 신용구간은 “관측된 자료가 주어졌을 때 θ 가 이 구간에 속할 확률”로 직접 해석될 수 있다.
- 베이저안 추론의 산출물은 단일한 점추정치가 아니라 θ 에 대한 완전한 확률분포(사후분포)이며, 점추정, 구간추정, 가설검정은 모두 이 사후분포의 함수로 도출된다.

이 강의노트에서 다루는 거시/금융 계량경제 모형들(VAR, 상태공간모형, 확률적 변동성 모형, 국면전환모형 등)은 대개 표본크기가 편안하게 감당할 수 있는 수준보다 모수의 개수가 많거나, 비선형/비표준적인 우도함수를 갖는다. 베이저안 방법은 이 두 문제를 동일한 기제로 해결한다: 사전분포는 그렇지 않으면 과소결정된 모수의 수를 규율하고(13장), MCMC(마르코프 연쇄 몬테카를로)는 닫힌 형태가 없는 사후분포로부터 표본을 생성함으로써(3-4장) 프로빗(7장)과 같은 비선형 모형도 선형 모형과 마찬가지로 일상적으로 추정할 수 있게 해준다.

1.1 베이즈 정리

자료 y 와 모수 θ 에 대한 확률변수의 결합분포 $p(y, \theta)$ 는 두 가지 동등한 방식으로 분해될 수 있다:

$$p(y, \theta) = p(y | \theta) p(\theta) = p(\theta | y) p(y).$$

두 표현을 같다고 놓고 $p(\theta | y)$ 에 대해 풀면 베이즈 정리를 얻는다.

$$p(\theta | y) = \frac{p(y | \theta) p(\theta)}{p(y)} = \frac{p(y | \theta) p(\theta)}{\int p(y | \theta) p(\theta) d\theta}.$$

각 구성 요소의 명칭과 역할은 다음과 같다.

용어	의미
$p(\theta)$ (사전분포)	자료를 관측하기 전에 θ 에 대해 가지고 있던 믿음이다. 연구자의 경제이론적 지식, 선행 연구 결과, 또는 의도적으로 무정보적인 판단을 반영한다.
$p(y \theta)$ (우도)	θ 가 주어졌을 때 자료 y 가 나타날 확률(또는 밀도)이다. θ 의 함수로 볼 때는 $L(\theta; y)$ 로도 표기한다.
$p(\theta y)$ (사후분포)	자료를 관측한 후 갱신된 θ 에 대한 믿음이다. 베이지안 추론의 최종 산출물이다.
$p(y)$ (한계우도)	θ 를 적분하여 없앤, 자료의 무조건부 확률(밀도)이다. 이는 모형 비교(베이즈 요인)의 핵심 수량이며, 사후분포를 계산하는 데에는 단순히 정규화 상수일 뿐이다.

정규화 상수 $p(y)$ 가 θ 에 의존하지 않으므로, 사후분포의 형태를 특징짓는 데에는 다음의 비례관계만으로 충분하다:

$$p(\theta | y) \propto p(y | \theta)p(\theta) = \text{우도} \times \text{사전분포}.$$

이 비례관계는 이 강의노트 전체에서 가장 자주 사용되는 단일 관계식이다. 3장에서 다루는 MCMC 알고리즘의 본질은 $p(y)$ 를 결코 계산하지 않고 오직 이 비례관계만을 이용하여 θ 의 표본을 생성하는 데 있다.

실증 예제: 동전 던지기에서 경기침체 확률로

베이즈 정리에 대한 직관을 기르기 위해 이산적인 예를 살펴보자. 이번 분기에 경제가 경기침체 상태($R = 1$)에 있을 사전확률이 $p(R = 1) = 0.15$ 라고 하자(이는 전후 미국에서 NBER이 경기침체로 분류한 분기의 장기 평균 비중과 가깝다). 장단기 금리차(10년물에서 3개월물 국채 수익률의 뺄 값)가 역전되었음($I = 1$)을 관측했다고 하자. 과거 자료로부터 $p(I = 1 | R = 1) = 0.7$ (경기침체 직전 역전이 발생하는 빈도)이고 $p(I = 1 | R = 0) = 0.10$ (정상시의 오탐률)이라고 하자. 그러면

$$p(R = 1 | I = 1) = \frac{0.7 \times 0.15}{0.7 \times 0.15 + 0.10 \times 0.85} = \frac{0.105}{0.19} \approx 0.553.$$

수익률곡선 역전이라는 단 하나의 신호가 경기침체 확률을 15%에서 55%로 끌어올린다. 이것이 베이지안 갱신의 본질이며, 정확히 동일한 논리가 18장의 연속적, 다변량 VAR 기반 국면확률 추정으로 확장된다.

1.2 켈레사전분포: 정규평균

사전분포와 우도의 함수 형태가 잘 맞아떨어져 사후분포가 사전분포와 동일한 분포족에 속하게 되는 경우, 그 사전분포를 켈레사전분포라 부른다. 켈레성은 사후분포를 해석적으로 도출할 수 있게 해 주며,

동일한 기법이 깃스 샘플러 내부에서 사용되는 완전조건부분포를 유도할 때(예: 6장의 회귀모형, 9장의 토빗모형) 이 노트 전체에서 반복적으로 나타난다.

유도: 정규평균의 사후분포

$y_i | \mu \sim N(\mu, \sigma^2), i = 1, \dots, T$ 이고 σ^2 는 알려져 있다고 하자. 사전분포로 $\mu \sim N(\mu_0, \tau_0^2)$ 을 취한다. μ 에 대한 단일한 이차식으로 단순화한 우도와, 이를 사전밀도와 곱하여 얻은 사후 커널은 다음과 같다.

$$L(\mu; y) \propto \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^T (y_i - \mu)^2\right)$$

제곱합에서 완전제곱식을 만들면 다음과 같이 정리된다:

$$\propto \exp\left(-\frac{T}{2\sigma^2}(\mu - \bar{y})^2\right)$$

사전밀도를 곱하면 사후 커널을 얻는다:

$$p(\mu | y) \propto \exp\left(-\frac{1}{2\tau_0^2}(\mu - \mu_0)^2 - \frac{T}{2\sigma^2}(\mu - \bar{y})^2\right)$$

μ 에 대해 완전제곱식을 만들기 위해 두 이차식을 전개하면:

$$\propto \exp\left(-\frac{1}{2\tau_0^2}(\mu^2 - 2\mu\mu_0 + \mu_0^2) - \frac{T}{2\sigma^2}(\mu^2 - 2\mu\bar{y} + \bar{y}^2)\right)$$

μ 에 대해 이차항과 일차항을 각각 모으면(나머지는 모두 μ 와 무관한 상수이므로 비례관계 속으로 흡수된다):

$$\propto \exp\left(-\frac{1}{2} \left(\frac{1}{\tau_0^2} + \frac{T}{\sigma^2}\right) \mu^2 + \left(\frac{\mu_0}{\tau_0^2} + \frac{T\bar{y}}{\sigma^2}\right) \mu\right)$$

$\tau_1^2 := (1/\tau_0^2 + T/\sigma^2)^{-1}$ 와 $\mu_1 := \tau_1^2(\mu_0/\tau_0^2 + T\bar{y}/\sigma^2)$ 를 정의하면 위 대괄호 속 지수는 $-\frac{1}{2\tau_1^2}\mu^2 + \frac{\mu_1}{\tau_1^2}\mu$ 가 되고, 상수 $\mu_1^2/(2\tau_1^2)$ 를 더하고 빼면 이를 하나의 완전제곱식으로 만들 수 있다:

$$-\frac{1}{2\tau_1^2}\mu^2 + \frac{\mu_1}{\tau_1^2}\mu = -\frac{1}{2\tau_1^2}(\mu - \mu_1)^2 + \frac{\mu_1^2}{2\tau_1^2}$$

마지막 항은 μ 를 포함하지 않으므로 비례관계 속으로 흡수되고, 남는 것은 $p(\mu | y) \propto \exp\left(-\frac{1}{2\tau_1^2}(\mu - \mu_1)^2\right)$, 즉 $N(\mu_1, \tau_1^2)$ 밀도의 커널이다. 따라서

$$\begin{aligned} \mu | y &\sim N(\mu_1, \tau_1^2), \\ \tau_1^2 &= \left(\frac{1}{\tau_0^2} + \frac{T}{\sigma^2}\right)^{-1}, \\ \mu_1 &= \tau_1^2 \left(\frac{\mu_0}{\tau_0^2} + \frac{T\bar{y}}{\sigma^2}\right). \end{aligned}$$

사후평균 μ_1 은 사전평균 μ_0 와 표본평균 $\bar{y}$ 의 정밀도 가중평균이다: 사전 정밀도 $1/\tau_0^2$ 가 클수록(즉 사전 믿음이 강할수록) μ_1 은 μ_0 쪽으로 더 가깝게 끌리고, 표본크기 T 가 클수록 μ_1 은 $\bar{y}$ 쪽으로 더 가깝게 이동한다. $T \rightarrow \infty$ 일 때 베이저안 추정량은 빈도주의 MLE인 $\bar{y}$ 로 수렴하며, 이는 표본이 커짐에 따라 사전분포의 영향이 자연스럽게 사라짐을 보여준다.

실증 예제: 미국 실질 GDP 평균 성장을 추정

코로나19 팬데믹을 포함하도록 2026년 1분기까지 확장된 분기별 미국 거시경제 자료($T = 267$)를 이용하여 실질 GDP의 평균 성장률(연율, %) μ 에 대한 베이저안 갱신을 수행한다. 사전분포로 $\mu \sim N(\mu_0 = 2.5, \tau_0^2 = 1.0)$ 을 사용한다(전후 미국의 장기 평균 성장률을 반영하는 사전평균 2.5%에, 상당히 느슨한 사전분산 1.0을 부여한 것이다). 자료로부터 직접 계산한 표본평균과 표본분산은 $\bar{y} = 2.966, s^2 = 17.601$ (표본표준편차 4.195)이다 — 분산은 팬데믹 이전 표본보다 약 54% 더 큰데, 이는 전적으로 2020년의 두 분기(-28.0%와 +34.9%) 때문이며, 평균은 거의 움직이지 않는다.

정밀도 가중평균 공식을 적용하면,

$$\tau_1^2 = \left(\frac{1}{1.0} + \frac{267}{17.601} \right)^{-1} = 0.0618, \quad \mu_1 = 0.0618 \left(\frac{2.5}{1.0} + \frac{267 \times 2.966}{17.601} \right) = 2.938.$$

$T = 267$ 이 충분히 크기 때문에, 사후평균 $\mu_1 = 2.938$ 은 사전평균(2.5)보다 표본평균(2.966)에 훨씬 더 가깝다. 95% 신용구간은 $\mu_1 \pm 1.96\sqrt{\tau_1^2} = [2.45, 3.43]$ 이다. 이 예제는 실제 자료를 통해 표본이 클 때 사전분포의 영향이 무시할 만한 수준이 됨을 확인해 준다 — 반대로 더 짧은 분기별 거시 시계열(예: $T < 50$)에서는 사전분포가 훨씬 더 큰 역할을 하는데, 바로 이 때문에 13장의 LBVAR 모형과 17장의 TVP-VAR 모형에서 축소 사전분포가 필수적이다.

1.3 점추정, 구간추정, 가설검정

사후분포 $p(\theta | y)$ 가 확보되면, 전통적인 통계적 요약량들은 모두 이 분포의 함수로 자연스럽게 따라 나온다.

용어	의미
사후평균	$E[\theta y] = \int \theta p(\theta y) d\theta$. 이차손실 하에서 베이저안 위험을 최소화하는 점추정치이다.
사후중앙값	절대오차손실 하에서 최적인 점추정치이다. 비대칭적인 사후분포(예: 분산 모수)에서는 평균보다 더 대표성이 있을 수 있다.
사후최빈값	0-1 손실 하에서 최적이다. 사후분포의 봉우리 위치이며, MAP(최대사후확률) 추정치라고도 부른다.

신용구간

$P(\theta_L \leq \theta \leq \theta_U | y) = 1 - \alpha$ 를 만족하는 구간으로, 사후 분위 수로부터 직접 계산되며 직접적인 확률적 해석을 허용한다.

사후확률

$P(\theta \in A | y)$ 형태의 임의의 가설에 대한 직접적인 확률 진술이다. 예를 들어 $P(\beta > 0 | y)$ 는 빈도주의 p -값과 달리 문자 그대로 “ β 가 양수일 확률”을 의미한다.

MCMC가 사후분포로부터 표본 $\{\theta^{(1)}, \dots, \theta^{(N)}\}$ 을 생성하면, 위의 모든 수량은 몬테카를로 방법으로 쉽게 근사된다: 표본평균, 표본분위수, 표본비율 등이 그것이며, 예를 들면

$$\widehat{E[\theta | y]} = \frac{1}{N} \sum_{s=1}^N \theta^{(s)}, \quad P(\widehat{\theta > c} | y) = \frac{1}{N} \sum_{s=1}^N \mathbb{I}\{\theta^{(s)} > c\}.$$

바로 이 점이 3장 이후에서 전개되는 것처럼 MCMC 기반 추정이 실제로 강력한 이유이다: 사후 표본을 얻고 나면, 관심 있는 어떤 추정치나 가설도 그 표본에 대한 단순한 계산으로 귀결된다.

1.4 예측분포

베이저안 분석은 모수뿐 아니라 미래 관측값 y_{T+1} 에 대해서도 자연스러운 확률적 진술을 제공한다. 사후예측분포는 다음과 같이 정의된다.

$$p(y_{T+1} | y_{1:T}) = \int p(y_{T+1} | \theta) p(\theta | y_{1:T}) d\theta,$$

이는 모수 불확실성($p(\theta | y_{1:T})$)과 조건부 모형 불확실성($p(y_{T+1} | \theta)$) 모두에 걸쳐 적분한 것이다. 이 예측구간은 $\hat{\theta}$ 를 단일 값으로 고정하는 플러그인 예측보다 항상 (약하게) 더 넓으며, 이 추가적인 폭은 모수 추정 오차를 정직하게 반영한다 — 이는 순수하게 점추정 중심적인 빈도주의 접근법에서는 얻기 어려운 통찰이다. MCMC 추출값 $\theta^{(s)}$ 가 주어지면, 각 추출값에 대해 $y_{T+1}^{(s)} \sim p(\cdot | \theta^{(s)})$ 를 시뮬레이션함으로써 예측분포로부터의 표본을 즉시 얻을 수 있으며, 이는 11장(VAR)과 15장(상태공간 모형)의 예측 사례에서 실제로 사용되는 방법 그대로이다.

참고: 순차적 베이저안 학습

베이저 정리는 시간에 걸쳐 반복적, 순차적인 방식으로 자연스럽게 적용된다. $t - 1$ 까지의 자료로 얻은 사후분포 $p(\theta | y_{1:t-1})$ 을 시점 t 에서의 사전분포로 사용하면,

$$p(\theta | y_{1:t}) \propto p(y_t | \theta) p(\theta | y_{1:t-1})$$

이 성립한다. 다시 말해 오늘의 사후분포가 내일의 사전분포가 된다 — 이는 실시간 거시경제 나우 캐스팅과 상태공간모형(15장)에서 사용되는 칼만 필터의 근간이 되는 구조와 정확히 동일하다.

1.5 계산이 어려운 이유

위의 정규-정규 예에서는 사전분포와 우도가 켈레이므로 사후분포를 해석적으로 도출할 수 있다. 그러나 이 강의노트에서 다루는 대부분의 모형(프로빗모형(7장), 토빗모형(9장), 확률적 변동성 모형(16장), 국면전환모형(18장) 등)은 몇 가지 이유로 닫힌 형태의 사후분포로 환원될 수 없다.

- 모수공간이 고차원이어서(예: VAR 계수행렬과 공분산행렬), 정규화 적분 $\int p(y | \theta)p(\theta)d\theta$ 가 해석적 해를 갖지 않는다.
- 우도가 비선형이거나(예: 프로빗모형의 표준정규 CDF $\Phi(\cdot)$) 잠재변수를 포함하여, 사전분포와의 컬레성이 깨진다.
- 모수들이 서로 결합되어 있어(예: 회귀계수 β 와 오차분산 σ^2), 결합 사후분포가 어떠한 표준 분포족에도 속하지 않는다.

이 문제에 대한 해법이 MCMC(마르코프 연쇄 몬테카를로)이다: 정규화 상수를 결코 계산하지 않고 $p(\theta | y) \propto p(y | \theta)p(\theta)$ 라는 비례관계에만 의존하여 사후분포로부터 표본을 생성하는 일군의 알고리즘이다. 3장은 MCMC의 이론적 토대(마르코프 연쇄, 정상분포, 에르고딕 정리)를 전개하고, 4장은 실제로 사용되는 구체적인 표본추출 기법(깁스 샘플링, 메트로폴리스-헤이스팅스, 슬라이스 샘플링 등)을 다룬다.

2. 베이지안 방법론의 경제적 의의

로드맵

1장은 정규평균이라는 하나의 스칼라 사례를 통해 베이지안 갱신이 어떻게 작동하는지 보여주었다. 실제 계량경제 모형을 세우기 전에, 응용 거시/금융 연구자들이 이 기제를 단순한 수학적 호기심으로 여기지 않고 왜 굳이 선택하는지 물어볼 필요가 있다. 아래에서 전개하는 짧은 답은, 경제 자료가 가진 세 가지 구조적 특성(짧은 표본, 고차원 모형, 어느 모형이 옳은지에 대한 진정한 불확실성)이 실제로 베이지안 방법을 거의 필수적인 것으로 만든다는 것이다. 각 특성은 이후의 특정 장으로 이어진다: 짧은 표본은 13장의 축소 사전분포를, 모형 불확실성은 8장의 변수선택을 동기 부여하며, 그 바탕이 되는 계산은 3-4장에서 구축된다.

베이지안 방법론이 순수하게 통계적인 매력을 넘어 계량경제학, 특히 거시/금융 계량경제학의 중심적 위치를 차지하게 된 이유를 이해하려면 경제 자료가 가진 몇 가지 구조적 특성을 살펴볼 필요가 있다. 이 절에서는 짧은 시계열, 높은 모수 차원, 구조적 불확실성이라는 세 가지 실제적 제약을 다루며, 이들이 함께 베이지안 접근법을 거의 불가결한 것으로 만든다는 점을 논의한다.

2.1 짧은 표본과 축소추정

분기별 거시경제 시계열은 여러 수십 년치 자료를 합쳐도 대체로 $T = 200\text{--}270$ 안팎의 관측치만을 제공한다(예를 들어 이 노트 전체에서 사용하는 분기별 미국 거시자료는 1959년부터 2026년까지(코로나19 팬데믹을 포함해 거의 67년)를 포괄하지만 관측치는 $T = 267$ 개에 불과하다). 한편 VAR류 모형에서 추정해야 할 계수의 개수는 변수의 수 n 과 시차의 수 p 에 대해 n^2p 로 증가한다. 예를 들어 변수 $n = 5$ 개, 시차 $p = 4$ 개인 VAR은 방정식당 $5 \times 4 = 20$ 개의 계수(상수항을 포함하면 21개)를 가지므로, 전체 시스템은 $5 \times 21 = 105$ 개의 계수에 더해 공분산행렬의 자유모수 15개를 가져 — 합계 약 120개의 모수를 겨우 $T \approx 200$ 개의 관측치로부터 추정해야 한다.

참고: 차원의 저주와 과적합

빈도주의 최소제곱 추정은 모수의 개수가 표본크기에 근접함에 따라 분산이 폭발적으로 커지고 표본외 예측 성능이 급격히 악화되는(과적합) 문제를 겪는다. 축소 사전분포를 사용하는 베이지안 방법은 이러한 편-분산 상충관계를 명시적으로 관리한다: “대부분의 계수는 0에 가깝다”는 믿

음을 부호화함으로써, 약간의 편의를 감수하는 대신 분산을 상당히 줄인다. 13장의 미네소타/리터만 사전분포와 17장의 시변모수 사전분포는 이 원리를 구체적으로 구현한 것이다.

2.2 모형 불확실성과 베이지안 모형평균

경제이론은 동일한 현상에 대해 종종 여러 경쟁 모형을 제시한다(예를 들어 인플레이션을 설명하는 필립스곡선의 서로 다른 정식화, 또는 항상소득가설 대 유동성제약 소비모형). 빈도주의 접근법은 통상 정보기준(AIC, BIC 등)을 이용해 단일한 “최선의” 모형을 선택한 후, 이후의 모든 추론에서 마치 그 모형이 참인 것처럼 취급한다 — 즉 모형선택 단계 자체에 내재한 불확실성을 무시한다.

베이지안 모형평균(BMA)은 각 후보모형 $M_1, \dots, M_K$ 에 사전확률 $p(M_k)$ 를 부여하고, 자료를 관측한 후 사후모형확률을 계산한다.

$$p(M_k | y) = \frac{p(y | M_k) p(M_k)}{\sum_{j=1}^K p(y | M_j) p(M_j)},$$

이를 결합하여 관심 있는 수량 Δ (예측치, 정책승수 등)에 대한 전체 예측분포를 구성한다.

$$p(\Delta | y) = \sum_{k=1}^K p(\Delta | y, M_k) p(M_k | y).$$

여기서 $p(y | M_k) = \int p(y | \theta_k, M_k) p(\theta_k | M_k) d\theta_k$ 는 모형 M_k 의 한계우도이며, 두 모형 사이의 사후 오즈는 다음과 같이 분해된다.

$$\frac{p(M_1 | y)}{p(M_2 | y)} = \underbrace{\frac{p(y | M_1)}{p(y | M_2)}}_{\text{베이즈 요인}(BF_{12})} \times \frac{p(M_1)}{p(M_2)}.$$

베이즈 요인은 우도비 검정을 모형비교 지표로 자연스럽게 일반화한 것으로, 표본외 예측력과 모형 복잡도(모수의 수에 대한 자동적인 벌점)를 본질적으로 균형 있게 반영한다 — 정보기준과 달리 이 벌점은 임의로 부과되는 것이 아니라 자연히 발생하며, 이 때문에 베이즈 요인은 종종 오컴의 면도날을 확률적으로 구현한 것으로 설명된다. 8장(변수선택)은 스파이크-슬랩 사전분포를 사용하여 회귀변수를 포함할지 제외할지에 관한 이산적인 모형공간에 이 아이디어를 적용한다.

2.3 경제이론을 사전분포로 부호화하기

베이지안 틀의 또 다른 경제적 의미는 경제이론이 함의하는 제약이나 믿음을 사전분포의 형태로 명시적으로 도입할 수 있다는 점이다. 대표적인 예는 다음과 같다.

용어	의미
미네소타 사전분포	대부분의 VAR 계수는 0에 가깝고 각 변수 자신의 1시차 계수는 1에 가깝다는 믿음을 반영한다(즉 개별 시계열이 대략 임의보행처럼 움직인다는 것이다(13장)).

부호제약	구조적 충격의 이론적 방향) 예를 들어 긴축적 통화정책 충격이 물가를 낮추고 산출을 감소시킨다는 것 — 을 구조적 충격에 대한 사전(또는 식별) 제약으로 부과한다(12장).
정상성 사전분포	자기회귀 계수의 사전확률질량을 단위근 경계로부터 멀리 밀어내어 정상적인 영역으로 이동시킨다(11장, 17장).
제로금리하한 사전분포	절단된 사전분포/우도를 통해 정책금리가 실효하한 근처에서 특별하게 행동한다는 정보를 부호화한다(9장의 토빗모형과 연결된다).

이는 사후적으로 부호제약을 검정하거나 임시방편적으로 계수를 0으로 강제하는 빈도주의적 관행과 근본적으로 다르다: 베이지안 접근법에서는 이론적 제약이 추정 이전에 확률적으로 도입되며, 자료가 이론과 상충할 경우(사전분포가 지나치게 강하지 않은 한) 사후분포가 그 제약으로부터 자연스럽게 벗어나도록 허용된다.

2.4 의사결정이론적 관점

베이지안 통계학은 통계적 의사결정이론과 자연스럽게 연결된다. 행동 a 를 취하는 정책결정자가 참 상태 θ 하에서 손실 $L(a, \theta)$ 를 입는다면, 베이지안 의사결정자는 사후분포 하에서 기대손실(베이지안 위험)을 최소화하는 행동을 선택한다.

$$a^* = \arg \min_a E_{\theta|y}[L(a, \theta)] = \arg \min_a \int L(a, \theta) p(\theta | y) d\theta.$$

이 틀은 모수 불확실성 하에서 최적의 행동을 선택해야 하는 모든 경제적 의사결정 문제(중앙은행의 통화정책 결정, 재정승수 추정, 포트폴리오 배분 등)에 직접 적용된다. 특히 손실함수가 비대칭적일 때(예를 들어 인플레이션이 목표를 초과할 때의 손실이 미달할 때의 손실보다 큰 경우), 최적 정책은 사후평균이 아닌 다른 사후 요약량이 될 수 있다 — 이는 순수하게 점추정 중심적인 빈도주의 접근법으로는 포착하기 어려운 통찰이다.

2.5 계산 방법의 발전과 실무적 확산

이론적 정교함을 넘어, 계산 도구의 급속한 발전은 1990년대 이후 베이지안 계량경제학이 거시/금융 실증연구의 주류 도구로 자리 잡는 데 결정적이었다. 깃스 샘플링과 메트로폴리스-헤이스팅스 알고리즘(3-4장)이 계량경제학에 완전히 통합되자, 이전에는 닫힌 형태의 해가 없어 추정하기 어려웠던 모형들이 실용적으로 가능해졌다: 대형 VAR(Doan, Litterman and Sims, 1984; Litterman, 1986), 구조적 벡터자기회귀모형(Sims, 1980; Sims and Zha, 1998), 상태공간모형과 확률적 변동성 모형(Kim, Shephard and Chib, 1998), 국면전환모형(Hamilton, 1989; Kim and Nelson, 1999), 그리고 대규모 패널/동태요인모형이 그것이다. 오늘날 연방준비제도, 유럽중앙은행 등 주요 중앙은행이 정책분석에 사용하는 동태확률일반균형(DSGE) 모형과 BVAR 예측모형은 거의 예외 없이 베이지안 방법으로 추정된다. 이 노트에서 6장 이후 다루는 모든 모형(회귀, 프로빗, 토빗, SUR, VAR, SVAR, LVAR, GARCH, 상태공간모형, VAR-SV, TVP-VAR, 국면전환)은 이 계산기술의 구체적인 사례이며, 각 장은 깃

스 샘플링이나 M-H 알고리즘을 실제 미국 거시/금융 자료에 직접 적용하여 사후추정 결과를 산출한다.

3. MCMC 알고리즘의 기초

로드맵

1장은 동일한 문제를 반복해서 남긴 채 끝났다: 이 노트에 나오는 대부분의 사후분포는 닫힌 형태를 갖지 않으므로, 정규평균 예제처럼 요약될 수 없다. MCMC가 그 해법이며, 이는 어떤 메커니즘의 요체를 먼저 짚어볼 가치가 있는 트릭으로 작동한다: 사후분포를 직접 계산하는 대신, 모수 공간을 배회하면서 각 지점을 정확히 사후밀도에 비례하는 장기 빈도로 방문하는 마르코프 연쇄를 구축하는 것이다. 이 절은 이 트릭이 작동함을 보장하는 하나의 조건(세부균형조건, detailed balance)을 유도하며, 4장은 이 조건을 만족하는 구체적인 방법들(깁스, 메트로폴리스-헤이스팅스 등)을 제공한다. 그리고 6장 이후 나오는 모든 algobox는 이 장을 마무리하는 여섯 단계 절차의 응용이다.

1장에서 살펴보았듯이, 대부분의 실용적인 베이지안 모형에서 사후분포 $p(\theta | y)$ 는 해석적으로 얻을 수 없다. MCMC(마르코프 연쇄 몬테카를로)는 정규화 상수를 결코 계산하지 않고 $p(\theta | y)$ 로부터 (근사적인) 표본을 추출하는 알고리즘들을 통칭하는 이름이다. 이 절은 4장에서 다루는 구체적인 표본추출 기법(깁스, M-H, 슬라이스 샘플링 등)의 바탕이 되는 마르코프 연쇄 이론의 기본 개념을 정리한다.

3.1 마르코프 연쇄

상태공간 Θ 를 움직이는 확률과정 $\{\theta^{(0)}, \theta^{(1)}, \theta^{(2)}, \dots\}$ 가 다음 상태의 조건부분포가 오직 현재 상태에만 의존하고 그 이전의 이력에는 의존하지 않는다는 마르코프 성질을 만족한다고 하자.

$$p(\theta^{(t+1)} | \theta^{(t)}, \theta^{(t-1)}, \dots, \theta^{(0)}) = p(\theta^{(t+1)} | \theta^{(t)}) \equiv K(\theta^{(t)}, \theta^{(t+1)}),$$

여기서 $K(\cdot, \cdot)$ 를 전이커널이라 부른다. 그림 1는 이것이 함의하는 의존구조를 보여준다: 각 상태는 오직 바로 직전 상태에만 의존하며, 그보다 더 이전의 어떤 것에도 의존하지 않는다.




Figure 1: 마르코프 연쇄의 의존구조: 각 상태는 매 단계 동일한 전이커널 K 를 통해 오직 바로 직전 상태에만 의존한다

MCMC의 핵심 발상은 정상분포가 목표분포(여기서는 사후분포 $\pi(\theta) := p(\theta | y)$)가 되도록 전이커널 K 를 설계하는 것이다.

용어	의미
전이커널 $K(\theta, \theta')$	현재 상태 θ 에서 다음 상태 θ' 로 이동할 확률(밀도)이다. 마르코프 연쇄의 동학을 완전히 결정한다.

정상분포 $\pi(\cdot)$	$\pi(\theta') = \int \pi(\theta)K(\theta, \theta') d\theta$ 를 만족하는 분포이다. 연쇄가 이 분포로부터 출발하면, 이후 계속 이 분포에 머문다.
기약성(irreducibility)	상태공간의 임의의 지점에서 출발하여, 유한한 단계 안에 양의 확률로 다른 임의의 지점에 도달할 수 있는 성질이다.
비주기성(aperiodicity)	연쇄가 특정 상태로 고정된 주기적 간격에서만 되돌아오지 않는 성질이다. 기약성과 함께 연쇄가 유일한 극한분포로 수렴함을 보장한다.
에르고딕성	기약적이고 비주기적인 마르코프 연쇄는 초기값과 무관하게 유일한 정상분포로 수렴하는 에르고딕 성질을 갖는다.

3.2 세부균형조건과 가역성

정상분포가 π 인 전이커널을 구성하는 데 가장 널리 사용되는 충분조건은 세부균형조건 (detailed balance)이다. 전이커널 K 는 다음이 성립할 때 π 에 대해 세부균형조건을 만족한다고 한다.

$$\pi(\theta)K(\theta, \theta') = \pi(\theta')K(\theta', \theta) \quad \text{모든 } \theta, \theta' \text{에 대해}$$

이는 정상상태에서 $\theta \rightarrow \theta'$ 로의 “확률 흐름”이 $\theta' \rightarrow \theta$ 로의 역방향 흐름과 정확히 같다는 물리적 직관(가역성)을 표현한다.

유도: 세부균형조건이 정상성을 함의함

세부균형조건이 성립하면, 양변을 θ 에 대해 적분하여 다음을 얻는다.

$$\int \pi(\theta)K(\theta, \theta') d\theta = \int \pi(\theta')K(\theta', \theta) d\theta$$

θ' 는 적분변수 θ 에 의존하지 않으므로 우변의 적분 밖으로 꺼낼 수 있다:

$$= \pi(\theta') \int K(\theta', \theta) d\theta$$

그리고 전이커널은 두 번째 인수에 대해 확률분포이므로 $\int K(\theta', \theta) d\theta = 1$ 이 성립하여:

$$= \pi(\theta')$$

좌변은 정확히 정상분포의 정의인 $\int \pi(\theta)K(\theta, \theta') d\theta$ 이므로, $\pi(\theta') = \int \pi(\theta)K(\theta, \theta') d\theta$ 가 성립하고 π 가 실제로 K 의 정상분포임이 증명된다. 이 결과는 4장에서 소개하는 메트로폴리스-헤이스팅스와 깁스 샘플러가 왜 목표 사후분포로 수렴하는지를 보이는 데 핵심적이다: 두 알고리즘 모두 세부균형조건이 구성상 성립하도록 설계되어 있다.

3.3 에르고딕 정리와 몬테카를로 근사

연쇄가 기약적이고 비주기적이며 정상분포 π 를 가지면, 초기값 $\theta^{(0)}$ 의 분포와 무관하게 $\theta^{(t)}$ 의 분포는 $t \rightarrow \infty$ 에 따라 π 로 수렴한다(수렴정리). 나아가 마르코프 연쇄에 대한 대수의 법칙(마르코프 연쇄 에르고딕 정리)에 의해, 임의의 함수 $g(\cdot)$ 에 대해

$$\frac{1}{N} \sum_{t=1}^N g(\theta^{(t)}) \xrightarrow{a.s.} E_{\pi}[g(\theta)] = \int g(\theta) \pi(\theta) d\theta$$

이 성립한다. 이는 독립동일분포(i.i.d.) 표본에 대한 통상적인 대수의 법칙을 (약하게 의존하는) 마르코프 연쇄 표본으로 일반화한 것으로, 1장에서 논의한 사후평균과 사후확률의 몬테카를로 근사가 MCMC 표본에 대해서도 여전히 유효함을 정당화하는 이론적 근거이다. 다만 MCMC 표본은 서로 독립적이지 않고 계열상관을 가지므로, i.i.d. 표본과 동일한 표본크기 N 이라도 유효표본크기는 더 작다 — 이 개념은 5장(수렴 진단)에서 비효율성 계수를 통해 공식화된다.

실증 예제: 2상태 마르코프 연쇄의 정상분포 수렴: 경기순환 예제

마르코프 연쇄의 수렴을 시각적으로 확인하기 위해, 경제를 확장(상태 1)과 침체(상태 2)의 두 상태로 단순화한 연쇄를 생각해 보자. 전이확률행렬을 다음과 같이 설정한다.

$$P = \begin{pmatrix} p_{11} & p_{12} \\ p_{21} & p_{22} \end{pmatrix} = \begin{pmatrix} 0.95 & 0.05 \\ 0.35 & 0.65 \end{pmatrix}$$

(확장국면의 평균 지속기간은 $1/(1 - 0.95) = 20$ 분기이고 침체국면은 $1/(1 - 0.65) \approx 2.9$ 분기로, 이는 전후 미국 경기순환의 대략적인 비대칭적 지속성 패턴과 질적으로 부합한다). 정상분포 $\pi = (\pi_1, \pi_2)$ 는 $\pi P = \pi, \pi_1 + \pi_2 = 1$ 을 풀어서 얻으며, $\pi_1 = p_{21}/(p_{12} + p_{21}) = 0.35/0.40 = 0.875, \pi_2 = 0.125$ 가 된다.

파이썬으로 $T = 20,000$ 단계 동안 연쇄를 시뮬레이션하면, 상태 1(확장)을 방문한 비율의 경험적 누적평균은 0.8748로 수렴하며, 이는 이론값 $\pi_1 = 0.8750$ 과 사실상 일치한다(그림 2). 이는 초기값(여기서는 상태 1에서 출발)과 무관하게 마르코프 연쇄가 정상분포로 수렴한다는 에르고딕 정리의 함의를 수치적으로 확인해 준다. 18장(국면전환)은 실제 미국 인플레이션 자료에서 국면 변화를 포착하기 위해 바로 이 2상태 마르코프 연쇄 구조를 사용한다.




Figure 2: 2상태 마르코프 연쇄의 정상분포 수렴 ($T = 20,000$, 파이썬 시뮬레이션)

3.4 베이지안 계산에서 MCMC의 일반적 사용

베이지안 추론에 MCMC를 적용하는 절차는 다음과 같이 요약된다.

알고리즘: 베이지안 MCMC의 일반적 절차

1. 목표분포를 사후분포 $\pi(\theta) = p(\theta | y) \propto p(y | \theta)p(\theta)$ 로 설정한다(정규화 상수는 알 필요가 없다).
2. 정상분포가 $\pi(\theta)$ 인 전이커널 K 를 설계한다(4장의 깃스, M-H, 슬라이스 샘플링 등이 구체적인 설계 방법이다).
3. 임의의 초기값 $\theta^{(0)}$ 에서 출발하여, 전이커널 K 를 따라 반복적으로 $\theta^{(1)}, \theta^{(2)}, \dots, \theta^{(N)}$ 을 생성한다.
4. 연쇄가 정상분포에 도달하기 전의 초기 구간(번인)을 폐기한다: 통상 전체 n 회의 반복 중 처음 n_0 회를 폐기하고 $n_1 = n - n_0$ 회만 사용한다.
5. 남은 표본 $\{\theta^{(n_0+1)}, \dots, \theta^{(n)}\}$ 을 사용하여 사후평균, 신용구간, 사후확률 등의 몬테카를로 근사를 계산한다.
6. 연쇄가 실제로 정상분포에 도달했는지를 5장의 수렴 진단(추적도표, 비효율성 계수, Geweke의 p , Gelman-Rubin 통계량)을 이용해 확인한다.

참고: 번인과 시닝(thinning)

초기값 $\theta^{(0)}$ 가 사후분포의 고밀도 영역에서 멀리 떨어져 있으면, 연쇄는 정상분포에 도달하기까지 일정한 “적응기간”을 필요로 한다. 이 기간의 표본(번인)은 목표분포를 대표하지 않으므로 폐기된다. 이 노트의 실증 예제들은 Chan(2017) 계열 MATLAB 코드의 관행을 따라, 통상 $n_0 = 1,000$ 에서 5,000회의 번인 반복 후 $n_1 = 5,000$ 에서 10,000개의 사후 표본을 사용한다. 연속된 표본 사이의 자기상관이 매우 높을 때는 저장공간을 절약하기 위해 시닝(몇 개마다 하나씩만 남기는 것)을 사용하기도 하지만, 최근 문헌(예: Link and Eaton, 2012)은 시닝이 저장공간만 절약할 뿐 몬테카를로 근사의 효율 자체를 개선하지는 않는다는 점을 지적한다(오히려 유용한 정보를 버릴 수도 있다). 이 때문에 이 노트는 기본적으로 시닝 없이 전체 사후 표본을 사용하는 것을 원칙으로 한다.

다음 장은 이러한 일반원리를 구체적으로 구현하는 여덟 가지 표본추출 기법(합성법, 확률적분변환, 수락-기각 표본추출, 중요도 표본추출, M-H 표본추출, 다중블록 M-H, 깃스 샘플링, 슬라이스 샘플링)을 차례로 살펴보고, 각각에 대해 이론과 실증 예제를 함께 제시한다.

4. 표본추출 기법

로드맵

3장은 올바른 정상분포를 갖는 어떤 전이커널이든 사후분포를 구할 수 없는 문제를 항상 해결한다는 것을 증명했다. 그러나 그러한 전이커널을 어떻게 만드는지는 말해주지 않았다. 이 장이 바로 그 도구상자이다: “정확하며 마르코프 연쇄가 필요 없는” 방법(합성법, 확률적분변환)에서 “마르코프 연쇄가 필요한” 방법(M-H, 깃스, 슬라이스)에 이르기까지 대략적인 순서로 배열된 여덟 가지 구체적인 레시피이다. 이 중 깃스 샘플링과 다중블록 M-H 두 가지는 6장 이후 모든 실증 장의 주력 도구이다 — 이후 장의 algobox가 “ β 를 추출하고, 그다음 σ^2 를 추출하고, 그다음 γ 를 추출한

다”라고 말할 때, 이는 여기서 소개하는 다중블록 순환의 직접적인 사례이다.

3장은 MCMC가 목표 사후분포 $\pi(\theta) = p(\theta | y)$ 를 정상분포로 갖는 전이커널을 구성함으로써 작동한다는 것을 확립했다. 이 장은 이러한 표본을 생성하는 여덟 가지 구체적인 기법을 살펴보는데, 마르코프 연쇄가 전혀 필요 없는 정확한 방법(합성법, 확률적분변환, 수락-기각, 중요도 표본추출)에서부터 현대 베이지안 계량경제학을 실용적으로 만든 마르코프 연쇄 알고리즘 (메트로폴리스-헤이스팅스, 다중블록 M-H, 깃스 샘플링, 슬라이스 샘플링)에 이르기까지 다양하다. 각 기법은 파이썬으로 구현되어 알려진 목표값에 대해 수치적으로 검증되며, 바탕이 되는 MATLAB 라이브러리(Bayes_Lib)가 실증 예제를 제공하는 경우 그 구현을 그대로 따른다.

4.1 합성법(Method of Composition)

많은 분포는 혼합으로 표현될 수 있다: 어떤 분포로부터 보조변수 λ 를 추출한 다음, λ 로 인덱싱된 분포로부터 x 를 추출하는 것이다. 두 단계 모두 직접 표본추출이 가능하다면, x 의 한계추출은 정확하다 — 수락 단계나 마르코프 연쇄가 전혀 필요 없다.

알고리즘: 합성법

1. $\lambda \sim p(\lambda)$ 를 추출한다.
2. $x | \lambda \sim p(x | \lambda)$ 를 추출한다.
3. x 를 반환한다. 구성상 $x \sim \int p(x | \lambda)p(\lambda) d\lambda = p(x)$ 가 된다.

대표적인 예이자, 6장에서 두꺼운 꼬리를 갖는 회귀오차를 모형화할 때 다시 등장할 예는, 스튜던트- t 분포를 정규/역감마(척도) 혼합으로 표현하는 것이다.

$$x | \lambda \sim N(0, \lambda), \quad \lambda = \frac{\nu}{\chi_\nu^2} \\ \implies x \sim t_\nu.$$

실증 예제: 스튜던트- t 분포의 합성 표본추출

$\nu = 5$ 로 설정하고 합성법을 통해 $N = 200,000$ 개의 쌍 (λ, x) 를 추출하면, 표본평균은 $\bar{x} = -0.0009$, 표본분산은 $\widehat{\text{Var}}(x) = 1.6629$ 로, t_5 의 이론적 분산 $\nu/(\nu - 2) = 5/3 = 1.6667$ 과의 차이가 0.3% 이내이다. 검산을 위해 `scipy.stats.t`로부터 직접 추출한 200,000개의 표본은 표본평균 -0.0011 , 분산 1.6591 을 주며 — 이는 합성법 기반 추출값과 통계적으로 구분되지 않는다. 합성법 추출값의 표본 초과첨도는 4.27로, $\nu = 5$ 에 대한 이론값 $6/(\nu - 4) = 6.0$ 과 차이가 있다. 이 차이가 줄어들지 않는 것은 예상된 결과인데, t_5 변수의 4차 적률은 유한하지만 꼬리가 매우 두꺼워 $N = 200,000$ 에서도 그 표본추정치가 평균이나 분산보다 훨씬 느리게 수렴하기 때문이다 — 두꺼운 꼬리를 갖는 분포의 유한한 MCMC나 몬테카를로 표본으로부터 고차 적률 진단을 신뢰하는 것에 대한 실용적인 경고이다.

4.2 확률적분변환

F 가 목표분포의 (가역인) CDF라면, $U \sim \text{Uniform}(0, 1)$ 일 때 $F^{-1}(U)$ 는 분포 F 를 갖는다. 이것이 확률적분변환(PIT)이며, F^{-1} 이 닫힌 형태로 존재할 때 가능한 가장 단순한 정확 표본추출 방법이다.

알고리즘: 확률적분변환을 통한 표본추출

1. $u \sim \text{Uniform}(0, 1)$ 을 추출한다.
2. $x = F^{-1}(u)$ 를 반환한다.

실증 예제: 지수분포의 PIT 표본추출

$x \sim \text{Exponential}(\lambda)$ 에 대해 $F(x) = 1 - e^{-\lambda x}$ 이므로 $F^{-1}(u) = -\ln(1 - u)/\lambda$ 이다. $\lambda = 0.5$ 로 설정하고 $N = 200,000$ 개의 값을 추출하면 표본평균 2.0001, 표본분산 3.9777을 얻으며, 이는 이론값 $1/\lambda = 2.0$ 과 $1/\lambda^2 = 4.0$ 에 대응한다. PIT 표본에 대해 $\text{Exponential}(0.5)$ 과의 콜모고로프-스미르노프 검정을 수행하면 $D = 0.0016$, $p = 0.70$ 으로, 정확히 일치한다는 귀무가설을 기각할 수 없다. PIT는 이 노트 후반부에서 사용되는 절단분포 표본추출기의 바탕이 되는 정확한 방법이다 — 예를 들어 9장의 토빗모형에서 절단된 정규오차를 시뮬레이션할 때, 적절한 꼬리 확률로 제한된 $\text{Uniform}(0, 1)$ 추출값에 역CDF를 적용하는 방식이 그것이다.

4.3 수락-기각 표본추출

F^{-1} 을 이용할 수 없지만 목표밀도 f 가 상수 배까지는 알려져 있는 경우, 수락-기각(A-R) 표본추출은 추출하기 쉬운 제안밀도 g 와 모든 x 에 대해 $f(x) \leq c g(x)$ 를 만족하는 포락선 상수 c 를 이용하여, 수락된 추출값이 정확히 f 를 따르도록 각 제안을 수락하거나 기각한다.

알고리즘: 수락-기각 표본추출

1. 후보 $v \sim g(\cdot)$ 를 추출한다.
2. $u \sim \text{Uniform}(0, 1)$ 을 추출한다.
3. $u \leq f(v)/(c g(v))$ 이면 $x = v$ 를 수락하고, 그렇지 않으면 1단계로 돌아간다.

전체 수락확률은 $1/c$ 이므로, f/g 의 실제 상한에 가까운 포락선 상수를 사용할수록 알고리즘의 효율이 높아진다.

실증 예제: Beta(3,3)로부터의 A-R 표본추출

$(0, 1)$ 위의 목표밀도 $f(x) = \text{Beta}(3, 3)$ 과 제안분포 $g(x) = \text{Uniform}(0, 1)$ 을 취하고, 포락선 상수는 $c = 1.875$ 로 한다($x = 0.5$ 에서 달성되는 $\text{Beta}(3, 3)$ 밀도의 정확한 최댓값이다). $T = 50,000$ 개의 수락된 표본을 추출하면 표본평균 0.5004, 표본분산 0.03576을 얻으며, 이는 이론값 $a/(a + b) = 0.5$ 와 $ab/[(a + b)^2(a + b + 1)] = 9/252 = 0.03571$ 에 대응한다. 경험적 수락률은 53.18%로, 이론적 수락률 $1/c = 53.33\%$ 와 거의 정확히 일치한다. 그림 3는 수락된 추출값의 히스토그램을 정확한 $\text{Beta}(3, 3)$ 밀도 위에 겹쳐 그린 것이다.




Figure 3: Beta(3,3)로부터의 수락-기각 표본추출: 수락된 50,000개 추출값의 히스토그램 대 정확한 밀도

4.4 중요도 표본추출

수락-기각법은 제안값을 버리는데, c 가 클 경우 이는 낭비가 될 수 있다. 중요도 표본추출은 대신 제안 분포(여기서는 중요도밀도 h 라 부른다)로부터의 모든 추출값에 가중치를 부여하여 어떤 추출값도 버려지지 않도록 한다.

$$E_f[g(X)] = \int g(x)f(x) dx = \int g(x) \frac{f(x)}{h(x)} h(x) dx = E_h \left[g(X) \frac{f(X)}{h(X)} \right].$$

알고리즘: 중요도 표본추출

1. $x^{(1)}, \dots, x^{(N)} \sim h(\cdot)$ 를 추출한다.
2. 중요도 가중치 $w^{(i)} = f(x^{(i)})/h(x^{(i)})$ 를 계산한다.
3. $E_f[g(X)] \approx \frac{1}{N} \sum_i g(x^{(i)})w^{(i)}$ 로 근사한다.

추정량의 효율은 h 가 f 와 얼마나 가까운지에 달려 있다: h 의 꼬리가 f 보다 훨씬 얇으면, 소수의 추출값이 엄청나게 큰 가중치를 받아 추정량의 분산이 커진다(유효표본크기 $ESS = (\sum_i w^{(i)})^2 / \sum_i (w^{(i)})^2$ 로 측정된다).

실증 예제: $X \sim N(0, 1)$ 에 대한 $E[g(X)]$ 의 중요도 표본추출

$X \sim N(0, 1)$ 이고 $g(x) = 1/(1 + x^2)$ 이라 하자. $E[g(X)]$ 를 구하고자 한다. 수치적분은 사실상 정확한 값인 0.65568을 준다. $N = 200,000$ 개의 표준정규 추출값을 이용한 직접 몬테카를로는 0.65448을 준다. $N(0, 1)$ 목표 f 보다 꼬리가 더 두꺼운(따라서 중요도 가중치 f/h 가 유계로 유지되는) 스튜던트- t_5 중요도밀도 h 를 사용하면 중요도 표본추출 추정치는 0.65563을 주는데(정확한 값과의 차이가 0.0001 이내이며) 유효표본크기는 전체 200,000개 추출값 중 191,584개(95.8%)로, 이 응용에서 t_5 가 표준정규 목표에 대해 효율적인 중요도밀도임을 확인해 준다.

4.5 메트로폴리스-헤이스팅스 표본추출

위의 방법들은 다루기 쉬운 역CDF나 포락선을 필요로 하는데, 이는 계량경제 모형에서 전형적으로 나타나는 다중모수, 비표준 사후분포에서는 구성하기 어려워진다. 메트로폴리스-헤이스팅스(M-H) 알고리즘은 오직 비율 $\pi(\theta')/\pi(\theta)$ 만을 이용하여 $\pi(\theta) = p(\theta | y)$ 에 대해 세부균형조건(3장)을 만족하는 전이를 갖는 마르코프 연쇄를 구성함으로써 이 문제를 우회한다 — 즉 사후분포의 정규화 상수가 전혀 필요하지 않다.

알고리즘: 임의보행 메트로폴리스-헤이스팅스

1. $\theta^{(t)}$ 에서 후보 $\theta' = \theta^{(t)} + \tau \varepsilon, \varepsilon \sim N(0, 1)$ 를 추출한다(대칭 임의보행 제안).
2. 수락확률을 계산한다.

$$\alpha(\theta^{(t)}, \theta') = \min \left\{ 1, \frac{\pi(\theta')}{\pi(\theta^{(t)})} \right\}.$$

3. 확률 α 로 $\theta^{(t+1)} = \theta'$ 로 설정하고, 그렇지 않으면 $\theta^{(t+1)} = \theta^{(t)}$ 로 둔다.

스텝크기 τ 는 조정모수이다: 너무 크면 수락률이 낮아지고 혼합이 나빠지며, 너무 작으면 수락률은 높아지지만 탐색이 느려진다(높은 자기상관). 흔히 인용되는 경험칙은 단일 모수에 대해 0.44 부근의 수락률을 목표로 한다(Roberts and Rosenthal, 2001).

실제 자료에 무언가를 적합시키기 전에, 그림으로 그릴 수 있을 만큼 단순한 설정에서 그 메커니즘을 살펴보는 것이 도움이 된다: 상관된 두 모수 $\theta = (\theta_1, \theta_2)$ 로 이루어진 이변량 정규 목표분포($\text{Corr}(\theta_1, \theta_2) = 0.8$)이다. 그림 4는 꼬리 부분의 먼 출발점에서 40개의 임의보행 제안을 실행한다. 각 제안은 수락(실선 경로)되거나 기각(회색 ×)되며, 대칭적인 임의보행은 상관관계가 어느 방향으로 흐르는지 알지 못하므로 많은 제안이 목표분포의 능선을 벗어나 기각된다.




Figure 4: 이변량 정규 목표분포($\text{Corr} = 0.8$)에 대한 임의보행 M-H: 수락된 경로(실선) 대 기각된 제안(회색 ×)

실증 예제: 미국 GDP 성장률의 AR(1) 지속성 모수에 대한 M-H 표본추출

단순화된 평균 0의 AR(1) 모형 $y_t = \rho y_{t-1} + e_t$, $e_t \sim N(0, \sigma^2)$ 을 분기별 미국 실질 GDP 성장률(코로나19 팬데믹을 포함하도록 2026년 1분기까지 확장, 시차를 취한 후 $T = 266$)에 적합시키되, $(-1, 1)$ 위에서 정상성으로 절단된 제프리스형 사전분포 $p(\rho) \propto (1 - \rho^2)^{-1/2}$ 를 사용한다고 하자. 이 사전분포는 정규우도와 결레가 아니므로 닫힌 형태의 깃스 갱신을 이용할 수 없고, M-H가 자연스러운 선택이다. 스텝크기 $\tau = 0.06$ 인 임의보행 M-H 샘플러를 번인 2,000회 후 12,000개의 사후 추출값에 대해 실행하면, 사후평균 $\hat{\rho} = 0.357$, 사후표준편차 0.052, 95% 신용구간 $[0.256, 0.460]$ 을 얻는다. 경험적 수락률은 67.3%였고 비효율성 계수는 6.96이었다(즉 12,000개의 상관된 추출값은 대략 $12,000/6.96 \approx 1,724$ 개의 독립적인 추출값과 같은 정보량을 갖는다) — 두 결과 모두 τ 를 다소 늘려 0.44라는 경험칙에 더 가깝게 만들 수 있음을 시사한다. 검산으로, 동일한 평균 0 모형설정에서 ρ 의 최대우도(OLS) 추정치는 0.358로, 사후평균과 사실상 동일하며, 샘플러가 올바른 목표분포로 수렴했음을 확인해 준다. 그림 5는 추적도표와 사후 히스토그램을 보여준다.




Figure 5: 미국 실질 GDP 성장률의 AR(1) 지속성 모수 ρ 에 대한 임의보행 M-H 표본추출

참고: 평균 0 모형설정이 지속성을 과대추정하는 이유

여기서 얻은 $\hat{\rho} \approx 0.36$ 이 이 장 후반부(4.6–4.7절)에서 명시적인 평균을 갖는 모형 하에 보고되는 GDP 성장률의 AR(1) 지속성($\hat{\rho} \approx 0.03$ – 0.04)보다 눈에 띄게 높다는 점에 주목하라 — 이 격차는 자료 확장 이전보다 비율상 훨씬 더 커졌는데, 이는 2020Q2의 -28.0% 와 2020Q3의 $+34.9\%$ 가 표본에 들어오면서 평균-포함 추정치가 크게 하락했기 때문이다: 크기가 거의 같고 부호가 반대인 인접한 두 분기는 시차 1 자기공분산에 강한 음(-)의 항을 기여하여, 평균-포함 지속성 추정치를 0 근처로 끌어당긴다. 이는 샘플러의 오류가 아니다: 실질 GDP 성장률은 양의 무조건부 평균(대략 3%)을 가지므로, 회귀식을 원점을 지나도록 강제하면 y_{t-1} 이 순수한 기간간 지속성이 아니라 생략된 평균의 일부를 대신 대리하게 되어 $\hat{\rho}$ 가 위로 편의된다 — 어느 표본을 쓰든 마찬가지다. 평균 0 추정치가 코로나 시기의 급등락에 상대적으로 덜 민감한 것은 단지 그것이 확장 이전부터 이미 편의되어 과대추정된 수치였기 때문이다. 여기서 평균 0 모형은 순전히 가능한 가장 작은 모수집합으로 M-H 표본추출의 메커니즘을 분리해서 보여주기 위해 사용된 것이며, 4.6절과 4.7절은 모형설정을 바로잡는다.

4.6 다중블록 메트로폴리스-헤이스팅스

θ 가 여러 성분으로 이루어져 있을 때, 이들 모두를 단일한 M-H 단계에서 한꺼번에 갱신하는 것은 대개 성능이 나쁘다: 고차원 공간에서의 결합 이동 제안은 수락될 가능성이 낮기 때문이다. 다중블록(또는 블록별) M-H는 대신 θ 를 여러 블록으로 나누고, 다른 블록들의 현재 값에 조건화하면서 각 블록을 차례로 갱신한다. 각 블록의 전이가 나머지 블록에 조건화된 상태에서 개별적으로 세부균형조건을 만족하므로, 전체 사이클은 여전히 $\pi(\theta)$ 를 불변으로 유지한다. 그림 6는 두 블록에 대해 그 결과로 나타나는 의존구조를 보여준다: 3장의 단일연쇄 DAG와 달리, 이제 각 블록은 다른 모든 블록의 현재 값에도 의존한다.




Figure 6: 다중블록 의존구조: 실선 화살표는 각 블록 자신의 갱신을 나타내고, 점선 화살표는 다른 블록의 가장 최근에 추출된 값에 대한 조건화를 나타낸다

알고리즘: 다중블록 메트로폴리스-헤이스팅스

$\theta = (\theta_1, \theta_2)$ 로 분할한다. 반복 t 에서:

1. $\theta_1^{(t)}$ 가 주어졌을 때 θ_1' 을 제안한다. 단일블록 M-H와 정확히 동일하게, $\pi(\theta_1' | \theta_2^{(t)}, y)$ 를 $\pi(\theta_1^{(t)} | \theta_2^{(t)}, y)$ 와 비교하여 수락/기각한다.
2. $\theta_2^{(t)}$ 가 주어졌을 때 θ_2' 을 제안한다. $\pi(\theta_2' | \theta_1^{(t+1)}, y)$ 를 $\pi(\theta_2^{(t)} | \theta_1^{(t+1)}, y)$ 와 비교하여 수락/기각한다.
3. 필요한 만큼의 블록 수에 대해 반복한다. 각 블록은 자신만의 스텝크기를 사용할 수 있으며, 각자의 최적 수락률에 맞추어 별도로 조정된다.

실증 예제: 다중블록 M-H: 미국 GDP 성장률에 대한 미지의 평균을 갖는 AR(1)

4.5절의 모델을 $y_t - \mu = \rho(y_{t-1} - \mu) + e_t$ 로 확장하고, 블록 $\theta_1 = \mu$ (느슨한 $N(3, 100)$ 사전분포)와 $\theta_2 = \rho$ (이전과 동일한 정상성-절단 사전분포)로 나눈다. 각 블록은 매 반복에서 두 블록을 순환하며 자신만의 임의보행 M-H 단계($\tau_\mu = 0.35, \tau_\rho = 0.06$)로 갱신된다. 12,000개의 사후 추출값을 이용하면, 사후평균은 $\hat{\mu} = 2.998$ (1장의 GDP 성장률 표본평균 2.966과 가깝다)과 $\hat{\rho} = 0.039$ 이며, 수락률은 각각 64.3%(블록 μ)와 72.3%(블록 ρ)이다. 평균을 적절히 고려하고 나면, 지속성 추정치는 0.36에서 약 0.04로 떨어진다 — 이는 4.5절의 remark에서 설명한 편의 메커니즘을 확인해 주며, 확장된 표본의 가장 극단적인 급등락이 제대로 중심화되고 나면 GDP 성장률 자체의 선형 지속성이 얼마나 약해지는지를 보여준다. 4.7절은 검산으로서 이 동일한 평균-포함 AR(1) 모델을 깁스 샘플링으로 다시 추정한다.




Figure 7: 다중블록 M-H 추적도표: 블록 1(μ)과 블록 2(ρ)

4.7 깁스 샘플링

깁스 샘플링은 다중블록 M-H의 특수한 경우로, 각 블록의 완전조건부 사후분포가 닫힌 형태로 존재하여 후보값이 그 조건부분포로부터 직접 추출되고 항상 수락되는 경우이다(수락확률 $\equiv 1$). 켈레사전분포를 이용할 수 있는 경우(정규-역감마 선형회귀모형에서처럼) 깁스 샘플링은 통상 M-H보다 훨씬 효율적인데, 제안을 조정할 필요가 없고 기각으로 낭비되는 추출값도 없기 때문이다.

알고리즘: 깁스 샘플링

1. $\theta = (\theta_1, \dots, \theta_K)$ 에 대해, 반복 t 에서 $k = 1, \dots, K$ 를 순환하며 각 좌표를 다른 모든 좌표의 가장 최근에 갱신된 값이 주어진 완전조건부분포로부터 추출한다.

$$\theta_k^{(t+1)} \sim p\left(\theta_k \mid \theta_1^{(t+1)}, \dots, \theta_{k-1}^{(t+1)}, \theta_{k+1}^{(t)}, \dots, \theta_K^{(t)}, y\right).$$

2. $t = 1, 2, \dots$ 에 대해 반복한다. 메트로폴리스-헤이스팅스와 달리 수락/기각 단계가 없이 제안된 이동이 자동으로 모두 수락된다.

앞서 M-H를 설명하는 데 사용한 것과 동일한 상관된 정규 목표분포(두 모수)에 대해, 그림 8는 10번의

깁스 사이클을 실행한다: $\theta_1 | \theta_2$ 를 추출(수평 이동)한 다음 $\theta_2 | \theta_1$ 을 추출(수직 이동)하고, 이를 반복한다. 제안된 모든 이동이 수락된다(기각 단계가 전혀 없다)지만, 그 대가는 그림에서 드러난다: 목표분포가 좁고 기울어진 능선이기 때문에, 순전히 수평-후-수직인 경로는 그 능선을 따라 작은 걸음만 뒀을 수 있어, 깁스는 M-H가 동일한 거리를 이동하는 데 필요한 제안 수보다 훨씬 많은 사이클을 필요로 한다. 이러한 상충관계(깁스는 추출값을 결코 낭비하지 않지만 강한 상관관계 하에서 느리게 기어가고, M-H는 더 멀리 도약할 수 있지만 많은 추출값을 기각으로 낭비한다)는 두 방법 사이의 핵심적인 실용적 선택이다.





Figure 8: 동일한 이변량 정규 목표분포(Corr = 0.8)에 대한 깁스 샘플링: 한 번에 한 좌표씩 갱신하는 특징적인 축-정렬 지그재그

실증 예제: 깁스 샘플링: 미국 GDP 성장률의 AR(1) 회귀

4.6절의 평균-포함 AR(1) 모델을 선형회귀 $y_t = c + \rho y_{t-1} + e_t$ 로 다시 써서, 켈레 정규-역감마 사전분포($\beta \sim N(0, 100I)$, $\sigma^2 \sim IG(1.5, 1.5)$)를 부여하고, 6장의 켈레 깁스 샘플러(gibbs_linear_normal에 구현됨)로 표본을 추출하여 재추정한다. 10,000개의 사후 추출값을 이용하면, 사후평균은 $\hat{c} = 2.875$ 와 $\hat{\rho} = 0.035$ 이며(이는 $\hat{c}/(1 - \hat{\rho}) = 2.978$ 이라는 함의된 무조건부 평균을 주는데, 이는 4.6절의 다중블록 M-H 추정치 및 1장의 GDP 성장률 표본평균과 일치한다), 사후 표준편차는 각각 0.314와 0.061이다. ρ 에 대한 비효율성 계수는 0.93으로 — 사실상 1이며, 이는 켈레 깁스 추출값이 거의 i.i.d. 표본만큼 효율적임을 의미한다. 이는 4.5절의 임의보행 M-H 샘플러의 비효율성 계수 6.96과 대조된다. 이는 켈레성을 이용할 수 있을 때마다 그것을 활용하는 것의 핵심적인 실용적 이점이다.



4.8 슬라이스 샘플링

슬라이스 샘플링은 깃스 샘플링처럼 제안분포의 조정이 전혀 필요 없으면서도, 켈레 조건부분포를 이용할 수 없는 경우에도 적용할 수 있는 보조변수 기법이다. 핵심적인 장치는 θ 에 보조적인 수직 좌표 h 를 추가하고, (정규화되지 않은) 목표밀도 곡선 아래 영역으로부터 균등하게 표본을 추출하는 것이다.

알고리즘: 일변량 슬라이스 샘플링

1. $x^{(t)}$ 에서 $h \sim \text{Uniform}(0, f(x^{(t)}))$ 를 추출하여 수평 “슬라이스” $S = \{x : f(x) > h\}$ 를 정의한다.
2. $x^{(t)}$ 를 포함하며 S 를 덮는 구간 $(\ell, r) \supseteq S$ 를 찾는다. 통상 초기 폭 w 의 창을 양 끝점이 모두 h 아래로 떨어질 때까지 확장하는 단계적 확장 절차를 통해 찾는다.
3. $x' \sim \text{Uniform}(\ell, r)$ 을 추출한다. $f(x') > h$ 이면 $x^{(t+1)} = x'$ 를 수락하고, 그렇지 않으면 구간을 $x^{(t)}$ 쪽으로 축소한 후(ℓ 또는 r 을 x' 로 대체) 반복한다.

위의 일변량 레시피는 깃스 샘플링과 정확히 동일한 방식으로 좌표를 번갈아 가며 두 모수로 즉시 확장된다: $\theta_1 \mid \theta_2$ 를 슬라이스 표본추출한 다음 $\theta_2 \mid \theta_1$ 을 슬라이스 표본추출하고, 이를 반복한다. 그림 10는 위 두 그림과 동일한 상관된 정규 목표분포에 대해 이러한 사이클을 9번 실행하며, 이제 각 단계의 슬라이스 창(다음 지점에 도달하기 전에 실제로 탐색된 수평 또는 수직 구간)도 함께 그린다. 결과 경로는 동일한 좌표교대 구조를 사용하기 때문에 깃스의 지그재그처럼 보이지만, 각 단계는 자체적으로 조정된다(창 폭 w 는 단지 시작 추정값을 설정할 뿐이며 단계적 확장 절차에 의해 자동으로 확장된다) 반면 위의 깃스는 정확한 조건부분포가 닫힌 형태로 알려져 있어야 했다.




Figure 10: 동일한 이변량 정규 목표분포(Corr = 0.8)에 대한 좌표별 슬라이스 샘플링: 각 단계의 수평/수직 슬라이스 창이 그 단계가 만들어내는 점보다 먼저 표시되어 있다

실증 예제: Gamma(3,1)로부터의 슬라이스 샘플링

단계적 확장-축소 슬라이스 샘플러를 (정규화되지 않은) Gamma(3, 1) 밀도 $f(x) \propto x^2 e^{-x}$ 에 적용하여 12,000개의 사후 추출값을 얻으면 표본평균 3.013, 표본분산 3.024를 얻으며, 이는 이론값 3.0과 3.0에 대응한다. 그림 11는 추출된 히스토그램을 정확한 Gamma(3,1) 밀도 위에 겹쳐 그린 것이다. 슬라이스 샘플링은 이 노트 후반부에서 완전조건부분포가 컬레도 아니고 M-H 제안으로 쉽게 경계지를 수도 없을 때 강건한 대안으로 사용된다 — 예를 들어 17장의 시변모수 VAR에서 평활화 모수에 대해 그러하다.




Figure 11: Gamma(3,1)로부터의 슬라이스 샘플링: 12,000개 추출값의 히스토그램 대 정확한 밀도

5. 수렴 진단(Convergence Diagnostics)

로드맵

3 4장은 결국 올바른 사후분포를 목표로 하는 마르코프 연쇄를 구성하고, 이로부터 효율적으로 표본을 추출하는 방법을 다루었다. 그러나 두 장 모두 이 뒤로 이어지는 모든 응용 장이 반드시 마주하게 될 질문에는 답하지 않았다. 이번에 실행한 특정 길이의 이 특정한 실행이 실제로 그 목표에 도달했는가? 이 장은 간단한 시각적 점검부터 공식적인 연쇄 간 검정에 이르는 네 가지 점검 방법을 제공하며, 6장 이후에 보고되는 모든 사후 추정치는 암묵적으로 이 중 최소 하나에 의해 검증된 것이다.


3장은 MCMC 표본추출기가 번인(burn-in) 이후 점근적으로만 목표 사후분포로부터의 표본을 생성한다는 것을 보였고, 4장은 서로 다른 알고리즘(그리고 동일 알고리즘 내의 서로 다른 튜닝 선택)이 매우 다른 속도로 혼합될 수 있음을 보였다. 실제로는 수렴을 직접 관찰할 수 없으며 — 유한한 길이의 연쇄만을 관찰하고 그것이 신뢰할 만한지를 판단해야 한다. 이 장은 이 노트의 나머지 부분 전체에서 사용되는 네 가지 진단법을 제시한다. 트레이스 플롯과 자기상관함수(시각적/정성적 진단), 비효율성 계수(혼합 속도를 정량화), 게웨키의 수렴 진단(연쇄 내부의 수렴을 검정), 겔먼-루빈 통계량(연쇄 간 일치를 검정)이 그것이다. 네 가지 모두 4장에서 사용한 미국 실질 GDP 성장률의 동일한 AR(1) 모형에 적용하여, 혼합이 잘 이루어지는 켈레 깁스 샘플러와 의도적으로 서투르게 조율된 랜덤워크 메트로폴리스-헤이스팅스(M-H) 샘플러를 대비시켜 예시한다.

5.1 트레이스 플롯과 자기상관함수

가장 단순한 진단법은 $\theta^{(t)}$ 를 반복 지표 t 에 대해 도표화하는 것이다 — 이를 트레이스 플롯이라 한다. 혼합이 잘 이루어지는 연쇄는 뚜렷한 추세 없이 평균으로 회귀하는 정상적인 띠 모양을 보이며 실행 기간 동안 자신의 범위를 여러 번 왕복해야 한다. 반면 혼합이 잘 이루어지지 않는 연쇄는 장기 평균에서 멀리 벗어난 긴 이탈을 보이며 느리게 표류한다.

실증 예제: 트레이스 플롯: 혼합이 잘 되는 샘플러 대 잘 안 되는 샘플러


그림 12는 미국 실질 GDP 성장률에 대한 동일한 AR(1) 계수 사후분포를 목표로 하는 두 샘플러를 비교한다. 4.7절의 켈레 깁스 샘플러(왼쪽)와, 스텝 크기 $\tau = 0.008$ 로 의도적으로 잘못 조율한 랜덤워크 M-H 샘플러(오른쪽, 5,000회 번인 이후 10,000개 표본)이다. 두 연쇄는 동일한 사후분포를 목표로 하지만 표본평균은 여전히 눈에 띄게 다르고(0.035 대 0.087)(이 차이 자체가 M-H 연쇄의 느린 수렴을 보여주는 증상이다) 깁스 연쇄는 매 반복마다 거의 즉시 자신의 범위를 채우는 반면, M-H 연쇄는 길고 느린 이탈을 눈에 띄게 보인다 — 이는 혼합이 잘 안 되는 연쇄의 전형적인 특징이다.



자기상관함수(ACF), $\hat{\rho}_k = \widehat{\text{Corr}}(\theta^{(t)}, \theta^{(t+k)})$ 는 동일한 정보를 정밀하게 보여준다. 혼합이 잘 되는 연쇄의 ACF는 몇 개의 시차 안에 0으로 빠르게 떨어지는 반면, 혼합이 잘 안 되는 연쇄의 ACF는 느리게 감소한다.

실증 예제: 자기상관함수 비교

그림 13는 (시차 60까지) 동일한 두 연쇄의 ACF를 도표화한다. 깃스 샘플러의 자기상관은 시차 1을 넘어서면 통계적으로 0과 구분되지 않는 반면, 스텝 크기가 작은 M-H 샘플러의 자기상관은 시차 60에서도 여전히 0.67로, 트레이스 플롯이 시사했던 바를 시각적으로 확인해 준다.



5.2 비효율성 계수

트레이스 플롯과 ACF는 정성적인 도구이다. 비효율성 계수(동등하게, 유효표본크기 비율의 역수)는 혼합 속도를 하나의 숫자로 정량화하며, 이미 4장에서 비공식적으로 사용된 바 있다.

$$IF = 1 + 2 \sum_{k=1}^K \hat{\rho}_k,$$

이는 ACF에 대한 Newey-West/Parzen형 절단함이다. N 개의 상관된 표본이 비효율성 계수 IF 를 가진다면, 몬테카를로 평균화를 위한 유효표본크기는 대략 N/IF 이다. 비효율성 계수가 10이라는 것은, 동일한 몬테카를로 정밀도를 얻으려면 i.i.d. 샘플러보다 약 10배 더 긴 연쇄를 실행해야 함을 의미한다.

용어	의미
$IF \approx 1$	표본이 거의 독립적이다(잘 조율된 겹스 스텝의 전형적인 특징).
$1 < IF \lesssim 20$	비교적 잘 조율된 M-H 샘플러에서 전형적이며, 대부분의 응용에서 허용 가능하다.
$IF \gg 20$	혼합이 나쁨을 의미하며, 제안분포의 재조율, 재모수화, 또는 가능하다면 겹스 표본추출/블로킹으로의 전환을 고려해야 한다.

실증 예제: 비효율성 계수: 겹스 대 스텝 크기가 작은 M-H

그림 12의 두 연쇄에 대해, 비효율성 계수는 겹스 샘플러의 경우 0.98(사실상 i.i.d. 표본)인 반면, 스텝 크기가 작은 M-H 샘플러의 경우 225.5이며, 이 샘플러의 채택률은 매우 높은 93.6%이다 — 스텝 크기가 너무 작다는 전형적인 징후로, 샘플러가 의미 있는 거리만큼 이동을 거의 제안하지 않기 때문에 거의 항상 채택하게 된다. 이 230배에 달하는 효율성 격차는 4장이 가능한 경우 겹스성(겹스 표본추출)을 활용하는 것을 강조했던 이유, 그리고 M-H 스텝 크기를 적당한 기각률에서 멀어지는 방향이 아니라 그쪽을 향해 조율해야 하는 이유를 구체적으로 보여준다.

5.3 게웨키의 수렴 진단

비효율성 계수는 혼합 속도를 측정할 뿐, 번인이 충분히 길었는지에 대해서는 아무것도 말해주지 않는다. 게웨키(Geweke, 1992)는 연쇄 내부의 공식적인 검정을 제안했다. 번인 이후 표본을 초기 구간(처음 n_A 개, 일반적으로 처음 10%)과 후기 구간(마지막 n_C 개, 일반적으로 마지막 50%)으로 나누고, 두 구간의 평균이 같은지 검정하는 것이다. 연쇄가 수렴했다면 두 구간은 동일한 정상분포로부터의 표본이므로 평균이 통계적으로 구분되지 않아야 한다. 반면 연쇄가 여전히 표류하고 있다면(번인이 불충분하다면) 초기 구간은 후기 구간과 체계적으로 다를 것이다.

알고리즘: 게웨키의 수렴 진단(CD)

1. 연쇄를 처음 10%의 초기 구간과 마지막 50%의 후기 구간으로 나눈다.
2. 구간 평균 $\bar{\theta}_A, \bar{\theta}_C$ 와 이들의 몬테카를로 표준오차 $\widehat{\text{se}}(\bar{\theta}_A), \widehat{\text{se}}(\bar{\theta}_C)$ 를 계산하되, 각각을 해당 구간 고유의 비효율성 계수를 이용해 자기상관에 대해 보정한다 (즉, $\widehat{\text{se}}^2 = \text{IF} \times \widehat{\text{Var}}/n$).
3. 검정통계량을 계산한다.

$$z = \frac{\bar{\theta}_A - \bar{\theta}_C}{\sqrt{\widehat{\text{se}}(\bar{\theta}_A)^2 + \widehat{\text{se}}(\bar{\theta}_C)^2}},$$

이는 수렴이라는 귀무가설 하에서 점근적으로 $N(0, 1)$ 을 따른다. p 값이 0에 가까우면 연쇄가 아직 수렴하지 않았거나(또는 번인이 너무 짧았음)를 나타낸다.

실증 예제: 게웨키의 CD: 수렴한 연쇄, 혼합이 나쁜 연쇄, 수렴하지 않은 연쇄

동일한 AR(1) 사후분포를 목표로 하는 세 연쇄에 게웨키 검정을 적용하면 다음과 같다.

- 혼합이 잘 되는 깃스 연쇄는 $z = 0.32, p = 0.75$ 를 주며 — 예상대로 수렴에 반하는 증거가 없다.
- 5.1 5.2절의 혼합이 잘 안 되는 스텝 크기 작은 M-H 연쇄는 $z = 4.52, p < 0.0001$ 을 주며 — 게웨키 검정 역시 이 연쇄를 문제가 있는 것으로 표시한다. 이는 중요한 점을 보여준다. 심각한 자기상관은 계산상의 노력을 낭비할 뿐만 아니라 부적절하게 짧은 번인을 은폐할 수도 있는데, 이렇게 느리게 움직이는 연쇄는 5,000회의 번인 안에서도 참 사후평균을 향한 이동을 마치지 못했을 수 있기 때문이다.
- 사후분포에서 의도적으로 멀리 떨어진 곳($\rho_0 = -0.9, \mu_0 = -5$)에서 초기화하고 번인을 전혀 버리지 않은 채 3,000회 실행한 연쇄는 $z = -5.65, p \approx 1.6 \times 10^{-8}$ 을 주며 — 수렴에 대한 명백한 기각이다. 그림 14는 그 이유를 보여준다. 초기 10% 구간(평균 -0.48)은 아직 초기 과도 상태에서 벗어나는 중인 반면, 후기 50% 구간(평균 0.47)은 참 사후 영역을 향해 여전히 나아가는 중이다 — 이 사후 영역 자체도 이 노트의 데이터 확장 이전보다 훨씬 0에 가까워졌는데, 확장된 표본의 2020년 급등락이 적절히 중심화되고 나면(4장) AR(1) 계수 자체의 사후평균이 약 0.33에서 약 0.04로 급락하기 때문이다. 이는 게웨키의 진단이 정확히 포착하도록 설계된 패턴이다.




Figure 14: 번인이 불충분한 연쇄: 초기 구간 평균이 후기 구간 평균과 크게 다르다

참고: 계웨키 검정은 일부 대립가설에 대해 검정력이 제한적이다

계웨키 검정은 두 구간의 평균만을 비교하므로, 더 높은 차수의 적률에서 나타나는 비수렴을 탐지하지 못할 수 있다(예: 평균은 안정되었지만 분산은 여전히 줄어들고 있는 연쇄). 또한 초기 구간 자체가 길고 완만한 과도상태에 걸쳐 있는 경우 검정력이 저하되는데, 이는 $\widehat{\text{se}}(\bar{\theta}_A)$ 를 형성하는 데 사용되는 구간 내 분산 자체가 과도상태에 의해 부풀려지기 때문이다. 실무에서는 계웨키의 CD를 여러 진단법 중 하나로 취급해야 하며, 트레이스 플롯의 시각적 검토를 대체하는 수단으로 여겨서는 안 된다.

5.4 겔먼-루빈 통계량

계웨키의 진단은 단일 연쇄를 검토한다. 겔먼-루빈 통계량(Gelman and Rubin, 1992)은 때때로 $\hat{R}$ 또는 루빈의 잠재적 척도축소계수(potential scale reduction factor)라 불리며, 대신 과분산(overdispersed) 초깃값에서 시작한 $M \geq 2$ 개의 독립적인 연쇄를 실행하여 연쇄 간 분산과 연쇄 내 분산을 비교한다. 모든 연쇄가 동일한 정상분포로 수렴했다면 두 분산은 서로 일치해야 하며, 일부 연쇄가 여전히 (서로 다른) 초깃값 근처에 갇혀 있다면 연쇄 간 분산이 연쇄 내 분산에 비해 부풀려질 것이다.

알고리즘: 겔먼-루빈 통계량($\hat{R}$)

1. 분산된 초깃값으로부터 길이 N (번인 이후)의 M 개 연쇄를 실행한다. $\bar{\theta}_m$ 과 s_m^2 를 연쇄 m 의 평균과 분산, $\bar{\theta}$ 를 연쇄들에 걸친 전체 평균이라 하자.
2. 연쇄 내 분산과 연쇄 간 분산을 계산한다.

$$W = \frac{1}{M} \sum_{m=1}^M s_m^2, \quad B = \frac{N}{M-1} \sum_{m=1}^M (\bar{\theta}_m - \bar{\theta})^2.$$


3. 이를 결합하여 풀링된 분산 추정치와 $\hat{R}$ 통계량을 구한다.

$$\widehat{\text{Var}}^+(\theta) = \left(1 - \frac{1}{N}\right) W + \frac{B}{N}, \quad \hat{R} = \sqrt{\frac{\widehat{\text{Var}}^+(\theta)}{W}}.$$

4. 해석: 모든 연쇄가 동일한 분포로 수렴하면 $\hat{R}$ 은 1에 가까워진다 (일반적인 경험 법칙으로는 $\hat{R} > 1.1$ 을, 더 보수적으로는 $\hat{R} > 1.01$ 을 비수렴의 증거로 표시한다). $\hat{R}$ 은 각 연쇄의 평균과 분산만 필요로 하므로, 대규모 모형의 모든 모수에 대해서도 계산이 간단하다.

실증 예제: 겔먼-루빈 진단: 분산된 초깃값에서 시작한 네 연쇄

AR(1) 계수에 대한 네 개의 깃스 연쇄를 폭넓게 분산된 초깃값 ($\rho_0 \in \{-0.8, 0, 0.8, 0.95\}$)에서 실행했으며, 각각 1,000회의 짧은 번인과 $N = 4,000$ 개의 유지 표본을 사용했다. 그 결과 $\hat{R} = 1.0000$ 으로, 연쇄 간에 사실상 정확히 일치하며 — 이는 트레이스 플롯에서 이미 관찰된 거의 즉각적인 혼합과 일치한다. 대비되는 사례로서, 스택 크기가 작은 네 개의 랜덤워크 M-H 연쇄(5.2 절의 동일한 혼합이 나쁜 샘플러)를 분산된 값에서 시작하여 번인을 전혀 버리지 않고 단 200회만 실행했더니 $\hat{R} = 3.83$ 으로, 1.1이라는 기준값을 크게 상회하여 이 연쇄들이 아직 초깃값을 벗어나지 못했음을 정확히 나타낸다. 그림 15는 두 경우를 모두 보여준다. 왼쪽 패널의 네 깃스 연쇄는 거의 즉시 시각적으로 겹쳐지는 반면, 오른쪽 패널의 네 M-H 연쇄는 눈에 띄게 분리된 채 남아 있으며 각각 공통 사후 영역을 향해 여전히 표류하고 있다.



참고: 애초에 왜 여러 연쇄를 실행하는가?

단일한 긴 연쇄는 원칙적으로 멀리서 출발하더라도 결국 전체 사후분포를 탐색할 수 있으며, 게웨이 검정은 그 하나의 연쇄 안에서 부적절하게 짧은 번인을 포착할 수 있다. 그러나 단일 연쇄는 다봉형 사후분포의 한 영역에 매우 오랫동안 “갇혀” 있으면서도 연쇄 내부에 아무런 이상 징후를 보이지 않을 수 있다 — 단일 트레이스 플롯만으로는 이러한 가능성을 배제할 수 없다. 겔먼-루빈 진단이 요구하는 것처럼 의도적으로 분산된 초기값에서 여러 연쇄를 실행하는 것은 바로 이러한 실패 양상에 대한 표준적인 방어책이며, 18장의 국면전환 모형에서 나타나는 다봉형 사후분포에 대해서는 특히 중요하다.

6. 다중회귀(Multiple Regression)

로드맵

4장은 하나의 계수, 즉 AR(1) 지속성 모수에 대한 깁스 샘플러를 구성하고 조율했으며, 이를 표본 추출 기법 자체에 대한 개념 증명으로 다루었다. 이 장은 그 기법이 실제 계량경제학적 도구가 되는 지점이다. 동일한 이중 블록 깁스 샘플러를, 하나가 아닌 k 개의 회귀변수에 대해 행렬 형태로 작성한다. 여기서 전 과정을 상세히 수행하는 유도(계수 블록에 대한 완전제곱식, 분산 블록에 대한 지수 및 거듭제곱 항의 매칭)는 회귀에만 국한된 것이 아니다. 이 노트의 모든 켄레 사후분포(7장의 프로빗, 9장의 토빗, 10장의 SUR, 11장의 VAR)는 더 크거나 다른 형태의 행렬에 적용된 동일한 두 단계에 불과하다. 이 장의 증명 상자들을 꼼꼼히 읽어두면 이후에도 여러 번 그 이점을 누리게 될 것이다.

4장과 5장은 미국 GDP 성장률에 대한 단일 회귀변수 AR(1) 모형을 예시로 사용하여 표본추출 및 진단 도구를 구축했다. 이 장은 그 모형을 k 개의 회귀변수로 일반화하고, 켄레 깁스 샘플러를 완전한 행렬 형

태로 전개하며, 4.1절에서 소개한 척도-혼합 표현을 이용해 두꺼운 꼬리(스튜던트- t) 오차로 확장한다. 베이저안 다중회귀는 또한 나머지 장들이 그 위에 구축되는 기초이기도 하다. 프로빗(7장)과 토빗(9장)은 비-정규 관측 규칙 아래에 잠재적인 선형회귀를 두는 동일한 컬레 기법을 재사용하고, 변수선택(8장)은 어떤 회귀변수를 포함할지에 대한 사전분포를 부여하며, SUR(10장)은 상관된 오차를 갖는 여러 개의 이러한 회귀식을 쌓아 올린다.

6.1 모형과 컬레 사전분포

다중회귀 모형은 다음과 같다.

$$y = X\beta + e, \quad e \sim N(0, \sigma^2 I_T),$$

여기서 y 는 $T \times 1$, X 는 $T \times k$, β 는 $k \times 1$ 이다. 이 노트 전체에서 사용되는 자연컬레(natural-conjugate) 정규-역감마 사전분포는 다음과 같다.

$$\beta \sim N(b_0, V_0), \quad \sigma^2 \sim IG\left(\frac{a_0}{2}, \frac{d_0}{2}\right),$$

여기서 β 와 σ^2 는 사전적으로 독립이다. 이 사전분포는 가우시안 우도와 결합하면 두 블록 모두에 대해 닫힌 형태의 완전조건부 사후분포를 낳는다 — 이는 4.7절의 단일 회귀변수 AR(1) 모형에서 사용한 것과 동일한 컬레 구조를 일반적인 k 에 대해 다시 쓴 것이다.

6.2 사후분포 유도

깁스 샘플러가 사용하는 두 완전조건부분포는 그저 가정된 것이 아니라, 가우시안 우도에 정규-역감마 사전분포를 곱하고 그 결과로 나오는 커널을 식별함으로써 직접 도출된다. 이 절은 두 유도 과정을 모두 상세히 다루는데, 이 노트에서 이후에 사용되는 모든 컬레 사후분포(프로빗, 토빗, SUR, VAR 등)가 정확히 동일한 두 단계로부터 구성되기 때문이다. 정규 블록에 대한 완전제곱식 만들기, 역감마 블록에 대한 거듭제곱과 지수 항의 매칭이 그것이다.

유도: $\beta \mid \sigma^2, y$

베이저 규칙에 의해, σ^2 를 고정한 채로 볼 때 사후 커널은 우도와 β 에 대한 사전분포의 곱이다.

$$p(\beta \mid \sigma^2, y) \propto \underbrace{\exp\left\{-\frac{1}{2\sigma^2}(y - X\beta)'(y - X\beta)\right\}}_{\text{우도}} \underbrace{\exp\left\{-\frac{1}{2}(\beta - b_0)'V_0^{-1}(\beta - b_0)\right\}}_{\text{사전분포}}$$

(σ^2 자체의 사전분포는 β 를 포함하지 않는 곱셈 상수만을 기여하므로 이미 생략되었다). 두 이차 형식을 하나의 지수 안에 모으면:

$$= \exp\left\{-\frac{1}{2}\left[\sigma^{-2}(y - X\beta)'(y - X\beta) + (\beta - b_0)'V_0^{-1}(\beta - b_0)\right]\right\}$$

각 이차형식을 β 에 대해 전개하면:

$$= \exp\left\{-\frac{1}{2}\left[\sigma^{-2}(y'y - 2\beta'X'y + \beta'X'X\beta) + \beta'V_0^{-1}\beta - 2\beta'V_0^{-1}b_0 + b_0'V_0^{-1}b_0\right]\right\}$$

β 에 대해 이차인 항과 일차인 항을 따로 모으면(그 외의 모든 항($y'y$ 와 $b_0'V_0^{-1}b_0$)은 β 에 의존하지 않으므로 비례상수에 포함시킨다):

$$\propto \exp\left\{-\frac{1}{2}[\beta'(V_0^{-1} + \sigma^{-2}X'X)\beta - 2\beta'(V_0^{-1}b_0 + \sigma^{-2}X'y)]\right\}$$

$\bar{V} \equiv (V_0^{-1} + \sigma^{-2}X'X)^{-1}$ 와 $\bar{\beta} \equiv \bar{V}(V_0^{-1}b_0 + \sigma^{-2}X'y)$ 를 정의하고 완전제곱식 만들기 항등식을 적용하면 — 이차형식 $\beta'A\beta - 2\beta'c$ 는 항상 $(\beta - A^{-1}c)'A(\beta - A^{-1}c) - c'A^{-1}c$ 와 같으며, 여기서 $A = V_0^{-1} + \sigma^{-2}X'X = \bar{V}^{-1}$, $c = V_0^{-1}b_0 + \sigma^{-2}X'y$ 이므로 $A^{-1}c = \bar{\beta}$ 이다 — 위 대괄호 안의 지수는 $(\beta - \bar{\beta})'\bar{V}^{-1}(\beta - \bar{\beta}) + \text{상수}$ 와 같아지며, 여기서 추가된 상수 $\bar{\beta}'\bar{V}^{-1}\bar{\beta}$ 역시 β 와 무관하므로 제거된다:

$$p(\beta | \sigma^2, y) \propto \exp\left\{-\frac{1}{2}(\beta - \bar{\beta})'\bar{V}^{-1}(\beta - \bar{\beta})\right\}$$

이는 $N(\bar{\beta}, \bar{V})$ 밀도의 커널이다. 확률밀도는 그 커널에 의해 유일하게 결정되므로(빠진 정규화 상수는 적분값을 1로 만드는 값일 뿐이다), $\beta | \sigma^2, y \sim N(\bar{\beta}, \bar{V})$ 이다.

유도: $\sigma^2 | \beta, y$

이제 β 를 고정하고 σ^2 를 미지수로 취급하며, $e \equiv y - X\beta$ 라 하자. σ^2 만의 함수로 쓴 가우시안 우도와 역감마 사전분포 커널은 다음과 같다.

$$p(y | \beta, \sigma^2) = (2\pi\sigma^2)^{-T/2} \exp\left\{-\frac{e'e}{2\sigma^2}\right\},$$

$$p(\sigma^2) \propto (\sigma^2)^{-(a_0/2+1)} \exp\left\{-\frac{d_0}{2\sigma^2}\right\}.$$

둘을 곱한 뒤 σ^2 의 거듭제곱 항을 지수 항과 따로 모으면(이는 $(\sigma^2)^{-T/2}$ 와 $(\sigma^2)^{-(a_0/2+1)}$ 이 지수를 더함으로써 결합되고, 두 지수함수가 공통인수 $-1/(2\sigma^2)$ 을 공유하므로 정당하다):

$$p(\sigma^2 | \beta, y) \propto (\sigma^2)^{-T/2-(a_0/2+1)} \exp\left\{-\frac{1}{2\sigma^2}(e'e + d_0)\right\}$$

그리고 결합된 σ^2 의 거듭제곱을 사전분포와 동일한 형태/척도 형식으로 쓰면:

$$= (\sigma^2)^{-\left(\frac{a_0+T}{2}+1\right)} \exp\left\{-\frac{d_0 + e'e}{2\sigma^2}\right\}.$$

이는 형태모수 $(a_0 + T)/2$, 척도모수 $(d_0 + e'e)/2$ 를 갖는 역감마 밀도의 커널과 정확히 일치한다. 따라서 $\sigma^2 | \beta, y \sim IG\left(\frac{a_0 + T}{2}, \frac{d_0 + e'e}{2}\right)$ 이며, 사전 자유도 a_0 와 사전 제곱합 d_0 는 각각 표본 크기 T 와 실현된 잔차제곱합 $e'e$ 를 더함으로써 단순히 갱신된다 — 이는 통상적인 역감마 켄레 갱신 규칙이다.

6.3 깃스 표본추출 알고리즘

알고리즘: 다중회귀에 대한 켄레 깃스 샘플러

σ^2 의 현재 값이 주어지면 다음을 순환한다.

1. $\beta \mid \sigma^2, y \sim N(\bar{\beta}, \bar{V})$ 를 추출한다. 여기서

$$\bar{V} = (V_0^{-1} + \sigma^{-2} X'X)^{-1}, \quad \bar{\beta} = \bar{V} (V_0^{-1}b_0 + \sigma^{-2} X'y).$$

2. $\sigma^2 \mid \beta, y \sim IG\left(\frac{a_0 + T}{2}, \frac{d_0 + e'e}{2}\right)$ 를 추출한다. 여기서 $e = y - X\beta$ 이다.

이를 반복하고, n_0 개의 번인 표본을 버린 뒤 사후 추론을 위해 n_1 개의 번인 이후 표본을 유지한다.

6.4 실증 예제: 미국 경제에 대한 축약형 산출량 방정식

실제 회귀변수를 이용해 다중회귀를 예시하기 위해, 분기별 미국 실질 GDP 성장률 y_t 를 자신의 시차, 시차 CPI 인플레이션(π_{t-1}), 시차 실효 연방기금금리(i_{t-1})의 함수로 나타낸 소규모 축약형 모델을 고려하며, 45장과 동일한 분기별 패널(1959Q3–2026Q1, 코로나19 팬데믹을 포함하도록 45장의 원본 1959Q3–2013Q4 구간에서 확장됨)을 사용한다.

$$y_t = c + \phi y_{t-1} + \gamma \pi_{t-1} + \delta i_{t-1} + e_t.$$

이는 4.7절의 AR(1) 모델을 $k = 4$ 로 확장한 것으로, 실증 거시경제학에서 출발점으로 널리 사용되는 소규모 “IS곡선”형 축약형에 해당한다.

실증 예제: 사후 추정치: 무정보적 사전분포

무정보적 사전분포($\beta \sim N(0, 100I_4)$, $\sigma^2 \sim IG(1.5, 1.5)$)와 10,000개의 번인 이후 깃스 표본을 사용할 때, 사후평균(표준편차, 95% 신용구간)은 다음과 같다.

$$\hat{c} = 3.794 (0.484) \quad [2.863, 4.741]$$

$$\hat{\phi} = 0.040 (0.061) \quad [-0.078, 0.161]$$

$$\hat{\gamma} = -0.290 (0.108) \quad [-0.502, -0.078]$$

$$\hat{\delta} = 0.025 (0.090) \quad [-0.150, 0.206]$$

네 개의 비효율성 계수 모두 1에 가까워 (0.93–1.03), 켄레 깃스 샘플러가 4.7절에서 예상한 대로 사실상 완벽하게 혼합됨을 확인시켜 준다. 이 사후평균들은 OLS 추정치 (3.805, 0.040, -0.290, 0.023)와 소수점 두세 자리까지 일치하는데, 무정보적 사전분포와 $T = 266$ 개의 관측치 하에서는 당연한 결과이다 — 그림 16는 둘을 겹쳐서 보여준다. 시차 성장 계수 $\hat{\phi} = 0.040$ 은 4.7절의 평균-포함 AR(1) 추정치(0.039)와 가까운데, 두 값 모두 확장 이전 값에서 크게 하락한 것이다(4.7절의 원래 값은 0.333이었고, 이 방정식 자체의 $\hat{\phi}$ 도 원본 1959Q3–2013Q4 표본에서는 0.314였다). 이는 2020Q2/Q3의 극단적 변동이 시차-1 이차적률에 반영되면서 나타난 결과이다(이 메커니즘에 대해서는 4.5절의 remark 참조). 확장 이전 표본에서는 인플레이션 계수의 신용구간이 겨우 0을 포함하는 정도였던 것과 달리, 확장된 표본의 신용구간 $[-0.502, -0.078]$ 은 0을 완전히 배제한다. 팬데믹 분기들이 포함되면서 시차 인플레이션

과 이후 성장률 사이의 경기역행적 혹은 비용상승형(cost-push) 관계가 이제 신용성 있게 음(-)으로 나타난다. 연방기금금리 계수는 이 시계에서 여전히 0과 구분되지 않는다. 이 회귀는 이제 분기별 성장률 변동의 단 $R^2 = 0.039$ 만을 설명하는데(그림 20, 왼쪽 패널) — 확장 이전의 0.146에서 크게 하락한 것으로, 2020Q2/Q3의 극단적 변동이 제곱합을 지배하여 한 시차만을 갖는 순수하게 후향적인(backward-looking) 선형 축약형이 그것을 거의 설명하지 못하기 때문이다.




Figure 16: 세 기울기 계수의 사후밀도(무정보적 사전분포), OLS 점추정치가 표시됨

6.5 Rudebusch and Svensson (1999)

위의 축약형 방정식은 범용적인 예시이다. 여기서 잠시 멈추어, 동일한 아이디어가 실제로 영향력 있는 응용 거시경제학 연구에서 어떻게 쓰였는지 살펴볼 만하다. Rudebusch and Svensson(1999, 이하 RS), “Policy Rules for Inflation Targeting”는 미국 경제에 대한 소규모 2방정식 모형(후향적(backward-looking) 필립스곡선과 후향적 IS곡선)을 구성하여 인플레이션 타게팅을 위한 통화정책 준칙을 평가한다. 이들의 IS곡선은 1961:1–96:2 분기 미국 자료에 OLS로 추정된다.

$$y_{t+1} = \beta_1 y_t + \beta_2 y_{t-1} - \beta_r (\bar{r}_t - \bar{\pi}_t) + \eta_{t+1},$$

여기서 y_t 는 산출량 갭(실질GDP 대비 잠재GDP, 퍼센트), $\bar{r}_t$ 는 4분기 평균 연방기금금리, $\bar{\pi}_t$ 는 4분기 평균 GDP디플레이터 인플레이션율로, 사후적(ex post) 실질금리에 대한 근사치이다. 모든 변수는 추정에 앞서 평균이 제거되므로 이 방정식에는 절편이 없다. RS(1999)가 보고한 OLS 추정치는 $\hat{\beta}_1 = 1.16$, $\hat{\beta}_2 = -0.25$, $\hat{\beta}_r = -0.10$ (표준오차 0.08, 0.08, 0.03), 잔차표준오차 = 0.819이다.

이 노트 전체에서 사용한 것과 같은 3단계 논리(재현(replicate), 확장(extend), 설명(explain))을 따라, 먼저 FRED의 실질GDP(GDPC1), CBO 잠재GDP (GDPP0T), GDP디플레이터(GDPDEF), 실효연방기금금리 (FEDFUNDS) 시리즈를 이용해 원논문의 표본을 그대로 재구성한 뒤, OLS 대신 6.2–6.3절의 켈레-김스 샘플러로 동일한 방정식을 재추정하고, 마지막으로 동일한 변수들을 현재까지 연장한 표본에서 다시 추정한다.

실증 예제: 원표본, 1961Q1-1996Q2

무정보적 사전분포($\beta \sim N(0, 100I_3)$, 절편 없음, $\sigma^2 \sim IG(1.5, 1.5)$)와 10,000개의 번인 이후 표본을 사용할 때, 사후평균(표준편차)은 $\hat{\beta}_1 = 1.152$ (0.084), $\hat{\beta}_2 = -0.253$ (0.082), $\hat{\beta}_r = -0.081$ (0.032)로, RS(1999)의 OLS 추정치 1.16, -0.25, -0.10과 모든 계수에서 사후표준편차 1개 이내로 일치하며, 논문이 보고한 표준오차(0.08, 0.08, 0.03)와도 거의 정확히 일치한다. 이는 강한 재현이다. 1999년 이후 수십 년에 걸친 GDP디플레이터 및 잠재GDP 자료의 개정에도 불구하고 원표본의 IS곡선은 사실상 변하지 않았으며, 이는 잘 식별된 저차원 축약형 관계에서 기대할 수 있는 바와 정확히 일치한다. 그림 17은 세 사후밀도와 적합값 대 실제값을 보여준다.




Figure 17: Rudebusch-Svensson (1999) IS곡선을 원표본(1961Q1-1996Q2)에서 재현: OLS 마커가 표시된 $\beta_1, \beta_2, \beta_r$ 의 사후밀도와, 평균이 제거된 산출량갭 성장률의 적합값 대 실제값

실증 예제: 전체표본, 1961Q1-현재

동일한 모형과 사전분포를, 동일한 네 시리즈를 1961Q1부터 가장 최근 분기까지 연장한 자료로 재추정하면 $\hat{\beta}_1 = 0.934$ (0.063), $\hat{\beta}_2 = -0.038$ (0.062), $\hat{\beta}_r = -0.037$ (0.023)을 얻는다. 두 가지 변화가 두드러진다. 첫째, 산출량갭의 지속성을 나타내는 합 $\hat{\beta}_1 + \hat{\beta}_2$ 는 거의 변하지 않는다(원표본 0.899 대 전체표본 0.896). 즉 산출량갭 자체의 AR 구조는 크게 바뀌지 않았다. 둘째, 더 두드러지기는 실질금리 계수 $\hat{\beta}_r$ 이 절반 이상 줄어들어 -0.081에서 -0.037이 되었고, 그 95% 신용구간 $[-0.083, 0.008]$ 은 더 이상 0을 배제하지 않는다. 애초에 정책준칙 분석을 위해 IS곡선을 추정하는 핵심 이유였던, 이 축약형에서 통화정책이 산출량갭에 영향을 미치는 경로가 RS(1999)의 원표본에 비해 전체표본에서 측정 가능할 정도로 약해진 것이다.




Figure 18: 동일한 IS곡선을 전체표본(1961Q1-현재)에서 재추정: 실질금리 계수 β_r 이 그림 17 대비 0을 향해 축소됨

참고: 감쇠의 설명: 단절이 아니라 약화된 전이 경로

후향적 축약형에서 실질금리 계수가 줄어드는 패턴은 RS(1999)의 원표본 시기 전후로 축적된 통화정책 전이(transmission) 문헌이 기록해온 바와 일치한다. Boivin and Giannoni (2002, 2006)는 미국 자료를 볼커(Volcker) 디스인플레이션 시점(1979:4)을 기준으로 나누어, 식별된 통화정책 충격에 대한 산출량 반응이 볼커 이후 시기에는 이전 시기의 약 4분의 1에 불과함을 발견했다 — 여기서 확인된 하락(전체표본에서 $\hat{\beta}_r$ 이 원표본 값의 절반 이하로 줄어든 것)과 같은 차수이다. Boivin, Kiley, and Mishkin (2010)은 요인증강 VAR(FAVAR)과 추정된 DSGE 모델을 모두 사용하여, 최근 수십 년간 통화정책 충격이 실물경제 활동에 미치는 효과가 더 완만해졌음을 확인하고, 이를 민간부문의 지출 행태 변화가 아니라 정책 행태 자체의 변화로 설명한다. 볼커 이후 통화정책이 더 체계적이고 물가안정에 초점을 맞추게 되면서, 민간 경제주체들이 정책 대응을 예상하고 부분적으로 선반영하게 되었고, 그 결과 후향적 회귀식이 포착할 수 있는 예상치 못한(unanticipated) 금리 변동, 즉 산출량을 움직이는 변동 폭 자체가 줄어들었다는 것이다. 여기서 사용한 전체표본에 특유한 두 번째 요인은, 표본이 제로금리하한(zero lower bound) 근방의 두 긴 시기(2009–2015년, 2020–2022년)를 포함한다는 점이다. 이 기간에는 산출량갭과 인플레이션이 크게 변동했음에도 명목 기금금리는 거의 움직이지 않았고, 이는 $(\bar{\pi}_t - \pi_t)$ 회귀변수의 분산을 압축시켜 위의 전이 메커니즘 설명 위에 $\hat{\beta}_r$ 하락의 요인을 하나 더 더한다. 역시 기계적인 세 번째 가능성은 중립 실질금리 r^* 의 장기 하락이다(Laubach and Williams, 2003): 전체표본에 걸쳐 $(\bar{\pi}_t - \pi_t)$ 를 탈평균하는 것은 정책 기조를 상수 기준점에 상대적으로 측정하는 것이므로, r^* 가 하락해 왔다면 회귀변수에 점점 커지는 측정오차가 실리고 — 회귀변수의 고전적 측정오차는 그 계수를 영 쪽으로 감쇠시킨다. 두 설명은 같은 방향을 가리키며 서로 배타적이지 않다. 오늘날 IS 곡선의 금리민감도 계수가 더 작은 것은 재현 자체가 잘못되어서가 아니라, 그것이 측정하는 대상(특정 실질금리 갭이 한 분기 뒤 산출량갭을 얼마나 강하게 움직이는가)이 RS(1999)가 연구했던 시기 이후로 실제로 작아졌기 때문이다.

6.6 사전분포 민감도: 무정보적 사전분포 대 축소 사전분포

결레 사전분포는 단순한 계산상의 편의가 아니라, 분석자가 실제 사전 믿음을 반영하도록 해준다. 그리고 결론이 V_0 의 선택에 얼마나 의존하는지 점검하는 것은 바람직한 관행이다. 무정보적 사전분포를, 절편과 자기회귀 계수는 느슨하게 남겨둔 채 큰 폭의 축약형 인플레이션 및 금리 전이(pass-through)에 대해 회의적인 입장을 표현하는 정보적 사전분포로 대체하는 것을 고려해 보자.

$$V_0^{\text{tight}} = \text{diag}(100, 1, 0.01, 0.0001).$$

실증 예제: 사후 추정치: 강한 축소 사전분포

V_0^{tight} 하에서 사후평균은 $\hat{c} = 3.443$ (0.391), $\hat{\phi} = 0.037$ (0.061), $\hat{\gamma} = -0.156$ (0.065), $\hat{\delta} = -0.001$ (0.010)로 이동한다. 자기회귀 계수 $\hat{\phi}$ 는 사실상 변하지 않는데(이에 대한 사전분포는 느슨하게 두었기 때문), $\hat{\gamma}$ 는 0을 향해 축소되고 $\hat{\delta}$ 는 거의 정확히 사전평균 0으로 끌어당겨지며, 사후 표준편차는 무정보적 사전분포 하에서보다 한 자릿수 더 작아진다. 이는 결레 갱신 공식이 예측하는 바와 정확히 일치한다. V_0 의 항목이 매우 촘촘하면, 우도가 압도적인 반대 증거를 담고 있지 않는 한 해당 사후분포는 사전분포에 의해 지배된다.

참고: 회귀변수가 상관되어 있을 때 이것이 더 중요한 이유

시차 인플레이션과 시차 연방기금금리는 그 자체로 상관되어 있으므로(연방준비제도는 부분적으로 인플레이션에 대응하여 금리를 인상한다), 자료만으로는 γ 와 δ 를 뚜렷하게 분리할 수 없다 — 이는 무정보적 사전분포 하에서 두 계수 모두의 사후표준편차를 부풀리는 일종의 근사 다중공선성이다. 회귀변수가 상관되어 있을 때, 사전분포의 선택은 두 공선 계수 중 어느 쪽이 추정된 효과를 흡수하는지에 실질적인 영향을 줄 수 있으며, 위와 같이 무정보적 사전분포와 의도적으로 정보적인 사전분포 양쪽 하에서 결과를 보고하는 것은 결론이 얼마나 자료 주도적인지, 얼마나 사전분포 주도적인지를 전달하는 간단하고 투명한 방법이다. 애초에 어떤 회귀변수가 모형에 속하는지를 자료가 결정하도록 하는 공식적인 모형 기반 대안은 8장의 주제이다.

6.7 스튜던트- t 오차를 이용한 강건한 회귀

정규 우도는 편리하지만 강건하지 않다. 소수의 극단적인 관측치가 가우시안 제곱합을 지배하여 $\hat{\beta}$ 를 왜곡할 수 있다. 4.1절은 스튜던트- t 분포를 정규/역감마 척도-혼합으로 소개했으며, 동일한 표현이 회귀 오차에도 직접 확장되어 각 관측치에 고유한 국소 오차분산 σ^2/λ_i 를 부여한다.

$$e_i \mid \lambda_i \sim N\left(0, \frac{\sigma^2}{\lambda_i}\right), \quad \lambda_i \sim \text{Gamma}\left(\frac{\nu}{2}, \frac{\nu}{2}\right) \implies e_i \sim t_\nu(0, \sigma^2).$$

잔차가 큰 관측치에는 작은 사후 λ_i 가 부여되어 그 유효 오차분산을 부풀리고 β 에 대한 영향력을 하향 가중한다 — 이는 임시방편적인 이상치 제거 규칙이 아니라 자동적인, 모형 기반의 강건회귀 형태이다. 그림 19는 세 블록이 이제 서로 어떻게 의존하는지를 보여준다. β 와 σ^2 는 가중치 벡터 $\{\lambda_i\}$ 전체에 의존하는 반면, 각 λ_i 는 오직 β, σ^2 , 그리고 자신의 잔차 e_i 에만 의존한다.




Figure 19: 스튜던트- t 회귀의 세 깃스 블록의 의존 구조: β 와 σ^2 는 T 개 가중치 전체에 걸친 정보를 모으는 반면, 각 λ_i 는 자신의 관측치만을 되돌아본다

유도: $\lambda_i \mid \beta, \sigma^2, y$ (그리고 가중치 하에서의 β, σ^2 갱신)

λ_i 가 주어지면, 관측치 i 는 분산 σ^2/λ_i 를 갖는 정규 우도 항을 기여하며, $e_i \equiv y_i - x_i'\beta$ 이다. $\text{Gamma}(\nu/2, \nu/2)$ 사전분포(비율 모수화)와 결합하면,

$$p(y_i \mid \beta, \sigma^2, \lambda_i) \propto \lambda_i^{1/2} \exp\left\{-\frac{\lambda_i e_i^2}{2\sigma^2}\right\},$$

이 $\lambda_i^{1/2}$ 인자는 정규 정규화 상수의 $(\sigma^2/\lambda_i)^{-1/2} = \sigma^{-1}\lambda_i^{1/2}$ 에서 나오며, λ_i 와 무관한 σ^{-1} 부분은 제거되었다. 그리고

$$p(\lambda_i) \propto \lambda_i^{\nu/2-1} \exp\left\{-\frac{\nu}{2}\lambda_i\right\}.$$

우도와 사전분포를 곱하고 λ_i 의 거듭제곱을 λ_i 에 선형인 공통 지수 항과 다시 따로 모으면:

$$p(\lambda_i \mid \beta, \sigma^2, y) \propto \lambda_i^{\frac{\nu+1}{2}-1} \exp\left\{-\frac{\lambda_i}{2}\left(\nu + \frac{e_i^2}{\sigma^2}\right)\right\},$$

이는 $\text{Gamma}\left(\frac{\nu+1}{2}, \frac{\nu + e_i^2/\sigma^2}{2}\right)$ (비율 모수화)의 커널이다. 이는 4.1절의 일반적인 정규 분포의 척도-혼합 갱신 규칙으로, 단일 자료점 y_i 에 의해 하나의 추가 “의사관측치(pseudo-observation)” 정보 ($\nu/2 \rightarrow (\nu+1)/2$, 형태모수에서)가 더해지고, 비율모수는 표준화된 잔차 제곱 e_i^2/σ^2 만큼 부풀려진다.

$\{\lambda_i\}$ 가 주어지면, β 와 σ^2 의 완전조건부분포는 위의 두 유도과 정확히 동일하게 따르되, $X'X, X'y, e'e$ 의 모든 항이 각각 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_T)$ 로 가중된 대응물인 $X'\Lambda X, X'\Lambda y, \sum_i \lambda_i e_i^2 = e'\Lambda e$ 로 대체된다. 이는 결합우도 $\prod_i N(y_i; x_i'\beta, \sigma^2/\lambda_i)$ 가 $N(y; X\beta, \sigma^2\Lambda^{-1})$ 로 간결하게 쓰일 수 있고, $\Lambda^{1/2}$ 를 앞에서 곱하면 이것이 오차분산 σ^2 를 갖는 $\Lambda^{1/2}y$ 에 대한 $\Lambda^{1/2}X$ 의 등분산(homoskedastic) 회귀로 바뀌기 때문이다^a — 이는 $X \rightarrow \Lambda^{1/2}X, y \rightarrow \Lambda^{1/2}y$ 로 바뀐 6.2절과 동일한 모형이며, 완전제곱식 만들기과 거듭제곱 매칭 논변은 $X'X \rightarrow X'\Lambda X$ 등의 대체 하에서 변경 없이 그대로 적용된다.

^a구체적으로: $e = y - X\beta \sim N(0, \sigma^2\Lambda^{-1})$ 라면, $\tilde{y} = \Lambda^{1/2}y, \tilde{X} = \Lambda^{1/2}X$ 로 정의하자. 그러면 $\tilde{y} - \tilde{X}\beta = \Lambda^{1/2}e \sim N(0, \sigma^2\Lambda^{1/2}\Lambda^{-1}\Lambda^{1/2}) = N(0, \sigma^2 I_T)$ 로, 통상적인 등분산 회귀가 된다. 이 등분산으로의 재척도화 기법은 알려진, 대각행렬 형태의 이분산성을 깃스 스텝을 처음부터 다시 유도하지 않고 다루는 표준적인 방법이며, 16장의 확률적변동성(stochastic volatility) 모형에서 Λ 가 시변 변동성 $\{\sigma_t^2\}$ 로 대체되어 다시 등장한다.

알고리즘: 스튜던트- t 회귀에 대한 깃스 샘플러

현재값 $(\beta, \sigma^2, \{\lambda_i\})$ 가 주어지면 다음을 순환한다.

1. $\beta \mid \sigma^2, \{\lambda_i\}, y \sim N(\bar{\beta}, \bar{V})$ 를 추출한다. 단, $\bar{V} = (V_0^{-1} + \sigma^{-2} X' \Lambda X)^{-1}$, $\bar{\beta} = \bar{V} (V_0^{-1} b_0 + \sigma^{-2} X' \Lambda y)$, $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_T)$ 이다.
2. $\sigma^2 \mid \beta, \{\lambda_i\}, y \sim IG\left(\frac{a_0 + T}{2}, \frac{d_0 + \sum_i \lambda_i e_i^2}{2}\right)$ 를 추출한다. 단, $e_i = y_i - x_i' \beta$ 이다.
3. $i = 1, \dots, T$ 에 대해, $\lambda_i \mid \beta, \sigma^2, y \sim \text{Gamma}\left(\frac{\nu + 1}{2}, \frac{\nu + e_i^2 / \sigma^2}{2}\right)$ 를 추출한다.

이는 정규-오차 사례에서 앞서 사용한 척도-혼합 깃스 샘플러의 다변량 유사체이다. λ_i 의 완전조건부분포는 4.1절에서 사용한 것과 동일한 감마/정규 결합에서 얻어지는 표준적인 척도-혼합 갱신이다.

실증 예제: 강건 추정치 대 정규 추정치, $\nu = 5$

동일한 축약형 방정식을 t_5 오차와 무정보적 사전분포로 재추정하면 $\hat{c} = 2.911$ (0.377), $\hat{\phi} = 0.210$ (0.056), $\hat{\gamma} = -0.194$ (0.082), $\hat{\delta} = 0.032$ (0.064)를 얻는다. 확장 이전 표본에서는 스튜던트- t 추정치와 정규-오차 추정치가 대체로 유사했던 것과 달리, 확장된 표본에서는 상당한 괴리가 나타난다. 정규-오차 $\hat{\phi}$ 는 0.040으로 하락한 반면(6.4절), 스튜던트- t $\hat{\phi}$ 는 0.210을 유지하며 원래의 팬데믹 이전 추정치 0.314에 훨씬 가깝다 — 이는 스튜던트- t 모형이 정규-오차 지속성 추정치를 0 쪽으로 끌어당기는 두 개의 극단적인 2020년 분기를 하향 가중하기 때문이다. 266개 분기 중 13개가 사후평균 가중치 $\lambda_i < 0.5$ 를 받는다(즉, 유효 오차분산이 기준값의 두 배를 넘는다). 그중에서도 압도적으로 크게 하향 가중된 두 분기는 팬데믹의 두 분기, 즉 2020Q3($\bar{\lambda} = 0.02$; GDP 성장률 +34.9%, 경제활동 재개에 따른 반등)과 2020Q2($\bar{\lambda} = 0.04$; -28.0%, 팬데믹 수축)이다. 나머지 크게 하향 가중된 분기들은 전후 미국 경기순환사의 익숙한 극단적 국면들이다 — 2008-09년 금융위기의 저점(2008Q4, 2009Q1), 1980년대 초와 스태그플레이션 시기의 큰 변동 (1980Q2, 1978Q2, 1971Q1), 그리고 팬데믹 개시 분기인 2020Q1로, 모두 $\bar{\lambda}$ 가 대략 0.17에서 0.36 사이에 위치한다. 이들은 정확히 하나의 선형 방정식으로는 설명을 기대하기 어려운 관측치들이며, 스튜던트- t 오차모형은 이들을 자동으로 식별하여 하향 가중한다.




Figure 20: 위: 실제 대 적합한 GDP 성장률, 정규분포 오차 무정보적 사전분포 사후평균. 아래: 스튜던트- t 모형의 잔차 제곱, 위에서 분기별 가중치로 살펴본 것과 동일한 강건성 비교를 적합값을 통해 살펴본 것

참고: 이제 강건성은 점추정치를 상당히 변화시킨다 — 팬데믹 분기가 그 이유이다

표본이 팬데믹을 포함하게 되자 스튜던트- t 와 정규-오차 사후평균은 더 이상 일치하지 않는다. $\hat{\phi}$ 는 정규-오차 하에서 0.040이었다가 스튜던트- t 하에서 0.210으로 이동하는데, 이는 사후표준편차 여러 개만큼 떨어진 차이이며, 절편도 3.794에서 2.911로 이동한다. 이는 확장 이전 표본에서 강건회귀와 정규-오차 회귀가 (정규 $\hat{\phi} = 0.314$ 대 스튜던트- t $\hat{\phi} \approx 0.28$ 로) 밀접하게 일치했던 것과는 극적인 반전이다. 미국 전후 GDP 성장률은 이따금 변동성이 크더라도 문제가 될 만큼 극단적인 관측치를 포함하지 않았기 때문이었다. 2020Q2(-28.0%)와 2020Q3(+34.9%) 분기는 정도가 아니라 종류 자체가 다르다. 이 둘이 시차-1 표본 이차적률에 미치는 결합 효과는 정규-오차 모형에서 추정된 지속성을 거의 지워버릴 만큼 크며, 반면 스튜던트- t 모형의 관측치별 가중치는 이들을 이례적인 것으로 인식하고($\bar{\lambda} \approx 0.02-0.04$ 로, 전후 어떤 경기순환이나 금융위기 분기와 비교해도 그에 필적하거나 그보다 더 극단적이다) 그에 따라 할인함으로써, 원래의 팬데믹 이전 값에 가까운 지속성 추정치를 복원한다. 이는 정확히 강건회귀가 제공해야 할 진단적 가치이다. 두 모형이 일치할 때는 그 자체가 안심할 근거가 되고, 지금처럼 불일치할 때는 그 자체가 어떤 관측치가 그 괴리를 만들어내는지를 직접 가리키는 정보가 된다. 다음 예제는 보완적이고 완전히 통제된 점검을 제공한다. 팬데믹이 아닌 평범한 분기들에 세 개의 인위적이고 명확히 표시된 자료 오류를 주입하여, 동일한 하향 가중 메커니즘이 이례성의 원천과 무관하게 항상 작동함을 확인한다.

실증 예제: 이상치 주입 실험: 두 번째의 통제된 예시

팬데믹과 무관한, 통제된 이상치에 대해서도 동일한 하향 가중 메커니즘이 작동하는지 보기 위해, 이 절 전체에서 사용한 동일한 y 를 가져와 266개 분기 중 세 개를(실제 GDP 수치가 아니라, 오직 이 실험을 위해 주입된 인위적 값이다) 고의로 바꾸되 모든 회귀변수는 그대로 둔다. 1972Q2의 성장률(실제로는 +2.5%)은 +40.0%로, 1989Q4의 성장률(실제로는 +0.8%)은 -35.0%로,

2004Q4의 성장률(실제로는 +3.4%)은 +32.0%로 대체하여, 종속변수에서만 발생한 심각한 자료입력 또는 전사(transcription) 오류를 모방한다. 세 분기 중 팬데믹 분기는 하나도 없으므로, 이 실험은 6.6절에서 확인한 코로나19로 인한 괴리와는 독립적이다. 위와 동일한 무정보적 사전 분포와 t_5 자유도로 두 김스 샘플러를 이 이상치가 주입된 계열에 대해 다시 실행하면 다음을 얻는다.

	원본 자료	오류 주입, 정규	오류 주입, 스튜던트- t
$\hat{c}$	3.794 (0.484)	4.108 (0.645)	2.920 (0.389)
$\hat{\phi}$	0.040 (0.061)	0.066 (0.081)	0.208 (0.056)
$\hat{\gamma}$	-0.290 (0.108)	-0.210 (0.146)	-0.199 (0.084)
$\hat{\delta}$	0.025 (0.090)	-0.098 (0.123)	0.036 (0.066)

266개 분기 중 단 세 개의 인위적 자료 오류만으로도 정규-오차 사후분포를 이동시키기에 충분하다. $\hat{\gamma}$ 는 0쪽으로 끌려가며(-0.290 $\rightarrow$ -0.210), 그 95% 신용구간은 [-0.502, -0.078]에서 [-0.492, 0.075]로 넓어져 6.4절에서 확립했던 “시차 인플레이션이 신용성 있게 음(-)이다”라는 결론을 뒤집는다. $\hat{\delta}$ 는 0과 구분되지 않던 값에서 다소 음(-)인 -0.098로 밀려나지만, 그 신용구간 [-0.339, 0.143]은 여전히 0을 포함한다. 이에 반해 스튜던트- t 사후분포는 $\hat{\gamma}$ 와 $\hat{\delta}$ 에서 다소만 이동하며, $\hat{\phi} = 0.208$ 은 6.6절의 원본 자료 스튜던트- t 추정치 0.210에 가깝게 위치한다 — 즉 극단적 관측치가 실제 2020년 팬데믹 분기이든 인위적 자료 오류이든 사실상 동일한 기저 지속성을 복원한다. 그 메커니즘은 정확히 이 절의 하향 가중 규칙이 작동한 것이다. 세 개의 주입된 분기는 사후 평균 가중치 $\bar{\lambda} = 0.028(1972Q2)$, $0.025(1989Q4)$, $0.044(2004Q4)$ 을 받는데(이는 6.6절에서 확인한 실제 2020Q2/Q3 팬데믹 분기에 부여된 가중치와 비슷한 크기이며, 평범한 경기순환 분기 보다는 훨씬 낮다) 따라서 샘플러는 인위적 오류와 실제 팬데믹 극단값을 동일한 자동적 회귀주의로 다루는 반면, 정규 우도에는 그러한 메커니즘이 없어 실제 값이든 훼손된 값이든 모든 점을 제 곱합을 통해 수용할 수밖에 없다.




Figure 21: 왼쪽: y_t 를 자신의 시차변수 gdp_{t-1} 에 대해 산점도로 나타내고(다른 두 회귀변수는 표본평균값에 고정), 정규 오차 및 스튜던트- t 오차 사후평균 적합선을 함께 표시하였다. 세로축은 217개 정상 분기가 분포하는 범위로 확대되어 있으며, 이 범위를 크게 벗어나는 3개의 주입된 이상치는 빨간 별표로 표시하고 그 값을 그림 테두리에 표기하였다. 분기 지수에 대한 시계열 곡선으로 그릴 때와 달리, 이렇게 나타내면 두 적합선이 서로 구분되지 않는 것이 아니라 뚜렷이 다른 직선으로 나타난다. 가운데: 스튜던트- t 사후평균 가중치 λ_i , 3개의 주입된 이상치가 실제로 하향 가중된 어떤 분기보다도 훨씬 아래에 위치함. 오른쪽: 원본 자료, 정규 오차를 사용한 오류 주입 자료, 스튜던트- t 오차를 사용한 오류 주입 자료 각각에서의 사후평균 계수, 정규-오차의 끌림 효과와 이에 대한 스튜던트- t 모형의 저항성을 보여줌

참고: 두 실험, 하나의 메커니즘

위의 두 비교는 동일한 근본 메커니즘을 서로 독립적인 두 각도에서 보여줄 뿐이다. 6.6절은 확장된 표본에서는 실제 자료만으로도 정규-오차와 스튜던트- t -오차 사후분포가 상당히 갈라짐에 충분함을 보여준다. 2020년 팬데믹 분기들이 지난 70여 년의 GDP 성장률에 비해 진정으로 극단적이기 때문이다. 이 절의 이상치 주입 실험은 팬데믹과 무관한 세 개의 인위적이고 명확히 표시된 자료 오류에서 동일한 메커니즘이 작동함을 보여준다. 진짜 극단적 관측치와 자료 오류를 구분할 방법이 없는 정규 우도는 소수의 이례적인 점이 점추정치를 이동시키고 심지어(여기서 $\hat{\gamma}$ 가 그렇듯) 신용구간 결론을 뒤집도록 허용하는 반면, 스튜던트- t 모형의 관측치별 가중치 λ_i 는 팬데믹 분기든, 금융위기 분기든, 스태그플레이션 시기 분기든, 혹은 조작된 전사 오류든 사후분포가 이례적이라고 판단하는 관측치의 어떤 조합이든 자동으로 식별하여 할인한다. 두 예시를 함께 보면, 사후에 잔차 도표를 눈으로 살펴 이상치를 찾아내거나 특정 역사적 표본이 우연히 극단적 사건으로부터 자유롭기를 바라는 방식에 의존하기보다, 처음부터 척도-혼합 표현을 회귀모형에 내장하는 것이 실용적으로 정당화되는 근거가 된다.

7. 프로빗 모형(The Probit Model)

6장의 모든 컬레 결과는 y 자체가 연속형이고 정규분포를 따른다는 데에 의존했다. 이진(binary) 결과변수는 이를 즉시 무너뜨린다 — 0/1 변수에 대한 정규-역감마 컬레 사전분포는 존재하지 않는다. 6장의 기법을 포기하는 대신, 이 장은 그것을 복원하는 방법을 보여준다. y_i 가 그 임계값 처리(thresholded)된 형태인 잠재적 연속변수 z_i 를 고안하고, 깁스 샘플러가 z_i 를 대체(impute)하는 단계와 대체된 자료에 대해 6장 고유의 회귀 스텝을 실행하는 단계를 교대로 반복하도록 한다. 이 자료증강(data augmentation) 기법이야말로(프로빗 연결함수 자체가 아니라) 오래도록 남는 아이디어이다. 9장의 토빗 모형과 18장의 국면전환 모형 모두 정확히 같은 이유로, 즉 다루기 어려운 우도를 익숙한 컬레 기법으로 되돌리기 위해 잠재변수를 도입한다.

6장의 다중회귀 모형은 연속적인 결과변수 y 를 필요로 한다. 그러나 경제학적으로 흥미로운 많은 결과변수는 이진형이다 — 경기침체가 발생했는가, 기업이 부도를 냈는가, 가구가 노동시장 참여를 선택했는가 등이다. 이 장은 앨버트와 치브(Albert and Chib, 1993)의 자료증강 깁스 샘플러를 통해 이러한 결과변수에 대한 베이저안 프로빗 모형을 전개하는데, 이는 잠재적 연속변수를 도입함으로써 이진 결과 모형을 6장의 익숙한 컬레 선형회귀 기법으로 되돌린다.

7.1 잠재변수 프로빗 모형

$y_i \in \{0, 1\}$ 이 관측되지 않은(잠재적인) 선형회귀를 임계값 처리하여 생성된다고 가정하자.

$$z_i = x_i' \beta + e_i, \quad e_i \sim N(0, 1), \quad y_i = \mathbb{I}\{z_i > 0\}.$$

e_i 에 대해 주변화(marginalize)하면 $P(y_i = 1 \mid x_i) = P(e_i > -x_i' \beta) = \Phi(x_i' \beta)$ 를 얻는데, 이는 표준적인 프로빗 연결함수이다. z_i 가 관측된다면 (z, X) 는 알려진 오차분산 1을 갖는 통상적인 가우시안 선형회귀가 되며, 6장의 컬레 깁스 샘플러가 곧바로 적용될 것이다. 앨버트와 치브의 통찰은 z_i 자체를 깁스 샘플러 안에서 대체해야 할 결측값으로 취급하는 것이다. β 가 주어지면 각 z_i 는 $y_i = 1$ 이면 $(0, \infty)$ 로, $y_i = 0$ 이면 $(-\infty, 0)$ 로 절단된 정규분포를 갖는다. z 가 주어지면 β 는 6장에서와 동일한 컬레 정규 완전조건부분포를 $\sigma^2 \equiv 1$ 로 하여 갖는다.

7.2 사후분포 유도

증강된 모수 벡터는 $z = (z_1, \dots, z_T)'$ 를 포함하는 (β, z) 이다. y_i 가 z_i 의 결정론적 함수(즉 $y_i = \mathbb{I}\{z_i > 0\}$)이므로, 관측된 자료 y 가 주어졌을 때 (β, z) 의 결합 사후 커널은 매우 간단하게 인수분해된다.

$$p(\beta, z \mid y) \propto p(y \mid z) p(z \mid \beta) p(\beta) = \left[\prod_{i=1}^T \mathbb{I}\{\text{sign}(z_i) = \text{sign}(y_i - \frac{1}{2})\} \right] p(z \mid \beta) p(\beta),$$

여기서 $p(y \mid z)$ 는 모든 z_i 가 관측된 y_i 와 부합하는 부호를 가지면 1, 그렇지 않으면 0이며, $p(z \mid \beta) = \prod_i N(z_i; x_i' \beta, 1)$ 은 잠재회귀 우도이다. 이 인수분해가 자료증강 기법 전체의 핵심이다. z 가 일단 모수로 포함되고 나면, 모형은 z 의 지지집합을 제한하는 0/1 지시함수를 가진 완전히 표준적인 가우시안 선형회귀가 되며, 아래의 두 완전조건부분포가 즉시 도출된다.

유도: $z_i \mid y_i, \beta$

β 를 고정하고 하나의 i 를 고려하자. z_i 만의 함수로 볼 때 위의 결합 커널은

$$p(z_i \mid y_i, \beta) \propto \mathbb{I}\{\text{sign}(z_i) = \text{sign}(y_i - \frac{1}{2})\} \times \exp\{-\frac{1}{2}(z_i - x_i' \beta)^2\}$$

즉, $N(x'_i\beta, 1)$ 커널에 $y_i = 1$ 일 때는 z_i 를 $(0, \infty)$ 로, $y_i = 0$ 일 때는 $(-\infty, 0)$ 로 제한하는 지시함수를 곱한 형태이다. 밀도의 지지집합을 부분구간으로 제한하고 재정규화하는 것은 정의상 절단(truncation)이다. 지시함수를 만족하는 z_i 들은 원래의(비정규화된) 정규밀도 형태를 그대로 유지하므로:

$$z_i | y_i, \beta \sim \begin{cases} N(x'_i\beta, 1) \text{ 을 } (0, \infty) \text{ 로 절단} & y_i = 1 \\ N(x'_i\beta, 1) \text{ 을 } (-\infty, 0) \text{ 로 절단} & y_i = 0. \end{cases}$$

β 가 고정된 상태에서 z_i 들이 결합 커널에서 곱셈적이고 분리 가능한 형태로 나타나므로($i \neq j$ 일 때 z_i 와 z_j 를 연결하는 항이 없다), 이 논변은 각 i 에 대해 독립적으로 적용되며, 알고리즘이 사용하는 T 개의 조건부 독립 표본을 준다. 절단정규분포로부터의 표본추출은 4.2절의 역누적분포함수(확률적분변환) 방법으로 이루어진다. $u_i \sim U(0, 1)$ 을 추출하고, 적절한 절단 경계 $(a_i, b_i) = (-x'_i\beta, \infty)$ 또는 $(-\infty, -x'_i\beta)$ 에 대해 $z_i = x'_i\beta + \Phi^{-1}(\Phi(a_i) + u_i[\Phi(b_i) - \Phi(a_i)])$ 로 둔다.

유도: $\beta | z$

이제 z 를 고정하고(이는 β 가 주어졌을 때, 이를 추출하는 데 이미 사용된 절단 영역을 통하지 않고는 더 이상 y 에 의존하지 않는다) β 를 미지수로 취급하자. 관련 커널은

$$p(\beta | z) \propto p(z | \beta) p(\beta) \propto \exp\{-\frac{1}{2}(z - X\beta)'(z - X\beta)\} \exp\{-\frac{1}{2}(\beta - b_0)'B_0^{-1}(\beta - b_0)\}$$

이는 6.2절의 $\beta | \sigma^2, y$ 유도과 형태상 동일하다 — z 가 종속변수의 역할을 하고, 오차분산은 표본 추출되는 대신 $\sigma^2 = 1$ 로 고정된다. 그 결과에 $\sigma^2 = 1$ 과 $y \rightarrow z$ 를 대입하면 즉시 다음을 얻는다:

$$\beta | z \sim N(\bar{\beta}, \bar{B}), \quad \bar{B} = (B_0^{-1} + X'X)^{-1}, \quad \bar{\beta} = \bar{B}(B_0^{-1}b_0 + X'z)$$

완전제곱식 만들기 대수를 반복할 필요가 없다. 프로빗의 β 스텝은, 항목별로 보면, 6장의 켄레 회귀 스텝을 대체된 연속 결과변수 z 에 y 대신 적용한 것과 동일하다.

7.3 자료증강(앨버트-치브) 깃스 샘플러

그림 22는 두 블록의 순환을 요약한다. β 는 대체된 벡터 z 전체에 의존하며, 각 z_i 는 β 와 자신의 관측된 라벨 y_i 에만 의존한다.




Figure 22: 앨버트-치브 순환: β 와 잠재벡터 z 는 서로를 갱신하며, z 는 자신의 절단 영역을 통해 관측된 라벨 y 도 추가로 반영한다

알고리즘: 자료증강을 통한 베이지안 프로빗

컬레 사전분포 $\beta \sim N(b_0, B_0)$ 와 β 의 현재 값이 주어지면 다음을 순환한다.

1. 각 i 에 대해, 잠재효용

$$z_i \mid y_i, \beta \sim \begin{cases} N(x_i' \beta, 1) \text{를 } (0, \infty) \text{로 절단} & y_i = 1 \\ N(x_i' \beta, 1) \text{를 } (-\infty, 0) \text{로 절단} & y_i = 0, \end{cases}$$

를 추출하되, 절단정규분포에 4.2절의 역누적분포함수(확률적분변환) 방법을 적용한다.

2. $\bar{B} = (B_0^{-1} + X'X)^{-1}$, $\bar{\beta} = \bar{B}(B_0^{-1}b_0 + X'z)$ 를 이용하여 $\beta \mid z \sim N(\bar{\beta}, \bar{B})$ 를 추출한다 — 이는 $\sigma^2 = 1$ 인 6.2절의 컬레 회귀 스텝과 형태상 동일하다.

참고: 왜 β 에 직접 M-H를 적용하지 않고 자료증강을 사용하는가?

대신 4.5절에서처럼 프로빗 우도 $\prod_i \Phi(x_i' \beta)^{y_i} (1 - \Phi(x_i' \beta))^{1-y_i}$ 를 이용해 β 에 직접 메트로폴리스-헤이스팅스를 실행할 수도 있다. 자료증강이 보통 선호되는 이유는 완전한 컬레성을 복원하기 때문이다 — 결과 샘플러의 모든 스텝이 알려진 분포로부터의 정확한 표본추출이며, 조율할 제안 분포도 없고 기각되는 표본도 없다. 이는 4.7절에서 깁스 표본추출에 대해 제시한 효율성 논거와 정확히 같다.

7.4 실증 예제: 미국 경기침체 분기 예측

응용 사례로서, 전 분기 말에 이용 가능한 정보만을 이용하여 미국 실질 GDP가 수축하는지($y_t = \mathbb{1}\{\text{GDP 성장률}_t < 0\}$) 예측하는 문제를 고려하자. 시차 연방기금금리 수준, 실업률의 시차 변화, 시차 CPI 인플레이션(6장에서 사용한 것과 동일한 분기별 계열)을 사용한다.

$$P(y_t = 1) = \Phi(c + \beta_1 i_{t-1} + \beta_2 \Delta u_{t-1} + \beta_3 \pi_{t-1}).$$

사용 가능한 $T = 265$ 개 분기(1960Q1–2026Q1, 이 노트의 데이터 확장 이전에 사용되던 원래의 1960Q1–2013Q4 구간에서 확장됨) 중 31개(11.7%)가 수축 분기이다 — 다소 불균형한 이진 결과변수이며, 이는 아래에서 중요하게 작용한다.

실증 예제: 사후 추정치와 MLE와의 비교

무정보적 사전분포($\beta \sim N(0, 4I_4)$)와 10,000개의 번인 이후 깁스 표본을 사용할 때, 사후평균(표준편차, 95% 신용구간)은 다음과 같다.

$$\hat{c} = -1.746 \text{ (0.187)} \quad [-2.125, -1.389]$$

$$\hat{\beta}_1 = 0.037 \text{ (0.035)} \quad [-0.031, 0.105]$$

$$\hat{\beta}_2 = 0.279 \text{ (0.124)} \quad [0.025, 0.511]$$

$$\hat{\beta}_3 = 0.079 \text{ (0.039)} \quad [0.001, 0.157]$$

이는 고전적인 MLE 프로빗 적합값(statsmodels)과 유효숫자 두세 자리까지 일치한다($\hat{c} = -1.742$, $\hat{\beta}_1 = 0.036$, $\hat{\beta}_2 = 0.292$, $\hat{\beta}_3 = 0.080$). 무정보적 사전분포 하에서 예상되는 결과이다. 비효율성 계수 (3.15–5.63)는 6장의 컬레 깁스 샘플러에서 나온 1에 가까운 값들보다 높는데, 이

는 자료증강 스텝이 한 반복에서 다음 반복으로 β 와 대체된 z_i 사이에 추가적인 의존성을 도입하기 때문이다 — 그림에도 5.2절의 경험 법칙이 제시하는 “허용 가능한” 범위 안에 충분히 들어온다. 실업률의 시차 변화 Δu_{t-1} 와 시차 인플레이션 모두 이제 0을 배제하는 신용구간을 갖지만, 그 정도는 미미하다. $\hat{\beta}_2$ 의 구간 $[0.025, 0.511]$ 과 $\hat{\beta}_3$ 의 구간 $[0.001, 0.157]$ 모두 하한이 0에 가깝게 붙어 있으며, 이는 확장 이전 추정치($\hat{\beta}_2 = 1.456, [0.826, 2.078]$)이었고, $\hat{\beta}_3$ 는 아예 0과 신용성 있게 구분되지 않았다)에 비해 뚜렷하게 약화된 것이다. 이는 4 6장에서 확인한 것과 동일한 메커니즘을 반영한다. 2020년의 크고 단기적인 Δu_{t-1} 변동(2020Q2의 약 +10퍼센트포인트 상승에 이은 2020Q4까지의 약 -4퍼센트포인트 하락)이 분기별 수축 지표와 깔끔하게 맞아떨어지지 않으면서, 팬데믹 이전 표본에서는 훨씬 뚜렷했던 선형관계를 약화시킨다. 시차 연방기금금리는 이 시계에서 여전히 신뢰할 만한 효과를 갖지 않는다.




Figure 23: 세 프로빗 기울기 계수의 사후밀도, MLE 추정치가 표시됨

실증 예제: 한계효과와 표본 내 적합도

Φ 가 비선형이므로 β_j 자체는 확률 변화로 직접 해석될 수 없다. 평균 한계효과 $\overline{\phi(x'_i \beta)} \beta_j$ (정규밀도 ϕ 를 표본에 걸쳐 평균낸 것)는 이를 확률 단위로 변환한다. 사후평균에서, Δu_{t-1} 의 1퍼센트포인트 상승은 평균 예측 수축 확률을 5.0퍼센트포인트 높이는데(확장 이전의 22.4포인트에서 크게 하락한 값이다) 연방기금금리와 인플레이션은 각각 0.7, 1.4포인트에 그친다. 맥패든의 유사- R^2 , $1 - \ell(\hat{\beta})/\ell(0)$ 는 (확장 이전의 0.228에서) 0.097로 떨어져, 팬데믹 분기가 포함되면서 이 단일 시차 축약형의 적합도가 훨씬 약해졌음을 보여준다. $\hat{P}(y_t = 1) > 0.5$ 일 때마다 $\hat{y}_t = 1$ 로 분류하면 전체 정확도는 88.7%이다(혼동행렬: 참양성 2, 거짓양성 1, 거짓음성 29, 참음성 233) — 확장 이전(26개 중 5개)보다 참양성이 훨씬 적는데, 이는 적합된 확률이 전체 표본에서 단 세 번만 0.5를 넘기 때문이다(그 이유는 이 절 끝의 remark에서 설명한다).




Figure 24: 사후평균 예측 수축확률 대 실제 수축 분기(음영 표시)

실증 예제: 왜 그냥 OLS를 쓰면 안 되는가? 선형확률모형과의 비교

이 장의 잠재변수 기법을 완전히 무시하고 단순히 원자료 0/1 결과변수 y_t 를 X_t 에 대해 OLS로 회귀하지 못할 이유는 없다 — 이것이 선형확률모형 (linear probability model, LPM)이다. 위와 동일한 $T = 265$ 개 분기와 회귀변수에 적합하면 OLS는 다음을 준다.

$$\hat{y}_t = -0.0004 + 0.0076 i_{t-1} + 0.0679 \Delta u_{t-1} + 0.0223 \pi_{t-1}, \quad R^2 = 0.089,$$

적합된 “확률”은 표본 전체에서 -0.183 에서 0.535 까지의 범위를 갖는다 — 265개 분기 중 11개 (4.2%)가 0 미만의 LPM 적합값을 가지며, 이는 확장 이전의 14.4%에서 낮아진 것이다. Δu_{t-1} 에 대한 추정 기울기가 (위 7.4절에서 본 2020년의 극단적 변동으로 인해) 더 완만해지면서 극단적인 적합값 자체가 전반적으로 줄어들었기 때문이다. 열한 개 중 열 개는 실업률 하락 ($\Delta u_{t-1} < 0$)이 있었던 분기 다음 분기이며, 예외는 2009Q1 ($\Delta u_{t-1} = +0.9$)로 그 음의 적합값은 실업률 향 하나가 아니라 세 회귀변수 전체의 조합에서 비롯된다. 가장 심한 사례인 2020Q4는 $\hat{y} = -0.183$ 을 받는다. 이 분기의 $\Delta u_{t-1} = -4.2$ 는(초기 팬데믹 급등이 풀리며 실업률이 급락한 것으로) 팬데믹 이전 표본이 만들어낸 그 어떤 값보다도 훨씬 벗어나 있으며, 선형모형은 이러한 극단적인 입력값이 범위를 벗어난 출력값을 만들어내는 것을 막을 방법이 없다. 확장 이전과 마찬가지로, 범위를 벗어난 분기 중 하나는 실제 수축 분기이다. 2009Q1($y_t = 1$) — 따라서 LPM은 표본의 중요하지 않은 구석에서 어색한 숫자를 내놓는 데 그치지 않고, 실제로 일어난 결과에 무의미한 음의 확률을 부여한다. 이에 반해 위의 베이지안 프로빗 적합값은 동일한 표본에서 결코 $[0.005, 0.692]$ 를 벗어나지 않는다. 이는 구조적으로 그러한데, $x'_i \beta$ 가 아무리 극단적이더라도 $\Phi(\cdot)$ 는 $[0, 1]$ 밖의 값을 결코 반환할 수 없기 때문이다. 그림 25은 그 이유를 보여준다. 다른 두 회귀변수를 표본평균에 고정한 채 Δu_{t-1} (신뢰할 만한 효과를 갖는 유일한 회귀변수)의 함수로 두 적합 곡선을 도표화하면, LPM은 직선을 외삽할 수밖에 없는데, 이는 $\Delta u_{t-1} \approx 0$ 근처에서는 좋은 국소 근사가 되지만(두 곡선이 그곳에서는 거의 구분되지 않으며, LPM의 전체 분류 정확도 87.9%도 프로빗의 88.7%에 가깝다

(다만 더 이상 정확히 일치하지는 않는다) Δu_{t-1} 이 자료의 중심에서 충분히 멀어지면 불가피하게 0이나 1을 넘어서게 된다) 이는 정확히 경기침체 확률 모형이 올바르게 다루어야 할 꼬리 행태이며, 이제는 2020년 팬데믹 분기들이 확장 이전 표본의 어떤 분기보다도 이를 더 가혹하게 시험한다. 이는 어떤 학생이든 비선형모형을 신뢰하기 전에 가져야 할 직관을 실제로 검증한 사례이다. 프로빗이 선호되는 것은 그것이 전통적이기 때문이 아니라, 확률은 정의상 반드시 $[0, 1]$ 을 지켜야 하며, $\Phi(\cdot)$ 와 같은 유계(bounded) 연결함수로 구성된 모형만이 전형적인 표본뿐 아니라 모든 표본에서 이를 보장할 수 있기 때문이다.




Figure 25: OLS 선형확률모형 대 베이지안 프로빗(사후평균), 실업률 시차 변화의 함수로서, 다른 두 회귀변수는 표본평균에 고정. LPM 자체의 적합확률이 0 미만인 실제 분기는 동그라미로 표시됨

참고: 88.7%의 정확도는 보이는 것보다도 더 인상적이지 않다

분기 중 11.7%만이 수축 분기이므로, 항상 “경기침체 없음”을 예측하는 사소한 모형조차 이미 88.3%의 정확도를 갖는다 — 따라서 적합된 모형의 88.7% 전체 정확도는 계급 불균형을 감안하면 사실상 진정한 예측력을 전혀 반영하지 못하며, 이는 확장 이전 표본의 89.4% 대 88.0% 기준 선보다도 더 얇은 격차이다. 혼동행렬은 이를 정밀하게 보여준다. 재현율(recall, 실제 수축을 올바르게 표시한 비율)은 $2/31 = 6.5\%$ 로 크게 하락했다(확장 이전에는 19.2%). 반면 정밀도(precision, 표시된 분기 중 실제로 수축이었던 비율)는 여전히 합리적인 $2/3 = 66.7\%$ 이고, 특이도(specificity)는 $233/234 = 99.6\%$ 이다. 그림 24는 그 이유를 보여준다. 적합된 확률은 이제 265개 분기 전체 표본에서 단 세 번만 통상적인 0.5 문턱값을 넘는다. 1980Q2와 1980Q3(올바르게, 1980년대 초 이중침체)와 2020Q3(잘못됨: 거짓양성인데, 2020Q3의 Δu_{t-1} 은 2020Q2의 거대한 실업률 급등이 풀리는 것을 반영하여 적합확률을 0.69까지 끌어올리지만, 2020Q3 자체는 수축이 아니라 급격한 재개 호황이었다). 그 외의 모든 역사적 경기침체 — 1973–75년 오일쇼크 경기침체(정점 적합확률 0.44, 1975Q1), 2008–09년 금융위기 전체(정점 0.16, 2008Q4), 심지어 2020Q1과 2020Q2 자체의 팬데믹 수축 분기(적합확률 각각 0.07과 0.06에 불과) — 는 이제 0.5 절단값에 전혀 미치지 못한다. 이는 확장 이전 표본의 교훈을 바꾸기보다는 더 날카롭게 만든

다. 경기침체를 놓치는 것이 오경보보다 훨씬 더 큰 비용을 초래하는 응용에서는, 더 낮은 분류 문턱값(더 많은 오경보를 감수하고 더 많은 실제 경기침체를 포착하는)이나 완전한 결정이론적 손실 함수가 기본 0.5 규칙보다 훨씬 더 적절할 것이며, 팬데믹이 표본에 추가되면서 이 함정은 덜해지기는커녕 오히려 더 증대해졌다.

7.5 Estrella and Mishkin (1998)

제6장이 Rudebusch and Svensson (1999)의 IS곡선을 원 데이터로 재구성했던 것과 마찬가지로, 이 절에서는 Estrella and Mishkin (1998), “Predicting U.S. Recessions: Financial Variables as Leading Indicators,” Review of Economics and Statistics의 가장 많이 인용되는 결과를 재구성한다. 위 7.4절의 4변수 축약형과 달리, 이 논문의 대표 모형은 단 하나의 설명변수(10년물 국채와 3개월물 T-bill의 기간스프레드 (SPREAD)) 만으로 k 분기 후 NBER 경기침체 지표를 예측한다:

$$P(R_{t+k} = 1) = \Phi(a_0 + a_1 \text{SPREAD}_t), \quad k = 1, \dots, 8.$$

Estrella and Mishkin(이하 EM)은 이 식을 지평선 k 마다 각각 최우추정법(MLE)으로 1959Q1–1995Q1 표본에서 추정하고, 그 결과 얻어진 pseudo- R^2 (Estrella, 1995)를 근거로 수익률곡선 스프레드가 1분기를 넘어서는 지평선에서 가장 뛰어난 단순 선행지표라고 주장한다.¹

실증 예제: 원표본, 1959Q1–1995Q1

FRED 시계열 GS10(10년물 국채)과 TB3MS(3개월물 T-bill)를 분기평균하여 SPREAD를 재구성하고, FRED USREC로부터 NBER 경기침체 지표를 구성하여 1959Q1–1995Q1 표본에서 동일한 8개 지평선별 프로빗 방정식을 추정하면:

k	1	2	3	4	5	6	7	8
EM(1998)	0.071	0.211	0.271	0.296	0.256	0.149	0.078	0.031
재현	0.110	0.220	0.271	0.235	0.202	0.133	0.069	0.034

$k = 1$ 에서 상승하여 $k = 3-4$ 부근에서 정점을 찍고 $k = 8$ 까지 감소하는 hump형 지평선 프로파일이 정확히 재현되며, SPREAD의 계수는 모든 지평선에서 음수이고 0과 신뢰구간이 겹치지 않는다(더 가파르고 양의 값을 갖는 기간스프레드일수록 경기침체 확률이 낮아진다) — EM(1998)이 보고한 것과 정확히 같은 부호이다. 8개 지평선 중 5개는 EM(1998)의 pseudo- R^2 와 0.02 이내로 일치하며, 가장 큰 차이는 $k = 1$ (재현이 더 높음, 0.110 vs. 0.071)과 $k = 4$ (재현이 더 낮음, 0.235 vs. 0.296)에서 나타난다.

¹EM(1998)의 분석은 최우추정법(MLE)으로 이루어졌으나, 우리의 재현은 7.3절의 Albert–Chib 깃스표집기를 무정보적 사전분포 ($a \sim N(0, 4I_2)$) 하에서 사용한다. 사후평균과 MLE가 정확히 일치할 필요는 없지만, 아래의 지평선별 비교는 동일한 hump 형태의 프로파일을 재현하며, 나머지 지평선에서의 수치적 차이는 구조적 불일치라기보다 추정방식과 데이터 vintage의 차이에서 비롯된 것으로 볼 수 있다.




Figure 26: 적합된 $P(R_{t+4} = 1)$ 대 실제 경기침체 지표, SPREAD 단독 프로빗, 원표본

실증 예제: 전체표본, 1959Q1-2026Q1

동일한 8개 지평선별 방정식을 2026Q1까지 재추정하여(EM(1998)의 원 표본기간 이후의 닷컴 버블·금융위기·팬데믹 경기침체를 추가하여) 얻은 결과는:

k	1	2	3	4	5	6	7	8
EM(1998)	0.071	0.211	0.271	0.296	0.256	0.149	0.078	0.031
1959Q1-2026Q1	0.027	0.081	0.133	0.140	0.136	0.104	0.066	0.046

hump 형태 자체는 유지되지만 그 크기는 $k = 6$ 까지 모든 지평선에서 대략 절반으로 줄어들고 (예: $k = 3$: $0.271 \rightarrow 0.133$; $k = 4$: $0.296 \rightarrow 0.140$), 정점도 $k = 4$ 에서 뾰족하게 솟기보다는 $k = 3-5$ 구간에서 평평하게 퍼진다. a_1 의 부호와 유의성은 그대로 유지되므로 기간스프레드는 전체표본에서도 여전히 정보력을 갖지만, EM(1998) 자체의 36년 표본에서보다는 뚜렷이 약해진 모습이다.




Figure 27: 예측지평선별 pseudo- R^2 : Estrella and Mishkin (1998)의 발표값 대 본 장의 베이 지안 재현 및 전체표본 결과




Figure 28: 적합된 $P(R_{t+4} = 1)$ 대 실제 경기침체 지표, SPREAD 단독 프로빗, 전체표본

약화는 적합도뿐 아니라 계수 자체에서도 나타난다. 그림 29는 모든 시계에서 두 표본의 SPREAD 기울기 a_1 사후밀도를 겹쳐 보여준다. $k = 1-5$ 에서 전체표본 사후분포는 원표본보다 눈에 띄게 영에 가깝다(표본 확장은 유사 R^2 가 가장 크게 떨어지는 바로 그 시계에서 계수를 약화시킨다) 반면 $k = 6-7$ 에서는 두 사후분포가 대체로 포개지고, $k = 8$ 에서는 오히려 전체표본 사후분포가 영에서 조금 더 멀다. 두 사후분포 모두 모든 시계에서 영을 배제한다: 추가된 경기침체들이 스프레

드의 신호를 흐리게 하지만, 지우지는 못한다.




Figure 29: 각 시계 k 에서 SPREAD 계수 a_1 의 사후밀도: 원표본 1959Q1–1995Q1(파란색) 대 전체표본 1959Q1–2026Q1(빨간색); 점선 수직선은 영

참고: 기간스프레드의 예측력이 약해진 이유

전체표본에 새로 추가된 1995년 이후 세 차례의 경기침체 중 두 건은 EM(1998)의 메커니즘과 부합한다: 2001년 닷컴버블 침체와 2008–09년 금융위기 모두 1959–1995년의 경기침체들과 마찬가지로 수익률곡선의 평탄화 또는 역전이 선행했다. 그러나 세 번째인 2020년 팬데믹 경기침체는 그렇지 않았다 — 이는 수익률곡선을 먼저 평탄화시키고 이어서 실물활동을 위축시키는 통화 긴축 사이클이 아니라, 외생적인 공중보건 충격과 전국적 섯다운에 의해 촉발되었다. (수익률곡선이 2019년 중반에 잠시 역전되어 2020년 진입 시점의 적합확률이 다소 높아져 있긴 했지만, 이는 예지가 아니라 우연이다: 2019년의 기간구조 어디에도 팬데믹에 관한 정보는 없었고, 적합확률도 1980–82년이나 2008–09년 침체 직전 수준에는 한참 못 미쳤다.) pseudo- R^2 는 표본 전체에 걸쳐 계산되므로, 이 하나의 경기침체가 모든 지평선의 평균적합도를 낮춘다 — 이는 위 7.4절의 4변수 모형에서 2020년 분기들이 계수 추정의 정밀도를 낮췄던 것과 같은 메커니즘이다. 두 번째로, 제6장의 IS곡선에서 확인했던 것과 동일한 보완적 요인도 작용한다: 전체표본은 두 차례의 긴 제로금리하한(ZLB) 구간(2009–2015년, 2020–2022년)을 포함하는데, 이 기간 동안 수익률곡선의 단기 쪽이 정책에 의해 0 근처에 고정되면서, 긴축 사이클과 통상적인 금리 변동을 구별하는 데 쓰일 SPREAD의 변동성 자체가 압축되었다. 두 요인 모두 EM(1998) 저자들 스스로가 예견했던 결론과 같은 곳을 가리킨다: 하나의 역사적 시대에서 추정된 단순 축약형 지표는, 진정으로 다른 종류의 경기침체들이 표본에 편입되면 그 예측력의 일부를(전부는 아니더라도) 잃을 것으로 예상해야 한다는 것이다.

8. 베이지안 변수선택(Bayesian Variable Selection)

6장과 7장은 모두 분석자가 어떤 회귀변수가 모형에 속하는지 이미 알고 있다고 가정했다. 그 가정은 실무에서 거의 성립하지 않으며, 6.4절은 이미 그것이 잘못되었을 때의 한 증상을 보여준 바 있다. 상관된 회귀변수의 개별 계수는 짚어내기가 어려워진다. 이 장은 “어떤 회귀변수가 속하는가”를 깁스 샘플러가 추정하는 또 하나의 대상으로 바꿈으로써 그 가정을 제거하며, 각 계수에 부착된 이진 지시변수 γ_j 를 통해 이를 수행한다. 이를 위해 필요한 모든 것은 이미 갖추어져 있다. 계수 스텝은 6.2절의 컬레 정규 결과를 그대로 재사용하며, 새로운 지시변수 및 분산 스텝은 6.2절의 역감마 결과와 단순한 베타-베르누이 갱신을 재사용한다. 진정으로 새로운 아이디어는 이로 인해 생겨나는 여섯 갈래의 위계적 의존관계이며, 이는 대수 전에 아래에서 시작된다.

6장과 7장은 모두 회귀변수의 집합을 미리 고정했다. 실무에서 분석자는 여러 후보 예측변수 중 어느 것이 진정으로 모형에 속하는지 좀처럼 알지 못하며, 6.4절이 상관된 ϕ 와 γ 계수로 미리 보여주었듯이, 지나치게 큰 회귀는 어떤 포함된 변수가 실제로 작동하고 있는지 분석자가 구분하지 못하게 만들 수 있다. 이 장은 조지와 매컬록(George and McCulloch, 1993)의 확률적 탐색 변수선택(Stochastic Search Variable Selection, SSVS)을 전개하는데, 이는 변수선택을 베이지안 추정 문제로 재구성한다. 각 계수에 이진 지시변수 $\gamma_j \in \{0, 1\}$ 를 부여하여 회귀를 증강하고, 깁스 샘플러가 어떤 계수가 사실상 0인지와 남은 계수들이 얼마인지를 동시에 학습하도록 한다.

8.1 위계적 스파이크-슬래브 사전분포

k 개의 후보 회귀변수를 갖는 선형회귀 $y = X\beta + e, e \sim N(0, \sigma^2 I)$ 를 고려하자. SSVS는 각 기울기 계수 β_j 에 γ_j 로 색인화된 이성분 혼합 사전분포를 부여한다.

$$\beta_j | \gamma_j \sim \begin{cases} N(0, \tau_0^2), & \gamma_j = 0 \quad (\text{“스파이크”}: \beta_j \text{는 무시할 만함}) \\ N(0, \tau_1^2), & \gamma_j = 1 \quad (\text{“슬래브”}: \beta_j \text{는 제약 없음}) \end{cases}$$

여기서 $\tau_0^2 \ll \tau_1^2$ 이며, $\gamma_j \sim \text{Bernoulli}(p)$ 는 j 에 대해 독립적이다. $\gamma_j = 0$ 일 때, 촘촘한 스파이크 분산 τ_0^2 는 회귀변수를 모형에서 실제로 제거하지 않고도 β_j 를 거의 0으로 축소한다 — 이 점이 X 의 열을 실제로 제거하고 다시 추가해야 하는 방법들과 달리, 그 결과인 완전조건부분포를 컬레형으로 만들고 샘플러를 정확하게 만드는 요인이다. τ_0^2, τ_1^2, p 를 임의의 값으로 고정하는 대신, 여기서 사용하는 완전한 위계적 버전은 세 값 모두를 각자의 컬레 초사전분포(hyperprior)를 갖는 미지수로 취급한다. τ_0^2 와 τ_1^2 는 각각(작은 값과 큰 값을 중심으로 하는) 역감마 초사전분포를 가지며, p 는 Beta(a_0, c_0) 초사전분포를 갖는다. 후보 회귀변수들은 이 사전분포를 적용하기 전에 표준화(평균 0, 단위분산)되어, 단일한 스파이크/슬래브 초모수 쌍이 매우 다른 단위로 측정된 예측변수 전반에 걸쳐 비교 가능하도록 한다.

8.2 사후분포 유도

$(\beta, \gamma, \sigma^2, \tau_0^2, \tau_1^2, p)$ 의 전체 결합 사후 커널은 정규 우도, γ 가 주어졌을 때 β 에 대한 이성분 혼합 사전분포, γ_j 들에 대한 독립적인 Bernoulli(p) 사전분포, τ_0^2, τ_1^2 에 대한 역감마 초사전분포, p 에 대한 베타 초사전분포, σ^2 에 대한 역감마 사전분포의 곱이다. 아래의 각 완전조건부분포는 나머지 모든 것을 고정한 채, 해당 블록에 여전히 의존하는 이 곱의 인자들만을 읽어냄으로써 얻어진다 — 이는 지금까지의 모든 유도에서 사용된 것과 정확히 동일한 기계적 전략이다.

유도: $\beta | \gamma, \sigma^2, y$

γ 가 주어지면, β 에 대한 사전분포는 단순히 $D_\gamma = \text{diag}(\tau_{\gamma_1}^2, \dots, \tau_{\gamma_k}^2)$ 인 $\beta \sim N(0, D_\gamma)$ 이다 — 평균이 0이고 (블록 대각, 실제로는 완전 대각인) 공분산행렬을 갖는 정규 사전분포로, 6.2절의 일반적인 $N(b_0, V_0)$ 사전분포와 종류상 다르지 않다. 6.2절의 완전제곱식 만들기 커널은 V_0 가 고정되

고 가역적이며 대칭이라는 것 외에는 어떤 성질도 사용하지 않았으므로, $V_0 \rightarrow D_\gamma$ 와 $b_0 \rightarrow 0$ 을 직접 대입하면 여기서도 변경 없이 적용된다.

$$\exp\left\{-\frac{1}{2}[\beta'(V_0^{-1} + \sigma^{-2}X'X) - 2\beta'(V_0^{-1}b_0 + \sigma^{-2}X'y)]\right\} \xrightarrow[b_0 \rightarrow 0]{V_0 \rightarrow D_\gamma} \exp\left\{-\frac{1}{2}[\beta'(D_\gamma^{-1} + \sigma^{-2}X'X)\beta - 2\beta'\sigma^{-2}X'y]\right\}$$

$V_0^{-1}b_0 = D_\gamma^{-1} \cdot 0 = 0$ 이 일차항에서 사라지기 때문이다. 이 동일한 대입 하에서 6.2절로부터 $\bar{V} \equiv (V_0^{-1} + \sigma^{-2}X'X)^{-1}$ 와 $\bar{\beta} \equiv \bar{V}(V_0^{-1}b_0 + \sigma^{-2}X'y)$ 를 읽어내면 다음을 얻는다.

$$\begin{aligned}\bar{V}_\gamma &= (D_\gamma^{-1} + \sigma^{-2}X'X)^{-1}, \\ \bar{\beta}_\gamma &= \bar{V}_\gamma(D_\gamma^{-1} \cdot 0 + \sigma^{-2}X'y) = \bar{V}_\gamma \sigma^{-2}X'y,\end{aligned}$$

따라서

$$\beta \mid \gamma, \sigma^2, y \sim N(\bar{\beta}_\gamma, \bar{V}_\gamma).$$

이것이 SSVS가 축소를 일으키는 정확한 메커니즘이다. 현재 스파이크에 있는 계수($\gamma_j = 0$)는 τ_0^2 가 극히 작으므로 D_γ^{-1} 의 해당 위치의 항이 거대해지고, 이것이 $\bar{V}_\gamma^{-1}$ 에서 $\sigma^{-2}X'X$ 를 압도하여 자료 자체가 말해주는 바와 무관하게 $\bar{\beta}_{\gamma,j}$ 를 사전평균 0쪽으로 끌어당긴다.

유도: $\gamma_j \mid \beta_j, \tau_0^2, \tau_1^2, p$

γ_j 는 두 가지 값을 갖는 이산변수이므로, 그 완전조건부분포는 베이즈 규칙을 직접 적용하여 얻어진다(완전제곱식 만들기는 필요 없다). 결합 커널 중 γ_j 를 포함하는 유일한 인자는 γ_j 가 주어졌을 때의 β_j 의 사전밀도와 γ_j 자체에 대한 베르누이 사전분포이다.

$$P(\gamma_j = g \mid \beta_j, \tau_0^2, \tau_1^2, p) \propto p(\beta_j \mid \gamma_j = g) P(\gamma_j = g)$$

두 인자를 명시적으로 풀어 쓰면:

$$= \phi(\beta_j; 0, \tau_g^2) \times p^g(1-p)^{1-g}, \quad g \in \{0, 1\}$$

$g = 1$ 과 $g = 0$ 에서 각각 평가하면 $p \cdot \phi(\beta_j; 0, \tau_1^2)$ 와 $(1-p) \cdot \phi(\beta_j; 0, \tau_0^2)$ 라는 두 숫자를 얻는다. 두 확률의 합이 1이 되도록 정규화하면(각각을 그 합으로 나누면) 정확히 다음을 얻는다:

$$P(\gamma_j = 1 \mid \beta_j, \tau_0^2, \tau_1^2, p) = \frac{p \cdot \phi(\beta_j; 0, \tau_1^2)}{p \cdot \phi(\beta_j; 0, \tau_1^2) + (1-p) \cdot \phi(\beta_j; 0, \tau_0^2)}$$

직관적으로, $\phi(\beta_j; 0, \tau_1^2)$ (넓은 밀도)는 폭넓은 범위의 β_j 값에 비슷한 우도를 부여하는 반면, $\phi(\beta_j; 0, \tau_0^2)$ ($\tau_0^2 \ll \tau_1^2$ 이므로 좁은 밀도)는 0에 매우 가까운 β_j 에만 높은 우도를 부여한다. 따라서 0에서 먼 β_j 는 이 비율이 $\gamma_j = 1$ 을 선호하게 만든다.

유도: $\tau_0^2 \mid \gamma, \beta$ 와 $\tau_1^2 \mid \gamma, \beta$

$n_0 = \#\{j : \gamma_j = 0\}$ 이라 하고 τ_0^2 에 대한 역감마 조사전분포를 $IG(\kappa_0/2, s_0/2)$ 로 쓰자. τ_0^2 를 포함하는 유일한 우도 인자는 현재 스파이크에 배정된 β_j 들의 사전밀도 $\prod_{j:\gamma_j=0} N(\beta_j; 0, \tau_0^2)$ 이다. 이를 조사전분포와 곱하면 사후 커널을 얻는다.

$$p(\tau_0^2 \mid \gamma, \beta) \propto (\tau_0^2)^{-n_0/2} \exp\left\{-\frac{1}{2\tau_0^2} \sum_{j:\gamma_j=0} \beta_j^2\right\} \times (\tau_0^2)^{-(\kappa_0/2+1)} \exp\left\{-\frac{s_0}{2\tau_0^2}\right\}$$

이는 정확히 6.2절의 $\sigma^2 \mid \beta, y$ 유도가 다른 모습으로 나타난 것으로, $e'e \rightarrow \sum_{j:\gamma_j=0} \beta_j^2, T \rightarrow n_0$ 이다(각 스파이크 계수 β_j 가 분산 τ_0^2 를 갖는 평균 0 모형에서 하나의 “잔차” 역할을 한다). 따라서 동일한 거듭제곱 매칭 논변이 다음을 준다:

$$\tau_0^2 \mid \gamma, \beta \sim IG\left(\frac{\kappa_0 + n_0}{2}, \frac{s_0 + \sum_{j:\gamma_j=0} \beta_j^2}{2}\right)$$

그리고 조사전분포 $IG(\kappa_1/2, s_1/2)$ 를 갖는 $n_1 = k - n_0$ 개의 슬래브 계수에 동일한 논변을 적용하면:

$$\tau_1^2 \mid \gamma, \beta \sim IG\left(\frac{\kappa_1 + n_1}{2}, \frac{s_1 + \sum_{j:\gamma_j=1} \beta_j^2}{2}\right)$$

유도: $p \mid \gamma$

Beta(a_0, c_0) 조사전분포는 커널 $p^{a_0-1}(1-p)^{c_0-1}$ 을 가지며, $\gamma_1, \dots, \gamma_k$ 에 대한 k 개의 독립적인 Bernoulli(p) 사전분포는 두 번째 인자를 기여한다.

$$\prod_j p^{\gamma_j} (1-p)^{1-\gamma_j} = p^{\sum_j \gamma_j} (1-p)^{k-\sum_j \gamma_j}$$

이 우도 기여분을 베타 조사전분포 커널과 곱하고 p 와 $1-p$ 의 거듭제곱을 따로 모으면:

$$p(p \mid \gamma) \propto p^{a_0+\sum_j \gamma_j-1} (1-p)^{c_0+k-\sum_j \gamma_j-1}$$

이는 정확히 Beta($a_0 + \sum_j \gamma_j, c_0 + k - \sum_j \gamma_j$)의 커널이다 — 표준적인 베타-베르누이 켄레 갱신으로, k 개의 포함 지시변수 중 “성공” $\sum_j \gamma_j$ 와 “실패” $k - \sum_j \gamma_j$ 가 단순히 사전 유사관측치 (pseudo-count) a_0 와 c_0 에 더해진다.

참고: σ^2 는 새로운 유도가 필요 없다

아래 알고리즘의 2단계에서 사용되는 $\sigma^2 \mid \beta, y$ 완전조건부분포는 β 에 대한 스파이크-슬래브 사전 분포의 영향을 받지 않는다(σ^2 는 β 가 주어졌을 때 y 의 정규 우도를 통해서만 등장하며, 이는 6.2절과 정확히 같다) 따라서 이는 그곳에서 유도된 $IG\left(\frac{a_0+T}{2}, \frac{d_0+e'e}{2}\right)$ 결과 그대로이며, 수정이 필요 없다.

8.3 SSVS 깃스 샘플러

이제 여섯 개의 블록이 매 반복마다 서로를 갱신한다. 그림 30은 알고리즘을 목록으로 서술하기에 앞서 누가 누구에게 의존하는지를 배치해서 보여준다.




Figure 30: 여섯 개 SSVS 블록의 의존 구조: γ 가 중심에 위치하여 그 포함 패턴이 계수 분산 (τ_0^2, τ_1^2)과 사전확률 p 를 설정하고, 매 반복마다 각각으로부터 다시 갱신받는다(양방향 화살표). σ^2 는 오직 β 만을 바라보는 유일한 블록이다

알고리즘: 확률적 탐색 변수선택(조지-매컬록)

표준화된 X 를 갖는 자료 (y, X) 가 주어지면 다음을 순환한다.

1. **계수.** 현재 γ 에 따라 τ_0^2 와 τ_1^2 사이를 계수 별로 전환하는 사전 공분산 $D_\gamma = \text{diag}(\tau_{\gamma_1}^2, \dots, \tau_{\gamma_k}^2)$ 를 이용하여, 6.2절의 켄레 정규 사후분포로부터 $\beta \mid \gamma, \sigma^2, \tau_0^2, \tau_1^2, y$ 를 추출한다.
2. **오차분산.** 6.2절과 동일한 켄레 역감마 완전조건부분포로부터 $\sigma^2 \mid \beta, y$ 를 추출한다.
3. **포함 지시변수.** 각 j 에 대해, 성공확률이

$$P(\gamma_j = 1 \mid \beta_j, \tau_0^2, \tau_1^2, p) = \frac{p \cdot \phi(\beta_j; 0, \tau_1^2)}{p \cdot \phi(\beta_j; 0, \tau_1^2) + (1 - p) \cdot \phi(\beta_j; 0, \tau_0^2)},$$

인 베르누이 완전조건부분포로부터 γ_j 를 추출한다. 여기서 $\phi(\cdot; 0, \tau^2)$ 는 $N(0, \tau^2)$ 밀도이다 — τ_0^2 에 비해 0에서 먼 계수는 $\gamma_j = 1$ 쪽으로 끌어당겨진다.

4. **스파이크 및 슬래브 분산.** 현재 스파이크에 있는 계수($\gamma_j = 0$)만을 이용하여 τ_0^2 를 그 켄레 역감마 완전조건부분포로부터 추출하고, τ_1^2 도 마찬가지로 슬래브에 있는 계수($\gamma_j = 1$)만을 이용해 추출한다.
5. **포함확률.** $p \mid \gamma \sim \text{Beta}(a_0 + \sum_j \gamma_j, c_0 + k - \sum_j \gamma_j)$ 를 추출한다.

관심있는 산출물은 사후 포함확률 $\hat{P}(\gamma_j = 1 \mid y)$ 로, 표본추출된 γ_j 들의 몬테카를로 평균이다. 이 값이 1에 가까우면 자료가 β_j 를 일관되게 슬래브에 두는 것을 선호함을, 0에 가까우면 스파이크에 속함을 나타낸다.

참고: 왜 모든 부분집합을 비교하지 않고 탐색을 하는가?

k 개의 후보 회귀변수가 있으면 2^k 개의 가능한 부분집합이 있으며, 각각에 대해 주변우도를 계산하는 것은 작은 k 에서만 실현 가능하다. SSVS는 전수 탐색을 완전히 우회한다. 위의 모든 스텝이 알려진 켄레분포로부터의 표본추출이기 때문에 (4.7절에서 깃스 표본추출에 대해 제시한 효율성

논거와 정확히 같다), 샘플러는 사후 지지가 높은 몇 안 되는 γ 구성을 방문하는 데 대부분의 시간을 쓰며, 포함 빈도 $\hat{P}(\gamma_j = 1 | y)$ 는 자동으로 회귀변수 j 를 포함하는 2^{k-1} 개의 부분집합 전체에 걸쳐 합산된, 회귀변수 j 가 모형에 속할 주변 사후확률의 몬테카를로 추정치가 된다.

실증 예제: 실제 응용에 앞선 두 회귀변수 장난감 예제

아래의 여덟 예측변수 인플레이션 모형에 앞서, 스파이크-슬래브 메커니즘이 어떤 역할이라도 할 수 있는 가장 작은 사례를 살펴보는 것이 도움이 된다. 하나의 진짜 신호와 하나의 순수한 잡음 회귀변수이다. $x_1, x_2 \sim N(0, 1)$ 이 독립이고 x_2 는 참모형에 전혀 등장하지 않는 상태에서 $y = 1.5x_1 + e$, $e \sim N(0, 1)$ 로부터 $T = 60$ 개의 관측치를 시뮬레이션한다. 두 회귀변수를 표준화하고 위 알고리즘의 8,000개 번인 이후 표본을 실행하면 참 신호에 대해서는 $\hat{P}(\gamma_1 = 1 | y) = 1.000$, 잡음 회귀변수에 대해서는 $\hat{P}(\gamma_2 = 1 | y) = 0.202$ 라는 사후 포함확률을 얻으며, 표준화된 사후 계수 평균은 $2.09(x_1)$ 와 $-0.03(x_2)$ 이다. 샘플러는 x_1 을 사실상 매 반복마다 슬래브에 두고 x_2 는 다섯 번 중 약 네 번 스파이크에 두는데 — 이는 정확히 아래 CPI 응용이 의존하는 정성적 행태이며, 다만 후보가 둘뿐이고 이를 검증할 명확한 정답이 있다는 점만 다르다.

8.4 실증 예제: CPI 인플레이션의 예측변수 선택

응용 사례로서, 6.7장에서 사용한 것과 동일한 검증된 분기별 계열로부터 구성한 여덟 개의 시차 후보 거시 예측변수를 이용하여 분기별 CPI 인플레이션 π_t 를 예측하는 문제를 고려하자. 인플레이션 자신의 시차 두 개, GDP 성장률의 시차 두 개, 시차 연방기금금리 수준과 그 시차 변화, 시차 실업률과 그 시차 변화이다.

$$\pi_t = c + \beta_1 \pi_{t-1} + \beta_2 \pi_{t-2} + \beta_3 \text{gdp}_{t-1} + \beta_4 \text{gdp}_{t-2} + \beta_5 i_{t-1} + \beta_6 \Delta i_{t-1} + \beta_7 u_{t-1} + \beta_8 \Delta u_{t-1} + e_t.$$

$T = 265$ 개의 사용 가능한 분기(원래의 $T = 216$, 1960Q1–2013Q4 구간에서 1960Q1–2026Q1로 확장됨), 스파이크와 슬래브 분산에 대한 약한 정보적 초사전분포(표준화된 회귀변수 기준으로 스파이크는 사전평균 분산 0.0025, 슬래브는 1.0), p 에 대한 Beta(2, 2) 초사전분포, 15,000개의 번인 이후 깃스 표본을 사용한다.

실증 예제: 사후 포함확률

여덟 후보는 사후 포함확률에 의해 다음과 같이 나뉜다.

π_{t-1}	1.000	Δu_{t-1}	0.826
Δi_{t-1}	0.997	gdp_{t-1}	0.677
π_{t-2}	0.987	u_{t-1}	0.590
i_{t-1}	0.923	gdp_{t-2}	0.531

자기시차 인플레이션, 연방기금금리의 시차 변화, 그리고 인플레이션 두 번째 시차가 모두 0.98을 넘는, 가장 확실하게 포함되는 예측변수이다. 여기서 두드러지는 점은 여덟 후보 전부가 0.5 임계값을 넘는다는 것이다 — 가장 약한 gdp_{t-2} 조차 0.531로, 비록 간신히이지만 “포함” 쪽에 속한다. 이는 소수의 강한 예측변수와 소수의 거의 0에 가까운 예측변수로 깔끔하게 나뉘는 결과와는 확연히 다른 그림이며, 아래 remark 박스가 그 이유를 설명한다. 이번 샘플러 실행이 2^8 개 부분집합

공간 중 다른 실행과는 다르지만 똑같이 타당한 영역에 안착했기 때문이다.

참고: 직접 실행하면 왜 다른 숫자가 나올 수 있는가?

이 절의 MATLAB 런처를 직접 실행하면 위 표와 정확히 같은 결과를 얻지 못할 수도 있다 — 무언가 잘못되어서가 아니라, 이 인플레이션 방정식에 실제로 공선적인 후보 쌍이 여럿 있기 때문이다. π_{t-1} 과 π_{t-2} 는 0.75로, gdp_{t-1} 과 Δu_{t-1} 은 -0.75로 상관되어 있고, 인플레이션 시차들은 i_{t-1} 과 약 0.62로 상관되어 있다. 이렇게 후보들이 상관되어 있으면, SSVS의 기반이 되는 좌표별 (coordinate-by-coordinate) 깃스 샘플러 (8.3절의 알고리즘 박스)가 여러 개의 자기강화적 구성 중 하나에 정착해 전체 실행 동안 거기 머무를 수 있다 — 난수 시드나 체인 길이를 바꾸어도 신뢰성 있게 벗어나지는 못하는데, 한 번의 전체 스위치는 다른 모든 예측변수를 현재 값에 고정한 채로 오직 한 예측변수의 포함 여부를만 제안하기 때문이다. 동일한 상관구조를 갖되 정답이 구성상 고정되어 있는 알려진 희소 패턴에 대한 합성 자료 검증은 알고리즘 자체에는 문제가 없음을 확인해 준다. 모든 시드에서 참으로 포함된 예측변수와 참으로 제외된 예측변수를 정확히 복원했다. 교훈은 코드가 아니라 모형에 관한 것이다. 후보 예측변수들이 강하게 상관되어 있을 때는 단일 SSVS 실행의 포함확률이 체인이 어디서부터 탐색을 시작하는지에 좌우될 수 있으며, 결과를 책임 있게 읽는다면 하나의 실행 결과표를 유일한 답으로 제시하기보다는 이 점을 밝혀야 한다. 이것이 바로 이 절 뒤쪽의 주변우도 비교가 0.5 임계값 규칙에 의존하지 않고 축소모형을 변수명으로 직접 고정하는 이유이기도 하다.




Figure 31: 사후 포함확률(왼쪽)과 표준화된 기울기 계수의 95% 신용구간(오른쪽), 포함확률순으로 정렬됨. 오른쪽 패널의 짙은 표시는 95% 구간이 0을 배제하는 계수를 나타낸다.

실증 예제: 계수 추정치와 간명성 점검

그림 31(b)는 각 표준화 계수의 사후평균과 95% 신용구간을 보고한다(γ 에 대해 무조건적으로, 즉 스파이크와 슬래브 표본 모두에 걸쳐 평균낸 것이다). 세 계수가 0을 완전히 배제하는 구간을 갖는다. π_{t-1} (1.540, 신용구간 [1.151, 1.955]), Δi_{t-1} (0.487, 신용구간 [0.202, 0.734]), π_{t-2} (0.548, 신용구간 [0.024, 0.953], 겨우 0을 배제)이다. 확장 이전 표본과 달리, i_{t-1} 은 더 이상 0을 배제하는 신용구간을 갖지 않는다(0.297, 신용구간 [-0.025, 0.669]). 그럼에도 여전히 92.3%의 상당한 사후 포함확률을 유지한다. 나머지 네 계수는 모두 0을 넉넉히 포함하는 구간을 갖는다.

0.5를 넘는 사후 포함확률을 갖는 네 개 예측변수(π_{t-1} , π_{t-2} , i_{t-1} , Δi_{t-1})만을 이용하여 6장의 컬레 회귀를 다시 적합하면 $R^2 = 0.607$ 을 얻는데, 이는 전체 아홉 회귀변수 SSVS 적합값($R^2 = 0.613$)과 전체 OLS 적합값($R^2 = 0.616$) 양쪽 모두와 통계적으로 구분되지 않는다. 선택된 네 예측변수 모형은 전체 여덟 후보 명세의 설명력을 거의 그대로 회복하면서도 기울기 계수는 절반에 불과하다 — 확장 이전 표본의 여섯 예측변수 선택보다도 더 간명한 결과이다.

참고: 포함확률은 p 값이 아니다

$\hat{P}(\gamma_j = 1 | y)$ 를 고전적 유의성 검정의 베이지안 유사물로 읽고 싶은 유혹이 들 수 있으며, 실제로 둘은 종종 정신적으로 일치한다 — 하지만 둘은 서로 다른 질문에 답한다. 빈도주의 p 값은 β_j 가 정확히 0이라면 관측된 $\hat{\beta}_j$ 가 얼마나 놀라운 값일지를 묻는다. SSVS 포함확률은 모형 안의 다른 모든 계수에 대한 결합 불확실성 전체에 걸쳐 평균낼 때, 얼마나 많은 사후질량이 촘촘한 스파이크가 아닌 확산된 슬래브로부터 β_j 가 나왔음을 지지하는지를 묻는다. 이것이 바로 여기서 i_{t-1} 이 한계 신용구간이 0을 넉넉히 포함함에도(그림 31b) 높은 포함확률(0.923)을 갖는 이유이다. 깁스 샘플러는 다른 회귀변수들이 제외되었을 때 i_{t-1} 이 인플레이션을 설명하는 데 도움이 되는 구성을 이따금 찾아내는데, 이는 그 무조건적 사후평균이 부정확하게 추정되어 있음에도 불구하고 그렇다. 하나의 계수에 대한 신용구간과 포함확률을, 어느 하나만이 아니라 함께 읽는 것이 더 온전한 그림을 제공한다.

8.5 치브의 방법을 통한 주변우도

SSVS는 탐색적인 질문에 답한다. 2^8 개의 부분집합 중 어느 것을 자료가 선호하는지, 그러나 뚜렷한 승자를 명시적으로 지목하지는 않은 채로 말이다. 더 오래된 다른 질문은 동일한 자료에게, 이름이 붙은 특정한 두 모형을 정면으로 비교하도록 요구한다. 전체 아홉 회귀변수 모형과 이름이 붙은 더 작은 축소 모형 중, 각 모형 고유의 추가 유연성을 벌점화한 뒤에는 어느 쪽이 더 잘 적합하는가? 이 질문에 답하려면 SSVS가 계산을 피하도록 특별히 설계된 바로 그 양, 즉 주변우도가 필요하며, 치브(Chib, 1995)의 방법은 연구자가 어차피 생성했을 통상적인 깁스 샘플러 산출물로부터 이를 얻는 표준적인 방법이다.

주변우도와 베이즈 인자 모수 θ , 사전분포 $p(\theta)$, 우도 $p(y | \theta)$ 를 갖는 모형 $\mathcal{M}$ 에 대해, 주변우도는 자료의 사전예측밀도이다.

$$m(y) = \int p(y | \theta) p(\theta) d\theta,$$

이는 베이즈 규칙의 정규화 상수로서, 이 노트의 모든 사후분포 계산은 지금까지 $p(\theta | y) \propto p(y | \theta)p(\theta)$ 가 결코 이를 요구하지 않으므로 무시할 수 있었다. 두 모형 $\mathcal{M}_1, \mathcal{M}_2$ 를 비교하는 데는 그 비율인 베이즈 인자 $\text{BF}_{12} = m_1(y)/m_2(y)$ 를 사용하며, 이는 Kass and Raftery(1995) 척도로 해석된다. $2 \ln \text{BF}_{12}$ 가 2와 6 사이면 $\mathcal{M}_1$ 에 대한 “유의미한(positive)” 증거, 6과 10 사이면 “강한(strong)” 증거, 10을 넘으면 “결정적인(decisive)” 증거이다. 사후 시뮬레이터 산출물로부터 $m(y)$ 를 추정하는 출발점은 기본 주변우도 항등식(basic marginal likelihood identity)이다. 임의의 점 θ^* 에 대해,

$$m(y) = \frac{p(y | \theta^*) p(\theta^*)}{p(\theta^* | y)},$$

이는 베이즈 규칙 $p(\theta^* | y) = p(y | \theta^*)p(\theta^*)/m(y)$ 를 재정리하면 즉시 나온다. 우도 $p(y | \theta^*)$ 와 사전분포 $p(\theta^*)$ 는 모두 알려진 함수로서 임의의 θ^* 에서 평가하기 쉽다. 유일하게 미지수인 부분은 사후분포 증거(ordinate) $p(\theta^* | y)$ 자체인데 — 이것이 바로 깁스 또는 M-H 샘플러의 산출물이 추정할 수 있는 것으로, 샘플러가 특별히 θ^* 를 목표로 했을 필요는 전혀 없다.

유도: 이중 블록 깃스 샘플러에 대한 치브(1995)의 추정량

6.2절의 켄레 회귀 모형 하에서 $\theta = (\beta, \sigma^2)$ 를 취하고, $\theta^* = (\beta^*, \sigma^{2*})$ 를 통상적인 깃스 실행의 사후평균으로 선택하자. 연쇄법칙에 의해, 사후분포 증거는 다음과 같이 인수분해된다.

$$p(\theta^* | y) = p(\beta^* | y) p(\sigma^{2*} | \beta^*, y)$$

두 번째 인자는 이미 닫힌 형태로 알려져 있다. 이는 정확히 6.2절의 역감마 완전조건부분포로, 형태모수와 척도모수가 앞서와 같이 갱신되고 σ^{2*} 에서 직접 평가된다(이 부분에는 시뮬레이션이 필요 없는데, 완전조건부분포의 함수형이 정확히 알려져 있기 때문이다):

$$\sigma^{2*} | \beta^*, y \sim IG\left(\frac{a_1}{2}, \frac{d_1}{2}\right), \quad a_1 = a_0 + T, \quad d_1 = d_0 + (y - X\beta^*)'(y - X\beta^*)$$

첫 번째 인자는 직접적으로 이용할 수 없는데, 샘플러가 $p(\beta | y)$ 자체로부터는 결코 표본을 추출하지 않기 때문이다(한 번에 하나의 σ^2 에 대해 $p(\beta | \sigma^2, y)$ 로부터만 추출한다). 하지만 이는 샘플러가 실제로 산출하는 바로 그 분포에 대한 기댓값으로 쓸 수 있다:

$$p(\beta^* | y) = \int p(\beta^* | \sigma^2, y) p(\sigma^2 | y) d\sigma^2$$

이 적분을 주요 깃스 실행에서 이미 산출된 M 개의 표본 $\sigma^{2(1)}, \dots, \sigma^{2(M)}$ 에 대한 몬테카를로 평균으로 근사하면(깃스 표본추출이 전체 결합 사후분포를 목표로 하기 때문에 이 표본들은 정확히 올바른 주변분포 $p(\sigma^2 | y)$ 로부터 추출된 것이다) 다음을 얻는다:

$$\approx \frac{1}{M} \sum_{m=1}^M p(\beta^* | \sigma^{2(m)}, y)$$

합 안의 각 조건부밀도 $p(\beta^* | \sigma^{2(m)}, y)$ 는 다시 6.2절의 알려진 정규 완전조건부분포 $N(\bar{\beta}^{(m)}, \bar{V}^{(m)})$ 이며, 이를 표본추출하는 대신 고정된 점 β^* 에서 평가한다. 이 평균화 스텝은 라오-블랙웰화된 추정치이다. 표본의 히스토그램으로 밀도를 추정하는 대신(잡음이 많다), 알려진 조건부밀도 공식 자체를 샘플러의 σ^2 표본에 걸쳐 평균낸다(구간화나 커널평활화가 관여하지 않으므로 잡음이 훨씬 적다). 위의 항등식과 두 인자를 결합하면 다음을 얻는다:

$$\widehat{\ln m(y)} = \ln p(y | \theta^*) + \ln p(\theta^*) - \ln p(\beta^* | y) - \ln p(\sigma^{2*} | \beta^*, y)$$

두 블록보다 많은 모형에서는 이 축소된-조건부-증거 기법을 블록별로 반복하며, 각 블록의 증거는 앞선 블록들을 θ^* 값에 고정한 채 실행하는 더 짧은 추가 보조 깃스 실행으로부터 추정된다 — 일반적인 처방은 변하지 않으며, 장부기록(bookkeeping)만 블록 수에 따라 늘어난다.

알고리즘: 치브의 방법(이중 블록 경우)

1. 6.2절의 통상적인 깃스 샘플러를 수렴할 때까지 실행하고, 평소처럼 번인을 버린다.
2. $\theta^* = (\beta^*, \sigma^{2*})$ 를 유지된 표본의 사후평균으로 설정한다(사후질량이 무시할 수 없을 정도인 어떤 점이든 가능하며, 평균이 관례적인 선택이다).
3. 우도와 사전분포 공식으로부터 $\ln p(y | \theta^*)$ 와 $\ln p(\theta^*)$ 를 직접 평가한다.

4. 알려진 역감마 완전조건부분포로부터 $\ln p(\sigma^{2*} | \beta^*, y)$ 를 직접 평가한다.
5. 주요 실행에서 유지된 $\sigma^{2(m)}$ 표본에 걸쳐 알려진 정규 조건부밀도 $p(\beta^* | \sigma^{2(m)}, y)$ 를 평균낸 뒤 로그를 취하여 $\ln p(\beta^* | y)$ 를 추정한다.
6. 위 항등식을 통해 네 조각을 결합하여 $\widehat{\ln m(y)}$ 를 얻는다.

참고: 치브-젤리아즈코프(2001): M-H 산출물에 대한 같은 아이디어

위의 치브 추정량은 각 블록의 완전조건부분포가 닫힌 형태로 알려져 있다는 데에 의존하는데 — 14장의 맞춤형 GARCH 샘플러와 같은 M-H 블록에서는 이를 이용할 수 없다. 치브와 젤리아즈코프(Chib and Jeliazkov, 2001)는 알려진 조건부분포 대신 상세균형(detailed balance) 자체를 이용하여 동일한 기본 항등식을 M-H 산출물로 확장한다. 제안분포 $q(\theta, \theta')$ 와 채택확률 $\alpha(\theta, \theta')$ 를 갖는 M-H 커널에 대해, 상세균형은 다음을 만족한다.

$$\pi(\theta)q(\theta, \theta')\alpha(\theta, \theta') = \pi(\theta')q(\theta', \theta)\alpha(\theta', \theta).$$

$\theta' = \theta^*$ 로 고정하고 사후분포 $\pi(\theta | y)$ 에 대해 양변을 θ 에 대해 적분하면 다음을 얻는다.

$$\pi(\theta^* | y) = \frac{E_{\theta|y}[\alpha(\theta, \theta^*) q(\theta, \theta^*)]}{E_{\theta \sim q(\theta^*, \cdot)}[\alpha(\theta^*, \theta)]} \approx \frac{\frac{1}{M} \sum_{m=1}^M \alpha(\theta^{(m)}, \theta^*) q(\theta^{(m)}, \theta^*)}{\frac{1}{J} \sum_{j=1}^J \alpha(\theta^*, \theta^{(j)})},$$

여기서 $\theta^{(1)}, \dots, \theta^{(M)}$ 은 주요 연쇄의 유지된 표본이며, $\theta^{(1)}, \dots, \theta^{(J)}$ (별도의 두 번째 집합)는 $q(\theta^*, \cdot)$ 로부터 제안으로만 추출된 것이다 — 마치 연쇄가 현재 θ^* 에 앉아 있는 것처럼 생성되며, 이후 어떠한 채택/기각 스텝도 적용되지 않는다. 분자는 정확히 치브의 라오-블랙웰화 평균화 아이디어를, 알려진 조건부밀도가 아니라 αq 에 적용한 것이다. 분모는 추가적인 전체 연쇄가 필요한, 기존 제안 메커니즘으로부터의 J 개 표본만 필요로 하는 새롭고 값싼 몬테카를로 평균이다.

실증 예제: 전체 모형 대 축소 인플레이션 모형의 주변우도

전체 아홉 모수 모형과, SSVS 예제의 더 약한 예측변수 두 개인 gdp_{t-1} 과 u_{t-1} 을 제외한 이름이 붙은 일곱 모수 축소모형(이 축소모형은 8.5절의 0.5-문턱값 규칙이 실제로 무엇을 선택하는지와 무관하게 그 자체로 고정된 모형이다)에 치브의 방법을 각각 8,000개의 번인 이후 김스 표본으로 적용하면 다음을 얻는다.

$$\widehat{\ln m_{\text{full}}}(y) = -586.54, \quad \widehat{\ln m_{\text{restricted}}}(y) = -577.27,$$

로그 베이즈 인자 $\ln \text{BF} = -9.27$ ($2 \ln \text{BF} = -18.5$)로, 더 작은 모형을 지지한다 — Kass-Raftery 척도에서 결정적이며, 포함확률이 가리켰던 것과 같은 방향이다. 추정량 자체에 대한 독립적인 점검으로서(일반적으로는 이러한 점검이 불가능하기 때문에 이 방법이 정확히 필요한 것이지만, 이는 일반적 방법의 일부가 아니다): 이 특정 쉼표 모형에서는 임의의 고정된 σ^2 에서 β 를 닫힌 형태로 적분해 낼 수 있어, $m(y)$ 를 σ^2 에 대한 단일한 수치적분으로 줄일 수 있으며, 이는 세밀한 격자 구적법(fine-grid quadrature)으로 기계정밀도에 가깝게 계산할 수 있다. 그 구적법 벤치마크는 두 모형에 대해 각각 -586.54 와 -577.27 을 주는데 — 이는 치브의 시뮬레이션 기반 추정치와 로그 단위로 0.005 이내로 일치하며, 14장의 설정처럼 그러한 점검이 불가능한 곳에서 이를 신뢰하기 전에, 이 몬테카를로 추정량이 여기서는 편향되지 않았음을 확인해 준다.

이 베이즈 인자의 크기 자체도 유의사항이 있다. SSVS 고유의 스파이크 분산은 촘촘하여(사전평균이 0.0025 인 τ_0^2), 포함을 온화하게 억제한다. 반면 위의 치브 비교는 전체 모형을 무정보적인 $\beta \sim N(0, 100I)$ 사전분포 안에 직접 내포시키는데, 사실상 무관한 두 계수에 대한 무정보적 사전분포는 정확히 베이즈 인자가 사전분포의 퍼짐에 지나치게 민감하다고 알려진 설정이다(린들리의 역설, Lindley's paradox). 두 추가 계수가 그럴듯하게 취할 수 있는 사전분포가 넓을수록, 자료가 명백히 배제하는 값들의 그럴듯한 범위에 대해 주변우도가 더 많이 벌점을 받는다. 두 방법 모두 gdp_{t-1} 과 u_{t-1} 이 거의 기여하지 않는다는 데 동의하지만 — 베이즈 인자의 18.5 로그단위 격차는 “이 특정한 무정보적 사전분포 하에서 결정적”이라고 읽어야 하며, 사전분포와 무관한 판정으로 읽어서는 안 된다.

9. 토빗 모형(Tobit Model)

로드맵

7장의 잠재변수 기법은 이진(binary) 결과변수를 다루었다. 이 장에서는 이와 관련되어 있지만 뚜렷이 구별되는 문제, 즉 본질적으로는 연속적이지만 어떤 경계에서 기계적으로 상한(또는 하한)이 걸리는 결과변수를 다룬다. 이 경우 관측된 자료에 그대로 최소제곱법을 적용하면 편향이 발생한다. 그 해결책은 7장의 두 가지 구성요소를 거의 그대로 재사용한다. 즉 경계에 놓인 관측치에 대한 절단된 잠재변수 추출과, 그 외의 경우에 대한 6.2절의 켈레(conjugate) 회귀 단계이다. 여기에서 다시 이를 살펴보는 이유는 토빗 모형 자체보다, 이 모형이 완성하는 패턴에 있다 — 이 장이 끝날 무렵이면 세 가지 서로 다른 다루기 어려운 우도(이진형, 검열형, 그리고 곧 다루게 될 혼합 모형 분산)가 모두 동일한 켈레 회귀 핵심으로 환원되었음을 보게 될 것이다.

7장에서는 이진 결과변수를 다루었다면, 이 장에서는 검열(censored)된 결과변수를 다룬다 — 원리상으로는 연속적이지만, 기계적 혹은 제도적 이유로 어떤 경계를 넘지 못하도록 막혀 있어서, 매끄러운 연속분포가 예측하는 것보다 그 경계값이 훨씬 더 자주 관측되는 경우이다. 가계의 자선 기부(많은 가계가 정확히 \$0을 기부한다), 기업의 연구개발 지출, 그리고 아래에서 계속 다룰 예제인 영(0) 하한에 고정된 명목 정책금리가 모두 이러한 유형의 결과변수이다. 토빈(Tobin, 1958)의 검열회귀모형(“토빗(Tobit)”)은 7장의 프로빗 모형에서 사용한 것과 동일한 잠재변수 자료증강 기법으로 이를 다룬다.

9.1 검열된 결과변수와 잠재변수 토빗 모형

관측되지 않는(잠재적인) 연속변수가 통상적인 선형회귀 $z_i = x_i'\beta + e_i, e_i \sim N(0, \sigma^2)$ 를 따른다고 하자. 그러나 실제로 기록되는 것은 알려진 지점 c 아래에서 하방 검열된 z_i 이다.

$$y_i = \begin{cases} z_i & z_i > c \\ c & z_i \leq c. \end{cases}$$

이는 7장의 프로빗 모형과 한 가지 결정적인 점에서 다르다. $y_i > c$ 일 때는 z_i 의 부호만이 아니라 그 정확한 값이 관측되므로, 우도는 비검열 관측치에 대한 연속적인 정규밀도와, 검열된 관측치의 $y_i = c$ 에서의 이산적 확률질량 $\Phi((c - x_i'\beta)/\sigma)$ 을 결합한 형태가 된다. 최소제곱법을 y 에 직접 적용하는 것은 이 경우 비일치적(inconsistent)이다. 모든 검열된 관측치를 마치 c 가 그 참값인 것처럼 취급하기 때문에, 검열되지 않았다면 c 보다 더 극단적이었을 정도만큼 정확히 추정된 기울기가 영(0) 쪽으로 당겨진다(감쇠 편의, attenuation bias).

9.2 사후분포 유도

관측된 검열자료 y 가 주어졌을 때 (β, σ^2, z) 에 대한 결합사후 커널은 7장과 동일한 방식으로 구성된다. 즉 잠재변수 $z = (z_1, \dots, z_T)'$ 로 자료를 증강하고, (y, z, β, σ^2) 의 결합밀도를 다음 세 요소의 곱으로 쓴다. (i) z 에서 y 로의 결정론적 검열 사상, (ii) β, σ^2 가 주어졌을 때의 z 의 정규밀도, (iii) 사전분포. $y_i = \max(z_i, c)$ 가 z_i 의 결정론적 함수이므로, z 에 조건화하면 y 는 불필요해지고, 아래의 완전조건부 분포는 다음으로부터 얻어진다.

$$p(\beta, \sigma^2, z | y) \propto p(z | \beta, \sigma^2) p(\beta) p(\sigma^2) = \prod_{i=1}^T N(z_i | x_i' \beta, \sigma^2) N(\beta | b_0, B_0) IG(\sigma^2 | a_0/2, d_0/2),$$

7장의 인수분해와 정확히 동일하되, 프로빗 모형의 부호제약 지시함수가 검열 제약으로 대체된 형태이다.

유도: $z_i | y_i = c, \beta, \sigma^2$

$y_i = c$ (검열됨)인 i 를 고정하자. z_i 가 결합 커널에 들어오는 유일한 경로는 그 자신의 정규밀도 $N(z_i | x_i' \beta, \sigma^2)$ 를 통해서인데, 이는 β 와 σ^2 가 z_i 에 의존하지 않고, β, σ^2 가 주어졌을 때 다른 z_j ($j \neq i$)들이 z_i 와 조건부 독립이기 때문이다. $z_i = c$ 검열이 실제로 기여하는 바는 지지집합 (support)에 대한 제약이다. 즉 $y_i = \max(z_i, c)$ 모형 아래에서 $y_i = c$ 가 관측되었다는 것은 잠재 값이 $z_i \leq c$ 를 만족한다는 것만을 알려준다 — $(-\infty, c]$ 위의 어떤 값도 관측된 검열 결과와 부합하는 반면, (c, ∞) 위의 값은 대신 $y_i = z_i > c$ 를 산출했을 것인데 이는 관측되지 않았다. 공식적으로,

$$p(z_i | y_i = c, \beta, \sigma^2) \propto N(z_i | x_i' \beta, \sigma^2) \cdot \mathbb{I}\{z_i \leq c\}$$

즉 반직선 $(-\infty, c]$ 로 제한되고 $\Phi((c - x_i' \beta)/\sigma)$ 로 재정규화된 통상적인 정규 커널이며, 이로부터 다음을 얻는다.

$$z_i | y_i = c, \beta, \sigma^2 \sim N(x_i' \beta, \sigma^2) \text{ 를 } (-\infty, c] \text{로 절단한 분포}$$

이는 7.2절의 $z_i | y_i, \beta$ 단계와 동일한 절단정규 구성이며, 방법 자체를 바꾸지 않고 대입되는 숫자만 바꾸는 두 가지 차이가 있을 뿐이다. 절단 임계값이 0이 아니라 일반적인 검열점 c 라는 점, 그리고 분산이 식별을 위해 고정된 값 1이 아니라 자유롭게 추정되는 σ^2 라는 점이다.

$y_i > c$ (비검열)인 i 에 대해서는, 검열 사상이 그 관측치에서 일대일(one-to-one)이다 ($z_i > c$ 인 한 $y_i = \max(z_i, c) = z_i$ 이다) 따라서 y_i 를 관측하면 $z_i = y_i$ 가 정확히 결정되며, 표집해야 할 잔여 불확실성이 남지 않는다. z_i 의 "완전조건부분포"는 관측된 y_i 에서의 점질량으로 퇴화하며, 이것이 알고리즘이 z_i 를 추출하는 대신 직접 $z_i = y_i$ 로 설정하는 이유이다.

유도: $(\beta, \sigma^2) | z$

모든 z_i (관측되었든 대체되었든)를 자료로 취급하고 나면, (β, σ^2) 로 제한된 증강 커널 $p(\beta, \sigma^2, z | y)$ 는 다음과 같다.

$$p(\beta, \sigma^2 | z) \propto \prod_{i=1}^T N(z_i | x_i' \beta, \sigma^2) N(\beta | b_0, B_0) IG(\sigma^2 | a_0/2, d_0/2)$$

이는 관측된 결과변수 y 가 완성된 자료 벡터 z 로 어디서나 대체된 것을 제외하면 통상적인 선형회귀모형에 대한 6.2절의 사후 커널과 형태가 동일하다. 새로운 대수 전개는 필요하지 않다. $y \rightarrow z$ 대입을 6.2절의 완전제곱 및 지수 대응(power-matching) 결과에 그대로 적용하면 다음이 바로 얻어진다.

$$\beta \mid \sigma^2, z \sim N(\bar{\beta}, \bar{B}), \quad \bar{B} = (B_0^{-1} + \sigma^{-2} X'X)^{-1}, \quad \bar{\beta} = \bar{B}(B_0^{-1}b_0 + \sigma^{-2} X'z),$$

$$\sigma^2 \mid \beta, z \sim IG\left(\frac{a_0 + T}{2}, \frac{d_0 + (z - X\beta)'(z - X\beta)}{2}\right)$$

이 단계에서 $y \rightarrow z$ 라는 기록상의 치환을 넘어서는 실질적인 내용은, 이러한 치환 자체가 타당하다는 점이다. 1단계에서 이미 검열된 모든 $y_i = c$ 를 그 올바른 완전조건부분포로부터 뽑은 완전한 값 z_i 로 대체했으므로, 깃스 샘플러의 관점에서 벡터 z 는 정확히 통상적인 비검열 연속 결과변수처럼 행동한다. 따라서 사전분포에서 완전제곱, 지수 대응에 이르는 6.2절의 유도 전체가 변경 없이 그대로 적용된다.

9.3 자료증강 깃스 샘플러

알고리즘: 자료증강을 통한 베이저안 토빗

컬레 사전분포 $\beta \sim N(b_0, B_0)$, $\sigma^2 \sim IG(a_0/2, d_0/2)$ 와 (β, σ^2) 의 현재값이 주어졌을 때, 다음을 반복한다.

1. 각 검열된 관측치($y_i = c$)에 대해, 잠재값을

$$z_i \mid y_i = c, \beta, \sigma^2 \sim N(x_i' \beta, \sigma^2) \text{ 를 } (-\infty, c] \text{로 절단한 분포에서}$$

추출한다. 이는 7.2절의 프로빗 샘플러와 동일한 절단정규 기법을 사용한다. 비검열 관측치에 대해서는 단순히 $z_i = y_i$ 로 설정한다(이미 z_i 가 관측되어 있으므로 증강이 필요 없다).

2. 6.2절 선형회귀 깃스 샘플러와 동일한 컬레 정규/역감마 완전조건부분포로부터 $(\beta, \sigma^2) \mid z$ 를 추출하되, 완성된 자료 z 를 마치 통상적으로 관측된 연속 결과변수인 것처럼 취급한다.

이는 고정된 검열점 $c = 0$ 인 경우를 임의의 알려진 c 로 일반화한 것이다.

참고: 토빗은 새로운 알고리즘이 아니라 프로빗과 6장의 결합이다

위의 모든 단계는 이미 이 강의노트에서 등장한 바 있다. 잠재변수의 절단정규 표집은 정확히 7.2절의 1단계이며, 컬레 회귀 갱신은 정확히 6.2절의 2단계이다. 유일하게 새로운 요소는 비검열 관측치에는 증강이 전혀 필요하지 않다는 점인데, 이는 프로빗 모형의 이진 y_i 와 달리 토빗 모형의 비검열 y_i 는 이미 잠재변수 그 자체이기 때문이다. 이는 이 강의의 제2부 전반에 걸쳐 반복되는 주제이다. 자료증강은 다루기 어려운 우도를, 매 새로운 모형마다 맞춤형 샘플러를 요구하는 대신, 앞선 장들에서 재할용된 일련의 단계들로 전환시킨다.

9.4 실증 예제: 영 하한에서의 연방기금금리

이 노트 전체에서 사용하는 표본 안에서 FOMC는 연방기금금리 목표범위를 두 차례에 걸쳐 0-0.25%로 유지했다 — 2008년 금융위기 이후 이어진 영 하한(zero lower bound, ZLB) 국면(2009년 1분기-2015년 4분기)과, 코로나19 팬데믹 동안의 더 짧은 두 번째 영 하한 국면(2020년 2분기-2022년 1분기)이다. 이에 따라 표본 내 실효 연방기금금리는 두 기간 모두에서 0.25% 아래로 거의 내려가지 않는

데, 단순한 반응함수라면 하한이 없었을 경우 훨씬 더 낮은(어쩌면 음(-)의) 정책금리를 요구했을 것이다. 이는 교과서적인 검열 문제로서, "그림자 금리(shadow rate)" 문헌(예: Wu and Xia, 2016)과 밀접하게 관련되어 있으며, 여기서는 다음과 같이 모형화된다.

$$i_t = c + \beta_1 \pi_{t-1} + \beta_2 u_{t-1} + \beta_3 \text{gdp}_{t-1} + e_t, \quad \text{관측되는 } i_t = \max(z_t, 0.25),$$

시차를 둔 소비자물가지수(CPI) 인플레이션, 시차를 둔 실업률, 시차를 둔 GDP 성장률에 대한 단순한 테일러 준칙(Taylor-rule) 형태의 반응이며, $c = 0.25$ 는 알려진 목표범위 하한을 나타낸다. 사용 가능한 $T = 266$ 개 분기(1959년 4분기–2026년 1분기, 원래의 1959년 4분기–2013년 4분기 구간에서 확장됨) 중 36개(13.5%)가 하한에서 검열되어 있으며, 두 ZLB 국면에 걸쳐 28개 분기(2009년 1분기–2015년 4분기)와 8개 분기(2020년 2분기–2022년 1분기)로 나뉜다.

실증 예제: 감쇠 편의: 단순 OLS 대 토빗 사후분포

확산 사전분포($\beta \sim N(0, 100I_4)$, $\sigma^2 \sim IG(1.5, 1.5)$)와 번인 이후 10,000개의 깃스 추출을 사용할 때, 토빗 사후평균(표준편차, 95% 신용구간)은 다음과 같다.

$$\begin{aligned} \hat{c} &= 1.894 \text{ (0.777)} & [0.379, 3.402] \\ \hat{\beta}_1 &= 0.843 \text{ (0.069)} & [0.706, 0.980] \\ \hat{\beta}_2 &= -0.095 \text{ (0.121)} & [-0.329, 0.140] \\ \hat{\beta}_3 &= 0.044 \text{ (0.052)} & [-0.056, 0.148] \end{aligned}$$

이는 검열된 자료에 직접 적합시킨 단순 OLS 결과 $\hat{\beta}_1^{OLS} = 0.741$, $\hat{\beta}_2^{OLS} = 0.081$, $\hat{\beta}_3^{OLS} = -0.002$ 와 대비된다. 인플레이션 반응은 예전처럼 영(0) 쪽으로 12%만큼 감쇠되지만, 실업률과 GDP 성장률 반응에서는 단순한 감쇠보다 질적으로 더 심각한 문제가 나타난다. 단순 OLS가 부호를 잘못 추정하는 것이다. OLS의 실업률 계수는 완만한 양(+)의 0.081인 반면 토빗 사후평균은 음(-)의 -0.095 이며, OLS의 GDP 성장률 계수는 약간 음(-)인 -0.002 인 반면 토빗 사후평균은 양(+)의 0.044 이다. 이는 확장 이전 표본(부호 반전 없이 각각 11%, 63%, 50%만큼 감쇠되었던)보다 훨씬 더 심각한 왜곡인데, 검열된 부분표본이 이제 더 클 뿐만 아니라(266개 분기 중 36개, 13.5%, 이전에는 217개 중 20개, 9.2%였다) 구조적으로 서로 다른 두 ZLB 국면에 걸쳐 있어, 단순 OLS가 마치 자유롭게 선택된 값처럼 평균을 낼 검열 자료가 훨씬 더 많아졌기 때문이다. β_2 와 β_3 어느 쪽도 토빗 사후분포 하에서 0과 신용성 있게 구분되지 않는다(두 신용구간 모두 0을 포함한다) — 이는 확장 이전 표본에서 GDP 성장률 반응이 겨우 신용성 있게 양(+)이었던 것 $[0.006, 0.242]$ 과 달라진 점이다. 따라서 점추정치의 부호 반전은 정밀하게 확정된 역전이 아니라 실질적인 사후 불확실성이 수반된 것으로 읽어야 한다.




Figure 32: 토빗 기울기 계수 세 개의 사후밀도(열은 히스토그램). 검열자료에 대한 단순 OLS 추정값(점선)과 토빗 사후평균(실선)을 함께 표시하였다

실증 예제: 내재된 명목(”그림자”) 금리

깁스 샘플러가 검열된 모든 분기에 대해 잠재값 $z_t = x_t' \beta + e_t$ 를 대체하므로, 그 사후평균은 내재된 명목 정책금리(영 하한 제약이 없었다면 추정된 반응함수가 시사했을 연방기금금리)를 복원해 낸다. 그림 33는 이를 관측된(하한에 고정된) 금리와 함께 그린 것이다. 두 ZLB 국면 대부분에서 내재된 명목금리는 완만하게 음(-)의 값을 보이며, 대체로 -0.7% 에서 -3.0% 범위에 있고, 첫 번째 국면에 대해 발표된 그림자 금리 추정치(Wu and Xia, 2016은 2009–2013년 동안 대략 0에서 -3% 로 보고한다)와 부호 및 크기의 자릿수 면에서 대체로 일치한다. 두 분기가 각 국면에서 하나씩 두드러진 이상치로 나타난다. 2009년 1분기는 근 -7.0% 에 이르는 명목금리를 시사하는데, 이는 금융위기의 급성 발발 시점에 실업률과 산출이 아직 완전히 반응하기 전, 유난히 급격했던 시차 인플레이션 수치($\pi_{t-1} = -9.3\%$, 연율)에 기인한다. 그리고 2020년 3분기는 근 -4.5% 에 이르는 명목금리를 시사하는데, 이는 2020년 2분기의 -28.0% 라는 GDP 급락이 한 분기의 시차를 두고 반응함수에 온전히 반영된 것으로, 정작 2020년 3분기 자체는 이미 급격히 반등하고 있었음에도 그러하다.




Figure 33: 관측된 실효 연방기금금리와 잠재변수 z_t 의 토빗 사후평균 비교 (음영 구간: 0.25% 하한에서 검열된 분기)

참고: 선형 반응함수를 지나치게 멀리 외삽해서는 안 된다

그림 33의 2009년 1분기와 2020년 3분기 이상치는 통화정책에 관한 발견이라기보다 유용한 경고성 사례로 보아야 한다. 비교적 평범했던 수십 년간의 분기 자료로 주로 적합된 선형 반응함수가, 토빗 잠재변수 단계를 통해 그것이 평소 다루던 범위를 크게 벗어난 시차 인플레이션 및 GDP 성장을 수치로 외삽하도록 요구받고 있는 것이며, 표본이 팬데믹까지 확장되면서 이제는 한 번이 아니라 두 번 이런 일이 벌어진다. 7장에서 프로빗 모형의 0.5 임계값 분류기에 대해 제기했던 것과 동일한 주의가 여기서도 다른 형태로 적용된다 — 단순한 선형 설정은 훨씬 더 복잡한 반응함수에 대한 합리적인 국소 근사이며, 조건화 변수가 그 모형을 추정할 자료로부터 멀어질수록 외삽된 함의는 더 신뢰해야 하는 것이 아니라 덜 신뢰해야 한다.

10. 외견상 무관한 회귀(Seemingly Unrelated Regressions, SUR)

로드맵

6장부터 9장까지는 모두 하나의 오차분산을 가진 단일 방정식을 추정했다. 그러나 실제 거시경제 체계는 방정식 하나씩 따로 오는 경우가 드물다. 산출 방정식과 인플레이션 방정식은 원리상으로는 별도로 적합되지만, 실제로는 동일한 경기침체와 정책충격의 영향을 받으므로 그 오차항이 함께 움직인다. 이 장은 이러한 상관을 직접 모형화하는 첫 장이다(Σ 는 하나의 숫자 σ^2 가 아니라 완전한 공분산행렬이 된다) 그리고 아래에서 유도되는 β 와 Σ 단계는 거의 변경 없이, 11장의 VAR 모형을 이끄는 두 단계와 동일하다. VAR은 단순히 이 장의 체계에서 모든 방정식이 동일한 설명변수를 공유하는 특수한 경우일 뿐이다.

6장부터 9장까지는 각각 단일 방정식을 모형화했다. 그러나 많은 경제적 질문은 언뜻 보기에는 서로 무관해 보이는(각기 다른 결과변수와 다른 설명변수 집합을 가진) 여러 방정식을 동시에 다룬다. 하지

만 이들의 오차항은 동일한 경기순환, 동일한 통화정책 기초, 혹은 동일한 총량충격의 영향을 받기 때문에 함께 움직인다. 젤너(Zellner, 1962)의 외견상 무관한 회귀(Seemingly Unrelated Regressions, SUR) 모형은 이러한 체계를 방정식별로가 아니라 결합적으로 추정하며, 이 노트에서 처음으로 진정한 의미의 다방정식 모형이다 — 단일방정식을 다룬 6장부터 9장과 11장부터 13장, 16장부터 17장의 VAR 체계를 잇는 다리 역할을 한다.

10.1 SUR 모형

동일한 T 개 시점을 공유하지만 각기 고유한 결과변수와 설명변수를 갖는 M 개의 방정식을 생각하자.

$$y_{jt} = x'_{jt}\beta_j + e_{jt}, \quad j = 1, \dots, M, \quad t = 1, \dots, T,$$

여기서 각 시점의 방정식별 오차벡터 $e_t = (e_{1t}, \dots, e_{Mt})'$ 는 방정식들 사이에서는 동시에 상관되어 있다고 가정한다. 즉 $e_t \sim N(0, \Sigma)$ 이며 t 에 걸쳐서는 독립이다. 모든 방정식이 동일한 설명변수를 사용한다면 방정식들은 서로 분리되어 방정식별로 적용한 OLS가 이미 효율적일 것이다. SUR은 정확히 방정식들 사이에 설명변수 집합이 다르면서 동시에 Σ 가 무시할 수 없는 비대각 상관을 가질 때 그 가치를 발휘한다. 이 경우 추정 과정에서 그 상관을 활용하는 것은 방정식별 OLS보다 더 효율적인 실행가능 일반화최소제곱법(feasible generalized least squares)의 한 형태가 된다.

10.2 사후분포 유도

t 시점의 M 개 방정식을 $y_t = Z_t\beta + e_t$, $e_t \sim N(0, \Sigma)$ 의 형태로 쌓아 올린다. 여기서 Z_t 는 위에서 정의한 $M \times K$ 블록대각(block-diagonal) 설명변수 행렬이다. $\Sigma \sim IW(S_0, \nu_0)$ 와 독립인 사전분포 $\beta \sim N(b_0, B_0)$ 가 주어지면, 결합사후 커널은

$$p(\beta, \Sigma | y) \propto |\Sigma|^{-T/2} \exp\left\{-\frac{1}{2} \sum_{t=1}^T (y_t - Z_t\beta)' \Sigma^{-1} (y_t - Z_t\beta)\right\} \times N(\beta | b_0, B_0) \times IW(\Sigma | S_0, \nu_0).$$

유도: $\beta | \Sigma, y$

커널 중 β 를 포함하는 모든 항을 모으면 다음과 같다.

$$p(\beta | \Sigma, y) \propto \exp\left\{-\frac{1}{2} \left[\sum_t (y_t - Z_t\beta)' \Sigma^{-1} (y_t - Z_t\beta) + (\beta - b_0)' B_0^{-1} (\beta - b_0) \right]\right\}$$

6.2절에서와 정확히 같은 방식으로 이차형식의 합을 전개하되, 그곳의 스칼라 가중치 σ^{-2} 는 행렬 가중치 Σ^{-1} 로, 스칼라 설명변수 행 x'_i 는 여기서 블록대각 Z_t 로 대체된다.

$$\begin{aligned} \sum_t (y_t - Z_t\beta)' \Sigma^{-1} (y_t - Z_t\beta) &= \sum_t y'_t \Sigma^{-1} y_t \\ &\quad - 2\beta' \sum_t Z'_t \Sigma^{-1} y_t + \beta' \left(\sum_t Z'_t \Sigma^{-1} Z_t \right) \beta \end{aligned}$$

사전분포의 이차형식 $(\beta - b_0)'B_0^{-1}(\beta - b_0) = \beta'B_0^{-1}\beta - 2\beta'B_0^{-1}b_0 + b_0'B_0^{-1}b_0$ 을 더하고 β 와 무관한 모든 항을 버리면, 괄호 안의 지수는 가법상수를 제외하고 다음과 같이 된다.

$$p(\beta | \Sigma, y) \propto \exp \left\{ -\frac{1}{2} \left[\beta' \left(B_0^{-1} + \sum_t Z_t' \Sigma^{-1} Z_t \right) \beta - 2\beta' \left(B_0^{-1} b_0 + \sum_t Z_t' \Sigma^{-1} y_t \right) \right] \right\}$$

이는 6.2절의 β 에 대한 이차항 더하기 일차항 형태의 정확한 행렬 유사형태이며, $V_0^{-1} \rightarrow B_0^{-1}$, $\sigma^{-2}X'X \rightarrow \sum_t Z_t' \Sigma^{-1} Z_t$, $\sigma^{-2}X'y \rightarrow \sum_t Z_t' \Sigma^{-1} y_t$ 로 대응된다. 그곳과 동일한 절차로 완전제곱을 취하고 $\bar{B} = (B_0^{-1} + \sum_t Z_t' \Sigma^{-1} Z_t)^{-1}$ 와 $\bar{\beta} = \bar{B}(B_0^{-1} b_0 + \sum_t Z_t' \Sigma^{-1} y_t)$ 를 정의하면 다음을 얻는다.

$$\beta | \Sigma, y \sim N(\bar{\beta}, \bar{B})$$

유도: $\Sigma | \beta, y$

Σ 를 포함하는 항들을 모은다. 동시점 잔차의 M 차원 벡터를 $e_t = y_t - Z_t \beta$ 로 쓰고, 대각합(trace) 항등식 $e_t' \Sigma^{-1} e_t = \text{tr}(\Sigma^{-1} e_t e_t')$ 을 이용하면, 유도 커널은 다음과 같이 된다.

$$|\Sigma|^{-T/2} \exp \left\{ -\frac{1}{2} \sum_t \text{tr}(\Sigma^{-1} e_t e_t') \right\} = |\Sigma|^{-T/2} \exp \left\{ -\frac{1}{2} \text{tr}(\Sigma^{-1} E' E) \right\},$$

여기서 E 는 e_t' 를 t 에 걸쳐 쌓은 $T \times M$ 행렬이며(따라서 $E'E = \sum_t e_t e_t'$), 대각합의 선형성을 이용해 합을 안으로 끌어들었다.^a 역위샤트(Inverse-Wishart) 사전분포의 커널은 $|\Sigma|^{-(\nu_0 + M + 1)/2} \exp\{-\frac{1}{2} \text{tr}(\Sigma^{-1} S_0)\}$ 이다. 두 식을 곱하고 $\text{tr}(\Sigma^{-1} S_0) + \text{tr}(\Sigma^{-1} E' E) = \text{tr}(\Sigma^{-1} (S_0 + E' E))$ 를 이용하면,

$$p(\Sigma | \beta, y) \propto |\Sigma|^{-(T + \nu_0 + M + 1)/2} \exp \left\{ -\frac{1}{2} \text{tr}(\Sigma^{-1} (S_0 + E' E)) \right\}$$

이는 척도(scale)와 자유도가 갱신된 정확한 역위샤트 커널이며, 취지상 6.2절의 역감마 단계와 같은 지수 대응 논리를 따르되 스칼라가 아니라 행렬 대각합 형태로 수행된 것이다.

$$\Sigma | \beta, y \sim IW(S_0 + E' E, \nu_0 + T)$$

^a항등식 $e_t' \Sigma^{-1} e_t = \text{tr}(\Sigma^{-1} e_t e_t')$ 이 성립하는 이유는 $e_t' \Sigma^{-1} e_t$ 가 이미 스칼라이고, 1×1 행렬은 그 자신의 대각합과 같기 때문이다. 그런 다음 대각합의 순환성질 $\text{tr}(ABC) = \text{tr}(BCA)$ 을 이용하면, t 에 따라 변하는 $e_t e_t'$ 는 합 안에 남겨둔 채 고정된 행렬인 Σ^{-1} 을 합 밖으로 끌어낼 수 있다. 이 대각합 기법 덕분에 행렬형 이차형식도 스칼라의 경우와 동일한 지수 대응 논리로 다룰 수 있으며, 이는 11장의 VAR 공분산 단계와 12장의 SVAR 충격반응함수 유도에서 그대로 다시 등장한다.

^a항등식 $e_t' \Sigma^{-1} e_t = \text{tr}(\Sigma^{-1} e_t e_t')$ 이 성립하는 이유는 $e_t' \Sigma^{-1} e_t$ 가 이미 스칼라이고, 1×1 행렬은 그 자신의 대각합과 같기 때문이다. 그런 다음 대각합의 순환성질 $\text{tr}(ABC) = \text{tr}(BCA)$ 을 이용하면, t 에 따라 변하는 $e_t e_t'$ 는 합 안에 남겨둔 채 고정된 행렬인 Σ^{-1} 을 합 밖으로 끌어낼 수 있다. 이 대각합 기법 덕분에 행렬형 이차형식도 스칼라의 경우와 동일한 지수 대응 논리로 다룰 수 있으며, 이는 11장의 VAR 공분산 단계와 12장의 SVAR 충격반응함수 유도에서 그대로 다시 등장한다.

10.3 깃스 샘플러

그림 34는 결합추정이 도움이 되는 이유를 보여준다. Σ 는 방정식 j 의 잔차가 방정식 j' 의 계수 추출에 정보를 전달하도록 해 주는 유일한 매개체이며, 이는 M 개의 개별 OLS 회귀로는 결코 얻을 수 없는 것이다.




Figure 34: SUR의 의존구조. 각 방정식의 계수가 공유된 공분산 Σ 로 유입되고, Σ 는 다시 모든 방정식의 계수 추출로 피드백된다 — 방정식 j 가 방정식 j' 로부터 학습하는 통로이다

알고리즘: 깃스 표집을 통한 베이저안 SUR

방정식별 계수를 $\beta = (\beta_1', \dots, \beta_M')'$ 로 쌓고, 켈레 사전분포 $\beta \sim N(b_0, B_0)$ 와 $\Sigma \sim IW(S_0, \nu_0)$ 를 사용한다. 현재 (β, Σ) 가 주어졌을 때 다음을 반복한다.

1. **계수.** $\bar{B} = (B_0^{-1} + \sum_t Z_t' \Sigma^{-1} Z_t)^{-1}$, $\bar{\beta} = \bar{B}(B_0^{-1} b_0 + \sum_t Z_t' \Sigma^{-1} y_t)$ 로부터 $\beta \mid \Sigma, y \sim N(\bar{\beta}, \bar{B})$ 를 추출한다. 여기서 Z_t 는 $x_{1t}', \dots, x_{Mt}'$ 를 대각 블록에 쌓은 $M \times K$ 블록대각 행렬이다. 이는 11장의 VAR 계수 단계와 동일한 GLS 가중 켈레 정규 갱신이며, 여기서는 공통 설명변수 대신 방정식별로 다른 설명변수를 사용한다.
2. **공분산.** $E_{tj} = y_{jt} - x_{jt}' \beta_j$ 로 $T \times M$ 잔차행렬 E 를 구성한 다음, $\Sigma \mid \beta, y \sim IW(S_0 + E'E, \nu_0 + T)$ 를 추출한다. 이는 $\Sigma^{-1} \sim \text{Wishart}((S_0 + E'E)^{-1}, \nu_0 + T)$ 를 뽑아 역행렬을 취하는 방식으로 이루어지며 — VAR 샘플러의 공분산 단계와 동일하다.

실제 구현에서는 전체 $MT \times K$ 회소 설계행렬을 그대로 만드는 대신 $Z_t' \Sigma^{-1} Z_t$ 의 블록 구조를 이용해 폐형식으로 계산한다.

참고: SUR이 방정식별 OLS를 실제로 능가하는 경우는 언제인가

두 가지 고전적인 특수한 경우는 Σ 에 관계없이 SUR을 개별 OLS로 되돌려 놓는다. 모든 방정식에서 설명변수가 동일한 경우($x_{1t} = \dots = x_{Mt}$)와, 방정식 간 상관관계가 영(0)인 경우(Σ 가 대각행렬인 경우)이다. 이러한 특수한 경우를 벗어나면, 결합추정에서 얻는 효율성 이득은 $|\text{Corr}(e_{jt}, e_{j't})|$ 에 대해 증가한다 — 방정식들의 설명되지 않은 변동이 공통 원인을 공유할수록, 이들을 함께 추정하는 것이 더 많은 정보를 준다. 이는 SUR이 6장의 단일방정식 깃스 샘플러를 방정식별로 적용하는 것보다 추가적인 계산비용을 감수할 가치가 있는지를 판단하는 핵심 진단 기준이 모형의 경제학적 타당성뿐 아니라 잔차 상관의 크기임을 의미한다.

10.4 실증 예제: 두 방정식으로 이루어진 거시 예측 체계

응용 사례로서, 검증된 분기별 거시 시계열로 구성된 소규모 두 방정식 축약형 예측 체계를 고려한다. 두 방정식에는 의도적으로 서로 다른 설명변수를 사용한다.

$$\text{gdp}_t = c_1 + \phi_1 \text{gdp}_{t-1} + \phi_2 i_{t-1} + e_{1t}, \quad \pi_t = c_2 + \psi_1 \pi_{t-1} + \psi_2 u_{t-1} + e_{2t},$$

산출 방정식은 자기 자신의 시차와 시차를 둔 정책금리에 반응하고, 인플레이션 방정식은 자기 자신의 시차와 시차를 둔 실업률에 반응한다 — 진정으로 서로 다른 두 정보집합이며, 동일 분기에 산출과 인플레이션을 함께 강타하는 충격을 통해서만 동시에 연결되어 있다.

실증 예제: SUR 대 방정식별 OLS

확산 사전분포($\beta \sim N(0, 100I_6)$, $\Sigma \sim IW(I_2, 3)$)와 $T = 266$ 개 분기(원래의 $T = 217$, 1959Q3–2013Q4 구간에서 확장됨)에 대한 번인 이후 10,000개의 겹스 추출을 사용할 때, SUR 사후평균은 모든 계수에서 개별 OLS 추정치와 표준오차의 작은 일부분 이내로 일치한다.

c_1	3.693 (0.467)	OLS: 3.491	c_2	0.896 (0.465)	OLS: 0.526
ϕ_1	0.037 (0.059)	OLS: 0.030	ψ_1	0.765 (0.040)	OLS: 0.747
ϕ_2	-0.173 (0.070)	OLS: -0.125	ψ_2	-0.007 (0.072)	OLS: 0.068

(4.6절에서와 마찬가지로, 산출 방정식 자신의 시차 계수 ϕ_1 은 2020년의 급등락이 표본에 들어오면서 확장 이전 값 0.314에서 0.037로 급락했다 — 다중 방정식 설정에서 다시 등장하는 동일한 메커니즘이다.) SUR 사후표준편차와 고전적 OLS 표준오차의 비율은 여섯 계수 모두에서 0.968에서 0.998 사이에 있다 — 확장 이전 표본과 달리, 이제는 모든 계수에서 작지만 일관되게 양(+)의 효율성 이득이 있다.




Figure 35: SUR 계수 여섯 개의 사후밀도. 방정식별 OLS 추정값(점선)과 SUR 사후평균(실선)을 함께 표시하였다

실증 예제: 이 경우 이득이 완만한 이유

그림 36가 그 이유를 보여준다. 산출 방정식과 인플레이션 방정식 사이의 OLS 잔차상관은 0.256이며, $\text{Corr}(e_{1t}, e_{2t})$ 의 SUR 사후평균은 0.277로, 95% 신용구간 $[0.158, 0.390]$ 은 이제 영(0)을 넉넉히 배제한다 — 확장 이전 표본에서는 이 동일한 방정식 쌍의 상관이 $\rho \approx 0.11$ 에 불과했고 신용구간이 영(0)에 거의 닿아 있었던 것과는 달라진 모습이다. 코로나19 경기침체는 위의 참고 내용이 설명하는 공통 총량충격의 정확한 사례로 보인다. 2020년에 산출과 인플레이션을 함께 크게 움직여, 두 방정식의 회귀변수 집합이 진정으로 다르다는 사실은 그대로 유지하면서도 오차상관을 끌어올렸다. 위의 참고 내용에 따르면 SUR이 개별 OLS에 대해 갖는 효율성 우위는 이 상관과 함께 커진다. $\rho \approx 0.28$ 수준에서는 결합추정이 활용할 만한 실질적인, 다만 여전히 완만한 공유 정보가 오차항에 존재하며, 이는 그림 35에서 나타나는 작지만 일관되게 양(+)인 효율성 이득에 정확히 반영되어 있다 — 확장 이전 표본보다는 크지만, 아래의 대응 체계에는 크게 못 미친다.




Figure 36: 방정식 간 오차상관 $\text{Corr}(e_{1t}, e_{2t})$ 의 사후분포

10.5 실증 예제: SUR이 실제로 도움이 되는 대응 체계

위의 참고 내용은 SUR이 언제 제 값을 발휘하는지를 정확히 예측한다. 상관이 낮은 방정식 쌍을, 오차항이 진정한 공통충격을 공유하는 두 방정식으로 대체하면 효율성 이득이 이론적인 수준을 넘어 실제로 눈에 보여야 한다. 앞서와 동일한 산출 방정식을 그대로 두고, 이번에는 인플레이션 방정식 대신 소비 방정식과 짝을 짓는다.

$$\text{gdp}_t = c_1 + \phi_1 \text{gdp}_{t-1} + \phi_2 i_{t-1} + e_{1t}, \quad \text{pce}_t = c_2 + \zeta_1 \text{pce}_{t-1} + \zeta_2 u_{t-1} + e_{2t},$$

여기서 pce_t 는 실질 개인소비지출 증가율이며(15장의 상태공간 예제에서 사용한 것과 동일한 검증된 분기별 수준(levels) 자료로부터 구성하였다), 그 밖의 모든 것(방정식 1 자체와, 방정식 2의 시차 실업률 설명변수)은 위의 체계와 동일하게 유지된다. 다만 자료 가용성에 관한 한 가지 유의사항이 있다. 이 대응 체계를 구성하는 데 사용된 GDP 및 PCE 수준(levels) 자료는 2015년 4분기에서 끝나며 이 노트의 데이터 확장을 위해 FRED에서 다시 가져오지 않았으므로, 위의 산출/인플레이션 체계가 이제 2026년 1분기까지 확장된 전체 표본을 사용하는 것과 달리, 이 대응 체계는 원래의 $T = 217$ 개 분기(1959Q3–2013Q4) 구간에 그대로 머문다. 국민계정 작성 방식상 소비는 대략 GDP의 3분의 2를 차지하므로, 공통의 총수요 충격(경기침체, 재정정책 또는 통화정책 조치)은 산출과 소비 증가율을 동일 분기에 함께 강타하는 경향이 있는데, 이는 산출과 인플레이션이 반드시 함께 영향을 받는 것과는 다르다.

실증 예제: SUR 대 방정식별 OLS: 실제로 상관된 방정식 쌍

위와 동일한 확산 사전분포와 원래의 $T = 217$ 개 분기에 대한 번인 이후 10,000개의 김스 추출을 사용할 때(따라서 여기서의 방정식 1은 위의 10.4절에서 확장된 표본으로 추정된 방정식 1과 명세는 동일하지만 수치는 다르다), 산출 방정식과 소비 방정식 사이의 OLS 잔차상관은 0.449로(확장된 표본의 산출/인플레이션 쌍에서 나타난 0.256보다 여전히 눈에 띄게 높다) $\text{Corr}(e_{1t}, e_{2t})$ 의 SUR 사후평균은 0.493이며, 95% 신용구간은 $[0.381, 0.594]$ 로 영(0)을 큰 폭으로 배제한다(그림 38). 이는 그림 36의 $[0.158, 0.390]$ 보다 훨씬 위에 위치한다.

c_1	3.473 (0.436)	OLS: 2.828	c_2	3.671 (0.796)	OLS: 2.554
ϕ_1	0.295 (0.059)	OLS: 0.321	ζ_1	0.400 (0.057)	OLS: 0.507
ϕ_2	-0.241 (0.057)	OLS: -0.137	ζ_2	0.047 (0.108)	OLS: 0.115

상관이 더 약한 쌍과 달리, 이제는 모든 계수에서 SUR과 OLS 점추정치에 눈에 띄게 불일치한다 — 이는 방정식 간에 활용할 실질적인 정보가 있을 때 결합추정이 마땅히 해야 할 바이다. SUR 사후표준편차와 고전적 OLS 표준오차의 비율은 이제 여섯 계수 모두에서 0.872에서 0.973 사이에 있다. 즉 모든 계수 하나하나가 방정식별 OLS보다 SUR 아래에서 더 정밀하게 추정되며, 이는 위에서 확장된 표본의 산출/인플레이션 쌍에서 나타난 0.968–0.998 범위보다 훨씬 큰 효율성 이득이다.




Figure 37: GDP/소비 증가율 체계에 대한 SUR 계수 여섯 개의 사후밀도. 방정식별 OLS 추정값 (점선)과 SUR 사후평균(실선)을 함께 표시하였다




Figure 38: GDP/소비 증가율 체계에 대한 방정식 간 오차상관 $\text{Corr}(e_{1t}, e_{2t})$ 의 사후분포

실증 예제: 두 체계의 직접 비교

그림 39는 두 체계의 효율성 비율을 계수별로 나란히 놓고 비교한다. 상관이 높은 (gdp, pce, $\rho \approx 0.49$) 쌍의 모든 막대는 상관이 더 약한 (gdp, infl, $\rho \approx 0.28$) 쌍의 대응 막대보다 눈에 띄게 아래에 위치하며, 둘 다 고전적 OLS와의 동등성을 나타내는 1의 선 아래에 있다. 다만 (gdp, infl) 쌍의 막대는 이 노트의 데이터 확장 이전보다 그 선에 훨씬 더 가까워졌다. 이 패턴은 위의 참고 내용을 정확히 뒷받침한다. 효율성 이득은 어떤 체계가 함께 적어 볼 만한 자연스러운 방정식 쌍처럼 보이는지가 아니라 $|\text{Corr}(e_{1t}, e_{2t})|$ 와 단조적으로 관련되어 있다.




Figure 39: 상관이 낮은 (gdp, infl) 쌍과 상관이 높은 (gdp, pce) 쌍에 대해, 계수별로 나타낸 SUR 사후표준편차 대 고전적 OLS 표준오차의 비율

참고: 완만한 결과도 여전히 유익한 결과이다

의도적으로 오차가 상관되도록 구성한 방정식 쌍 하나만을 만들어 이를 SUR의 전형적인 성과인 것처럼 제시하는 것은 손쉬운 일이었을 것이다. 두 거시 예측 방정식이 무엇을 산출하는지(적당한 정도의, 정직하게 추정된 상관과 그에 상응하는 완만한 효율성 이득으로, 대응 체계의 이득보다는

작지만 확장된 표본의 공유된 코로나19 충격이 포함되고 나면 더 이상 무시할 만한 수준이 아니다)를 먼저 보고하고, 그런 다음에야 위의 대응 체계를 덧붙이는 방식은 어느 한쪽만 제시하는 것보다 교육적으로 더 유용하다. 이는 SUR의 이득이 (그림 36 또는 38와 정확히 같은 사후상관 그래프를 통해) 각 응용에서 확인해야 할 경험적 질문이지, 어떤 체계가 상관된 오차를 가진 방정식들로 쓰일 수 있다는 이유만으로 가정해도 되는 이득이 아니며, 또한 표본과 무관하게 고정된 이득도 아님을 보여준다. 확장 이전 표본에서 거의 이득이 없었던 바로 그 산출/인플레이션 쌍이, 충분히 큰 공통충격이 자료에 들어오고 나자 실질적이지만 완만한 이득을 보인다.

11. 벡터자기회귀(Vector Autoregression, VAR)

로드맵

10장은 상관된 오차를 가진 방정식 체계를 위한 기계장치를 구축했지만, 각 방정식이 자신만의 설명변수를 유지하도록 허용했다. 이 장은 그 체계에 하나의 제약을 부과한다(모든 방정식이 동일한 변수들의 동일한 시차에 대해 회귀한다는 것이다) 그리고 그 대가로 새로운 샘플러 코드를 전혀 작성하지 않고도 실증 거시경제학의 주력 모형을 얻는다. 실증 절은 그 주력 모형에 관한 정전(canonical) 격의 해설 논문인 Stock and Watson (2001)을 그들 자신의 1960–2000년 표본에서 재현한 다음, 2000년까지로 추정된 고정모수 모형이 2001–2026년에 대해 무엇을 말해 주는가를 묻는다. 이 장의 예측 실패는 이 노트 후반부의 모든 시변(time-varying) 모형(14장, 16–18장)의 동기가 되는 사례이며, 13장의 대규모 BVAR와 12장의 구조적 VAR 모두 정확히 여기서 추정된 축약형 모형에서 출발한다.

10장의 SUR 체계는 모든 방정식이 자신만의 결과변수와 자신만의 설명변수를 갖도록 허용했다. 심즈(Sims, 1980)의 벡터자기회귀(Vector Autoregression, VAR)는 n 개의 모든 방정식이 동일한 변수 집합을 모형화하고, 그 구성상 모든 방정식이 동일한 설명변수(각 변수 자신의 시차와 다른 모든 변수의 시차를 함께)를 사용하는 특수한 경우이다. 이 장은 VAR을 정확히 SUR의 그러한 특수한 경우로 취급하여 10장의 깁스 샘플러를 그대로 재사용하며, 그런 다음 적합한 모형에 진정으로 중대한 시험을 부과한다. 즉 모수와 변동성을 2000년 시점 추정치에 고정한 채, Stock and Watson (2001) 표본의 마지막 분기인 2000년 말부터 세 차례의 경기침체와 두 차례의 영 하한(zero lower bound) 국면을 포함하는 사반세기를 관통하여 앞으로 예측하는 것이다.

11.1 VAR(p) 모형과 그 컴패니언 형태

$Y_t = (y_{1t}, \dots, y_{nt})'$ 를 거시경제 변수들의 n 차원 벡터라 하자. 차수 p 의 VAR은 Y_t 의 각 원소를 p 개의 자기 시차 및 교차변수 시차의 선형함수에 동시점에서 상관된 교란항을 더한 것으로 쓴다.

$$Y_t = c + \Phi_1 Y_{t-1} + \dots + \Phi_p Y_{t-p} + e_t, \quad e_t \sim N(0, \Sigma),$$

여기서 $\Phi_1, \dots, \Phi_p$ 는 각각 $n \times n$ 행렬이다. 그림 40는 $p = 2$ 일 때 이로부터 생겨나는 시간의존성을 보여준다. 지금까지의 모든 깁스 샘플러 DAG가 하나의 반복 내에서 모수들이 서로 어떻게 의존하는지를 보여주었던 것과 달리, 이 그림은 자료가 시간에 걸쳐 서로 어떻게 의존하는지를 보여준다.




Figure 40: VAR(2)의 시간의존성: Y_t 는 직전 시점과 두 시점 전의 이력 모두에 의존하며, 각 변수의 전체 벡터는 Φ_1, Φ_2 를 통해 다른 모든 변수의 방정식에 유입된다

가장 최근 p 개의 시차를 하나의 컴패니언 벡터로 쌓으면 1차 컴패니언 형태(companion form) $\tilde{Y}_t = F\tilde{Y}_{t-1} + \tilde{e}_t$ 를 얻으며, VAR이 공분산정상(covariance-stationary)일 필요충분조건은 $np \times np$ 컴패니언 행렬(companion matrix) F 의 모든 고유값(eigenvalue)이 단위원(unit circle) 내부에 엄격히 놓이는 것이다. 이것이 바로 추정 과정에서 강제되는 정상성 기준이다. 컴패니언 행렬이 $\max |\text{eig}(F)| \geq 1$ 을 만족하는 Φ_1, Φ_2 의 후보 추출값은 기각되고, 대신 이전 추출값으로 되돌린다.

11.2 사후분포 유도

VAR을 SUR 형태 $Y_t = Z_t\beta + e_t$, $e_t \sim N(0, \Sigma)$ 로 쓰면, 여기서 Z_t 는 공통 설명변수 벡터 $x_t = (1, Y'_{t-1}, \dots, Y'_{t-p})'$ 를 모든 대각 블록에 반복하여 구성한 $n \times nk$ 블록대각 행렬이다. 결합사후 커널 $p(\beta, \Sigma | Y) \propto |\Sigma|^{-T/2} \exp\{-\frac{1}{2} \sum_t (Y_t - Z_t\beta)' \Sigma^{-1} (Y_t - Z_t\beta)\} \times N(\beta | b_0, B_0) \times IW(\Sigma | S_0, \nu_0)$ 은 10.2절의 커널과 대수적으로 정확히 동일한 형태를 갖는다. 다만 결과변수 y_t 가 Y_t 로 다시 표기되고, 방정식별 블록대각 Z_t 가 이러한 공통 설명변수 블록대각 Z_t 로 대체되었을 뿐이다. 10장의 완전제곱과 대각합 항등식 논증 중 어느 것도 Z_t 의 대각 블록이 방정식마다 다르다는 가정을 사용하지 않았다(그 가정은 두 유도 어디에서도 원용된 적이 없다) 따라서 두 결과 모두 단순한 재표기만으로 그대로 옮겨진다.

유도: $\beta | \Sigma, Y$ and $\Sigma | \beta, Y$

$y_t \rightarrow Y_t$ 대입을 10.2절의 완전제곱 결과에 적용하면 다음을 얻는다.

$$\begin{aligned} \beta | \Sigma, Y &\sim N(\bar{\beta}, \bar{B}), \\ \bar{B} &= \left(B_0^{-1} + \sum_t Z_t' \Sigma^{-1} Z_t \right)^{-1}, \\ \bar{\beta} &= \bar{B} \left(B_0^{-1} b_0 + \sum_t Z_t' \Sigma^{-1} Y_t \right), \end{aligned}$$

그리고 $y_t \rightarrow Y_t$ 대입을 10.2절의 대각합 항등식 결과에 적용하되, 이제 E 를 VAR 잔차의 $T \times n$ 행렬 $E_t = (Y_t - Z_t\beta)'$ 로 두면 다음을 얻는다.

$$\Sigma | \beta, Y \sim IW(S_0 + E'E, \nu_0 + T)$$

새로운 완전제곱이나 대각합 항등식 논증은 전혀 필요하지 않다. Z_t 가 M 개의 서로 다른 설명변수 벡터가 아니라 반복된 공통 x_t 로부터 구성된다는 점만 이해하면, 10.2절 유도의 모든 단계가 그대로 성립한다. 그 유도는 이러한 Z_t 의 장부상(bookkeeping) 정의를 넘어서는 방정식별 설명변수를 애초에 사용한 적이 없기 때문이다.

11.3 SUR의 특수한 경우로서의 VAR

알고리즘: 10장의 SUR 깃스 샘플러를 통한 베이저안 VAR

Y_t 의 n 개 방정식을 SUR 형태로 쓰되, Z_t 는 동일한 $k = 1 + np$ 차원 벡터 $x_t = (1, Y'_{t-1}, \dots, Y'_{t-p})'$ 를 모든 대각 블록에 반복하여 구성한 $n \times nk$ 블록대각 행렬이다 — 이것이 10장과 유사하고 실질적인 차이이며, 10장에서는 각 방정식의 블록이 자신만의 고유한 설명 변수를 사용했다. 이 한 가지 변경만으로 알고리즘은 10장의 것과 동일하다.

1. **계수.** $\bar{B} = (B_0^{-1} + \sum_t Z'_t \Sigma^{-1} Z_t)^{-1}$, $\bar{\beta} = \bar{B}(B_0^{-1} b_0 + \sum_t Z'_t \Sigma^{-1} Y_t)$ 로부터 $\beta \mid \Sigma, Y \sim N(\bar{\beta}, \bar{B})$ 를 추출한다.

2. **공분산.** $T \times n$ 잔차행렬 E 를 구성하고 $\Sigma \mid \beta, Y \sim IW(S_0 + E'E, \nu_0 + T)$ 를 추출한다.

두 단계 모두 문자 그대로 10장의 SUR 깃스 샘플러이며, n 개의 서로 다른 행렬 대신 동일한 설계 행렬 X 를 방정식마다 한 번씩 대입하여 호출할 것일 뿐이다 — 이 장을 위해 새로 작성된 샘플러는 없다. 사전분포는 모든 기울기 계수에 정밀도(precision) 1(사전분산 1)을 부여하고, 각 방정식의 절편에는 정밀도 $1/10$ (사전분산 10, 즉 더 느슨한 사전분포)을 부여하며, $S_0 = I_n$, $\nu_0 = n + 3$ 이다.

참고: 이 장에 새로운 알고리즘이 없는 이유

6장부터 10장까지는 작은 도구모음(컬레 정규회귀, 절단정규 자료증강, 스파이크-슬래브(spike-and-slab) 변수선택, 그리고 이제 SUR 깃스 샘플러)를 쌓아 왔으며, VAR은 그 도구모음을 확장할 이유가 아니라 재사용할 기회이다. 모든 방정식이 동일한 설명변수를 공유하게 되면 SUR의 일반적인 $Z'_t \Sigma^{-1} Z_t$ 구성은 크로네커(Kronecker) 구조로 축약되지만, 샘플러가 이 사실을 알 필요는 없다. 동일한 설계행렬은 샘플러가 이미 처리하도록 구축된 블록대각 Z_t 의 한 특수한 경우일 뿐이므로, SUR 갱신 단계가 이를 자동으로 처리하기 때문이다. 이는 9장에서 토빗이 프로빗과 6장의 결합이라고 지적했던 것과 같은 교훈을, 한 단계 위에서 되풀이하는 것이다. 즉 새로운 경제 모형이 반드시 새로운 샘플러를 의미하지는 않는다.

11.4 Stock and Watson (2001)

이 장이 재현하는 실증 연구는 한 세대의 경제학자들에게 VAR이 무엇을 위한 도구인지를 가르친 논문, Stock and Watson (2001, 이하 SW)의 “Vector Autoregressions”(Journal of Economic Perspectives 15(4))이다. SW는 방법론 전체를 하나의 관통 예제(물가 인플레이션, 실업률, 연방기금금리의 세 변수 VAR(4)를 미국 분기 자료 1960Q1–2000Q4에 대해 추정)를 중심으로 조직하고, 이를 통해 거시경제학의 네 가지 과제, 즉 자료 기술, 예측, 구조적 추론, 정책 분석을 시연한다. 이 장은 그중 축약형 결과(자료 기술과 예측)를 재현하며, 같은 체계의 구조적 측면은 12장이 이어받는다. 인플레이션은 SW와 정확히 동일하게 $\pi_t = 400 \ln(P_t/P_{t-1})$ 로 구성되 P_t 는 연쇄가중 GDP 물가지수(FRED GDPDEF)이고, 실업률(UNRATE)과 연방기금금리(FEDFUNDS)는 월별 값의 분기 평균이다. 이 노트 전체에서 사용해 온 세 단계 논리(재현, 연장, 설명)에 따라, 먼저 SW 자신의 표본에서 10장의 깃스 샘플러로 체계를 추정하고(초기 시차 4개를 조건화한 뒤 유효 분기 $T = 163$, 방정식당 설명변수 $k = 13$ 개), 이어서 2026Q1까지의 전체표본($T = 264$)에서 동일한 모형을 다시 추정한다.

실증 예제: SW의 Table 1: 그레인저 인과, 재현

SW의 첫 번째 결과물은 그레인저 인과(Granger causality) p -값 표이다. 각 변수쌍에 대해, 한 변수의 시차 네 개가 다른 변수의 축약형 방정식에 들어가는지를 F -검정한 것이다.^a 아래 표는 재현 결과를 SW의 발표값(괄호 안)과 나란히 보여준다.

설명변수	π 방정식	u 방정식	R 방정식
π	—	0.35 (0.31)	0.00 (0.00)
u	0.15 (0.02)	—	0.00 (0.00)
R	0.21 (0.27)	0.007 (0.01)	—

비대각 여섯 칸 중 다섯 칸이 SW의 발표값을 거의 그대로 재생하며, 그들 Table 1의 정성적 결론은 모두 살아남는다. 인플레이션과 실업률은 각각 정책금리를 강하게 예측하는 데 도움이 되고(셋째 방정식에 내재된 테일러 준칙 형태의 반응함수), 정책금리는 실업률 예측에 도움이 되며, 정책금리는 인플레이션 예측에는 도움이 되지 않는다. 움직인 유일한 칸은 인플레이션 방정식에서 실업률의 역할이다(SW는 $p = 0.02$ 를 얻었지만 재현에서는 $p = 0.15$ 가 나온다) 그리고 이 불일치는 문제라기보다 유익한 정보이다. 연쇄가중 GDP 물가지수는 2001년 이후 여러 차례 전면 개정되었으므로 인플레이션 계열 자체가 SW가 사용한 그 계열이 아니며, 표에서 필립스 곡선에 해당하는 칸이야말로 디플레이터 개정이 드러날 것으로 예상되는 바로 그 자리이기 때문이다.

^a 그레인저 인과 F -검정은 빈도주의적 도구이며, 여기서는 SW가 보고한 방식 그대로(OLS 적합에서 한 번 계산되는 기술통계량으로서) 체계 자체의 베이지안 추정을 대체하는 것이 아니라 그 곁에 나란히 보고한다.

실증 예제: 원표본 1960Q1–2000Q4: 사후분포 대 OLS

10장의 사전분포(기울기에 분산 1, 절편에 10, $S_0 = I_3$, $\nu_0 = 6$)와 번인 이후 10,000개의 추출을 사용하면, 자료가 분명하게 말하는 곳에서는 모든 계수의 사후평균이 OLS 대응값 가까이에 놓이고, 가장 큰 간극은 정확히 있어야 할 곳(공선성이 심한 실업률 시차 다항)에서 나타난다. 예컨대 인플레이션 방정식에서 u_{t-2} 와 u_{t-3} 의 OLS 계수는 0.935와 -0.799 로 크고 서로 상쇄하며 개별적으로는 부정확하게 추정되는 반면, 그 사후평균은 0.474와 -0.396 이다. 사전분포가 상쇄쌍을 그 합은 바꾸지 않은 채 영 쪽으로 수축시킨 것인데, 그 합이야말로 우도가 실제로 식별하는 유일한 양이다. 39개 계수 전체에서 사후평균과 OLS의 최대 간극은 0.60이고, 컴패니언 행렬 고유값의 최대 절대값은 사후평균에서 0.973(OLS에서도 0.973)이다 — 체계는 지속성이 높지만 넉넉히 정상적이며, 그림 41가 이를 보여준다.




Figure 41: SW VAR(4)의 사후평균 컴패니언 행렬 고유값과 단위원, 원표본(1960Q1-2000Q4)

실증 예제: 전체표본 1960Q2-2026Q1

동일한 모형과 사전분포를 2026Q1까지의 계열에서 다시 추정하면 통계적 그림이 두 가지 교훈적인 방식으로 달라진다. 첫째, 유효 분기가 264개가 되면 사전분포는 거의 완전히 씻겨 나간다. 사후평균과 OLS의 최대 간극이 0.60에서 0.014로 떨어진다. 둘째, 경제적으로 더 의미심장하게, 그레인저 인과 표가 더 이상 SW의 것이 아니다. 실업률은 더 이상 정책금리 예측에 도움이 되지 않는다(SW 표본에서의 0.0000에 맞서 $p = 0.41$). 정책금리가 십사 년을 영 하한에 붙어 앉아(실업률이 13.0%까지 치솟았다 되돌아오는 동안에도 전혀 움직이지 않은 채) 보낸 사반세기가, 추정된 반응함수의 실업률 쪽을 지워버린 것이다. 이제 정책금리는 인플레이션 예측에 도움이 되고($p = 0.03$, 이전에는 0.21), 필립스 곡선 칸은 여전히 약하다($p = 0.14$). 고유값의 최대 절대값은 0.938로 내려간다(그림 42). 전체표본이 SW의 표본보다 덜 지속적으로 보이는 것인데, 이는 변동성이 컸던 1985년 이전 분기들이 이제 길고 조용한 두 ZLB 국면과 표본을 나눠 쓰기 때문이다. SW 스스로가 바로 이 취약성을 경고했다(저차원 VAR의 광범위한 불안정성과 정책준칙 변화에 대한 문헌을 인용하면서) 그리고 다음 절은 그 불안정성이 모형의 예측에 무엇을 하는지 보여준다.




Figure 42: SW VAR(4)의 사후평균 컴패니언 행렬 고유값, 전체표본(1960Q2-2026Q1)

11.5 SW 표본의 끝에서 2001–2026년을 예측하기

SW는 자신들의 VAR의 예측 성능을 2000Q4에 끝나는 유사 표본외(pseudo out-of-sample) 실험(매분기 모형을 다시 추정하는 방식)으로 평가했고, 단변량 자기회귀와 랜덤워크 벤치마크를 이긴다는 것을 확인했다. 여기서의 실험은 의도적으로 더 가혹하며 다른 질문에 답한다. 체계를 2000Q4까지 한 번만 추정한 뒤, 모수와 변동성을 2000년 시점의 사후분포에 고정한 채 101개 분기를 2026Q1까지 앞으로 시뮬레이션한다. 실무에서 누구도 이렇게 예측하지는 않겠지만, 이 예측과 현실 사이의 간극이야말로 1960–2000년에 적합된 고정모수 선형 모형이 2001–2026년에 관해 표현할 수 없는 모든 것을 측정해 주기 때문이다.

실증 예제: 고정모수 VAR, 2001–2026년과 마주치다

(Φ, Σ)의 사후 추출 2,000개 각각을 고유한 충격경로로 시뮬레이션하므로, 그림 43의 팬 차트는 모수 불확실성과 충격 불확실성을 모두 포착한다. 예측기간에는 2001년 닷컴 경기침체, 2008–09년 금융위기, 코로나19 팬데믹, 그리고 2021–22년 인플레이션 급등이 들어 있다. 101개 분기에 대한 예측 정확도는 다음과 같다.

	RMSFE	95% 구간 밖 비율
인플레이션	2.27	0.0%
실업률	1.95	7.9%
연방기금금리	5.09	1.0%

모든 변수의 중앙값 예측은 정상 VAR이 긴 예측기간에서 할 수 있는 유일한 일을 한다. 즉 1960–2000년의 무조건부 평균으로 회귀한다. 실업률의 경우 이는 이십오 년 동안 6% 부근을 표류한다는 뜻이다. 실현된 경로는 전혀 달랐다. 금융위기에서 9.9%로 정점을 찍고, 팬데믹에서는 13.0%까지 치솟았으며(구간 이탈 7.9%의 거의 전부가 이 분기들에서 나온다), 2015–2026년의 대부분은 오히려 4.5% 아래에서 보냈다 — 모형이 반대 방향으로도 거의 똑같이 일어나기 어렵다고 여기는 수준이다. 정책금리에서는 평균회귀가 한층 더 치명적이다. 중앙값 예측은 6–7%를 향해 되올라가 거기 머무는 반면, 실현된 금리는 2009–2015년과 2020–2022년을 0.25%에 못박힌 채 보냈다(9장의 토빗 장치로 직접 모형화했던 두 ZLB 국면이다) 그 결과 세 변수 중 가장 큰 RMSFE인 5.09퍼센트포인트가 나온다. 인플레이션은 가장 조용한 실패이다. 팬이 충분히 넓어서 2021–22년 연율 9%까지의 급등조차 (아슬아슬하게) 95% 구간 안에 머물기 때문에 커버리지는 완벽해 보이지만, 그 점예측(사반세기 동안 한결같은 4% 인플레이션)은 기간 대부분에서 수준 자체가 틀렸다.




Figure 43: 2000Q4까지 추정된 SW VAR(4)의 전방 시뮬레이션: 중앙값, 68%와 95% 예측구간 대 실현값, 2001Q1-2026Q1

참고: 구간 커버리지는 유용한 예측과 같지 않다

정책금리와 실업률은 같은 경고의 서로 반대되는 절반씩을 들려준다. 정책금리는 형식적 커버리지가 거의 완벽한데(95% 구간 밖 1.0%) RMSFE는 세 변수 중 최악이다. 1960-2000년으로 보정된 긴축국면이 할 법한 모든 일을 담아야 하는 구간은 십사 년의 영 하한 체류까지 담을 만큼 넓지만, 그 구간 안의 중앙값은 수십 년 동안 자신 있게 틀린 방향을 가리키기 때문이다. 실업률은 그 반대를 보여준다. RMSFE로는 눈에 띄게 더 나은 점예측(1.95)이지만 커버리지는 최악(7.9% 이탈)인데, 두 차례의 위기 급등이 급격하고 짧으며 상수 Σ 모형이 정당화할 수 있는 어떤 구간보다도 멀리 벗어나기 때문이다. 어느 한 진단만 읽으면 두 예측의 순위가 서로 반대로 매겨진다. 함께 읽으면, 모형이 양쪽 방식 모두로 실패했다고(정책금리에서는 중앙값이, 실업률에서는 꼬리가 틀렸다고) 말해 주며, 1960-2000년에서 추정된 그 무엇도 그 표본에 없던 국면들(구속력 있는 금리 하한, 팬데믹)을 표현할 준비가 되어 있지 않았다고 말해 준다. 이것이 이 노트 후반부의 시변모수·확률적 변동성 장들(14장, 16-18장)에 대한 표준적인 동기이다.

12. 구조적 VAR과 충격반응함수 분석

로드맵

11장은 VAR 잔차의 축약형 공분산인 Σ 를 추정하고 의도적으로 거기서 멈추었다. 상관된 잔차만으로는 그 어떤 선형결합이 "통화정책 충격"이라는 이름표를 받을 자격이 있는지 말해주지 않기 때문이다. 이 장은 샘플러에 아무것도 추가하지 않는다((Φ, Σ) 는 11장에서 얻은 것과 동일한 사후추출값이다) 대신 그 추출값에 대한 결정론적 변환, 즉 콜레스키(Cholesky) 분해와, 단일 충격을 앞으로 전파하는 시뮬레이션 방안을 추가한다. 그 시뮬레이션을 구축하는 데 사용되는 공통난수(common-random-numbers) 기법은 비해석적(non-analytical) 충격반응을 갖는 이후의 모

든 장(16–18장)에서 본질적으로 변경 없이 다시 등장한다.

11장은 의도적으로 축약형 VAR에서 멈추었다. 잔차 공분산 $\hat{\Sigma}$ 는 진정한 방정식 간 상관을 지니고 있지만, 축약형에서는 그 어떤 것도 상관된 잔차 e_t 의 특정 결합에 "통화정책 충격"이라는 경제적 이름표를 부여하지 않는다. 이 장은 그 공백을 두 단계로 메운다. 먼저 재귀적(recursive, 콜레스키) 식별 방안과 공통난수 충격반응 구성을 11장에서 추정된 것과 동일한 Stock and Watson (2001) 체계에 적용하여 — 무엇보다도 그 방안의 가장 유명한 병리 현상을 재현한다. 이어서 부호제약을 재귀적 순서의 표준적 대안으로 만든 논문인 Uhlig (2005)를 그 논문 자신의 월별 여섯 변수 체계에서 재현한다.

12.1 식별 문제

축약형 교란항 $e_t \sim N(0, \Sigma)$ 는 일반적으로 n 개의 상호독립인 구조적(structural) 충격 u_t 의 선형 결합이다. 즉 $u_t \sim N(0, I_n)$ 일 때 $e_t = Bu_t$ 이며, 따라서 $\Sigma = BB'$ 이다. 이 분해는 유일하지 않다($BB' = \Sigma$ 를 만족하는 어떤 B 도 성립하며, 임의의 직교행렬 Q 에 대해 B 와 BQ 는 동일한 Σ 를 준다) 따라서 경제적으로 해석 가능한 충격을 복원하려면 자료 그 자체만으로는 얻을 수 없는 추가적인 식별 가정이 B 에 필요하다.

참고: 재귀적(콜레스키) 식별 방안

가장 단순하고 가장 흔한 선택은 $B = C$, 즉 Σ 의 하삼각(lower-triangular) 콜레스키 인자($\Sigma = CC'$)로 두는 것이다. 하삼각성은 변수들에 재귀적 인과순서를 부과한다. 순서상 첫 번째 변수는 오직 자기 자신의 충격에만 동시에 반응할 수 있고, 두 번째 변수는 첫 번째 변수의 충격과 자기 자신의 충격에 동시에 반응할 수 있으며, 이런 식으로 계속되어 순서상 마지막 변수는 체계 내 모든 충격에 동시에 반응할 수 있다. 연방기금금리를 마지막에 두는 것(이 장이 따르는 크리스티아노–아이켄바움–에번스(Christiano–Eichenbaum–Evans, 1996)의 관행)은 중앙은행이 동일 분기 내에 실업률과 인플레이션의 서프라이즈를 관측하고 이에 반응하는 반면, 통화정책 충격 자체는 최소 한 분기의 시차를 두고서만 실업률과 인플레이션에 영향을 미친다는 가정을 담고 있다.

12.2 사후분포 유도

이 장은 새로운 사전분포를 도입하지 않으며, 11장의 깃스 샘플러가 이미 추출한 축약형 (Φ, Σ) 를 넘어서는 어떠한 새로운 모수도 추정하지 않는다 — 거기서 유도된 사후 완전조건부분포 $\beta \mid \Sigma, Y$ 와 $\Sigma \mid \beta, Y$ 는 변경되지 않는다. 여기서 새로운 것은 유지된 각 사후 추출값에 적용되는 결정론적 변환이며, 따라서 유도 과제의 성격 자체가 6–11장과는 다르다. 표집할 완전조건부분포를 유도하는 대신, 목표는 (i) 재귀적 인자 C 가 Σ 의 잘 정의된 함수임을, 그리고 (ii) (Φ, Σ) 의 각 사후 추출값에서 충격반응을 시뮬레이션하는 것이 충격반응 그 자체의 사후분포로부터 얻은 유효한 추출값을 산출함을 정당화하는데 있다.

유도: 재귀적 인자 C 의 존재성과 유일성

Σ 는 공분산행렬이므로 대칭 양정치(symmetric positive definite)이다. 주장하는 바는, $BB' = \Sigma$ 를 만족하는 모든 행렬 B 중에서 정확히 하나만이 엄격하게 양(+)인 대각원소를 갖는 하삼각행렬이라는 것이다.

1. **존재성.** 표준적인 선형대수학(콜레스키 분해)은 임의의 대칭 양정치 Σ 에 대해, 엄격하게 양인 대각원소를 갖고 $\Sigma = CC'$ 를 만족하는 하삼각행렬 C 가 존재함을 보장한다. 이는 정확히 가우

스 소거법(Gaussian elimination)과 같은 방식으로 열(column)별로 귀납적으로 구성된다.

2. **유일성 — 설정.** $\tilde{C}$ 가 $\tilde{C}\tilde{C}' = \Sigma = CC'$ 를 만족하는 또 다른, 엄격하게 양인 대각원소를 갖는 하삼각행렬이라 하자. C 가 가역(invertible)이므로(그 대각원소가 엄격하게 양이므로), $Q \equiv C^{-1}\tilde{C}$ 로 정의하면 $\tilde{C} = CQ$ 이다.
3. **유일성 — Q 는 직교행렬이다.** $\tilde{C} = CQ$ 를 $\tilde{C}\tilde{C}' = CC'$ 에 대입하면

$$CQQ'C' = CC'$$

C 가 가역이므로 양변에 각각 C^{-1} 을 좌측에서, $(C')^{-1} = (C^{-1})'$ 을 우측에서 곱하면 양변에서 C 가 소거되어

$$QQ' = I_n,$$

이 되어 Q 는 직교행렬이다.

4. **유일성 — Q 는 하삼각행렬이다.** 구성상 $Q = C^{-1}\tilde{C}$ 이다. C^{-1} 은 하삼각행렬이며(하삼각행렬의 역행렬은 하삼각행렬이다), $\tilde{C}$ 는 가정에 의해 하삼각행렬이고, 두 하삼각행렬의 곱은 하삼각행렬이므로 Q 는 하삼각행렬이다.
5. **유일성 — $Q = I$.** 동시에 하삼각이면서 직교인 행렬은 반드시 대각행렬이어야 하며(단위 행 벡터 노름과 삼각성이 함께 작용하면, 위쪽 행들이 고정된 이상 비대각 원소가 영이 아닐 여지가 없다), 대각인 직교행렬은 대각원소가 ± 1 이다. C 와 $\tilde{C} = CQ$ 가 모두 고정된 양의 대각부호 규약을 따르므로, Q 의 모든 대각원소는 $+1$ 이어야 한다. 즉 $Q = I$ 이고, 따라서 $\tilde{C} = C$ 이다.

따라서 $B = C$ 로 두는 것은 행렬 제곱근을 임의로 선택하는 것이 아니라, 동치류 (equivalence class) $\{CQ : Q \text{는 직교행렬}\}$ 중에서 동시에 하삼각행렬이기도 한(정확히 위 remarkbox의 재귀적 인과순서 제약과 같은) 유일한 원소를 고정된 양의 대각부호 정규화와 함께 선택하는 것이다. 이것이 바로 ”정책금리를 마지막에 둔다”는 것을 모호한 지시가 아니라 잘 정의되고 계산 가능한 지시로 만들어 준다. Σ 의 어떤 사후 추출값이 주어지더라도, 그 콜레스키 인자 C 는 여러 개의 동등하게 타당한 후보 중 하나가 아니라 단 하나의 특정 행렬이다.

유도: 충격반응의 사후분포

목표는 2,000개의 시뮬레이션된 충격반응 경로를, (Φ, Σ) 추출값의 2,000개 결정론적 부산물로서가 아니라 충격반응 그 자체의 사후분포로부터 얻은 정확한 몬테카를로 추출값으로 취급하는 것을 정당화하는 데 있다.

1. **정의.** 아래 알고리즘의 충격-비충격 차분 공통난수 시뮬레이션으로 계산되는, 시계(horizon) t 에서의 충격반응을 $IR^{(t)} = g_t(\Phi, \Sigma, u_0, \{\varepsilon_s\})$ 로 나타내자. 이는 계수 추출값 (Φ, Σ) , 고정된 구조적 충격 u_0 , 그리고 공유되는 미래 교란항의 수열 ε_s 의 결정론적 함수이다.
2. **푸시포워드(pushforward) 논증.** (Φ, Σ) 가 11장의 사후분포 $p(\Phi, \Sigma | Y)$ 로부터 추출되었다면, 고정된 u_0 와 공유된 $\{\varepsilon_s\}$ 의 임의의 실현값에 대해 $IR^{(t)}$ 그 자체가 확률변수이다. 그리고 g_t 가 확률벡터 (Φ, Σ) 에 적용되는 고정된 결정론적 사상이므로, 그 분포는 정확히 g_t 를 통한 $p(\Phi, \Sigma | Y)$ 의 푸시포워드이다. 즉 임의의 집합 A 에 대해 $P(IR^{(t)} \in A) = P((\Phi, \Sigma) \in g_t^{-1}(A))$ 가 성립한다.

3. **몬테카를로 일치성.** 유지된 깃스 추출값으로부터 임의의 사후 함수를 요약하기 위해 이 노트 전체에서 사용해 온 것과 동일한 몬테카를로 논리에 의해(예를 들어 11장의 컴패니언 행렬 고유값을, 해석적으로 유도하는 대신 Φ 의 각 사후 추출값에서 계산했던 것처럼), 어떤 분포로부터 얻은 M 개의 추출값 각각에 고정된 결정론적 함수를 적용하면 그 분포의 푸시포워드로부터 얻은 M 개의 정확한 몬테카를로 추출값이 산출된다.

4. **적용.** 따라서 2,000개의 유지된 추출값 $(\Phi^{(m)}, \Sigma^{(m)})$, $m = 1, \dots, 2000$ 각각에서 g_t 를 계산하면, $IR^{(t)}$ 의 사후분포로부터 얻은 정확한 몬테카를로 추출값인 2,000개의 추출값 $IR^{(t),(1)}, \dots, IR^{(t),(2000)}$ 가 산출된다.

따라서 이들의 경험적 분위수는 그림 45에 그려진 사후 신용구간을 일치추정한다. 이 단계에서는 새로운 메트로폴리스-헤이스팅스나 깃스 단계가 전혀 필요하지 않다. 정확히 g_t 가 (Φ, Σ) 그 자체를 넘어서는 어떠한 추가적인 잠재모수도 요구하지 않기 때문이다 — 이는 이미 손에 있는 추출값에 대한 순수한 후처리(post-processing)일 뿐이다.

12.3 공통난수 몬테카를로를 통한 충격반응

그림 44는 이 계산을 목록이 아니라 흐름으로 정리한 것이다. 동일한 무작위 교란항이 두 경로 모두를 이끌기 때문에, 끝에서 그 둘을 차분하면 서로 다른 단 하나의 충격을 제외한 모든 것이 상쇄된다.




Figure 44: 단일 충격반응의 공통난수 구성: 동일한 미래 충격이 두 경로를 모두 이끌기 때문에, 차분 후에는 최초의 구조적 충격 u_0 만이 남는다

알고리즘: 구조적 충격반응

사후 추출값 (Φ, Σ) 와 구조적 충격벡터 u_0 (여기서는 정책금리 방정식에 대한 1표준편차, 즉 100 베이시스포인트 충격: $u_0 = (0, 0, 1)'/C_{33}$)가 주어졌을 때, 미래의 축약형 충격 수열 $e_t = C\varepsilon_t$ 를 정확히 동일하게 사용하여 동일한 초기조건으로부터 두 경로를 앞으로 시뮬레이션한다.

1. **충격 경로.** $Y_1^{(0)} = Cu_0$; 이후 $Y_1^{(t)} = \Phi x_1^{(t)} + e_t$ 이며, 여기서 $x_1^{(t)}$ 은 충격 경로 자신의 시차를 쌓은 것이다.
2. **비충격(반사실적) 경로.** $Y_0^{(0)} = 0$; 이후 동일한 e_t 를 사용하되 비충격 경로 자신의 시차를 사용하여 $Y_0^{(t)} = \Phi x_0^{(t)} + e_t$ 로 둔다.
3. **충격반응.** $IR^{(t)} = Y_1^{(t)} - Y_0^{(t)}$.

두 경로가 동일한 미래 교란항에 의해 구동되므로, 이 둘을 차분하면 이후의 모든 공통 무작위성이

상쇄되어 단일한 최초 충격 u_0 의 한계효과만이 정확히 분리된다 — 이는 (예를 들어 $\Phi^t C u_0$ 를 해석적으로 평균 내는 대신) 분산축소(variance-reduction) 기법이며, 폐형식 충격반응이 존재하지 않는 16–18장의 비선형, 시변 모형에도 변경 없이 그대로 이어진다. 이를 (Φ, Σ) 의 2,000개 사후 추출값에 대해 반복하고 각 시계에서 분위수를 취하면, 사후평균에서의 점추정값뿐 아니라 충격반응의 완전한 사후분포가 산출된다.

12.4 재귀적 식별 아래의 SW 체계

11장이 SW (2001)의 축약형 절반을 재현했다면, 이 절은 같은 (π_t, u_t, R_t) VAR(4)에서 정책금리를 마지막에 두고 그 구조적 절반을 재현한다. 원표본 1960Q1–2000Q4와 2026Q1까지의 전체표본 양쪽에 서다.

실증 예제: 100bp 정책충격, 원표본 1960Q1–2000Q4

공통난수 알고리즘을 2,000개의 사후 추출값에 적용하고 충격 시점에 정책금리가 100bp 상승하도록 정규화하면 그림 45를 얻는다. OLS 기반의 결정론적 충격반응을 겹쳐 그렸는데 베이지안 사후 중앙값과 시각적으로 구별되지 않으며, 이는 11장의 계수 비교가 예고한 그대로이다. 두 가지 특징이 SW의 구조적 논의를 직접 재현한다. 첫째, 실업률은 교과서적인 지연된 봉우리로 반응한다. 충격 시점에는 사실상 영(재귀적 시점 가정 그 자체)이었다가 시계 8, 즉 충격 후 만 이 년에 +0.194퍼센트포인트로 정점을 찍고 서서히 잦아든다. SW는 자신들의 통화 실험에 대해 정확히 이 형태와 지연을 서술한다. 금리 인상이 만드는 통화의 노동시장 효과는 대부분 둘째와 셋째 해에 도착한다는 것이다. 둘째, 인플레이션은 충격 직후 오히려 상승하여(시계 1에서 +0.246포인트) 대략 일 년 반 동안 양(+)에 머문 뒤에야 지속적으로 음(-)으로 내려간다(긴 시계에서 약 -0.2포인트).





Figure 45: SW VAR(4)의 재귀적 식별, 원표본: 정책금리를 마지막에 둔 100bp 정책금리 충격에 대한 사후 중앙값, 68%와 95% 구간, OLS 겹쳐 그림

참고: 가격 퍼즐

긴축적 통화충격에 대한 인플레이션의 상승 반응은 긴축이 물가를 식혀야 한다는 예측에 정면으로 어긋나며, 이 특정 추정치 산물도 아니다. 이는 소규모 재귀 식별 통화 VAR에서 오래도록 기록되어 온 규칙성으로, 아이켄바움(Eichenbaum, 1992)이 “가격 퍼즐(price puzzle)”이라 이름 붙였고 심즈(Sims, 1992)와 Christiano, Eichenbaum, and Evans (1999)가 분석했다. SW 자신의 퍼즐 논의가 곧 표준적 설명이다. 세 변수 체계는 연준이 미래 인플레이션을 선제하여 금리를 올릴 때 사용하는 전향적(forward-looking) 정보(원자재 가격지수가 전통적인 예이다)를 반응함수에 보여줄 방법이 없으므로, 재귀적 방안은 선제적 긴축과 뒤이은 인플레이션 사이의 상관을 긴축 그 자체의 효과로 잘못 귀속시킨다. 표준적 처방은 재귀적 식별 자체를 불신하는 것이 아니라 체계에 원자재 가격을 추가하는 것인데 — 아래에서 재현하는 Uhlig (2005)의 여섯 변수 모형이 정확히 그렇게 한다. 이 절의 작은 체계를 그대로 둔 것은 이 잘 알려진 실패 양상이 감춰지지 않고 눈에 보이게 하기 위해서이다.

실증 예제: 같은 충격, 전체표본 1960Q2-2026Q1

동일한 실험을 전체표본에서 다시 수행하면(그림 46) 큰 형태는 유지되지만, 세부는 11장의 그래프 인저 인과 결과를 그대로 반영하는 방식으로 달라진다. 실업률 봉우리는 살아남되 더 늦게, 조금 더 작게 도착한다. 정점은 SW 표본의 이 년 대신 충격 후 사 년(시계 16, +0.181포인트)이다. 그리고 가격 퍼즐은 오히려 악화된다. 충격 연도의 인플레이션 반응이 +0.262포인트로 커지고, 중앙값 인플레이션 경로는 이제 표시된 어느 시계에서도 의미 있게 영 아래로 내려가지 않는다. 사반세기의 새 자료는 재귀적 방안의 “통화정책 충격”을 더 통화정책 충격답게 만들어 주지 않았다. 해석은 11장과 같다. 2001-2026년의 분기들은 두 차례의 ZLB 국면, 사전적 정책방향 제시(forward guidance), 양적완화를 정책금리 방정식에 섞어 넣으므로, 콜레스키 방안이 정책충격이라 이름 붙이는 잔차 변동은 갈수록 퍼즐을 낳는 선제적 성분이 된다(이로부터 자라난 현대 식별 문헌은 Ramey (2016)가 개관한다). 이것이 단일한 기계적 순서에 기대지 않는 식별 방안(이 장의 나머지가 다루는 주제)에 대해 이 장이 내놓을 수 있는 가장 강력한 실증적 동기이다.



12.5 고정된 순서를 넘어서: 부호제약과 영제약

콜레스키 방안은 실제 비용을 치르고서 유일하게 계산 가능한 B 를 얻는다. 연구자가 $n!$ 가지 가능성 중 하나의 특정한 인과순서를 선택해야 하며, 12.4절의 가격 퍼즐은 재귀적 형태가 얼마나 강하게 특정한 (때로는 틀린) 인과적 서사를 이후의 모든 숫자에 새겨 넣을 수 있는지를 보여준다. 대안적인 식별 노선인 부호제약과 영제약(sign and zero restrictions, Faust, 1998; Uhlig, 2005; Rubio-Ramírez, Waggoner, and Zha, 2010; Arias, Rubio-Ramírez, and Waggoner, 2018)은 단일한 B 를 확정하는 것 자체를 포기한다. 대신 후보 B 가 함의하는 충격반응이 경제이론이 확신하는 소수의 부호와 일치하기만을 요구하며(예를 들어 긴축적 정책충격은 정책금리를 상승시켜야 하고 물가를 하락시켜서는 안 된다는 것), 유일한 답을 강제하는 대신 그러한 부호와 부합하는 모든 회전을 받아들인다.

회전에 대한 탐색으로 다시 서술한 식별 문제 12.1절에서 B 가 직교행렬의 우측공범에 대해서만 식별됨을 상기하자. $BB' = \Sigma$ 이면 임의의 직교행렬 $Q(QQ' = I_n)$ 에 대해 $(BQ)(BQ)' = BQQ'B' = BB' = \Sigma$ 이므로, 그러한 어떤 Q 에 대해서도 BQ 는 동등하게 타당한 구조적 충격행렬이다. $B = C$ (콜레스키)로 고정하는 것은 단일한 Q 를 선택하는 한 가지 방법이다 — 구체적으로는, 12.2절의 유일성 결과에 의해 CQ 를 하삼각행렬로 만드는 유일한 Q 이다. 부호제약은 대신 직교행렬 Q 의 전체 공간(동등하게는, CQ 의 각 열이 후보 충격의 충격벡터이므로 가능한 모든 구조적 충격의 전체 공간)을 탐색하여, 함의된 충격반응이 원하는 부호 패턴을 만족하는 회전을 찾고, 그것을 만족하는 것은 유지하고 만족하지 않는 것은 버린다 — 단일한 결정론적 답 대신 허용되는 답들의 집합을 얻는 것이다.

유도: 직교군에서 Q 를 균등하게 추출하기

”모든” 직교행렬 Q 를 탐색하려면 직교군(orthogonal group) $O(n)$ 에서 Q 를 균등하게(하르-균등, Haar-uniformly) 추출할 수 있어야 하는데, 이는 보기보다 자동으로 되는 일이 아니다.

1. **구성.** i.i.d. $N(0, 1)$ 원소를 갖는 $n \times n$ 행렬 X 를 추출하고, 그 QR 분해 $X = QR$ 을 취한다. 여기서 Q 는 직교행렬이고 R 은 상삼각행렬이다.
2. **문제점.** Q 하나만으로는 아직 하르-균등이 아니다. 분해 $X = QR$ 은 부호 규약이 고정되었을 때만(예를 들어 R 의 대각원소가 양(+))이어야 한다는 요구) 유일하며, 표준적인 QR 루틴(LAPACK 포함)은 그러한 규약을 강제하지 않는다. 따라서 그것들이 반환하는 Q 의 각 열의 부호는 균등하게 추출되는 것이 아니라 R 의 대응하는 대각원소의 임의적인 부호에 묶여 있다.
3. **해결책 (Stewart, 1980; Rubio-Ramírez et al., 2010).** $D = \text{diag}(\text{sign}(R_{11}), \dots, \text{sign}(R_{nn}))$ 을 ± 1 의 대각행렬로 두고, Q 를 QD 로 대체한다. $D' = D$ 이고 $DD = I_n$ 이므로,

$$(QD)(QD)' = QDD'Q' = Q(DD)Q' = QQ' = I_n,$$

이므로 QD 자체가 직교행렬이며, 다시 $DD = I_n$ 을 이용하면

$$(QD)(DR) = Q(DD)R = QR = X,$$

가 성립하고, 교정된 삼각인자 DR 은 D 의 구성에 의해 $(DR)_{ii} = D_{ii}R_{ii} = \text{sign}(R_{ii})R_{ii} = |R_{ii}| > 0$ 인 엄격하게 양인 대각원소를 갖는다.

4. **결론.** 진정으로 $O(n)$ 위에서 하르-균등인 것은 QR 루틴이 반환하는 원본의, 부호가 임의적인 Q 와 R 이 아니라, 이렇게 부호가 교정된 QD (이제는 표준적인(canonical) 삼각인자 DR 과 짝지어진)이다.

이는 콜레스키 인자에 대한 12.2절의 유일성 논증과 정확히 유사하다. 삼각인자의 대각원소에 부호 규약을 고정하는 것이 그렇지 않으면 모호했을 분해를 잘 정의된 것으로 만들어 주는데, 여기서는 Q 그 자체를 유일하게 만들기 위해서가 아니라 Q 에 대한 표집분포를 잘 정의되도록 만들기 위해 사용된다.

알고리즘: 부호제약 구조적 VAR

목표 충격의 부호 패턴(여기서는: 긴축적 정책충격은 시계 $h = 0, \dots, H - 1$ 에서 i_t 를 상승시켜야 하고 π_t 를 상승시켜서는 안 된다)과 사후 추출값 (Φ, Σ) 가 주어졌을 때:

1. **후보 회전.** Σ 의 콜레스키 인자 C 를 계산하고, 하르-균등 $Q \in O(n)$ 을 추출하며(앞의 proof-box 참조), 후보 구조행렬 $B = CQ$ 를 구성한다.
2. **후보 충격.** B 의 각 열 B_j 는 후보 단위 구조충격의 충격벡터이다. 정책금리 반응이 충격 시점에 음(-)이 아니도록 필요하면 부호를 뒤집는다(이는 제약이 아니라 정규화이다).
3. **검사.** $h = 0, \dots, H - 1$ 에 대해 B_j 에 대한 결정론적 VAR 충격반응을 계산하고, 그 시계들 전 부에서 i_t 의 반응이 ≥ 0 이고 π_t 의 반응이 ≤ 0 인 경우에만 이 회전을 유지한다.
4. **반복.** B 의 어떤 열도 제약을 만족하지 않으면 새로운 Q 를 추출하여 다시 시도한다(최대 시도 횟수까지). 이 (Φ, Σ) 에 대해 어떤 시도도 성공하지 못하면, 그 사후 추출값은 채택된 회전을 하나도 기여하지 않는다.
5. **사후 추출값에 걸친 반복.** 유지된 다수의 (Φ, Σ) 추출값을 순환하며, 각각이 최대 하나의 채택된 충격반응을 기여함으로써 부호로 식별된 충격반응의 경험적 분포를 축적한다.

참고: 영제약: 기각표집이 작동을 멈추는 이유

부호제약은 정확한 영(0) 제약(예: "산출은 통화충격에 대해 해당 분기 내에는 반응하지 않는다")으로 보완될 수 있지만, 위의 알고리즘은 정확히 영에 도달하지 못하는 추출값도 기각하도록 단순히 확장할 수는 없다 — Q 의 연속표집 아래에서는 정확히 영에 도달할 확률 자체가 영이므로, 소박한 기각표집은 모든 추출값을 하나도 남김없이 기각하게 될 것이다. 아리아스, 루비오-라미레스, 웨고너(Arias, Rubio-Ramírez, and Waggoner, 2018)는 대신 영제약을 Q 의 구성 자체에 직접 새겨 넣는다. Q 의 각 열은 단위구(unit sphere) 전체가 아니라, 그 충격에 적용되는 어떠한 영제약에 대해서도 직교인 더 낮은 차원의 부분공간으로부터 추출된다(일련의 하우스홀더(Householder) 반사를 통해 열별로 구성되며, 각 반사는 이전 열들에 이미 부과된 제약만큼 허용 가능한 부분공간을 축소시킨다). 그 결과 모든 추출값이 구성상 영제약을 정확히 만족하며, 부호 제약만이 여전히 기각으로 검사되어야 한다. 그 메커니즘은 위의 하르-균등 proofbox를 직접 일반화한 것이다($O(n)$ 전체가 아니라 제한된 부분공간으로부터, 그러나 여전히 균등하게 추출한다는 점에서) 그리고 부호제약만을 사용하는 아래의 실증 예제에서는 수행되지 않는다.

12.6 Uhlig (2005)

위의 부호제약 방법론을, 그것을 표준으로 만든 논문에서 재현한다. Uhlig (2005), "What Are the Effects of Monetary Policy on Output? Results from an Agnostic Identification Procedure"(Journal of Monetary Economics 52(2))이다. SW (2001) 스스로도 식별 문제 논의를 마무리하며 바로 이 연구 노선(부등식 제약만으로부터의 추론(Faust, 1998; 당시 원고로 유통되던 Uhlig의 논문))을 재귀적 방안의 자의성에서 벗어나는 건설적인 출구로 지목했다. Uhlig의 설계는 의도적인 거절 위에 세워져 있다. 긴축적 통화정책 충격은 이론이 확신하는 것들로 정의된다(충격 후 여섯 달 동안($h = 0, \dots, 5$) 연방기금금리는 하락하지 않고, GDP 디플레이터와 원자재 가격은 상승하지 않으며, 비차입지준(nonborrowed reserves)은 증가하지 않는다) 반면 논문이 정작 알고자 하는 두 반응, 실질 GDP와 총지준은 완전히 제약 없이 남겨진다. 그러면 채택된 회전들이 산출에 관해 말하는 것은 무엇이든 가정이 아니라 발견이 된다. Uhlig의 헤드라인 결과는 산출 반응이 모호하다는 것이다. 통화 긴축 후 GDP가 오른다고 함의하는 허용 회전과 내린다고 함의하는 허용 회전의 수가 대략 비슷하다.

체계는 여섯 변수의 월별 VAR(12)이다(실질 GDP, GDP 디플레이터, 원자재 가격지수, 비차입지준, 총지준, 연방기금금리로, 앞의 다섯 개는 $100 \times \log$ 수준(level)) 1965:1–2003:12에 대해 거의 평탄한 사전분포로, 추세 제거 없이, 논문과 정확히 동일하게 추정한다.² 각 후보 사후 추출값(Φ, Σ)에 대해 네 부호제약을 모두 만족하는 열이 나올 때까지 하르-균등 회전을 짝지으며, 그 추출값은 채택된 충격반응 경로 하나를 기여한다. 충격 크기는 1 표준편차이고 재정규화는 하지 않는다. 논문의 관례 그대로이다.

실증 예제: 원표본 1965:1–2003:12

그림 47는 여섯 반응을 보여준다. 제약된 변수들은 마땅히 그래야 하는 대로 움직인다(정책금리는 충격 시점에 약 0.20퍼센트포인트 오른 뒤 잦아들고, 디플레이터와 원자재 가격은 지속적으로 하락하며, 지준은 감소한다) 그러나 결과는 제약 없는 GDP 패널이다. 그 중앙값 반응은 충격 시점에 오히려 약하게 양(+)이고(+0.04), 오 년까지의 모든 시계에서 ± 0.1 안에 머물며, 구간은 내내 영을 걸치고 있다. 채택된 회전 중 GDP 반응이 양인 비중은 충격 시점 0.77, 일 년 0.60, 이 년에서는 정확히 0.50이다 — 분포가 "효과 없음"을 중심으로 양쪽 부호에 상당한 질량을 두고 있는 것이

²사반세기가 지난 지금 불가피한 두 가지 자료 근사를 밝혀 둔다. 원자재 가격지수는 전품목 생산자물가지수(FRED PPIACO)로 대리하는데, Uhlig가 사용한 Commodity Research Bureau 지수의 해당 가공 계열이 더 이상 실시간으로 배포되지 않기 때문이다. 또 월별 실질 GDP와 디플레이터 값은 분기 계열을 분기 중앙월에 고정된 로그 선형 보간으로 얻는데, 이는 분기 집계량을 월별로 보간한 논문 자신의 방식과 같은 정신이다.

다. 이것이 Uhlig의 헤드라인 그림이자 발견이다. 자료에 불가지론적 제약을 더한 것만으로는 긴축이 산출을 낮춘다는 결론이 강제되지 않으며, 재귀 식별 연구들의 자신만만한 산출 하락은 그만큼 자료가 아니라 재귀적 가정의 산물이었다는 것이다.




Figure 47: Uhlig (2005) 재현: 부호제약된 긴축적 정책충격(1 표준편차)에 대한 반응, 원표본. 음영 띠는 제약이 걸린 시계 $h = 0-5$ 를 표시하며, GDP와 총지준은 제약이 없다.

실증 예제: 가용한 전체표본 1965:1-2007:12

Uhlig의 체계를 앞으로 연장하는 일은 교훈적인 벽에 부딪힌다. 2007:12까지만 갈 수 있는 것이다. 식별이 비차입기준에 기대고 있는데, 2008년 초에 그 계열이 음수가 된다(기간입찰대출(TAF) 공급이 총지준을 넘어섰기 때문이다) 따라서 그 로그가, 그리고 그와 함께 Uhlig의 설정 자체가 존재하기를 멈춘다. 그 후에 일어난 일은 아래 remark에서 다룬다. 가용한 사 년의 추가 자료에서 재현의 결론은 변하지 않는다. GDP 중앙값 반응은 충격 시점 $+0.04$, 이 년 부근에서 약하게 음(-0.03)으로 내려가고, 그 시계에서 양(+)의 GDP 회전 비중은 0.44 이다 — 절반을 다소 밀돌지만, 자신 있는 산출 하락과는 거리가 멀다(그림 48). 눈에 띄게 넓어진 지준 반응 구간은 표본이 자신의 끝을 조용히 예고하는 신호다. 지준 수요는 이미 식별이 기대는 안정적 관계에서 멀어져 가고 있었다.




Figure 48: 비차입지준이 음수가 되기 직전 달인 2007:12까지 추정된 동일한 부호제약 체계: 산출에 관한 불가지론적 결론은 변하지 않는다

참고: 이 재현이 현재까지 도달할 수 없는 이유

이 노트의 다른 모든 실증 장은 논문의 표본을 현재 분기까지 연장한다. 이 장은 그럴 수 없으며, 그 이유 자체가 식별에 관한 교훈이다. Uhlig의 제약은 비차입지준을 통화정책의 의미 있는 여백(연준이 정책금리를 움직일 때 조정하는 수량, 그래서 긴축이 그것을 증가시켜서는 안 되는 변수)으로 취급한다. 그 서술은 1965–2007년의 통로(corridor) 체계에는 들어맞았다. 2008년 10월, 연준이 지준부리(interest on reserves)를 시작하고 연이은 양적완화를 거쳐, 은행이 필요로 하는 것보다 몇 자릿수 큰 지준 위에서 정책금리를 행정적으로 조향하는 충분지준(ample-reserves) 체계로 이행하면서 그 서술은 들어맞기를 멈추었다. 비차입지준 자체가 2008년에 음수가 된 것도 위기 대출기구의 공급이 지준에서 차감 계상되었기 때문이다. 그런 세계에서 “긴축은 비차입지준을 늘리지 않는다”는 부호제약은 참도 거짓도 아니고 그저 과녁을 벗어나 있다 — 그 변수가 더 이상 식별 가정이 말하는 정책 여백을 측정하지 않는 것이다. 일반적 교훈은 이 논문을 훌쩍 넘어선다. 식별 가정은 행렬에 관한 진술이기 이전에 제도에 관한 진술이며, 제도가 바뀌면 만료될 수 있다. 현대의 통화충격 문헌은 정책 발표 전후의 고빈도 금융시장 서프라이즈로부터의 식별로 응답했는데(Ramey (2016)가 이 전개를 개관한다), 그 방식은 지준에 관한 가정을 전혀 필요로 하지 않는다.

13. 대형 베이지안 VAR와 미네소타 사전분포

11장과 12장은 식별과 추정을 방대한 모수 개수라는 추가적 복잡성 없이 연구할 수 있도록 VAR를 의도적으로 세 변수로 작게 유지했다. 이 장은 그러한 단순화를 건너내고, Banbura, Giannone and Reichlin(2010)의 131개 변수 월별 데이터셋 위에서 n 이 실제로 커질 때 무슨 일이 일어나는지를 묻는다. 13.1절은 변수 수의 증가가 애초에 왜 문제가 되는지를 정량화하고, 13.4절은 $n = 3$ 에서는 축소(shrinkage)가 아직 거의 중요하지 않음을 (BGR 자신의 보정 절차를 통해) 확인하며, 13.5–13.6절은 n 이 수백에 이르렀을 때 축소를 실제 해법으로 만드는 장치(더미 관측치, 적합도에 맞춘 강도 조정)를 구축한다. 이어서 13.7절은 자연스러운 후속 질문, 즉 축소 모수 λ 자체를 보정(calibrate)해야 하는지 아니면 추정해야 하는지를 묻는데, 이는 8장이 어떤 회귀변수가 모형에 포함되어야 하는지에 대해 물었던 질문과 동일하며, 이번에는 k 개의 이전 지시변수 대신 단일 조정 모수에 적용된다. 13.8절은 이를 계수 단위 축소로 한 걸음 더 밀어붙이며, 13.9절은 세 가지 답 중 실제로 무엇이 가장 잘 예측하는지를 직접 물으며 이 장을 마무리한다.

11장과 12장은 VAR를 세 변수, 두 시차, 방정식당 $k = 7$ 개 회귀변수로 작게 유지했다. 응용 거시경제 예측자들은 통상 더 많은 변수(더 많은 부문, 더 많은 국가, 더 많은 금융지표)와 더 풍부한 동학을 포착하기 위한 더 많은 시차를 원하지만, 변수가 하나 늘어날 때마다 모든 방정식에 하나가 아니라 $O(n)$ 개의 새로운 회귀변수가 추가되는데, 이는 각 방정식의 회귀변수 목록이 모든 변수의 모든 시차로 구성되기 때문이다. 이 장의 실증 프로그램 전체(모든 표, 모든 그림, 모든 보정)는 이제 Banbura, Giannone and Reichlin(2010, Journal of Applied Econometrics 25:71–92, 이하 BGR)의 원본 재현 데이터셋 위에서 돌아간다: Stock and Watson(2005)의 131개 월별 미국 거시-금융 계열 패널, 1959년 1월–2003년 12월, 저자들이 직접 공개한 재현 코드에서 가져왔으며 BGR 자신의 시차 차수 $p = 13$ 으로 추정한다.

참고: 감사의 말

이 장의 대형 BVAR 실증 프로그램 전체(데이터셋, 변수 그룹화, 더미 관측치 추정량, 적합도-맞춤 보정 규칙)는 교과서적 서술이 허용하는 한 최대한 충실하게 Banbura, Giannone and Reichlin(2010)을 따르며, 재구성이 아니라 저자들이 공개한 재현 파일을 그대로 사용한다. 이 노트의 이전 판은 독립적으로 구축한 25개 변수 분기별 패널을 사용했으나, 이번 판에서는 이 장의 모든 숫자를 원칙적으로 BGR 자신의 발표된 Table 1과 대조 검증할 수 있도록 그 패널을 원저자들의 월별 데이터로 대체한다. 전사, MATLAB에서 Python으로의 번역, 서술상 남아 있을 수 있는 오류는 전적으로 현재 저자의 책임이다.

그런 다음 “대형(Large)” 베이지안 VAR가 실제로 무엇을 위한 것인지를 수행한다. BGR과 De Mol, Giannone and Reichlin(2008)을 따라, BGR 자신의 SMALL/MEDIUM/LARGE 단계 구성을 그대로 사용하여 시스템을 세 단계로 키운다(**SMALL**($n = 3$: 전체 비농업부문 고용, CPI 인플레이션, 연방기금금리) BGR의 세 가지 핵심 예측 목표), **MEDIUM**($n = 20$, BGR 자신이 선정한 “핵심 거시경제 지표” — SMALL의 세 계열에 실질소득, 실질소비, 산업생산, 설비가동률, 실업률, 신규주택착공, 민감 원자재 가격지수, PCE 물가디플레이터, 생산자물가, 시간당평균임금, M1과 M2, 총지급준비금과 비차입지급준비금, S&P 500 지수, 10년 만기 국채수익률, 무역가중 달러환율을 추가), **LARGE**($n = 131$, Stock-Watson 패널 전체) — 그리고 축소로 규율된 대형 시스템이 세 개의 이름 붙은 목표변수를 소형 시스템보다 더 잘 예측하는지를 묻는데, 이때 전체 축소 강도는 BGR 자신의 적합도-맞춤(Fit-matching) 규칙에 따라 각 크기마다 재보정되어 한 모형이 다른 모형보다 단순히 더 느슨한 표본내 적합을 허용받는데서 비교가 왜곡되지 않도록 한다. 이것이 LBVAR에 대한 실제 실증적 근거이며, 이번에는 다른 패널로 근사한 것이 아니라 저자들 자신의 데이터 위에서 재현한 것이다.

13.1 VAR에서의 차원의 저주

참고: “대형” VAR가 어려운 이유

n 개 변수를 갖는 VAR(p)는 방정식당 $k = 1 + np$ 개의 회귀변수를 가지므로, 기울기·절편 모수만으로도 그 개수는 $n \cdot k = n(1 + np)$ 이며, 여기에 오차항 공분산 Σ 가 $n(n + 1)/2$ 개의 추가 자유 원소를 더한다. BGR 자신의 월별 시차 차수 $p = 13$ (대략 1년치 월별 동학)은 이 노트 다른 곳에서 쓰이는 분기별, 네 시차 시스템보다 훨씬 빠르게 이 수를 키운다: 총 모수 개수는 $n = 3$ (SMALL)에서 126개, $n = 20$ (MEDIUM)에서 5,430개, $n = 131$ (LARGE, 표 1)에서 231,870개로 증가한다 — p 를 고정했을 때 n 에 대해 대략 이차적으로, n 을 고정했을 때 p 에 대해 선형적으로 증가하는데, 이는 n 개 방정식 각각이 시차마다 n 개의 새로운 회귀변수를 얻기 때문이다. 수백 개 관측치에 불과한 월별 거시 표본으로는 무제약 최소제곱법으로 25만 개에 가까운 자유 모수를 결정하기에 전혀 미치지 못한다. 이것이 바로 Litterman의 원래 축소 제안을 촉발한 전형적인 차원의 저주이며, BGR 자신의 논문이 존재하는 이유도 축소가 n 을 얼마나 밀어붙일 수 있는지를 보여주기 위함이다.

	SMALL ($n = 3$)	MEDIUM ($n = 20$)	LARGE ($n = 131$)
$k = 1 + np$ (방정식당 회귀변수)	40	261	1,704
$n \cdot k$ (기울기+절편)	120	5,220	223,224
$+ n(n + 1)/2$ (Σ)	6	210	8,646
총 모수	126	5,430	231,870

Table 1: Banbura, Giannone and Reichlin 자신의 SMALL/MEDIUM/LARGE 시스템에 대한 VAR(p) 총 모수 개수 $n(1 + np) + n(n + 1)/2$, 월별 시차 차수 $p = 13$ 고정

이 장의 표본외(out-of-sample) 실습(13.6절)에서 사용되는 LARGE 시스템에서 이 압박은 진정으로 심각해진다: 131개 방정식 전체에 걸쳐 총 223,224개의 기울기·절편 계수가, 매년 재추정 시 이용 가능한 관측치 하나당 거의 1,900개의 기울기 모수를 요구하는 롤링 120개월(10년) 윈도우 위에서 추정된다 — 무제약 OLS는 방정식별로 부정확할 뿐 아니라 흔히 유일하게 정의조차 되지 않는 영역이다 ($k = 1,704$ 개 회귀변수인데 윈도우당 유효 관측치는 120개에 못 미친다). 평탄 사전분포는 이 정도 크기의 시스템을 전혀 규율할 수 없다. 13.6절은 BGR의 더미 관측치 축소 사전분포가 이를 어떻게 바로 잡는지, 그리고 λ 가 텍스트북 기본값에 고정되는 대신 n 이 커짐에 따라 어떻게 낮아지도록 보정되는지를 정확히 보여준다.

13.2 미네소타(Litterman) 사전분포

알고리즘: 미네소타 사전분포의 구성

Doan, Litterman and Sims (1984)과 Litterman (1986)을 따라, 미네소타 사전분포는 gibbs_sur이 이미 받아들이는 정규 사전평균 b_0 와 (대각) 공분산 B_0 에 직접 두 가지 믿음을 부과하며, 표본추출기(sampler) 자체에는 아무런 변경도 가하지 않는다.

- 1. 임의보행(random-walk) 사전평균.** 각 변수 자신의 시차 1 계수는 0이 아니라 1에 중심을 둔다: 개별 거시 계열은 사전적으로 백색잡음보다 임의보행에 더 가깝다고 본다. 그 밖의 모든 기울기 계수(교차변수 계수, 그리고 시차 2 이상의 자기변수 계수)는 0에 중심을 둔다.

2. 시차에 따라 감쇠하고 척도로 조정되는 축소. 방정식 i 에서 변수 j 의 시차 ℓ 계수에 대한 사전 분산은

$$\text{Var} = \begin{cases} (\lambda_1/\ell^{\lambda_3})^2 & i = j \\ (\lambda_1\lambda_2/\ell^{\lambda_3})^2 \cdot \sigma_i^2/\sigma_j^2 & i \neq j, \end{cases}$$

여기서 σ_i^2 는 변수 i 단독에 적합한 단변량 $\text{AR}(p)$ 의 잔차분산(사전적 척도 추정치로서, OLS로 한 번 계산됨)이고, λ_1 은 전체 강도(tightness), $\lambda_2 < 1$ 은 자기변수 시차보다 교차변수 시차를 더 공격적으로 축소하며, λ_3 은 시차 길이가 늘어남에 따라 사전분포가 얼마나 빨리 조여지는지를 결정한다. 이 장은 표준 교과서 값인 $\lambda_1 = 0.2$, $\lambda_2 = 0.5$, $\lambda_3 = 1$ 을 사용한다. 절편은 변수에 무관하게 100이라는 느슨한 사전분산을 유지한다.

b_0 와 B_0 가 평범한 깁스 표본추출기 입력이므로, 미네소타 사전분포 VAR을 추정하는 데는 이 두 대상을 구성하는 것 외에 새로운 코드가 전혀 필요하지 않다 — 10-12장에서 사용된 동일한 `gibbs_sur` 루틴이 변경 없이 그대로 호출된다.

13.3 사후분포 유도

미네소타 사전분포는 10.2절의 유도가 고정된 기지 상수로 취급하는 입력값 (b_0, B_0)만을 바꿀 뿐, 유도 $p(Y | \beta, \Sigma)$ 나 완전조건부분포를 만들어낸 대수적 단계에는 아무런 변화도 주지 않는다. 10.2절의 $\beta | \Sigma, Y$ 증명을 다시 살펴보면 이를 직접 확인할 수 있다: b_0 와 B_0 는 그 유도에서 완전제곱식의 항 $B_0^{-1}b_0$ 와 B_0^{-1} 에 나타나는 사전평균과 사전정밀도 B_0^{-1} 로만 등장하며, 그 유도는 b_0, B_0 가 고정된 벡터와 고정된 양의 정부호 행렬이라는 사실 외에 다른 어떤 성질도 사용하지 않는다 — 이는 (대각) 미네소타 B_0 와 임의보행에 중심을 둔 b_0 도 다른 어떤 선택과 마찬가지로 정확히 만족하는 성질이다. 마찬가지로 $\Sigma | \beta, Y$ 의 유도는 β 의 사전분포를 전혀 참조하지 않았다. 따라서

$$\begin{aligned} \beta | \Sigma, Y &\sim N(\bar{\beta}, \bar{B}), & \bar{B} &= \left(B_0^{-1} + \sum_t Z_t' \Sigma^{-1} Z_t \right)^{-1}, & \bar{\beta} &= \bar{B} \left(B_0^{-1} b_0 + \sum_t Z_t' \Sigma^{-1} Y_t \right), \\ \Sigma | \beta, Y &\sim IW(S_0 + E' E, \nu_0 + T) \end{aligned}$$

는 미네소타 사전분포 아래에서도 10.2절과 문자 그대로 동일한 증명으로 성립하며, 단지 b_0 가 이제 임의보행에 중심을 둔 평균벡터이고 B_0 가 위 알고리즘 상자의 시차감쇠·교차변수축소 대각 공분산행렬로, 평탄 사전분포의 $b_0 = 0$, $B_0 = \text{diag}(100 \text{ 절편, 그 외 } 1)$ 를 대체한다는 점만 다르다. 이것이 바로 위 알고리즘 상자가 새로운 깁스 단계를 전혀 필요로 하지 않는 이유다: 이미 유도된 사후분포에 다른 수치의 (b_0, B_0)를 대입하는 것은 사전분포 입력값의 변경이지, 새로운 유도를 요구하는 변경이 아니다.

13.4 고정된 소규모 시스템: 축소가 정말로 중요한가?

13.1절은 이미 $n = 3$ 이 차원의 저주 측면에서 비교적 온건한 경우임을 지적했다: 모수는 겨우 126개뿐이며, BGR 자신의 SMALL 시스템은 방정식당 40개 회귀변수만 사용한다. 아래에서 온전히 다루어지는 LBVAR에 대한 실제 실증적 근거는 n 이 커질 때 무슨 일이 벌어지는지에 관한 것이다. 하지만 그보다 좁은, 선행하는 질문을 먼저 점검할 가치가 있다: $n = 3$ 을 고정한 채, 축소는 조금이라도 무언가를 바꾸는가, 아니면 이 규모에서는 무제약 OLS로도 이미 충분한가?

실증 예제: BGR 자신의 적합도-맞춤 절차가 $n = 3$ 에서 직접 답한다

아래 13.5절은 더미 관측치 사전분포의 전체 강도 λ 를 크기별로 따로 보정하는데, 고정된 표본내 적합 목표에 대한 격자 탐색을 통해 이루어진다. 이를 BGR의 SMALL 시스템($n = 3$: 전체 비농업 부문 고용, CPI 인플레이션, 연방기금금리)에 1960년 2월-1970년 1월 사전평가 훈련구간에서 적용하면, 이 보정 절차는 $\lambda = \infty$ (무제약 OLS)를 SMALL 자신의 목표 표본내 적합에 가장 잘 맞는 강도로 선택한다. 이는 애초에 SMALL이 목표 적합도 Fit^* 자체를 정의하는 모형이기 때문에 당연한 결과다(13.5절 알고리즘 참조). 방정식당 $k = 40$ 개 회귀변수와 수십 년치 월별 훈련표본을 놓고 볼 때, $n = 3$ 은 아직 13.1절이 정량화한 차원의 저주와 씨름할 만큼 크지 않다: 여기서 미네소타류 사전분포가 바로잡을 것은 사실상 거의 없으며, 데이터셋을 BGR로 전환하기 전 이 절이(다른 n 에서, 다른 데이터셋으로) 이 노트의 11-12장 분기별 VAR에서 도달했던 것과 동일한 정성적 결론을, 이번에는 BGR 자신의 보정 절차를 통해 직접 확인한 것이다 — 그리고 아래 상자의 평탄-대-미네소타 직접 대결로 한 번 더 점검한다.

실증 예제: $n = 4$ 에서의 직접 대결: 평탄 대 미네소타, 롤링 예측

BGR의 보정 장치에 전혀 기대지 않는 교차 점검으로, 네 변수 분기별 VAR(4)(GDP 성장률, CPI 인플레이션, 실업률, 연방기금금리, 1959Q3-2026Q1)를 2008Q2 이후 모든 예측 시작점(64개, 확장 윈도우)에서 두 번 재추정한다: 한 번은 평탄 사전분포로, 한 번은 13.2절의 미네소타 사전분포로. 점예측 RMSFE는 다음과 같다:

	$h=1$		$h=8$	
	평탄	미네소타	평탄	미네소타
GDP 성장률	7.71	7.30	6.19	6.24
CPI 인플레이션	3.41	2.80	2.95	2.76
실업률	1.64	1.45	2.25	2.24
연방기금금리	1.08	0.56	2.50	2.25

$h = 8$ 에서 두 사전분포는 모든 변수에서 몇 퍼센트 이내로 붙어 있다(GDP 성장률에서는 오히려 평탄 사전분포가 근소하게 앞선다): $n = 4$ 에 수백 개의 분기 관측치가 있으면 자료가 이미 OLS를 충분히 규율하며, 이는 방금 적합도-맞춤 상자가 다른 경로로 도달한 결론과 같다. 눈에 띄는 예외 하나는 단기의 지속성이다: $h = 1$ 에서 연방기금금리의 RMSFE는 미네소타 사전분포 아래에서 절반으로 떨어지는데, 평가 구간이 2008Q2에 열려 제로금리 하한(ZLB) 시기가 대부분을 차지하기 때문이다. 이 시기에 사전분포의 임의보행 중심화는 다음 분기 예측을 현재의 (영 근처) 금리에 붙들어 두는 반면, 무제약 OLS는 계속 위로 평균회귀를 예측한다. 그림 49은 그런 시기 밖에서는 두 예측 경로가 거의 구별되지 않음을 확인해 준다: $n = 4$ 에서 축소는 구원이 아니라 완만한 보정이며, 아래의 $n = 131$ 결과를 읽을 때의 기준선이 바로 이것이다.

Ch.13: rolling 1-quarter-ahead point forecasts, flat vs. Minnesota VAR(4)




Figure 49: 평탄 및 미네소타 사전분포 아래 순환 1분기 점예측, $n = 4$ 분기별 VAR(4), 2008Q2부터 64개 확장-윈도우 시작점; 두 경로는 가장 변동성이 큰 분기에서만 눈에 띄게 갈라진다

참고: n 이 작을 때 축소는 거의 불필요에 가깝다

교훈은 이전에도 (다른 데이터셋, 다른 n 에서) 이 노트이 이미 전달한 것과 동일하다: 수백 개의 월별 관측치로 이루어진 훈련표본을 겨우 126개의 총 모수와 견주면, $n = 3$ 에서 OLS는 이미 자료에 의해 충분히 잘 규율된다. 이는 n 이 13.1절이 정량화한 BGR 자신의 MEDIUM(5,430개 모수)과 LARGE(231,870개 모수) 규모로 커지면 완전히 달라지는데, 이것이 바로 이 장의 나머지 부분이 답하는 질문이며, BGR 자신의 적합도-맞춤 규칙(13.5절)이 SMALL의 $\lambda = \infty$ 에 고정되어 머무르지 않고 n 이 커짐에 따라 λ 를 가파르게 낮추는 이유이기도 하다.

13.5 더미 관측치 구현과 적합도에 맞춘 축소

13.2절의 고전적 미네소타 사전분포는 (b_0, B_0) 를 gibbs_sur에 대입하고 MCMC로 추정한다 — 위의 소규모 시스템 예시에는 정확하고 충분하지만, 이는 Banbura, Giannone and Reichlin (2010)이 진정으로 대형 시스템에 대해 사전분포를 실제로 구현하고 보정하는 방식이 아니며, 그들의 핵심 주장을 검증 가능하게 만드는 방식도 아니다. 크기 문제를 제대로 답하려면 두 가지가 필요하다: MCMC를 전혀 실행하지 않고 수백 개의 모수를 가진 모형을 추정하는 방법, 그리고 각 크기에서 λ 가 얼마나 조여져야 하는지에 대한 원칙적인 규칙 — 교과서 기본값에 고정하는 대신. 이 절은 이 두 가지를 모두 유도한다.

알고리즘: 정규-역위사트 사전분포를 위한 더미 관측치

1. VAR를 다변량 회귀 $Y = XB + U, Y (T \times n), X (T \times k), k = 1 + np$ 로 쓰고, 계수행렬과

오차공분산에 결합적으로 정규-역위사트 사전분포를 부과한다:

$$\underbrace{\text{vec}(B)}_{\text{계수}} \mid \Sigma \sim N(\text{vec}(B_0), \Sigma \otimes \Omega_0),$$

$$\underbrace{\Sigma}_{\text{오차공분산}} \sim iW(S_0, \alpha_0).$$

2. Banbura 외 (2010, 식 4-5)가 이 사전분포를 정확히 재현함을 보인, 세 개의 블록으로 쌓인 $T_d = n(p+1) + 1$ 개의 더미 관측치 (Y_d, X_d) 를 구성한다:

$$Y_d = \begin{pmatrix} \text{diag}(\delta_1 \sigma_1, \dots, \delta_n \sigma_n) / \lambda \\ 0_{n(p-1) \times n} \\ \text{diag}(\sigma_1, \dots, \sigma_n) \\ 0_{1 \times n} \end{pmatrix} \quad X_d = \begin{pmatrix} J_p \otimes \text{diag}(\sigma_1, \dots, \sigma_n) / \lambda & 0_{np \times 1} \\ 0_{n \times np} & 0_{n \times 1} \\ 0_{1 \times np} & \varepsilon \end{pmatrix}$$

여기서 $J_p = \text{diag}(1, 2, \dots, p)$, σ_i^2 는 계열 i 의 $\text{AR}(p)$ 잔차분산(13.2절과 동일한 사전적 척도 추정치)이며, ε 은 절편에 사실상 평탄한 사전분포를 부여하는 아주 작은 수다. 첫 블록은 각 계열 자신의 첫 시차 계수를 δ_i 에 중심을 두어, 분산이 λ 와 시차 길이에 따라 줄어들게 한다. 둘째 블록은 Σ 의 사전 척도를 고정한다. 셋째 블록은 절편을 규율하지 않은 채로 둔다.

3. $Y^* = (Y', Y_d')'$, $X^* = (X', X_d')'$ 로 쌓고, 이 증강된 시스템에 OLS를 수행하여 MCMC 없이 사후분포를 직접 얻는다:

$$\hat{B} = (X^{*'} X^*)^{-1} X^{*'} Y^*,$$

$$\hat{\Sigma} = (Y^* - X^* \hat{B})' (Y^* - X^* \hat{B}),$$

$$\text{vec}(B) \mid \Sigma, Y \sim N(\text{vec}(\hat{B}), \Sigma \otimes (X^{*'} X^*)^{-1}).$$

4. 두 극한을 해석한다: $\lambda \rightarrow \infty$ 일 때 첫 블록의 행들은 사라지고 $\hat{B}$ 는 실제 자료만에 대한 OLS로 정확히 환원되며, $\lambda \rightarrow 0$ 일 때는 B 가 사전평균에 고정된다. 이 닫힌 형태(위의 고전적 깃스 표본추출기가 아니라)가 Banbura 외가 대형 시스템에 대해 실제로 사용하는 것이며, 아래의 보정을 계산적으로 가능하게 만드는 것이다.

참고: δ_i 선택하기: BGR 자신의 관행을 그대로

BGR은 Stock and Watson(2005)의 코딩 체계에서 정상화를 위해 1차 또는 로그 차분이 필요하다고 분류되는 모든 계열($\text{tcode} \in \{2, 5, 6\}$ — 패널의 거의 모든 실물경제·물가 계열이 여기 속하며, 이들은 $I(1)$ 로 취급된다)에 $\delta_i = 1$ (임의보행)을, Stock and Watson이 수준 또는 로그수준에서 이미 정상적이라고 코딩한 계열($\text{tcode} \in \{1, 4\}$ — 금리와 소수의 비율형 계열)에 $\delta_i = 0$ (백색 잡음)을 부여한다. 결정적으로, 이 장은 그와 함께 오는 덜 눈에 띄는 관행 또한 그대로 물려받는다: 모든 변수는 $\delta_i = 1$ 인 계열조차도 성장률이나 인플레이션율로 사전에 차분되지 않고 수준 또는 로그수준 그대로 VAR에 들어간다. 이는 의도적인 모형화 선택이지 실수가 아니다 — Litterman의 원래 임의보행 사전분포는 단위근에 가까운 거동을 다루는 일을 딱딱한 사전 변환이 아니라 바로 사전분포 자체가 하도록 설계되었으며, BGR 자신의 발표된 결과도 수준 자료 위에서 나온 것이

다. 이 장은 이제 이 관행을 저자들 자신의 자료 위에서 정확히 그대로 따르며, 이전 판에서 쓰였던 균일 $\delta_i = 0.5$ -사전차분-패널 관행은 사용하지 않는다.^a

^a한 가지 결과는 숨기지 않고 분명히 말할 필요가 있다: 사전평균 자체가 대부분 계열에서 정상성 영역의 경계 ($\delta_i = 1$)에 정확히 놓이기 때문에, 이 장의 (앞선 판의) 분기별 패널에 사용했던 엄격한 $\rho < 1$ 기각추출은 여기서는 적절치 않다: 실제로 13.7절의 위계적 사전분포 아래 MEDIUM 시스템에서 개별 Gibbs 표본추출의 80% 이상이 동반행렬 스펙트럼 반경 $\rho \geq 1$ 을 지니는데, 이는 단순히 사전평균이 $I(1)$ 로 분류된 모든 변수의 자기동학을 경계 위에 놓기 때문이다. 이 장은 따라서 정상성을 기각추출로 제거하는 대신, BGR 자신의 더미 관측치 추정량(역시 정상성을 강제하지 않는다)을 따라 정직한 진단 지표로 보고한다.

알고리즘: 적합도에 맞춘 전체 강도(Banbura 외 2010, 3절, p. 77)

Banbura 외의 핵심 주장은 “ n 이 커지면 일단 미네소타 사전분포를 추가한다”가 아니라, 모든 모형 크기가 동일한 표본내 적합을 달성하도록 λ 가 n 이 커짐에 따라 감소해야 한다는 것이다.

1. 사전평가 훈련표본 $t = 1, \dots, T_0 - 1$ 에서, 그 동일 표본에서 한 번 추정된 $\hat{B}$ 를 사용하여, 강도 λ 에서 모형 m 의 목표 i 에 대한 표본내 일단계 적합 MSFE를 정의한다:

$$\text{msfe}_i^{\lambda, m} = \frac{1}{T_0 - p - 1} \sum_{t=p}^{T_0-2} \left(\underbrace{\hat{y}_{i,t+1|t}}_{\text{강도 } \lambda \text{에서의 적합값}} - \underbrace{y_{i,t+1}}_{\text{실현값}} \right)^2,$$

그리고 동일한 방식으로 임의보행-표류 벤치마크로부터 계산한 유사한 msfe_i^0 를 정의한다.

2. 강도 λ 에서 모형 m 의 적합도(Fit), 그리고 목표 적합수준에 맞는 강도 λ_m 을 정의한다:

$$\text{Fit}(\lambda, m) = \frac{1}{|I|} \sum_{i \in I} \frac{\text{msfe}_i^{\lambda, m}}{\text{msfe}_i^0}, \quad \lambda_m = \arg \min_{\lambda} |\text{Fit}(\lambda, m) - \text{Fit}^*|,$$

여기서 I 는 세 개의 이름 붙은 목표변수의 집합이고, 목표 적합도 Fit^* 는 항상 가장 작은 모형에서 $\text{OLS}(\lambda = \infty)$ 가 달성하는 적합도로 고정된다: $\text{Fit}^* = \text{Fit}(\infty, \text{SMALL})$.

3. 이분법(bisection)으로 λ_m 을 구한다: $\text{Fit}(\lambda, m)$ 은 λ 에 대해 단조 감소하므로(자유도가 커지면 훈련표본을 더 잘 적합하므로) 근은 유일하다.
4. 이것이 왜 축소를 시스템 크기에 맞추어 조정하도록 강제하는지 주목하라: 더 큰 m 은 고정된 어떤 λ 에서도 Fit 을 Fit^* 아래로 손쉽게 떨어뜨릴 수 있으므로(자유모수가 많을수록 원자료 표본내 적합이 좋아지는, 즉 과적합), Fit^* 에 맞추는 것은 n 이 커짐에 따라 λ_m 을 아래로 밀어낸다 — 시스템 크기에 맞추어 조정되는 축소가 사후적으로 덧붙인 것이 아니라 메커니즘 자체다. 이 보정은 후보 λ 마다, 모형마다 선형 해 하나만 필요하며, 이는 위의 닫힌 형태 사후분포 덕분에만 가능한 것이다. 고전적 깁스 표본추출기의 접근법 아래에서는 격자점마다 완전한 gibbs_sur MCMC 실행이 필요했을 것이며, $n = 131$ 에서의 λ 탐색은 실행 불가능했을 것이다.

13.6 전체 비교: $n = 3, 20, 131$ 에 걸친 적합도-맞춤 축소

이는 BGR 자신의 대표 실습을, 그들 자신의 데이터 위에서 재현한 것이다: 세 가지 모형 크기를 세 개의 이름 붙은 예측 목표변수(전체 비농업부문 고용, CPI 인플레이션, 연방기금금리)에 계열을 추가하여 만든다 — **SMALL**($n = 3$, 이름 붙은 계열만), **MEDIUM**($n = 20$, 이 장 서두에서 나열한 BGR 자신의 열일곱 개 추가 “핵심 거시경제 지표”), **LARGE**($n = 131$, Stock-Watson 패널 전체). 시차 차수는 전체에 걸쳐 BGR 자신의 월별 $p = 13$ 이며, 평가구간도 BGR 자신의 것이다: $T_0 = 120$ 개월(10년) 롤링 재

추정 구간, 예측 시작점은 1971년 1월부터 2003년 1월까지, 시계는 $h = 1, 3, 6, 12$ 개월이다.

참고: $n = 20$ 이 이미 이득의 대부분을 포착하는 이유

BGR 자신의 논문은 이 절의 결과가 직접 확인해 주는 질문을 이미 예상하고 있다: MEDIUM($n = 20$, 13.1절의 표 1) 대비 LARGE($n = 131$)의 엄청난 추가 모수는 그만큼 가치가 있는가? 그들 자신의 결론은 아니오이며(“스무 개의 핵심 거시경제 지표로 이루어진 중간 규모 시스템만으로도 이미 좋은 성능을 얻는다”) 아래 숫자도 목표변수별로 이를 뒷받침한다: LARGE는 고용에서는 명확히, 인플레이션에서는 완만하게 MEDIUM을 이기지만, 연방기금금리에서는 $h = 3-6$ 에서 둘이 사실상 동률이고 $h = 12$ 에서는 MEDIUM이 명확히 더 낫다(아래 RMSFE 표). Koop(2013)의 독립적인 168변수 크기 확장 연구도 다른 패널에서 동일한 정성적 결론에 도달한다: 각 크기에서 축소가 제대로 보정되었을 때, 잘 축소된 20변수 VAR가 달성 가능한 예측 이득의 대부분을 포착하며, n 을 더 늘려도 체감하고 때로는 부(-)의 한계 수익을 낳는다는 것이다. n 을 20에서 131로 키우는 것은 적합도-맞춤 축소 아래에서도 공짜가 아니다: 실재하지만 목표변수에 따라 다른 개선을 얻는 것이지, 일률적인 향상을 얻는 것이 아니다.

실증 예제: n 이 커짐에 따라 보정된 강도가 하락한다

사전평가 구간(1960년 2월-1970년 1월, BGR 자신의 보정 표본)에서 $\text{Fit}^* = \text{Fit}(\infty, \text{SMALL}) = 0.660$ (소형 모형에 대한 OLS는 훈련표본을 순진한 임의보행-표류 벤치마크의 표본내 MSFE의 66.0%로 적합)에 맞추어 적합도를 맞추면 다음을 얻는다:

	SMALL ($n=3$)	MEDIUM ($n=20$)	LARGE ($n=131$)
λ_m	∞ (OLS)	0.099	0.032
$\text{Fit}(\lambda_m, m)$	0.660	0.660	0.660

n 이 커짐에 따라 축소가 단조롭게 조여지며, 이는 정확히 BGR의 주장과 일치하고, 구성상 모든 모형 크기가 동일한 표본내 적합에 도달한다 — 따라서 아래에서 보고되는 어떤 차이도 한 모형이 단순히 다른 모형보다 훈련자료를 더 잘 혹은 더 못 적합했다는 데 귀속시킬 수 없다. 그림 50은 동일한 패턴을 BGR 자신의 중간 크기인 CEE($n = 7$, Christiano-Eichenbaum-Evans 변수 집합)에서도 보여주어, λ 가 세 개의 대표 크기 사이에서만 뛰는 것이 아니라 매끄럽게 하락함을 확인한다.




Figure 50: 변수 개수 n 에 대한 적합도-맞춤 전체 강도 λ (λ 축은 로그 척도), BGR 자신의 SMALL/CEE/MEDIUM/LARGE 크기: 표본내 적합을 $\text{Fit}^* = 0.660$ 으로 고정한 채 시스템이 커질수록 축소가 단조롭게 조여진다

실증 예제: 임의보행-표류 벤치마크 대비 표본의 RMSFE

λ_m 을 그 보정값에 고정한 채, 각 모형은 1971년 1월부터 2003년 1월까지 모든 예측 시작점에서 120개월 롤링 윈도우로 재추정되며, 예측은 BGR 자신이 보고하는 것과 정확히 동일한 시계 집합인 $h = 1, 3, 6, 12$ 개월 앞에서 평가된다. $\text{RMSFE}_{i,h}^m$ 은 모형 m 의 평균제곱예측오차를 그 해당 시점의 동일한 임의보행-표류 벤치마크의 평균제곱예측오차로 나눈 비율이다(1 미만의 값은 순진한 벤치마크를 이긴다는 뜻; 전체 시계별 분해는 그림 51에 있다):

	$h=1$	$h=3$	$h=6$	$h=12$
고용				
SMALL	1.144	0.946	1.107	1.017
MEDIUM	0.538	0.509	0.664	0.870
LARGE	0.455	0.381	0.503	0.797
CPI 인플레이션				
SMALL	0.895	0.655	0.636	0.811
MEDIUM	0.497	0.404	0.393	0.465
LARGE	0.498	0.396	0.395	0.435
연방기금금리				
SMALL	1.863	1.764	2.078	2.547
MEDIUM	0.779	0.948	1.295	1.468
LARGE	0.753	0.943	1.288	1.920

이는 단일 공유 강도 시스템이 흔히 내놓는 것보다 훨씬 깔끔한 그림이다: SMALL에서 MEDIUM으로 커지는 것은 모든 목표변수를 모든 시계에서 개선하며, 흔히 절반 이상 개선한다(고용의 $h = 1$

RMSFE는 순진한 벤치마크보다 나빴던 1.144에서 0.538로 떨어지고, 연방기금금리는 1.863에서 0.779로 떨어진다). LARGE로 더 키우는 것은 고용을 계속 개선하고 인플레이션을 완만하게 개선하지만, 연방기금금리에서는 LARGE의 이점이 사라진다: $h = 3-6$ 에서는 MEDIUM과 사실상 동률이고, $h = 12$ 에서는 명확히 더 나쁘다($1.468 \rightarrow 1.920$) — 이는 정확히 위 remark가 예고한 “ $n = 20$ 이 이미 이득의 대부분을 포착한다”는 패턴이 이제 평균이 아니라 목표변수별로 확인된 것이다.




Figure 51: BGR의 세 헤드라인 목표변수에 대해 모형 크기와 시계별로 본, 임의보행-표류 벤치마크 대비 MSFE; 점선 아래의 막대는 순진한 벤치마크를 이긴다

실증 예제: 적합도-맞춤 비교가 실시간으로는 어떻게 보이는가

위의 RMSFE 표는 385개 예측 시작점을 몇 개의 평균값으로 압축한 것이다. 그림 52은 바로 그 실습 중 1개월($h=1$) 부분을 시작점별로 그대로 펼쳐 보여준다. 세 시스템 모두 1971년 1월부터 2003년 1월까지 모든 시작점에서 120개월 롤링 윈도우로 재추정되며, 각자 위에서 보정한 자신의 적합도-맞춤 λ 를 사용한다(SMALL은 $\lambda = \infty$, 즉 축소 없는 OLS; MEDIUM은 $\lambda = 0.099$; LARGE는 $\lambda = 0.032$). 385개 시작점 전체에 걸친 원시 $h = 1$ 평균제곱근오차는 다음과 같다:

	SMALL ($n=3$)	MEDIUM ($n=20$)	LARGE ($n=131$)
고용(천 명)	0.273	0.187	0.172
CPI(지수 포인트)	0.284	0.212	0.212
연방기금금리(%)	0.916	0.592	0.582

지속성이 강한 월별 계열에서는 세 예측 경로를 겹쳐 그려 봐야 시각적으로 거의 구별되지 않으므로, 그림 52은 그 대신 SMALL 대비 누적 제곱오차 차이를 그린다:

$$\text{CSSED}_t^{(m)} = \sum_{s \leq t} [e_{\text{SMALL},s}^2 - e_{m,s}^2], \quad m \in \{\text{MEDIUM, LARGE}\}.$$

어느 날짜 t 에서 곡선의 기울기가 위를 향하면 그 시점에 큰 모형이 SMALL을 이기고 있다는 뜻이고, 평평한 구간은 둘이 비긴다는 뜻이며, 마지막에 도달한 높이가 누적된 총 우위다. 두 가지가 한 눈에 보인다. 첫째, 두 곡선 모두 음영 구간(1973-75년 오일쇼크 경기침체와 1979-82년 볼커 디

스인플레이션)에서 가파르게 상승하고 그 밖에서는 비교적 평평하다: 큰 패널은 세 변수 시스템이 참고할 것이 거의 없는, 변동성이 크고 구조적으로 정보가 풍부한 시기에 정확히 우위를 벌어들이며, 이때 횡단면(에너지 가격, 통화량, 지급준비금, 수익률곡선)이 진짜 신호를 담는다. 둘째, 회색(MEDIUM) 곡선과 어두운(LARGE) 곡선 사이의 수직 간격이 $n = 20$ 을 넘는 111개 변수의 한계 가치인데, CPI 인플레이션과 연방기금금리에서는 두 곡선이 사실상 포개져 있고($h = 1$ RMSFE가 0.212로 동률이고, 0.592 대 0.582로 2% 이내다), 고용에서만 눈에 보이는 간격이 열리며 그것도 거의 전부 1980년대 초에 쌓인 것이다. 잘 선택된 중간 규모 시스템이 이미 달성 가능한 이득의 대부분을 포착한다는 BGR의 발표된 결론을, 자료에서 시작점별로 직접 읽어낸 셈이다.




Figure 52: SMALL($n = 3$) 대비 누적 제곱오차 격차, 1개월 예측, 385개 예측 시작점 전체(1971년 1월-2003년 1월): SMALL-MEDIUM(회색)과 SMALL-LARGE(암적색); 기울기가 위를 향하면 그 시점에 큰 시스템이 이기고 있다는 뜻이고, 두 곡선 사이의 간격은 $n = 20$ 을 넘는 111개 변수의 한계 기여다; 음영 구간은 1973-75년 오일쇼크와 1979-82년 볼커 디스인플레이션

참고: 이것이 진정한 LBVAR 비교인 이유

13.4절은 고정된 소규모 변수 집합에서 축소가 도움이 되는지를 물었고, BGR 자신의 보정 절차는 아니라고 답했는데, 이는 세 변수 시스템이 평탄 사전분포가 아직 파국적이지 않을 만큼 충분히 작기 때문이다. 이 절은 BGR가 실제로 묻는 질문을 묻고, 그들과 정확히 같은 방식으로 답한다: 구성에 의해(적합도-맞춤) 표본내 적합을 고정하고, n 이 커짐에 따라 λ 가 하락하도록 두며, 누구든 실제로 관심 있어 하는 변수들의 표본외 예측이 개선되는지 점검한다. BGR 자신의 자료 위에서, 답은 어정쩡한 절충보다 상당히 더 명확하다: $n = 3$ 에서 $n = 20$ 으로 커지는 것은 모든 헤드라인 목표변수를 모든 시계에서 개선하며, $n = 131$ 로 더 커지는 것은 세 목표변수 중 두 개를 더 개선하는 동시에 나머지 하나(연방기금금리)는 장기 시계에서 완만하게 악화시킨다 — 이는 점점 더 커지는 패널로부터 일관된 예측을 얻으려면 축소가 단지 나타나는 것이 아니라 조여져야 한다는 De Mol, Giannone and Reichlin (2008)의 공식적 결과와 일치하며, 잘 선택된 중간 규모 시스템이 이미 달성 가능한 이득의 대부분을 포착한다는 BGR 자신이 발표한 결론과도 일치한다. 단일하고 공유된 강도 모수가 이를 전달하기에 충분히 정교한지, 아니면 자료가 실제로 서로 다른 계수군을 서로 다른 정도로 축소하기를 원하는지는 13.7절의 위계적 사전분포가 직접 다루는 질문이다.

13.7 확장: 저자 자신의 코드로부터 추정된 위계적 사전분포

적합도-맞춤은 λ 를 사후분포 바깥에서 선택되어 보조적 기준(모형 크기에 걸쳐 동일한 표본내 적합)을 만족시키는 조정 모수로 취급한다. Giannone, Lenza and Primiceri (2015)는 대신 강도 모수들을 그

자체의 사전분포와 사후분포를 가진 모형의 진정한 모수로 취급한다 — 보정에 대한 완전히 베이지안적인 대안으로, 8장의 스파이크-앤-슬랩 변수선택과 같은 위계적 정신을 공유한다.³ 이 절은 이러한 사후분포를, 삼각형(triangular) 방정식별 재구성(Carriero, Clark and Marcellino 2019)에 대해 닫힌 형태로 유도하는데, 자기시차·교차변수·동시적·절편이라는 네 개의 개별 강도 초모수 $\kappa_1, \kappa_2, \kappa_3, \kappa_4$ 가 각각 사전분산에 선형으로 들어간다. 이를 이 장 자체의 SMALL, MEDIUM, LARGE 시스템에 적용하여 “축소가 얼마나 강해야 하는가”에 대한 두 경로를 직접 비교할 수 있도록 한다. 그림 53는 이것이 만들어내는 의존 구조를 미리 보여주는데, 이는 8장의 스파이크-앤-슬랩 DAG와 구조적으로 동일한 허브 패턴이다: 네 개의 강도 초모수 중 한 쌍(κ_1 , 자기시차; κ_2 , 교차변수 — 이 절의 핵심 결과가 다루는 대상)이 그곳에서 γ 가 맡았던 역할을 맡아, 자료와 모든 방정식의 계수 사이에 놓인다.




Figure 53: 위계적 사전분포의 의존 구조: 자기시차·교차변수 강도 (κ_1, κ_2)는 8장의 스파이크-앤-슬랩 DAG(그림 30)에서 γ 가 맡았던 것과 동일한 허브 역할을 여기서 맡는다; 절편·동시적 강도 (κ_4, κ_3)도 동일한 패턴을 따르며 가독성을 위해 생략했다

알고리즘: 미네소타 사전분포의 위계적·삼각형 버전

1. n 개 변수의 순서를 정하고(이 장 전체에서 쓰인 것과 동일한 순서), 방정식 $i = 1, \dots, n$ 을 구조적, 삼각형 형태로 쓴다. 즉 모든 변수의 첫 p 개 시차뿐 아니라 변수 $1, \dots, i-1$ 을 동시적으로도 포함한다:

$$y_{i,t} + \sum_{j < i} \alpha_{i,j} y_{j,t} = c_i + \sum_{\ell=1}^p \sum_{j=1}^n B_{i,\ell,j} y_{j,t-\ell} + u_{i,t}, \quad u_{i,t} \sim N(0, \sigma_i^2),$$

방정식마다 독립. 쌓으면 $Ay_t = c + \sum_{\ell} B_{\ell} y_{t-\ell} + u_t$ 가 되는데, 여기서 A 는 단위 하삼각행렬이고(대각 아래에 $\alpha_{i,j}$, $j < i$), 따라서 축약형 계수와 공분산은 $B^{\text{red}} = A^{-1}B$, $\Sigma = A^{-1} \text{diag}(\sigma_1^2, \dots, \sigma_n^2) A^{-\prime}$ 이다 — 11장이 구조적 식별에 쓰는 것과 동일한 콜레스키-재귀적 구성이며, 여기서는 동시에 모든 방정식의 사후분포를 쉼으로 유지하는 장치 역할도 한다.

2. 방정식 i 의 자유 계수를 $\theta_i = (c_i, B_{i,1,\cdot}, \dots, B_{i,p,\cdot}, \alpha_{i,1}, \dots, \alpha_{i,i-1})$ 로 모으고, 각 원소에 평균

³단일 쌍 $(\psi_1, \psi_2) = (\lambda_1^2, \lambda_2^2)$ 가 사전분산에 이차적으로 들어가는 매개변수화를, Σ 가 대각이고 동시적 계수가 전혀 없는 단순화된 방정식별 시스템 안에서 쓰면 실용적으로 두 가지 문제가 생긴다: 교차변수 초모수의 김스 갱신이 $\lambda_1^2 \lambda_2^2$ 형 결합 매개변수화 아래에서 자기시차 초모수와 별도로 식별되지 않으며, 동시적(콜레스키) 계수가 없는 대각- Σ 시스템은 아래의 안정성-제약 기각추출을 이 장이 다루는 패널 크기에서 병적으로 느리게 만들지 않고는 지탱할 수 없다. 이 절은 대신 실제 대형-BVAR 연구 코드베이스(베이지안 VAR의 확률적 변동성 변수선택에 관한 Song and Kang의 작업논문)의 매개변수화를 따른다: 네 개의 초모수가 삼각형 시스템 안에서 선형으로 들어가는 방식이다.

m_i , 분산 V_i (대각)인 독립 정규 사전분포를 부과한다:

$$[V_i]_{\ell,j} = \begin{cases} \kappa_4 \sigma_i^2 & \text{절편} \\ \kappa_1 / \ell^2 & \text{자기변수 시차, } j = i \\ \kappa_2 \sigma_i^2 / (\ell^2 \sigma_j^2) & \text{교차변수 시차, } j \neq i \\ \kappa_3 & \text{동시적 } (\alpha_{i,j}, j < i) \end{cases}$$

$$[m_i]_{\ell,j} = \begin{cases} \delta_i & j = i, \ell = 1 \\ 0 & \text{그 외} \end{cases}$$

σ_i^2 는 계열 i 의 $\text{AR}(p)$ 잔차분산이고, 자기시차-1 사전평균 $\delta_i \in \{0, 1\}$ 는 13.5절의 Stock-Watson 분류를 따른다. 교차변수 분산은 κ_2 단독으로 척도가 매겨지지 $\kappa_1 \kappa_2$ 가 아니다: 둘을 곱하면 둘의 역할이 뒤섞여 κ_2 의 깃스 갱신이 κ_1 에 대해 비식별이 된다.

3. 네 개의 강도 모수 모두에 독립적인 감마 초사전분포를, 형태-비율 매개변수화로 $\mathbb{E}[\kappa] = e_1/e_2$ 가 되도록 부과한다:

$$\kappa_1 \sim \mathcal{G}(1, 5), \quad \kappa_2 \sim \mathcal{G}(1, 25), \quad \kappa_3 \sim \mathcal{G}(1, 1), \quad \kappa_4 \sim \mathcal{G}(1, 1),$$

즉 $\mathbb{E}[\kappa_1] = 0.2, \mathbb{E}[\kappa_2] = 0.04$: 교차변수 축소는 자기시차 축소보다 사전적으로 훨씬 강하게 설정되며, 동등하게 확산적이지 않다 — 교과서 기본값이 아니라 저자 자신의 사전적 판단이다.

4. 매 회 표본추출 후 내재된 축약형 동반행렬의 정상성(스펙트럼 반경 $\rho < 1$)을 점검하여, 그렇지 않으면 (κ, σ^2 는 고정된 채) **전체 구조적 표본을 기각하고 다시 뽑는다** — 정확히 13.5절의 기각추출 장치를 달린 형태 NIW 표본이 아니라 깃스 표본에 적용한 것이다. 이것이 여기서 계산적으로 가능한 이유는 특히 삼각형 구조가 κ_2, κ_3 가 조여질 때 축약형 시스템을 안정적이고 약하게 교차결합된 시스템 가까이에 유지하기 때문이다. 동시적 계수가 전혀 없는 대각-Σ 버전은 n 이 두 자릿수에 이르면 거의 모든 표본을 기각하며 이런 방식으로 쓸 수 없다.

유도: $\kappa_1 \mid \theta$ 및 $\kappa_2 \mid \theta$

$\theta = (\theta_1, \dots, \theta_n)$ (모든 방정식의 절편, 시차 계수, 동시적 계수)을 고정하고 np 개의 자기시차 계수를 $S_1 = \{\theta_{\ell,i,i} : \ell = 1, \dots, p, i = 1, \dots, n\}$ 으로 모으면 $|S_1| = np$ 다. 각 $\theta_{\ell,i,i} \mid \kappa_1 \sim N(\delta_i \cdot \mathbb{I}\{\ell = 1\}, \kappa_1 / \ell^2)$ 은 독립이므로, 베이즈 규칙에 의해 S_1 의 우도에 $\mathcal{G}(1, 5)$ 초사전분포를 곱하면 다음 커널을 얻는다:

$$\pi(\kappa_1 \mid \theta) \propto \underbrace{\prod_{(\ell,i,i) \in S_1} \kappa_1^{-1/2} \exp\left(-\frac{\ell^2(\theta_{\ell,i,i} - \delta_i \cdot \mathbb{I}\{\ell = 1\})^2}{2\kappa_1}\right)}_{S_1 \text{의 우도}} \times \underbrace{\kappa_1^0 e^{-5\kappa_1}}_{\mathcal{G}(1,5) \text{ 초사전분포}}$$

$|S_1|$ 개 인자 각각이 동일한 거듭제곱 $\kappa_1^{-1/2}$ 를 기여한다; 이를 모으고, 지수함수들을(같은 밑 κ_1 을 공유하므로) 결합하고, $b_1 := \sum_{(\ell,i,i) \in S_1} \ell^2 (\theta_{\ell,i,i} - \delta_i \cdot \mathbb{I}\{\ell = 1\})^2$ 로 정의하면:

$$\propto \kappa_1^{-\frac{|S_1|}{2}} \exp\left[-\frac{1}{2} \left(10 \kappa_1 + \frac{b_1}{\kappa_1}\right)\right]$$

밀도가 $x^{p-1} \exp\{-\frac{1}{2}(ax + b/x)\}$ 에 비례하는 양의 확률변수 $x > 0$ 은 정의상 일반화 역가우스 분포, $x \sim \text{GIG}(p, a, b)$ 다. $p = 1 - |S_1|/2$, $a = 10$, $b = b_1$ 을 대응시키면

$$\kappa_1 | \theta \sim \text{GIG}\left(1 - \frac{|S_1|}{2}, 10, b_1\right).$$

$|S_2| = np(n-1)$ 개의 교차변수 계수 $S_2 = \{\theta_{\ell,i,j} : j \neq i\}$ 는 κ_2 가 주어졌을 때 정확히 같은 방식으로 조건부 정규이며, 평균 0, 분산 $\kappa_2 \sigma_i^2 / (\ell^2 \sigma_j^2)$ 다 — κ_1 으로 척도가 매겨지지 않으므로, 아래 κ_2 의 완전조건부분포는 κ_1 에 전혀 의존하지 않는다:

$$\kappa_2 | \theta \sim \text{GIG}\left(1 - \frac{|S_2|}{2}, 50, b_2\right), \quad b_2 = \sum_{(\ell,i,j) \in S_2} \ell^2 \frac{\sigma_j^2}{\sigma_i^2} \theta_{\ell,i,j}^2.$$

($\mathcal{G}(1, 25)$ 초사전분포로부터 $a = 2e_{22} = 50$.) 절편 강도 κ_4 와 동시적 강도 κ_3 는 각각 n 개의 절편과 $n(n-1)/2$ 개의 동시적 계수에 동일한 논증을 적용하면 얻어지며, 각각 자신만의 $\mathcal{G}(1, 1)$ 초사전분포를 가진다. 넷 모두 일차원의, 직접 표본추출 가능한 분포다 — 이 깃스 표본추출기 어디에서도 메트로폴리스-헤이스팅스 단계가 필요하지 않다.

이 닫힌 형태는 방정식별 삼각형 표현이 모든 방정식의 우도를 각 κ 의 감마 초사전분포와 켄레로 유지하기 때문에 가능하다. Giannone, Lenza and Primiceri 자신의 처리는 (13.5절의 더미관측치 시스템에서처럼) Σ 를 완전히 자유롭게 두는데, 이는 그들이 한계우도 $p(Y | \lambda)$ 를 직접 다루도록 강제한다. Σ 가 자유로울 때 그 우도는 감마 사전분포와 켄레가 아니므로, 그들은 깃스 추출 대신 $\log \lambda$ 에 대한 임의보행 메트로폴리스-헤이스팅스로 λ 를 표본추출한다. 위의 유도, 자유로운 Σ 를 삼각형 구조와 닫힌 형태 깃스 단계로 맞바꾸는데, 베이지안 VAR에서 확률적 변동성 변수선택에 관한 Song and Kang 자신의 작업논문을 초사전분포 선택까지 포함하여 정확히 따른 것이다.

알고리즘: 위계적·삼각형 사전분포를 위한 깃스 표본추출기

$g = 1, \dots, G$ 에 대해 반복한다:

1. $i = 1, \dots, n$ 에 대해 $\theta_i | \kappa, \sigma^2, y_i \sim N(\hat{\theta}_i, K_i^{-1})$ 를 추출한다(각 방정식의 회귀변수는 공통 시차 블록 X 에 $-y_{1,t}, \dots, -y_{i-1,t}$ 를 더한 것으로, 위 첫 알고리즘 박스의 삼각형 구조다). 결과로 나온 축약형 동반행렬의 정상성을 점검하고, 불안정하면(κ, σ^2 는 고정된 채) **이 단계 전체를 다시 뺀다**.
2. $i = 1, \dots, n$ 에 대해 $\sigma_i^2 | \theta \sim \text{역감마}(a_0 + T/2, b_{0,i} + S_i/2)$ 을 추출한다. $\text{AR}(p)$ 잔차분산 점추정에 중심을 둔 정보적 사전분포(변동계수 0.2)다.
3. $\kappa_1 | \theta \sim \text{GIG}\left(1 - \frac{|S_1|}{2}, 10, b_1\right)$, $\kappa_2 | \theta \sim \text{GIG}\left(1 - \frac{|S_2|}{2}, 50, b_2\right)$, 그리고 κ_3, κ_4 도 유사하게 추출한다.

$K_i, \hat{\theta}_i, b_1, b_2$ 는 위에서 유도된 대로다; 단계 1은 6장의 베이지안 회귀 공식을 방정식마다 한 번씩, 총 n 번 적용한 것이다(아래 remark에서 이 장이 왜 정상성을 강제하는 대신 진단으로 보고하는지

설명한다). 이 장은 BGR의 MEDIUM($n = 20$) 시스템에서 1,200개의 번인 이후 표본을 사용하며, 1959년 1월-1995년 12월($T = 444$ 개월, 이 노트 어디에서도 쓰이지 않은 가장 긴 창)에서 훈련한다. 방정식당 $k = 261$ 개 회귀변수가 이 장 다른 어느 MCMC 시스템보다 훨씬 크기 때문에 필요한 조치다.

실증 예제: 보정이 아니라 추정된 사후 강도

BGR의 MEDIUM 시스템($n = 20$, 방정식당 $k = 261$ 개 회귀변수)에 적용하면:

MEDIUM ($n=20$)	
κ_1 (자기시차), 평균	0.085
κ_1 , 95% 구간	[0.059, 0.119]
κ_2 (교차변수), 평균	0.0047
κ_2 , 95% 구간	[0.0040, 0.0054]
κ_3 (동시적), 평균	0.029
κ_4 (절편), 평균	26.6
λ (적합도-맞춤, § 13.6)	0.099

κ_1 의 완전조건부를 올바르게 구현하려면 주의가 필요하다: 합 b_1 은 자기시차 사전평균(여기서는 $\delta_i \in \{0, 1\}$, 13.5절의 remark)을 시차 $\ell = 1$ 에서만 빼야 하며, 이는 계수를 추출할 때 실제로 쓰는 평균(위 증명 참고)과 일치해야 한다. 모든 시차 $\ell = 1, \dots, p$ 에서 사전평균을 빼는 것은 언뜻 자연스러워 보이지만 모형이 명시하는 바가 아니며, κ_1 을 한 자릿수 정도 부풀린다. $n \cdot p = 260$ 개의 자기시차 계수와 $np(n-1) = 4,940$ 개의 교차변수 계수, 190개의 동시적 계수($n(n-1)/2$)가 모두 단 세 개의 강도 스칼라로 묶여 있음에도, 사후분포는 이 정도 규모의 시스템에 그럴듯한 범위 안에 안정적으로 자리 잡는다: κ_1 의 평균 0.085는 $\mathcal{G}(1, 5)$ 초사전분포 평균인 0.2보다 낮게 자리 잡아 (자기시차 계수는 전체적으로 자신의 δ_i 사전평균에 꽤 가깝게 당겨져 있다), 반면 κ_2 의 평균 0.0047은 κ_1 보다 정확히 한 자릿수 더 강하게 조여져 있다 — 교차변수 계수는 자기시차 계수보다 훨씬 강하게 축소되며, 이는 단일한 공유 적합도-맞춤 λ 로는 구성상 표현할 수 없는 정성적 패턴이다. 하나의 강도를 모든 계수군에 똑같이 적용하기 때문이다.




Figure 54: 위계적 사전분포 아래 κ_1 (자기시차), κ_2 (교차변수), κ_3 (동시적)의 사후 표본, BGR MEDIUM($n=20$) 시스템; 점선은 각 모수의 사후평균을 표시

참고: 단일 공유 λ 대 계수별 축소, 그리고 진정한 안정성 유보 사항

13.6절의 적합도-맞춤 비교는 단일 공유 강도 모수를 사용하여 $n = 3 \rightarrow 20 \rightarrow 131$ 로 키울 때 실질적이고 깔끔하게 정렬된 표본외 이득을 발견했다. 이 절의 결과는 그 이득이 계수군별 축소 아래에서는 훨씬 더 커질 수 있음을 시사하는데, 자료는 자기시차와 교차변수 계수가 서로 매우 다른 정도로 축소되기를 명확히 원하기 때문이다($\kappa_1 = 0.085$ 대 $\kappa_2 = 0.0047$, 약 18배 차이) — 이는 정확히 단일 적합도-맞춤 λ 가 구성상 전달할 수 없는 분할이다. 그러나 이 절 자체의 사후분포에는 얼버무리지 않고 명확히 밝혀야 할 유보 사항이 있다: BGR 자신의 $\delta_i \in \{0, 1\}$ 사전평균이 대부분 계열의 자기동학을 임의보행 경계 바로 위에 놓기 때문에(13.5절의 remark), 여기서 개별 깃스 표본추출의 80% 이상이 동반행렬 스펙트럼 반경 $\rho \geq 1$ (비정상)을 가지며, 이 장은 아래 말편자 사전분포와 동일한 방식으로 이를 기각추출로 제거하지 않고 정직하게 보고한다. 사후평균 축약형 시스템은 다행히도 간신히 안정적이지만($\rho = 0.9997$), 그 사후평균으로부터 만든 다단계 반복 예측은 $\rho = 1$ 경계에 이렇게 가까이 자리 잡은 시스템에서 예상해야 할 만큼 취약하다. 13.9절의 비교는 이 점으로 직접 되돌아간다.

13.8 확장: 말편자(horseshoe) 사전분포

지금까지 이 장의 모든 사전분포는 계수를 범주별로 축소한다: 13.2절의 미네소타 공식은 그 특정 계수가 실제로 중요한지 여부와 무관하게 모든 교차변수 계수를 동일한 λ_2 로 축소하며, 13.7절의 위계적 확장은 $\kappa_1, \dots, \kappa_4$ 를 임의로 만들지만 여전히 각각 하나의 계수군(자기시차, 교차시차, 동시적, 절편) 전체에 걸쳐 풀링된 단 네 개의 숫자일 뿐, 한 군 안에서 계수마다 다르게 움직이지는 않는다. 말편자 사전분포(Carvalho, Polson and Scott, 2010)는 계수별로 축소한다: 한 방정식의 np 개 기울기 계수 각각이 분석가가 부과하는 시차감쇠 공식, 자기/교차 구분, 군집 풀링 없이, 자료로부터 추정되는 자신만의 국소 축소 척도를 가진다. (이 절은 Carvalho, Polson and Scott 자신의 표기를 따라 계수별 국소 척도에도 κ 라는 글자를 재사용한다, $\kappa_{i,j}$ — 13.7절의 네 개 군집-수준 $\kappa_1, \dots, \kappa_4$ 와는 다르며, 첨자가 두 개라는 점으로 구별된다.)

말편자 사전분포 방정식 i 의 기울기 계수 $\theta_i = (\theta_{i,1}, \dots, \theta_{i,np})$ 에 대해(절편은 이 장의 다른 곳과 마찬가지로 평탄한 $N(0, 100)$ 사전분포를 유지한다),

$$\theta_{i,j} \mid \kappa_{i,j}, \tau_i, \sigma_i^2 \sim N(0, \kappa_{i,j}^2 \tau_i^2 \sigma_i^2), \quad \kappa_{i,j} \sim C^+(0, 1), \quad \tau_i \sim C^+(0, 1),$$

여기서 $C^+(0, 1)$ 은 $(0, \infty)$ 위의 표준 반코시(half-Cauchy) 분포다. 모든 계수는 자신만의 국소 축소 척도 $\kappa_{i,j}$ 를 가진다. τ_i 는 방정식 전체가 공유하는 단일 전역 척도로서, 13.7절의 $\kappa_1, \dots, \kappa_4$ 와 비슷한 역할을 하지만 내장된 시차감쇠나 자기/교차 구분은 없다. 계수 j 에 실제로 중요한 것은 곱 $\kappa_{i,j}\tau_i$ 다: 0에 가까우면 $\theta_{i,j}$ 를 거의 영점질량까지 축소하고, 1에 가까우면 $\theta_{i,j}$ 를 사실상 축소하지 않은 채로 둔다. 반코시의 극단적으로 두꺼운 꼬리는 $\kappa_{i,j}$ 가 이따금 큰 값을 취하여 진정으로 중요한 계수를 나머지와 함께 축소되는 것으로부터 구제할 수 있게 한다 — “말편자”라는 이름은 이것이 축소 인자 $\kappa_{i,j}\tau_i/(1 + \kappa_{i,j}\tau_i) \in (0, 1)$ 에 유도하는 U자형(쌍봉) 사전분포를 가리키는데, 이는 0(완전히 축소) 근처와 1(전혀 축소하지 않음) 근처 모두에 질량이 쌓이고 그 사이에는 비교적 질량이 적다.

유도: 반코시 사전분포를 위한 김스 표본추출기

반코시 사전분포는 어떤 것과도 켄레가 아니므로, 언뜻 14장의 GARCH 모수처럼 메트로폴리스-헤이스팅스를 강제하는 것처럼 보인다. Makalic and Schmidt (2016)는 대신 모든 것을 김스 표본추출 안에 유지하는 정확한 척도-혼합 표현을 제시한다:

$$\kappa_{i,j}^2 \mid \zeta_{i,j} \sim IG\left(\frac{1}{2}, 1/\zeta_{i,j}\right), \quad \zeta_{i,j} \sim IG\left(\frac{1}{2}, 1\right) \implies \kappa_{i,j} \sim C^+(0, 1),$$

반코시를 정확히 재현하는 이단계 역감마 혼합이다(4.1절과 같은 합성 발상이지만, 여기서는 감마 위에 정규을 혼합하는 대신 역감마를 다른 역감마 안에 혼합한다). $\zeta_{i,j}$ 를 보조변수로 도입하면 다루기 힘든 반코시 사전분포가 두 개의 평범한 켄레 역감마 완전조건부분포로 바뀐다. τ_i, σ_i^2 를 고정하고 간결하게 $s := \tau_i^2 \sigma_i^2$ 로 쓰면, $\kappa_{i,j}^2$ 에 대한 커널은 단일 계수 $\theta_{i,j}$ 의 정규 우도와 $IG(\frac{1}{2}, 1/\zeta_{i,j})$ 혼합밀도를 결합한다:

$$\pi(\kappa_{i,j}^2 \mid \theta_{i,j}, \tau_i, \zeta_{i,j}) \propto \underbrace{(\kappa_{i,j}^2)^{-1/2} \exp\left(-\frac{\theta_{i,j}^2}{2s \kappa_{i,j}^2}\right)}_{\theta_{i,j} \mid \kappa_{i,j}^2, \text{ 정규 우도}} \times \underbrace{(\kappa_{i,j}^2)^{-3/2} \exp\left(-\frac{1}{\zeta_{i,j} \kappa_{i,j}^2}\right)}_{IG(1/2, 1/\zeta_{i,j}) \text{ 혼합밀도}}$$

$\kappa_{i,j}^2$ 의 두 거듭제곱($-1/2$ 과 $-3/2$ 을 더하면 -2)을 모으고, 동일한 $1/\kappa_{i,j}^2$ 밀을 공유하는 두 지수항을 하나의 지수로 결합하면:

$$\propto (\kappa_{i,j}^2)^{-2} \exp\left[-\frac{1}{\kappa_{i,j}^2} \left(\frac{\theta_{i,j}^2}{2s} + \frac{1}{\zeta_{i,j}}\right)\right]$$

이는 검토해 보면 정확히 $IG(1, \theta_{i,j}^2/(2s) + 1/\zeta_{i,j})$ 의 커널이다($IG(a, b)$ 커널은 $x^{-a-1}e^{-b/x}$ 이며, 여기서 $a = 1$ 이다). 보조변수 $\zeta_{i,j}$ 는 역할을 뒤바꾼 동일한 논증으로 갱신된다(이제 $\kappa_{i,j}^2$ 가 위에서 $\theta_{i,j}^2/s$ 가 맡았던 역할을 맡는다) $\zeta_{i,j} \mid \kappa_{i,j}^2 \sim IG(1, 1 + 1/\kappa_{i,j}^2)$ 를 준다. 전역 척도 τ_i^2 와 그 자신의 보조변수 ξ_i 는 동일한 이단계 논증을 따르며, 방정식 i 의 np 개 계수 전체에 걸친 우도 기여를 한 번에 풀링한다(따라서 형태 모수는 1이 아니라 $(np + 1)/2$ 가 되며, 이는 6.2절의 σ^2 형태를

$a_0/2$ 에서 $(a_0 + T)/2$ 로 올리는 데 T 개의 관측치를 풀링한 것과 정확히 같다):

$$\tau_i^2 \mid \theta_i, \kappa_i, \xi_i \sim IG\left(\frac{np+1}{2}, \frac{1}{\xi_i} + \frac{1}{2} \sum_{j=1}^{np} \frac{\theta_{i,j}^2}{\kappa_{i,j}^2 \sigma_i^2}\right), \quad \xi_i \mid \tau_i^2 \sim IG(1, 1 + 1/\tau_i^2).$$

알고리즘: 말편자 김스 표본추출기(방정식 i 당)

σ_i^2 를 그 $AR(p)$ 잔차분산 점추정치에 고정한 채(13.2절 및 13.7절에서와 같이), 다음을 반복한다:

1. **계수.** $\theta_i \mid \kappa_i, \tau_i, y_i \sim N(\hat{\theta}_i, \hat{V}_i)$ 를 추출한다 — 6.2절의 평범한 켈레 회귀 공식으로, 사전분산 $\text{diag}(100, \kappa_{i,1}^2 \tau_i^2 \sigma_i^2, \dots, \kappa_{i,np}^2 \tau_i^2 \sigma_i^2)$ 을 사용한다.
2. **국소 척도.** $j = 1, \dots, np$ 각각에 대해, $\kappa_{i,j}^2 \mid \theta_{i,j}, \tau_i, \zeta_{i,j} \sim IG(1, \theta_{i,j}^2/(2\tau_i^2 \sigma_i^2) + 1/\zeta_{i,j})$ 를 추출한 다음, $\zeta_{i,j} \mid \kappa_{i,j}^2 \sim IG(1, 1 + 1/\kappa_{i,j}^2)$ 를 추출한다.
3. **전역 척도.** 위의 두 역감마 완전조건부분포로부터 $\tau_i^2 \mid \theta_i, \kappa_i, \xi_i$ 와 $\xi_i \mid \tau_i^2$ 를 추출한다.

모든 방정식 $i = 1, \dots, n$ 에 대해 반복하면 한 번의 스윕이 완성된다. 이 절을 시작할 때 하나가 필요할 것처럼 보였던 반코시 사전분포에도 불구하고, 어디에도 메트로폴리스-헤이스팅스 단계는 나타나지 않는다.

실증 예제: BGR MEDIUM($n = 20$) 시스템에서의 축소 패턴

위 위계적 사전분포에 사용된 것과 동일한 1959년 1월–1995년 12월 훈련구간과 방정식당 $np = 260$ 개 기울기 계수를 사용하여 BGR의 MEDIUM 시스템에 말편자 표본추출기를 적합하면 (1,200개의 번인 이후 표본), 사후평균 축소인자 $\kappa_{i,j} \tau_i$ 가 모든 $20 \times 260 = 5,200$ 개의 기울기 계수 중 98.7%에서 0.1 미만(사실상 영으로 축소)이고, 0.7%에서만 0.5를 넘는다 — 이 노트의 이전, 더 작은 패널에서도 나타났던 것과 동일한 쌍봉의 “말편자” 패턴이 이제 계수 개수가 50배인 시스템에서도 확인된 것이다. 헤드라인 변수 자신의 첫 시차 계수는 무엇이 살아남는지를 보여준다: 고용의 자기시차($\kappa_T = 6.22$), CPI의 자기시차($\kappa_T = 5.68$), 연방기금금리의 자기시차($\kappa_T = 2.43$)는 모두 사실상 축소되지 않고 남아 있다 — BGR 자신의 $\delta_i = 1$ 사전평균이 이미 이 계수들을 임의 보행 근처에 두고 있고, 월별 거시 수준 자료가 실증적으로 월 대 월 극도로 지속적이라는 점을 고려하면 놀랍지 않다. 반면 신규주택착공의 자기시차($\kappa_T = 0.089$)는 거의 영으로 축소되는데, 이미 계절조정된 이렇게 변동성이 큰 계열은 나머지 19개 변수의 횡단면적 정보가 이미 포착하는 것을 넘어서는 자기시차 신호를 거의 담고 있지 않기 때문이다. 어떤 시차감쇠 공식이나 단일 δ_i 분류도 표본추출기에게 이 구분을 기대하라고 알려주지 않았다. 이는 훈련자료만으로부터 발견된 것이다. 위 위계적 사전분포와 마찬가지로, 이 말편자 시스템에도 안정성 기각추출을 다루기 쉽게 만들어 줄 삼각형 동시적-계수 구조가 없지만, 여기서 진단은 훨씬 더 안심할 만하다: 사후평균 계수행렬의 동반행렬 스펙트럼 반경은 0.9992로, BGR 자신의 임의보행 중심 사전평균에도 불구하고 안전하게 정상성 영역 안에 있다 — 말편자의 공격적인 계수별 축소가 위계적 사전분포의 더 거친, 범주 단위 축소는 주지 못하는 진정한 수치적 안정성을 사는 것으로 보이며, 이는 13.9절이 세 사전분포에 걸친 반복 다단계 예측을 비교할 때 직접 되돌아가는 지점이다.

13.9 어느 사전분포가 이기는가? 3자 비교

이 장은 이제 “축소가 얼마나 강해야 하는가”에 대해 세 가지 서로 다른 답을 구축했다: 단일 적합도-맞춤 λ 를 사용하는 BGR 자신의 더미 관측치 미네소타 사전분포(13.5절), 네 개의 범주 단위 강도 초모수를 사용하는 위계적 사전분포(13.7절), 그리고 개별 계수마다 별도의 국소 강도를 사용하는 말편자 사

전분포(13.8절). 세 사전분포 모두 이제 동일한 BGR MEDIUM($n = 20$) 시스템에서, 동일한 1995년 12월 기준 시점까지 훈련되어 추정되었으므로, 이 장에서 처음으로 직접적인 동등 비교가 가능하다: 세 가지를 모두 한 번 적합시켜, 동일한 단일 시점에서 앞으로 예측하고, 실제로 어느 것이 가장 잘 예측하는지 확인하는 것이다.

실증 예제: 단일 시점 예측 비교, 세 사전분포 모두

각 사전분포의 사후평균(BGR-미네소타의 경우 점추정치) 축약형 계수를 사용하여 1995년 12월 훈련 기준 시점에서 반복 다단계 예측을 구성하고, 1996년 12월까지의 실현 경로($h = 1, \dots, 12$, BGR 자신이 보고한 최대 시계) 및 임의보행-표류 벤치마크와 비교한다. 상대 MSFE(모형 MSFE / 임의보행-표류 MSFE, 고용·CPI·기금금리에 걸쳐 평균; 1 미만이면 순진한 벤치마크를 이긴다):

	$h=1$	$h=3$	$h=6$	$h=12$
BGR-미네소타(\$ 13.5)	1.519	1.145	18.764	5.236
말편자(\$ 13.8)	0.680	1.250	1.062	3.418
위계적(\$ 13.7)	0.848	0.793	1.959	1.444

$h = 1$ 에서는 두 유연한 사전분포 모두 순진한 벤치마크를 이기고, 고정 단일- λ 더미 관측치 사전분포는 이기지 못한다. $h = 3$ 에서는 위계적 사전분포가 셋 중 유일하게 벤치마크보다 앞선다. $h = 6$ 에서는 BGR-미네소타가 무너지는데(고용 하나에서 나온 54.4배 벤치마크 MSFE가 18.76이라는 평균을 견인하며, 13.6절의 RMSFE 표가 이미 $h = 6$ 에서의 이러한 단일 시작점 민감성을 미리 보여주었다), 두 유연한 사전분포는 훨씬 완만하게 악화된다. $h = 12$ 에 이르면 위계적 사전분포가 확실히 앞서 나간다(3.42와 5.24 대 1.44). 변수 집합을 MEDIUM으로 고정하고 어느 사전분포가 이를 규율하는지만 바꾸었을 때, 고정 단일- λ 사전분포는 어느 시계에서도 이기지 못하고, 미네소타 범주 구조를 유지하면서 그 강도를 자료로부터 추정하는 사전분포(이 장의 위계적 사전분포)가 $h = 3$ 과 $h = 12$ 에서 이기며 나머지 시계에서도 말편자에 크게 뒤지지 않는다. 이 순위는 Chan (2021)과 일치한다: 그는 수백 개 예측 시작점을 평균하는 완전한 다중 시작점 예측 실험에서 같은 순위에 도달하는데, 미네소타 구조에 적응적으로 추정된 강도를 결합한 사전분포가 구조 없는 global-local 사전분포(말편자, 정규-감마)와 단일 강도 미네소타 사전분포를 모두 능가한다.




Figure 55: 3자 상대-MSFE 비교, BGR MEDIUM($n=20$) 시스템, 단일 시점(1995년 12월까지 훈련, 1996년 1월-12월 예측); 로그 척도, 점선은 임의보행-표류 벤치마크




Figure 56: 1995년 12월 시점에서의 12개월 예측 경로, 세 사전분포와 임의보행-표류 벤치마크 대 실현 경로(파선): 고용과 CPI는 근접하게 추적되지만 기금금리는 모든 사전분포가 위로 벗어난다 — 아래 remark가 논의하는 단위근 근방 누적 효과다

참고: 유연성은 단기 시계에서 도움이 된다 — 일반화 전에 새겨줄 두 가지 유보

이 표를 정직하게 읽으려면 두 가지 유보가 필요하다. 첫째, 안정성. 13.7절과 13.8절의 진단은 두 유연한 사후평균 시스템을 임의보행 경계에 거의 정확히 올려놓는다(말편자 $\rho = 0.9992$, 위계적 $\rho = 0.9997$). BGR 자신의 $\delta_i = 1$ 사전평균이 패널의 자기동학 대부분을 애초에 그곳에 놓기 때문이다. 반복 예측은 이 경계 근처에서 작은 단계별 편향을 기하급수적으로 누적시키며, 이는 그림 56에서 직접 보인다: 실현 금리는 평평한데 모든 사전분포의 기금금리 경로가 위로 기어오른다. 문헌의 표준 처방은 추가 더미 관측치 — Doan, Litterman and Sims (1984)와 Sims and Zha (1998)의 sum-of-coefficients 및 dummy-initial-observation 사전분포로, Giannone, Lenza and Primiceri (2015)에는 기본값으로 포함된다 — 인데, 여기서는 세 사전분포가 오직 축소 구조에서만 다르도록 의도적으로 생략했다. 둘째, 표본 잡음. 단일 시점이라는 것은 표의 각 칸이 소수의 제곱오차로 만들어졌다는 뜻이므로 크기 자체는 느슨하게 읽어야 한다. 올바른 지표

는 수백 개 예측 시작점의 평균이며, BGR가 그렇게 하고 Chan (2021)도 그렇게 하여 같은 정성적 순위에 도달한다. Chan의 다중 시작점 실험은 그 순위 뒤의 메커니즘도 식별한다: 모든 계수를 동일하게 취급하는 사전분포는 교차변수 축소와 시차 감쇠를 버리고, 금리류 변수에 필요한 지속적인 자기시차 동학을 정확히 과잉 축소하는 경향이 있다 — 미네소타 범주를 유지하면서 그 강도를 추정하는 이 장의 위계적 사전분포가 평균적으로 이기는 조합인 이유다. 이것이 Banbura, Giannone and Reichlin이 단기 시계 결과를 대표 사례로 보고하는 이유이자 이 장이 시종일관 $h = 1$ 을 강조하는 이유이기도 하다: 이 시계에서 이 장이 구축한 방법론적 차이들(더미 관측치, 적합도-맞춤, 위계적 강도, 계수별 축소)가 서로 가장 명확하게 구별되며, 모두가 똑같이 크게 악화된 장기 예측으로 수렴해 버리지 않는다.

14. GARCH 모형과 맞춤형 독립 메트로폴리스-헤이스팅스

로드맵

6장 아래의 모든 모형은 모든 모수 블록에 대해 닫힌 형태의 완전조건부분포를 가졌는데, 이는 모든 사전분포가 자신의 우도에 켄레가 되도록 선택되었기 때문이다. GARCH는 이 패턴을 의도적으로 깨뜨린다: 분산이 자신의 과거에 비선형적으로 의존하므로, 어떤 사전분포를 쓰더라도 사후분포는 이름 붙은 분포가 되지 않으며, 깃스 샘플링은 아예 선택지가 아니다. 따라서 이 장의 진정한 내용은 변동성 모형 그 자체가 아니라, 이를 다루기 위해 구축된 M-H 변형, 즉 사후분포의 최빈값에서의 형태로부터 한 번 구성되는 고정 제안분포다. 바로 이 제안분포 구성 아이디어가(GARCH 재귀식 자체가 아니라) 앞으로 이어진다: 16-18장은 서로 다른 모수에 대해 동일한 비켄레 문제에 직면하며 동일한 종류의 맞춤형 제안분포를 사용한다.

11-13장은 모두 오차항 공분산 Σ 를 시간에 걸쳐 상수로 유지했는데, 이는 금융 수익률 자료가 통상적으로 위배하는 가정이다: 변동성 자체가 군집을 이루어, 잠잠한 시기와 격동의 시기가 각각 여러 기간 지속된다. 이 장은 이러한 패턴을 위한 표준 모형, 즉 Bollerslev(1986)의 GARCH(1,1)을 실제 일별 주식 수익률 계열에 적합하며, 그 과정에서 새로운 사후분포 시뮬레이션 도구인 맞춤형 독립 메트로폴리스-헤이스팅스를 소개한다. 이는 이전 모든 장에서 사용된 국소적으로 적응하는 임의보행이나 깃스 단계와 달리, 사후분포 최빈값에서의 라플라스 근사로부터 고정된, 자료에 기반한 제안분포를 구축한다.

참고: 자료에 대한 참고

12장까지의 모든 거시 장은 이 노트 전체에서 사용된 동일한 분기별 미국 거시 패널을 활용했다 (13장은 대형 BVAR 사례연구를 위해 Banbura, Giannone and Reichlin 자신의 월별 패널로 전환했다). 이들 계열 중 어느 것도 일별이 아니므로, 이 장은 진정한, 완전히 문서화된 일별 금융 계열로 전환한다: **S&P 500 지수의 일별 백분율 로그 수익률**, 2013-01-03부터 2015-12-31까지, $T = 755$ 거래일이다. 아래의 GARCH 모형이나 표본추출 방법 어느 것도 이 특정 구간에 특유한 것이 아니다 — 길게 이어지는 잠잠한 구간이 특정할 수 있는 시장 사건 주위의 날카롭고 군집된 변동성 급등으로 끊기는 패턴은 충분히 긴 어떤 일별 주식 계열에서도 나타나는 동일한 패턴이다.

14.1 GARCH(1,1) 모형

GARCH(1,1) 평균이 0인 일별 수익률 y_t (퍼센트)에 대해,

$$y_t = \varepsilon_t, \quad \varepsilon_t \mid \mathcal{F}_{t-1} \sim N(0, \sigma_t^2), \quad \sigma_t^2 = a_0 + a_1 \varepsilon_{t-1}^2 + \gamma_1 \sigma_{t-1}^2,$$

여기서 $\mathcal{F}_{t-1}$ 는 $t-1$ 까지의 정보집합이다. 그림 57는 이것이 만들어내는 재귀 구조를 보여준다: VAR의 고정된 시차창(11장)과 달리, σ_t^2 는 모든 과거 충격에 의존하며, σ_{t-1}^2 을 통해 한 단계씩 앞으로 전파된다.




Figure 57: GARCH(1,1) 분산의 재귀 구조: 오늘의 분산은 어제의 분산과 어제의 제곱 충격에 의존하므로, 단일 충격의 영향은 고정된 시차 이후 사라지는 것이 아니라 비율 γ_1 로 기하학적으로 감쇠한다

$a_1 \varepsilon_{t-1}^2$ 항은 어제의 실현된 충격을 오늘의 분산에 직접 투입하고(ARCH 효과), $\gamma_1 \sigma_{t-1}^2$ 항은 분산 자체를 지속적으로 만든다(GARCH 효과). 분산 과정의 정상성은 $a_1 + \gamma_1 < 1$ 을 요구하며, 이 경우 비조건부 분산은 $a_0/(1 - a_1 - \gamma_1)$ 이다. 이 모형은 $t=1$ 에서 재귀를 시작하기 위해 분산과 충격이 필요하므로, 초기값 $\varepsilon_0^2 \equiv e^{\log \varepsilon_0^2}$ 는 자신의 사전분포를 가진 추가적인 자유 모수로 취급되며, σ_0^2 은 (a_0, a_1, γ_1) 의 현재 표본값에서 계산된 함의된 비조건부 분산 $a_0/(1 - a_1 - \gamma_1)$ 로 설정된다. 전체 모수벡터는 $\theta = (a_0, a_1, \gamma_1, \log \varepsilon_0^2)$ 이며, 로그우도는 θ 와 자료로부터 σ_t^2 을 $t=1, \dots, T$ 에 대해 재귀적으로 계산하여 얻는 가우스 로그밀도의 합이다(이 재귀는 위의 평범한 GARCH(1,1) 우도 재귀이지, 15장의 상태공간 의미에서의 칼만필터가 아니다).

알고리즘: 사전분포와 모수 제약

1. (a_0, a_1, γ_1) 에 독립적인 정규 사전분포를 부과하며, 교과서적 값 (0.01, 0.05, 0.90)에 중심을 두고 각각 분산 0.0025를 갖는다.
2. 초기 로그분산 상태 $\log \varepsilon_0^2$ 에 촘촘한 정규 사전분포를 부과하는데, 현재 표본값이 함의하는 비조건부 분산의 로그 $\log(a_0/(1 - a_1 - \gamma_1))$ 에 중심을 두고 분산 0.0001을 갖는다 — 이는 자기 참조적 사전분포로서, 표본 이전 상태를 자유롭게 떠돌게 두는 대신 현재 (a_0, a_1, γ_1) 표본값이 함의하는 어떤 정상 수준에든 고정된 상태로 유지한다.
3. $a_0 \leq 0, a_1 \leq 0, \gamma_1 \leq 0$, 또는 $a_1 + \gamma_1 \geq 0.99$ 일 때마다 사후분포 커널을 아예 기각하여(로그 밀도를 -10^{10} 으로 부여), 양성과 공분산-정상성을 강제한다.

14.2 사후분포 유도

6-13장의 모든 모형과 달리, GARCH(1,1) 사후분포에는 활용할 쉼표 구조가 없다: σ_t^2 은 (재귀를 통해) (a_0, a_1, γ_1) 에 비선형적으로 의존하므로, 우도는 어떤 편리한 사전분포와의 곱이 이름 붙은 분포를 내는 형태가 아니다. 따라서 여기서 필요한 두 가지 유도는 6-13장과는 성격이 다르다: 첫째, 모든 M-H 단계에서 수치적으로 최대화되고 평가되는 정확한 (비정규화된) 사후분포 커널을 적어 내는 것, 둘째, 알고리즘 상자의 수락확률 α 가 왜 독립 제안분포에 대해 올바른 것인지를 정당화하는 것이다.

유도: GARCH 사후분포 커널

$\theta = (a_0, a_1, \gamma_1, \log e_0^2)$ 가 주어졌을 때, 재귀 $\sigma_t^2 = a_0 + a_1 \varepsilon_{t-1}^2 + \gamma_1 \sigma_{t-1}^2$ ($\sigma_0^2 = a_0 / (1 - a_1 - \gamma_1)$ 와 $\varepsilon_0^2 = e^{\log e_0^2}$ 로 초기화됨)은 모든 $\sigma_t^2, t = 1, \dots, T$ 를 θ 와 자료의 결정론적 함수로 만든다. $\varepsilon_t | \mathcal{F}_{t-1} \sim N(0, \sigma_t^2)$ 이므로, 우도는 예측오차 분해(어떤 시계열 우도에서도 그렇듯 순차적 조건화)에 의해 인수분해된다:

$$p(y | \theta) = \prod_{t=1}^T p(y_t | \mathcal{F}_{t-1}, \theta) = \prod_{t=1}^T \frac{1}{\sqrt{2\pi\sigma_t^2(\theta)}} \exp\left\{-\frac{y_t^2}{2\sigma_t^2(\theta)}\right\}$$

독립 사전분포 $p(a_0)p(a_1)p(\gamma_1)p(\log e_0^2 | a_0, a_1, \gamma_1)$ (마지막 것은 위에서 언급한 대로 자기참조적이며 현재 표본값이 함의하는 비조건부 로그분산에 중심을 둔다)과 엄격한 지시함수 $\mathbb{I}\{a_0 > 0, a_1 > 0, \gamma_1 > 0, a_1 + \gamma_1 < 0.99\}$ 를 곱하면 정확한 목표 커널을 얻는다:

$$\begin{aligned} \pi(\theta | y) &\propto \left[\prod_{t=1}^T \sigma_t^2(\theta)^{-1/2} \exp\left\{-\frac{y_t^2}{2\sigma_t^2(\theta)}\right\} \right] \\ &\times N(a_0; 0.01, 0.0025) N(a_1; 0.05, 0.0025) N(\gamma_1; 0.90, 0.0025) \\ &\times N\left(\log e_0^2; \log \frac{a_0}{1-a_1-\gamma_1}, 0.0001\right) \times \mathbb{I}\{a_0 > 0, a_1 > 0, \gamma_1 > 0, a_1 + \gamma_1 < 0.99\} \end{aligned}$$

이것의 로그가 알고리즘 상자의 단계 1에서 최대화되고 모든 수락 단계에서 θ' 와 $\theta^{(s)}$ 양쪽에서 평가되는 목적함수 $\ln \pi(\theta)$ 다. $\sigma_t^2(\theta)$ 가 비선형적이고 재귀적으로 들어가므로, 이를 붙은 분포로의 추가적인 단순화는 불가능하며, 이것이 바로 이 장이 깃스 샘플링 대신 메트로폴리스-헤이스팅스로 전환하는 이유다.

유도: 맞춤형 독립 수락비가 올바른 이유

제안밀도 $q(\theta' | \theta)$ 와 수락확률 $\alpha(\theta, \theta')$ 를 갖는 어떤 메트로폴리스-헤이스팅스 연쇄도, 전이커널이 상세균형(detailed balance), $\pi(\theta') q(\theta' | \theta) \alpha(\theta, \theta') = \pi(\theta) q(\theta | \theta') \alpha(\theta', \theta)$ 를 만족한다면 π 를 그 정상분포로 갖는다: 양변을 θ 에 대해 합(적분)하면 이 조건이 연쇄 아래에서 π 가 불변임을 보이기에 충분함을 알 수 있다. 표준 메트로폴리스-헤이스팅스 선택

$$\alpha(\theta, \theta') = \min\left(1, \frac{\pi(\theta') q(\theta | \theta')}{\pi(\theta) q(\theta' | \theta)}\right)$$

은 어떤 제안분포 q 에 대해서도 상세균형을 만족한다: 사건 $\pi(\theta) q(\theta' | \theta) > \pi(\theta') q(\theta | \theta')$ 에서, 좌변의 $\alpha(\theta, \theta') = \pi(\theta') q(\theta | \theta') / [\pi(\theta) q(\theta' | \theta)]$ 와 우변의 $\alpha(\theta', \theta) = 1$ 은 양변을 모두 $\pi(\theta') q(\theta | \theta')$ 로 만들며, 반대 사건에서도 대칭적으로 성립한다. 이는 4장의 임의보행 연쇄를 뒷받침하는 것과 동일한 일반적인 M-H 유도다. 맞춤형 독립 제안분포의 경우 $q(\theta' | \theta) = q(\theta')$ 는 θ 에 의존하지 않으므로,

$$\frac{\pi(\theta') q(\theta | \theta')}{\pi(\theta) q(\theta' | \theta)} = \frac{\pi(\theta') q(\theta)}{\pi(\theta) q(\theta')}$$

$(q(\theta' | \theta) = q(\theta')$ 와 $q(\theta | \theta') = q(\theta)$ 를 대입(이는 제안분포가 현재 상태에 의존하지 않기 때문에 정확히 성립한다) 이를 정리하면 다음과 같다:

$$= \frac{\pi(\theta')/q(\theta')}{\pi(\theta)/q(\theta)},$$

이는 정확히 알고리즘 상자에서 사용된 중요도가중치-비율(ratio-of-importance-weights) 형태다. 이것이 바로 독립 제안분포가 대칭 임의보행 제안분포처럼 q 항을 없앨 수 없는 이유다(4장): q 는 $q(\theta) = q(\theta')$ 가 아닌 한 상쇄되지 않으며, q 가 현재 상태와 독립적으로 고정되어 있는 한 이는 보장되지 않는다.

14.3 맞춤형 독립 메트로폴리스-헤이스팅스

4장은 두 가지 메트로폴리스-헤이스팅스 변형을 소개했다: 제안분포가 현재 상태에 중심을 두는 임의보행 M-H, 그리고 모수 블록을 한 번에 하나씩 갱신하는 다중블록 M-H. 둘 다 연쇄가 움직임에 따라 국소적으로 적응한다. 맞춤형 독립 연쇄는 대신 연쇄가 실행되기 전에 제안분포를 한 번 고정하며, 사후분포 전체를 그 최빈값에서 정규 혹은 스튜던트- t 로 근사한 것(즉 라플라스 근사) 으로부터 구축한다. 동일한 제안분포가 현재 상태 θ 와 무관하게 매 반복에서 사용되므로, 메트로폴리스-헤이스팅스 수락비는 대칭 임의보행 제안분포처럼 상쇄하는 대신 제안밀도 q 를 양쪽 점 모두에서 명시적으로 나누어야 한다.

알고리즘: 맞춤형 독립 M-H

1. **최빈값 탐색.** 로그사후분포 $\ln \pi(\theta)$ 를 수치적으로 최대화하여 최빈값 $\hat{\theta}$ 를 얻는다(교과서적 접근법은 뉴턴 탐색으로 이를 수행한다. 이 구현은 미분에 의존하지 않는 넬더-미드 탐색 이후 BFGS 다듬기 단계를 사용하는데, 이는 여기서 경사기반 탐색만 사용하는 것보다 현저히 더 견고한 것으로 드러났다 — 위의 엄격한 기각 영역이 로그사후분포 표면에 날카로운 절벽을 만들어, 사전평균에서 시작할 때 BFGS의 선탐색과 유한차분 경사 추정을 반복적으로 흐트러뜨려 진짜 최빈값보다 로그사후분포 65 단위 이상 낮은 점으로 수렴시켰다. 넬더-미드의 심플렉스 탐색은 국소 경사 정보에 의존하지 않으며 동일한 시작점에서 진짜 최빈값을 안정적으로 찾아낸다).
2. **라플라스 근사.** $\hat{\theta}$ 에서 $\ln \pi(\theta)$ 의 헤시안을 수치적으로 계산하고, $V = (-\hat{H})^{-1}$ 을 설정한다 — 음의 역헤시안으로, 사후분포를 정규분포로 근사할 때 사용할 곡률 행렬과 동일하다.
3. **고정된 스튜던트- t 제안분포.** $\hat{\theta}$ 에 중심을 두고 척도행렬 V , 자유도 $\nu = 30$ 을 갖는 다변량 스튜던트- t 에서 후보를 추출한다(정규분포보다 두꺼운 꼬리를 가지므로, 라플라스 근사가 불완전한 곳에서도 고정 제안분포가 여전히 진짜 사후분포의 꼬리에 도달할 수 있다).
4. **수락.** 현재 상태 $\theta^{(s)}$ 로부터, $\theta' \sim q(\cdot) = t_\nu(\hat{\theta}, V)$ 를 추출하고, 다음 확률로 $\theta^{(s+1)}$ 로 수락한다:

$$\alpha = \min \left(1, \frac{\pi(\theta')/q(\theta')}{\pi(\theta^{(s)})/q(\theta^{(s)})} \right),$$

그렇지 않으면 $\theta^{(s+1)} = \theta^{(s)}$ 로 설정한다.

연쇄는 1,500개 번인 표본 이후 6,000개의 번인 이후 표본에 대해 실행된다.

참고: 제안분포가 스스로를 교정해야 하는 이유

0을 중심으로 대칭인 η 에 대한 임의보행 제안분포 $\theta' = \theta^{(s)} + \eta$ 는 $q(\theta' | \theta^{(s)}) = q(\theta^{(s)} | \theta')$ 를 만족하므로, 제안밀도가 수락비에서 상쇄되고 사후분포 비율 $\pi(\theta')/\pi(\theta^{(s)})$ 만 남는다 — 4장에서 익숙한 형태다. 독립 제안분포는 $\theta^{(s)}$ 에 전혀 의존하지 않으므로 아무것도 상쇄되지 않는다: π 에 비해 q 가 우연히 큰 영역에서 추출된 후보는, q 항을 없앤다면 과도하게 수락될 것이다. 위 알고리즘 상자에서처럼 후보점과 현재점 양쪽에서 사후분포를 제안밀도로 나누는 것이 결과로 나오는 연쇄의 정상분포를 π 와 q 의 어떤 혼합이 아니라 진짜 사후분포 π 와 같게 유지하는 방법이다.

14.4 실증 예제: S&P 500 일별 수익률에 대한 GARCH(1,1) 적합

실증 예제: 사후분포 추정

위 모델을 S&P 500 일별 로그 수익률의 전체 $T = 755$ 거래일에 적합하면 다음의 사후분포 요약을 얻는다(사후평균, 괄호 안은 사후표준편차):

	a_0	a_1	γ_1
사후평균 (표준편차)	0.0466 (0.0089)	0.1162 (0.0189)	0.8046 (0.0248)

함의된 지속성은 $a_1 + \gamma_1 = 0.921$ (표준편차 0.0161)로 — 일별 주식 변동성의 전형적인 값답게 높지만, $a_1 + \gamma_1 < 0.99$ 제약 영역 내에 안전하게 자리하며 경계 자체로부터는 멀리 떨어져 있어, 위 알고리즘 상자에서 논의한 잘못된 수렴한 적합과는 다르다. 맞춤형-M-H 수락률은 39.7%로, 독립 연쇄로서는 건전한 값이다(잘 조정된 맞춤형 제안분포는 통상 20–50% 범위에서 수락한다. 0%에 가까운 수락률은, 이 장 초기의 교정되지 않은 최빈값 탐색 시도가 처음에 낳았던 것처럼, 라플라스 근사가 잘못된 지점에서 구축되었거나 곡률 척도가 심하게 잘못되었다는 표준적인 진단 신호다). 그림 58는 a_1 , γ_1 , 그리고 그 합의 사후분포를 보여주는데, 셋 다 단봉이며 모수-제약 영역의 내부에 편안히 자리하는데, 이는 경계에 고정된 것이 아니라 진정으로 우도가 지배하는 사후분포로 수렴한 연쇄의 징표다.




Figure 58: ARCH 계수 α_1 , GARCH 계수 γ_1 , 그리고 그 합(지속성)의 사후분포; 점선은 사후평균을 표시

실증 예제: 적합된 변동성과 2015년 8월 급락

그림 59(a)는 사후평균 조건부 변동성 $\hat{\sigma}_t$ (200개의 사후 표본에 걸쳐 평균)를 실현된 절대 일별 수익률과, 평탄한 상수분산 벤치마크(위 모형의 퇴화 특수사례인 $a_1 = \gamma_1 = 0$, 그 베이지 추정치는

단순히 수익률의 표본표준편차인 하루 0.80%이며, 이는 11-13장의 상수 Σ 가 여기서 났을 값과 정확히 같다) 함께 그린다. 전체 표본에 걸친 평균 적합 GARCH 변동성은 하루 0.76%인데(평균 적으로 평탄한 벤치마크와 일치, 당연한 결과다), 이는 평탄함과 거리가 멀다: 잠잠한 시장에서 최저 0.53%부터 **2015-08-27**에 도달한 최고 2.07%까지 이르는데, 이는 중국의 깜짝 위안화 절하가 세계적 주식 급락을 촉발한 지 사흘 뒤이며(S&P 500 자체는 2015-08-24 “검은 월요일”에 4.0% 하락했다), 2013-2015 전체 표본에서 가장 변동성이 큰 구간이다 — 평탄한 벤치마크 선이 구성상 보여줄 수 없는 네 배 이상의 변동성 진폭이다. 더 작은 이차 군집이 **2013-06**(연준의 “테이퍼 탠트럼”, 양적완화 종료 논의에 대한 시장의 첫 반응)과 **2014-10/2014-12**(유가의 급락이 겹친 세계 성장 우려) 주위에도 나타난다. 이 세 에피소드 모두 GARCH 메커니즘이 의도한 대로 작동함을 보여준다: 큰 충격(ε_{t-1}^2)이 a_1 항을 통해 σ_t^2 을 급격히 밀어올리고, 높게 추정된 지속성 $\gamma_1 = 0.80$ 은 그 뒤 변동성을 즉시 되돌리는 대신 한두 주 동안 높은 수준으로 유지시킨다 — 이는 (a) 패널의 평탄한 상수분산 선이 구성상 표현할 수 없는 바로 그 변동성-군집 패턴이다.




Figure 59: (a) 사후평균 조건부 변동성 대 실현 |수익률|, S&P 500 전체 표본, 평탄한 상수분산 벤치마크(0.80%) 대비; (b) 2015년 8월 급락 동안의 5% 일단계 앞 VaR, 상수분산 벤치마크 대 적합된 GARCH(1,1); (c) 5% VaR와 기대손실을 표시한 일단계 앞 사후예측 수익률 분포

실증 예제: 일단계 앞 리스크: VaR와 기대손실

θ 의 1,500개 사후 표본 각각에 대해, 그 표본의 적합된 변동성 경로 아래에서 다음 거래일의 수익률을 시뮬레이션하면 일단계 앞 사후예측분포(그림 59(c))를 얻는데, 이는 평소의 수익률-혁신 불확실성과 함께 모수 불확실성도 제대로 통합해낸다 — θ 를 점추정치에 고정하는 대입식 예측과 달리 진정으로 베이저안적인 리스크 예측이다. 예측 평균은 -0.02% , 예측 표준편차는 0.89% 이며, 95% 예측구간은 $[-1.86\%, 1.77\%]$ 이다. 5% 예측확률로 넘어서는 손실 문턱인 5% VaR(Value-at-Risk)는 $\text{VaR}_{5\%} = -1.50\%$ 이고, 그 문턱을 넘었을 조건부 평균 손실인 5% 기대손실(Expected Shortfall)은 $\text{ES}_{5\%} = -1.88\%$ 로, VaR 자체보다 눈에 띄게 더 나쁜데, 이는 반드시 그래야 한다: ES는 VaR를 넘는 꼬리만을 평균하므로 항상 크기 면에서 VaR를 약하게 초과하

며, 여기서의 차이 (0.38 퍼센트포인트)는 변동성이 이미 적합된 모형의 극단적 꼬리에서 실현된 것으로 판명될 경우 나쁜 하루가 얼마나 더 나빠질 수 있는지를 정량화한다.

참고: 2015년 8월 급락에 대한 상수분산 VaR

평탄한 상수분산 벤치마크는 정말로 중요한 순간에 리스크를 틀리게 잡는가, 아니면 (a) 패널의 변동성-군집 그림은 그저 겉모습의 차이일 뿐인가? 그림 59(b)는 두 모형의 5% VaR($z_{0.05}\hat{\sigma}$, 여기서 $\hat{\sigma}$ 는 평탄한 0.80% 벤치마크이거나 GARCH의 일단계 앞 $\hat{\sigma}_t$)를 2015-08-17부터 2015-09-04까지의 실제 수익률에 대비하여 보여준다. 상수분산 VaR는 매일 -1.32%의 단일 평탄선인 반면, GARCH VaR는 잠잠한 시기의 -0.87%부터 재귀가 충격을 흡수한 이후의 -3.41%까지 이르러, 동일한 2주 구간에서 네 배의 확대를 보인다. 그 간극이 가장 두드러지는 것은 전체 표본에서 가장 나쁜 날인 **2015-08-24**($y_t = -4.02\%$)이다: 평탄한 상수분산 벤치마크에 대비하면 이는 -5.01 표준편차 사건으로, 정규분포 아래 꼬리확률이 2.7×10^{-7} 이다 — 370만 거래일에 한 번꼴보다 더 드문, 즉 상수분산 모형이 사실상 일어나서는 안 된다고 말하는 사건이다. GARCH 모형 자체의 그 날 변동성 평가($\hat{\sigma}_t = 1.43\%$, 이미 2015-08-20/21 이틀간의 충격으로 상승해 있었다)에 대비하면, 동일한 수익률은 -2.81 표준편차 사건으로 꼬리확률이 0.25%, 대략 400거래일에 한 번꼴이다 — 드물지만 터무니없지는 않다. 이것이 상수분산 모형이 변동성 군집을 “포착할 수 없다”는 것의 구체적인 의미다: 그것은 단지 더 매끄러운 것이 아니라, 정확히 그것이 중요할 때 틀린다, 실현된 폭락의 개연성을 네 자릿수 넘게 과소평가하면서. 전체 표본에 걸친 보완적 점검: 위의 네 가지 알려진 고변동성 에피소드(테이퍼 탠트럼, 2014년 10월/12월, 2015년 8월 급락, 표본의 755일 중 80일, 10.6%)는 상수분산-VaR 위반의 34.9%를 차지하지만 GARCH-VaR 위반의 23.9%만을 차지한다 — 상수분산의 예외는 잘 보정된 조건부 리스크 모형이라면 시간에 걸쳐 더 고르게 퍼뜨려야 할 바로 그 스트레스 시기에 군집하며, GARCH 모형은 이 군집을 완전히 없애지는 못하지만 그 집중도를 대략 삼분의 일 정도 줄인다.

14.5 두 번째 구간: 코로나19 폭락과 회복, 2019–2021년

실증 예제: 더 극단적인 시험대

위의 2013–2015년 구간은 GARCH(1,1)이 실제이지만 온건한 변동성 군집에 대해 의도한 대로 작동함을 보여준다. 동일한 메커니즘을 한계까지 밀어붙였을 때를 보기 위해, 이 절은 동일한 모형을 변경 없이 그대로, S&P 500 일별 수익률의 두 번째, 독립적인 구간에 다시 적합한다: $T = 524$ 거래일, **2019-06-04**부터 **2021-06-30**까지로, 지수 역사상 가장 빨랐던 약세장(2020년 2–3월의 고점 대비 저점 34% 하락)과 그 뒤에 이어진 회복을 포괄한다. 이 구간은 원래 구간을 대체하는 것이 아니라 나란히 추가된다: 두 구간을 함께 두면 동일한 모형과 동일한 샘플러가 통상적이고 온건하게 변동성이 있는 구간과 이 노트가 다루는 표본기간 전체에서 가장 극단적인 변동성 사건 양쪽 모두에 대해 어떻게 평가받는지 볼 수 있다. 사후평균(괄호 안은 사후표준편차):

	a_0	a_1	γ_1
사후평균(sd)	0.0402 (0.0087)	0.1671 (0.0220)	0.8038 (0.0222)

함의 지속성은 $a_1 + \gamma_1 = 0.971$ (sd 0.0064)로 — 2013–2015년 구간의 0.921보다 눈에 띄게 높고, $a_1 + \gamma_1 < 0.99$ 라는 정상성 경계에 더 가까워졌지만 여전히 그 안쪽에 충분히 위치한다. 정교화된(tailored) 독립 M-H의 수락률은 18.0%로, 앞선 구간의 39.7%보다 낮지만 독립체인 치고는

여전히 작동 가능한 범위 안에 있다: 이 표본의 더 날카롭고 극단적인 관측치들이 로그사후밀도 표면을 하나의 라플라스 근사에서 만든 단일한 고정 스튜던트-t 제안분포로 잘 근사되지 않게 만들기 때문에, 더 많은 후보가 기각되지만 그럼에도 체인은 여전히 잘 혼합되고 수렴한다. 그림 60는 그 결과 사후분포를 보여준다. 세 값 모두 여전히 단봉이며 제약영역 내부에 안전하게 위치한다.




Figure 60: α_1 , γ_1 , 그리고 그 합(지속성)의 사후분포, 코로나19 구간; 점선은 사후평균을 나타낸다

실증 예제: 평평한 벤치마크를 실제로 깨뜨리는 변동성

그림 61(a)는 이전과 동일한 비교(적합된 GARCH 변동성 대 평평한 상수분산 벤치마크)를 그리는데, 이제 벤치마크는 일 1.62%로, 단 한 달의 극단적 사건이 전체표본 평균에 반영되었을 뿐인데도 이미 앞선 구간의 0.80%의 두 배다. 적합된 GARCH 변동성은 평온한 시장의 최저치 0.51%부터 **2020-03-17**의 정점 **7.66%**까지 걸쳐 있다 — 앞선 구간의 최악치보다 **3.5배** 이상 크며, 하나의 표본 내에서 **15배**에 달하는 변동성 진폭으로, 앞선 구간의 이미 주목할 만했던 4배 진폭을 훨씬 능가한다. 패널 (b)는 폭락 그 자체(2020년 2-4월)를 확대해서 보여준다: 일별 수익률 계열은 같은 주 안에서도 두 자릿수 퍼센트의 등락을 양방향으로 오가며 요동치고, GARCH 조건부변동성 밴드는 거의 실시간으로 눈에 띄게 넓어지며 그 요동을 추적하는 반면, 평평한 상수분산 밴드는 그 내내 그 한가운데 무용하게 머물러 있다. 이 표본에서 최악의 거래일인 **2020-03-16**($y_t = -12.77\%$)은 평평한 상수분산 벤치마크 기준으로 -7.86 표준편차 사건이다 — 꼬리확률 1.9×10^{-15} 로 사실상 영(0)이며, 상수분산 모형에 따르면 우주의 전체 수명 동안 단 한 번도 일어나서는 안 되는 사건이다. GARCH 모형 자체가 그날 내린 변동성 평가(이미 그 전주의 충격들로 상승해 있었다) 기준으로 같은 수익률이 -2.05 표준편차 사건으로, 꼬리확률 2.0% — 드물지만 대략 50거래일에 한 번꼴로 실제 일어나는 사건이지, 불가능한 사건은 아니다. 그리고 변동성 군집은 양방향으로 작동한다: 이 표본에서 최고의 거래일인 **2020-03-24**($y_t = +8.97\%$, 부양책에 대한 기대로 시장이 반등한 날)는 최악의 날로부터 불과 **6거래일** 뒤에 온다 — 상승한 σ_t^2 가 단순히 “더 많은 폭락”이 아니라 양방향 모두에서 더 넓은 결과분포를 예측한다는 가장 명확한 예시이다.




Figure 61: (a) 사후평균 조건부변동성 대 실현된 |수익률|, 코로나19 구간 S&P 500 표본, 평평한 상수분산 벤치마크(1.62%)와 비교; (b) 2020년 2~4월 폭락 동안의 일별 수익률과 ± 1 GARCH 조건부표준편차 밴드 대 평평한 벤치마크; (c) 표본 끝(2021-06-30)에서 평가한 1기 앞 사후예측 수익률분포와 5% VaR 및 기대손실

참고: 상수분산 모형은 결코 회복되지 않지만 GARCH는 회복된다

두 구간 사이의 가장 뚜렷한 차이는 폭락 자체의 크기가 아니라 각 모형이 폭락 이후에 뭐라고 말하는가이다. 이 표본의 맨 끝인 2021-06-30(폭락이 바닥을 찍은 지 15개월이 지나 평온하고 변동성이 낮은 회복기 한가운데)을 기준으로 평가한 1기 앞 사후예측분포(그림 61(c))는 사후예측평균 -0.01% , 사후예측표준편차 0.64% , 5% VaR인 $\text{VaR}_{5\%} = -1.07\%$, 5% 기대손실인 $\text{ES}_{5\%} = -1.34\%$ 를 보이는데 — 이는 이 구간이 역사상 훨씬 더 극단적인 사건을 담고 있음에도 불구하고 2013~2015년 구간의 대응 수치(-1.50% , -1.88%)보다 절댓값이 더 작다. GARCH의 평균회귀적 지속성($\gamma_1 = 0.80$)은 충격이 재귀식을 통과한 뒤 적합된 변동성 경로가 다시 낮아지도록 허용하므로, 평온한 시점에서 만든 예측은 올바르게 평온해 보인다. 평평한 상수분산 벤치마크는 구조적으로 이렇게 할 수 없다: 그 단일 수치 일 1.62% 는 2020년 3월을 포함한 전체 구간에 대한 단순평균이며, 15개월 전의 나쁜 한 달이 그 이후의 모든 평온한 날과 표본평균에 동등하게 반영된다는 이유만으로, 실제로는 평온한 2021년 6월 30일 시점의 시장에 대해서도 그 상승한 리스크를 무기한 계속 예측할 것이다. 전체 구간에 걸친 보완적인 위반 군집 점검(폭락 자체에 더해 2020~21년의 두 후속 스트레스 사건인 2020년 11월 대선/백신발표 급등락과 2021년 1월 밈주식(meme-stock) 변동성 급등을 포함, 표본 524일 중 81일, 15.5%)은 앞선 구간에서 발견된 패턴을 더 뚜렷하게 보여준다: 이 스트레스 일수는 전체 상수분산-VaR 위반의 68.2% 를 차지하지만 GARCH-VaR 위반의 25.0% 만을 차지한다. 표본을 코로나 시기까지 확장하는 것은 GARCH 대 상수분산 비교를 단지 더 크게 만드는 데 그치지 않는다 — 그것은 시변 변동성을 무시하는 대가가 근저 충격이 얼마나 극단적이었는지에 비례해 커진다는 점에서, 시변 변동성을 써야 한다는 논거를 더 날카롭게 만든다. 폭락 동안뿐 아니라, 그에 못지않게 중요하게는 폭락 이후 몇 년 동안에도 그러하다.

14.6 Bollerslev (1986)

위의 두 S&P 500 구간은 GARCH(1,1)이 오늘날 가장 잘 알려진 일을 하는 모습을 보여주었다. 이 절은 이 모델을 만들어낸 논문의 실증 예제를 재현하는데, 그것은 자산수익률에 관한 것이 전혀 아니다. Bollerslev (1986), “Generalized Autoregressive Conditional Heteroskedasticity”(Journal of Econometrics 31(3))는 미국 인플레이션의 불확실성에 대한 응용으로 논문을 마무리한다. 분기 GNP 디플레이터 인플레이션 $\pi_t = 100 \ln(GD_t/GD_{t-1})$ (FRED GNPDEF), 1948Q2–1983Q4($T = 143$)에 AR(4) 조건부 평균과 당시 새로웠던 GARCH(1,1) 조건부 분산을 결합한 것이다.

$$\pi_t = c + \sum_{i=1}^4 b_i \pi_{t-i} + e_t, \quad h_t = a_0 + a_1 e_{t-1}^2 + \gamma_1 h_{t-1}.$$

논문의 논거는 간결성이었다. Engle and Kraft (1983)는 같은 평균식에 여덟 계수를 자의적인 선형 감소 시차 형태로 강제한 ARCH(8)을 적합했는데, Bollerslev는 시차 조건부 분산 하나(제약 딸린 여덟 개 대신 분산 모수 두 개)가 약간 더 잘 적합하면서 더 그럴듯한 학습 메커니즘을 준다는 것을 보였다. 재현은 이 장의 나머지와 동일한 tailored M-H 장치(SA_Newton으로 사후 최빈값, 스튜던트- t 독립 제안 분포)를 사용하며, 사전표본의 h 와 e^2 는 무조건부 분산으로 초기화한다.

실증 예제: 원표본 1948Q2–1983Q4

사후평균(표준편차)을 논문의 최우추정값(식 31, 괄호 안은 표준오차)과 비교하면 다음과 같다.

	사후분포	Bollerslev (1986)
c	0.075 (0.037)	0.141 (0.060)
b_1	0.496 (0.102)	0.433 (0.081)
b_2	0.190 (0.097)	0.229 (0.110)
b_3	0.206 (0.089)	0.349 (0.077)
b_4	0.028 (0.093)	−0.162 (0.104)
a_0	0.015 (0.006)	0.007 (0.006)
a_1	0.334 (0.062)	0.135 (0.070)
γ_1	0.620 (0.068)	0.829 (0.068)

논문의 헤드라인 수치는 정확히 살아남는다. 추정된 지속성 $a_1 + \gamma_1 = 0.954$ (표준편차 0.026) 대 Bollerslev의 0.964 — 인플레이션 불확실성은 매우 지속적이지만 정상적이며, 적분 GARCH(integrated GARCH) 경계 바로 안쪽에 있다. 그 지속성이 a_1 과 γ_1 사이에 나뉘는 방식은 다르게 나오는데(제공 충격에 더 큰 비중, 시차 분산에 더 작은 비중), 구별할 가치가 있는 두 가지 이유가 있다. 첫째, 143개의 분기 관측치에서 두 분산 모수는 개별적으로는 약하게만 식별된다($a_1 + \gamma_1$ 이 일정한 채로 뺀어 있는 우도의 길고 평평한 능선은 짧은 표본에서의 GARCH 추정이 갖는 잘 알려진 특징이다) 따라서 견고하게 추정되는 대상은 그 합이다. 둘째, 인플레이션 계열 자체가 Bollerslev가 사용한 그 계열이 아니다. 그의 디플레이터는 1984년 빈티지의 고정가중 지수였던 반면, 현재의 GNPDEF는 연쇄가중(1996년에 도입된 방법론)이며 그 후 여러 차례 전면 개정되었다. 작은 b_4 계수의 부호가 뒤집힌 것도 이것으로 설명된다. 그림 62은 논문의 마무리 그림(그

Figure 4)을 재현한다. 1940년대 말과 한국전쟁 시기의 변동성 국면에서는 넓고, 평온했던 1960년대 내내 계열에 바짝 붙으며(정확히 Bollerslev가 상수분산 구간은 “너무 넓어 보인다”고 지적한 시기이다) 1974년 오일쇼크 이후 완만하게 다시 넓어지는 1-스텝 95% 조건부 구간이다.





Figure 62: Bollerslev (1986) 재현: 1-스텝 95% 조건부 구간과 함께 그린 GNP 디플레이터 인플레이션(위, 논문의 Figure 4)과 상수분산 벤치마크에 견준 조건부 표준편차(아래), 원표본

실증 예제: 전체표본 1948Q2-2026Q1

동일한 여덟 모수 모형을 2026Q1까지 연장된 계열($T = 312$)에서 다시 추정하는 것은 1986년에 선택된 설정에 대한 사십이 년짜리 표본외 시험인데, 거의 아무것도 고칠 것 없이 통과한다. 지속성은 $a_1 + \gamma_1 = 0.959$ (표준편차 0.019), $P(a_1 + \gamma_1 > 0.95) = 0.87$ — 여전히 높고, 여전히 정상적이며, 여전히 경계 바로 안쪽이다. 경제학은 적합한 조건부 표준편차에 있다(그림 63, 아래 패널). Bollerslev가 알고 있던 경로 — 한국전쟁기의 요동, 1960년대의 평온, 오일쇼크 이후의 상승 — 뒤로 이제 대안정기의 긴 저점이 이어진다. 분기 인플레이션 불확실성이 사상 최저 부근에 머무는 사반세기다. 그리고 급반전이 온다. 2021-22년 인플레이션 급등이 조건부 변동성을 1980년대 초 이후 최고 수준으로 끌어올리고, 긴축 이후의 디스인플레이션이 그것을 일부만 되돌린다. 1970년대의 인플레이션 불확실성을 서술하기 위해 만들어진 모형이 이십오 년 동안 자신의 주제가 거의 사라졌다고 보고하다가, 그 귀환을 기록한 것이다 — 16장의 확률적 변동성 장치가 VAR 체계 전체에 대해 도달하는 것과 같은 결론을, 여기서는 분산 모수 두 개가 전달한다.



15. 상태공간모형과 칼만필터

로드맵

14장은 평균은 고정된 채 분산이 시간에 걸쳐 움직이도록 두었다. 이 장은 평균 자체가, 자료가 오직 y_t 를 통해 간접적으로만 관측하는 잠재상태 α_t 를 통해 움직이도록 둔다. 칼만필터는 이 상태를 추출하는 고전적 방법이지만, 이 장의 실제 구현은 대수적으로 동등한 경로를 사용한다. 즉 전체 경로 $\alpha_{1:T}$ 를 하나의 커다란 가우스 벡터로 취급하여 단일 선형 해법으로 추출한다. 이 재구성엔 이 장을 넘어서는 의미가 있다: 16-18장은 이를 통째로 재사용하여, 동일한 정밀도-표본추출 기법을 단일 스칼라 추세 대신 시간에 걸쳐 변화하는 VAR의 계수나 변동성에 적용한다.

14장은 하나의 방정식의 분산이 조건부평균을 0에 고정된 채 시간에 걸쳐 움직이도록 두었다. 이 장은 동일한 발상을 뒤집는다: 상태공간모형은 한 계열의 조건부 평균이 그 자체로 단순한 시계열 과정을 따르는 하나 이상의 관측되지 않은(잠재) 상태에 의해 구동되어 시간에 걸쳐 움직이도록 한다. 아래의 두 가지 대표 예시(성장률을 서서히 움직이는 추세와 잡음으로 분해하기, 그리고 GDP를 매끄러운 추세와 정상적인 경기순환 요소로 분해하기)는 응용 거시경제학 전반에 걸쳐 반복해서 나타나며, 16-18장 각각은 이와 동일한 잠재상태 기법을 완전한 VAR 시스템으로 확장할 것이다.

선형 가우스 상태공간모형 일반적인 선형 가우스 상태공간모형은 관측된 자료 y_t 를 관측되지 않은 상태 α_t 와 연결하는 측정방정식과, α_t 가 어떻게 진화하는지를 기술하는 상태방정식으로 구성된다:

$$(\text{측정}) \quad y_t = Z_t \alpha_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, H_t),$$

$$(\text{상태}) \quad \alpha_t = T_t \alpha_{t-1} + \eta_t, \quad \eta_t \sim N(0, Q_t),$$

여기서 ε_t 와 η_t 는 모든 선행·후행 시점에서 서로 독립이며, 초기상태 α_0 은 자신의 사전분포를 갖는다. 그림 64는 그 결과로 나오는 의존 구조를 보여준다: 상태들은 자신만의 마르코프 연쇄를 이루고(행렬값 전이를 갖는 3장의 의존 패턴이 다시 나타난 것이다), 각 y_t 는 다른 어떤 시점의 상태도 직접 보지 않고 오직 자신의 α_t 에서만 갈라져 나온다.




Figure 64: 선형 가우스 상태공간모형의 의존 구조: 잠재상태들은 마르코프 연쇄를 이루고, 각 관측치는 오직 자신의 시점의 상태에만 의존한다

이 장의 두 실증 모형은 모두 특수사례다: α_t 가 단일 임의보행 추세인 국소수준(local-level) 모형, 그리고 α_t 가 매끄럽게 진화하는 추세와 정상적인 AR(2) 순환을 쌓아 놓은 국소선형추세-플러스-순환 모형.

알고리즘: 칼만필터와 그 정밀도-표본추출 등가물

- 1. 고전적 알고리즘.** 이 모형을 위한 표준 도구는 **칼만필터**다: 각 t 에서 α_{t-1} 로부터 나온 α_t 의 사전예측을 새 관측치 y_t 와 결합하여 갱신된(필터링된) 추정치로 만드는 전방 재귀다. 여기서는 모든 것이 선형이고 가우스이므로 전체 분포가 아니라 평균과 공분산만 전파한다. 필터를 전방으로 실행한 다음 보완적인 **후방 평활화**(전방필터링, 후방표본추출, FFBS)를 실행하면 전체 잠재상태 경로 $\alpha_{1:T}$ 를 그 정확한 결합조건부 사후분포로부터 한 번에 추출할 수 있으며, 이는 각 스윕에서 깃스 표본추출기가 필요로 하는 것이다.
- 2. 여기서 사용되는 등가 구현.** FFBS를 직접 구현하는 대신, 모든 $t = 1, \dots, T$ 에 대한 상태방정식을 하나의 선형 시스템 $H\alpha = b + u$ 로 쌓는데, 여기서 H 는 희소하고 대역(banded)인 일차 혹은 이차 차분 연산자다. 전체 경로 $\alpha_{1:T}$ 에 대한 결합 사전분포는 그러면 정밀도(역공분산) 행렬 $H'Q^{-1}H$ 를 갖는 가우스분포다 - Chan and Jeliazkov (2009)의 정밀도-표본추출 접근법이다.
- 3. 우도 정밀도와 결합.** 측정방정식에서 나오는 (역시 가우스이고 대각인) 우도 정밀도를 더하면 $\alpha_{1:T}$ 에 대해 다음 정밀도를 갖는 결합 가우스 완전조건부분포를 얻는다:

$$K_\alpha = H'Q^{-1}H + Z'H_t^{-1}Z,$$

이는 대역행렬이므로 T 가 수백 단위여도 콜레스키 분해가 저렴하다.

4. **전체 경로를 하나의 블록으로 추출.** 한 번의 추출은 $\alpha = \hat{\alpha} + L^{-1}z, z \sim N(0, I_T)$ 이며, 여기서 L 은 K_α 의 콜레스키 인자이고 $\hat{\alpha} = K_\alpha^{-1}$ (사후평균 항)이다.
5. **둘이 왜 동등한가.** 선형 가우스 상태공간모형에서, 이는 FFBS가 낼 것과 정확히 동일한 $\alpha_{1:T}$ 에 대한 결합분포를 낸다(둘 다 동일한 가우스분포의 서로 다른 인수분해일 뿐이다) 따라서 이 장은 칼만필터를 표준적인 개념적 알고리즘으로 제시하되, 14장의 명명법 정리와 같은 정신에서, 아래의 실제 구현이 문자 그대로의 전방-후방 필터가 아니라 이 등가의 대역-정밀도 구성을 사용한다는 것을 명시적으로 밝힌다.

15.1 사후분포 유도: 잠재경로에 대한 정밀도-표본추출 완전조건부분포

아래의 유도는 국소수준 모형의 임의보행 추세에 대해 한 번 작성되며, 모형 2의 평활화된 추세(일차 차분 연산자 H 를 이차 차분 연산자 H_2 로 대체)에 대해서, 그리고 16-17장에서 다시 아무 수정 없이 재사용된다.

유도: $\tau_{1:T} \mid \sigma^2, \omega^2, y$

추세 경로를 $\tau = (\tau_1, \dots, \tau_T)'$ 로 쌓는다. 상태방정식 $\tau_t = \tau_{t-1} + \eta_t, t = 1, \dots, T$ (τ_0 은 주어짐)는 하나의 선형 시스템 $H\tau = b + u, u \sim N(0, \omega^2 I_T)$ 로 쓸 수 있는데, 여기서 H 는 $T \times T$ 하부이중 대각(lower-bidiagonal) 일차차분 행렬(대각선에 1, 부대각선에 -1)이고 $b = (\tau_0, 0, \dots, 0)'$ 은 고정 초기조건이 들어가는 유일한 곳을 흡수한다. H 가 가역(단위대각을 갖는 하부삼각행렬)이므로, 이는 τ 자체에 대한 가우스 사전분포와 동등하다: $\tau = H^{-1}b + H^{-1}u$ 이므로 $\tau \sim N(H^{-1}b, \omega^2(H'H)^{-1})$, 즉 정밀도 $\omega^{-2}H'H$ 를 직접 갖는 가우스분포다(H 가 삼각행렬이고 그 행렬식, 따라서 가역성이 자명하므로 $H'H$ 자체를 역행렬로 만들 필요가 결코 없다). 이 사전분포의 커널은

$$\begin{aligned} p(\tau) &\propto \exp\left\{-\frac{1}{2}(H\tau - b)' \omega^{-2} I_T (H\tau - b)\right\} \\ &= \exp\left\{-\frac{1}{2}(\tau - H^{-1}b)' (\omega^{-2} H'H) \right. \\ &\quad \left. (\tau - H^{-1}b)\right\} \end{aligned}$$

측정방정식 $y_t = \tau_t + \varepsilon_t, \varepsilon_t \sim N(0, \sigma^2)$ 을 t 에 대해 쌓으면 우도 커널 $\exp\{-\frac{1}{2}\sigma^{-2}(y - \tau)'(y - \tau)\}$ 을 얻는데, 이는 정밀도 $\sigma^{-2}I_T$ 와 평균 y 를 갖는 τ 에 대한 가우스분포다. 두 커널을 곱하고 τ 에 대한 이차항과 일차항을 모으면(6.2절과 동일한 완전제곱식 전략이지만, 이제 τ 가 K -벡터가 아니라 T -벡터이고 “사전”과 “우도” 정밀도가 스칼라가 아니라 대역행렬이라는 점만 다르다) 다음을 얻는다:

$$\begin{aligned} &-\frac{1}{2} \left[\tau' (\omega^{-2} H'H + \sigma^{-2} I_T) \tau \right. \\ &\quad \left. - 2\tau' (\omega^{-2} H'H H^{-1}b + \sigma^{-2} y) \right] \\ &= -\frac{1}{2} \left[\tau' K_\tau \tau - 2\tau' (\omega^{-2} H'b + \sigma^{-2} y) \right] \end{aligned}$$

$H'H H^{-1} = H'$ 를 사용하여.^a 6.2절과 정확히 같은 방식으로 완전제곱하면 다음을 얻는다:

$$\begin{aligned}\tau \mid \sigma^2, \omega^2, y &\sim N(\hat{\tau}, K_\tau^{-1}), \\ K_\tau &= \omega^{-2} H'H + \sigma^{-2} I_T, \\ \hat{\tau} &= K_\tau^{-1} (\omega^{-2} H'b + \sigma^{-2} y)\end{aligned}$$

이는 알고리즘 상자의 $K_\alpha = H'Q^{-1}H + Z'H_t^{-1}Z$ 에서 $Z_t = I$ 인 경우와 일치한다. K_τ 는 대역(삼중대각, $H'H$ 가 삼중대각이고 I_T 가 대각이므로)이므로, 그 콜레스키 인자 $K_\tau = LL'$ 은 $O(T^3)$ 이 아니라 $O(T)$ 의 비용으로 계산된다. $z \sim N(0, I_T)$ 를 추출하고 $\tau = \hat{\tau} + L^{-1}z$ 로 설정하면 올바른 공분산을 갖는 표본이 산출되는데, 이는 $\text{Cov}(L^{-1}z) = L^{-1}I_T L^{-1} = (LL')^{-1} = K_\tau^{-1}$ 이기 때문이다 — 이것이 바로 단일 선형 해법이 문자 그대로의 칼만필터 구현의 순차적인 전방필터/후방표본추출 재귀를 대체하면서도 전체 경로에 대해 동일한 결합분포를 산출하게 하는 것이다.

^a이는 단순히 H^{-1} 이 존재하고(삼각행렬이고 단위대각을 가지므로 가역) 행렬곱셈이 결합적이기 때문에 성립한다: $H'H H^{-1} = H'(H H^{-1}) = H'I = H'$. 이로써 얻는 이득은 일차항에서 H^{-1} 를 명시적으로 형성할 필요가 전혀 없다는 것이다 — 대역행렬 $H'H$ 만 필요하며, 이것이 전체 계산을 $O(T^3)$ 이 아니라 $O(T)$ 로 유지시킨다.

^a이는 단순히 H^{-1} 이 존재하고(삼각행렬이고 단위대각을 가지므로 가역) 행렬곱셈이 결합적이기 때문에 성립한다: $H'H H^{-1} = H'(H H^{-1}) = H'I = H'$. 이로써 얻는 이득은 일차항에서 H^{-1} 를 명시적으로 형성할 필요가 전혀 없다는 것이다 — 대역행렬 $H'H$ 만 필요하며, 이것이 전체 계산을 $O(T^3)$ 이 아니라 $O(T)$ 로 유지시킨다.

15.2 모형 1: 미국 실질 PCE 성장률에 대한 국소수준모형

국소수준모형 y_t 를 실질 개인소비지출(연율화, 백분율) 성장률이라 하자. 국소수준모형은 이를 서서히 움직이는 추세 τ_t 와 일시적 잡음으로 분해한다:

$$y_t = \tau_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma^2), \quad \tau_t = \tau_{t-1} + \eta_t, \quad \eta_t \sim N(0, \omega^2),$$

$\tau_0 \sim N(a_0, b_0)$ 과 함께. 비율 ω^2/σ^2 은 신호대잡음비다: 작은 값은 추세가 서서히만 움직이고 y_t 의 기간간 변동 대부분이 일시적 잡음임을 뜻하며, 큰 값은 추세 자체가 변동성이 크고 y_t 를 밀접하게 추적함을 뜻한다. σ^2 과 ω^2 은 각각 역감마 사전분포($\nu = 3$, 척도 $S = 2$)를 가지며 $\tau_0 \sim N(5, 100)$ 은 전후 미국 실질 소비 성장률의 전형적 값 부근에 중심을 둔 약하게 정보적인 사전분포다. 세 미지수(전체 추세경로 $\tau_{1:T}$, σ^2 , ω^2) 모두 깁스 샘플링으로 추출된다: $\tau_{1:T}$ 는 위의 정밀도 표본추출기를 통해 결합적으로(H 는 $T \times T$ 일차차분 연산자),^a 그런 다음 σ^2 과 ω^2 은 현재의 추세경로와 잔차가 주어졌을 때 각자의 역감마 완전조건부분포로부터 추출된다.

^a이 결합 경로 추출(칼만 재귀 없이, 띠 구조 사후 정밀도행렬의 희소 콜레스키 분해 한 번)이 Chan and Jeliazkov (2009)의 정밀도 표본추출기이며, 복제 킷의 `uc.m`이 정확히 이 블록을 구현한다.

유도: $\sigma^2 \mid \tau, y$ 와 $\omega^2 \mid \tau$

추세경로 τ 가 주어졌을 때, 두 분산 완전조건부분포 모두 정확히 6.2절의 커널-매칭 유형에 속하는 역감마 갱신이며, 서로 다른 두 잔차 계열에 적용된다. 둘 다 이 장의 $\nu = 3$, $S = 2$ 사전분포 매개변수화를 사용한다 (6.2절의 $IG(a_0/2, d_0/2)$ 표기법으로 $a_0 = 3$, $d_0 = 2$). 대수 전개는 단지 유추로 주장하는 대신 각각에 대해 실제로 적어 나간다.

1. $\sigma^2 \mid \tau, y$. $t = 1, \dots, T$ 에 대한 측정방정식 $y_t - \tau_t = \varepsilon_t \sim N(0, \sigma^2)$ 은 6.2절의 회귀잔차 역할을 하며, $e'e \rightarrow \sum_t (y_t - \tau_t)^2$ 이고 표본크기는 동일한 T 다. 가우스 우도를 σ^2 만의 함수로 쓰고

$IG(3/2, 1)$ 사전분포 커널을 곱하면,

$$p(y | \tau, \sigma^2) = (2\pi\sigma^2)^{-T/2} \exp\left\{-\frac{1}{2\sigma^2} \sum_{t=1}^T (y_t - \tau_t)^2\right\},$$

$$p(\sigma^2) \propto (\sigma^2)^{-(3/2+1)} \exp\left\{-\frac{2}{2\sigma^2}\right\}.$$

두 항을 곱하고 6.2절과 정확히 같은 방식으로 σ^2 의 거듭제곱을 공유 지수항과 별도로 모으면:

$$p(\sigma^2 | \tau, y) \propto (\sigma^2)^{-T/2-(3/2+1)} \exp\left\{-\frac{1}{2\sigma^2} \left[\sum_{t=1}^T (y_t - \tau_t)^2 + 2\right]\right\}$$

그리고 결합된 거듭제곱을 형태/척도 형식으로 쓰면 다음의 커널이다:

$$\sigma^2 | \tau, y \sim IG\left(\frac{3+T}{2}, \frac{2 + \sum_t (y_t - \tau_t)^2}{2}\right)$$

사전 자유도 3과 사전 제곱합 2가 각각 표본크기 T 와 실현된 측정잔차 제곱합에 의해 갱신된다.

2. $\omega^2 | \tau$. $t = 1, \dots, T$ 에 대한 상태혁신 $\eta_t = \tau_t - \tau_{t-1} \sim N(0, \omega^2)$ (τ_0 은 주어짐)는 동일한 역할을 하며, 측정잔차 대신 $e'e \rightarrow \sum_t (\tau_t - \tau_{t-1})^2$ 이지만 동일한 표본크기 T 와 동일한 $IG(3/2, 1)$ 사전분포를 갖는다:

$$p(\tau | \omega^2) = (2\pi\omega^2)^{-T/2} \exp\left\{-\frac{1}{2\omega^2} \sum_{t=1}^T (\tau_t - \tau_{t-1})^2\right\},$$

$$p(\omega^2) \propto (\omega^2)^{-(3/2+1)} \exp\left\{-\frac{2}{2\omega^2}\right\}.$$

위와 정확히 같은 방식으로 곱하고 ω^2 의 거듭제곱을 모으면:

$$p(\omega^2 | \tau) \propto (\omega^2)^{-T/2-(3/2+1)} \exp\left\{-\frac{1}{2\omega^2} \left[\sum_{t=1}^T (\tau_t - \tau_{t-1})^2 + 2\right]\right\}$$

이는 다음의 커널이다:

$$\omega^2 | \tau \sim IG\left(\frac{3+T}{2}, \frac{2 + \sum_t (\tau_t - \tau_{t-1})^2}{2}\right)$$

실증 예제: 실증 결과: 소비 성장률의 추세와 잡음

이 모형을 분기별 실질 PCE 성장률, 1959Q2–2015Q4 ($T = 227$, 수준의 로그차분에 400을 곱하여 계산)에 적합하고 6,000개의 번인 이후 길스 표본(1,200개 표본의 번인 이후)을 얻으면 사후평균 $\hat{\sigma}^2 = 5.28$ (95% 신용구간 [4.20, 6.59])과 $\hat{\omega}^2 = 0.449$ (95% 신용구간 [0.220, 0.828])를 주며, 신호대잡음비는 겨우 0.085다: 분기간 소비 성장률의 잡음은 대략 그 기저 추세의 진정한 분기간 움직임보다 열두 배 더 크며, 따라서 그림 65의 추세경로는 예상대로 원자료 성장률 계열 자체보다 훨씬 매끄럽다. 추정된 추세는 표본 시작 시점에 5.23%에서 출발하여 표본 최댓값인 10.96%까지

상승하고 (1970년대 후반의 고성장·고인플레이션 시기), 2008-09년 침체의 골에서 표본 최솟값인 0.60%까지 급격히 하락한 뒤, 표본 마지막 시점인 2015Q4까지 3.45%로 회복한다 — 이는 계열 특유의 추가적인 조정 없이도 일반적인 국소수준모형만으로 전후 미국 소비 성장률의 폭넓고 잘 문서화된 흐름과 일치하는 추세경로다.

이 기법이 가장 단순한 기성품 대안인 HP 필터($\lambda = 1600$, 표준 분기별 값)를 동일한 성장률 계열에 적용한 것에 비해 무엇을 사주는가? 전체 표본에 걸쳐 두 추세는 서로 가깝게 움직이며(상관계수 0.98, RMSE 0.45포인트), 따라서 보통의 분기에서는 두 방법이 크게 다투지 않는다. 그러나 가장 중요한 지점에서 이들은 날카롭게 갈라진다: 2008-09년 침체의 골에서 HP 추세는 겨우 2.57%까지만 하락하는 반면, 국소수준모형의 추세는 표본 최솟값인 0.60%까지, 즉 두 포인트 이상 더 낮게 하락한다. HP 필터의 고정된 평활화 별점은 추세 성장률의 진정하고 다분기에 걸친 급락을 평범한 기간간 잡음과 구분할 수 없으므로, 이 정도 크기의 충격에 과소반응한다. 반면 국소수준모형은 자신의 σ^2 과 ω^2 을 자료로부터 추정하여 충분히 크고 충분히 지속적인 충격이 추세를 그에 맞게 움직이도록 한다. 그림 65는 이를 직접 눈으로 확인할 수 있도록 HP 추세(청록색, 점선)를 같은 그림에 겹쳐 그린다.




Figure 65: 국소수준모형, 미국 실질 PCE 성장률: 원자료 분기별 성장률(회색) 대 사후평균 추세(실선), 그리고 비교를 위한 단순 HP 필터 추세($\lambda = 1600$, 파선)

15.3 모형 2: 미국 실질 GDP의 추세와 순환

국소선형추세 플러스 AR(2) 순환 $y_t = 100 \times \log(\text{실질 GDP}_t)$ 라 하자. 산출갭 모형은 y_t 를 매끄러운 추세 τ_t (잠재산출)와 정상적인 순환 c_t (산출갭)로 나눈다:

$$y_t = \tau_t + c_t, \quad c_t = \phi_1 c_{t-1} + \phi_2 c_{t-2} + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma_c^2),$$

여기서 추세는 임의보행이 아니라 매끄러운 과정을 따른다 — 그 자신의 성장률 $\Delta\tau_t = \tau_t - \tau_{t-1}$ 이 임의보행이다:

$$\Delta\tau_t = \Delta\tau_{t-1} + \eta_t, \quad \eta_t \sim N(0, \sigma_\tau^2).$$

이차차분 제약 $H_2\tau = b + u$ (H_2 는 $T \times T$ 이차차분 연산자로, H_2 의 i 번째 행은 $\tau_i, \tau_{i-1}, \tau_{i-2}$ 에 대해 $[\dots, 1, -2, 1, \dots]$)로 쓰면, 이는 위의 정밀도-표본추출 구성을 두 번 적용한 것과 정확히 같은데, 한 번은 추세의 성장률에 적용된다. 초기조건 (τ_0, τ_{-1}) 은 확산적인 이변량 정규 사전분포를 갖고, AR(2) 계수 (ϕ_1, ϕ_2) 는 $(1.3, -0.7)$ 에 중심을 둔 정규 사전분포를 가지며(지속적이고 완만하게 진동하는 동학을 함의하는 교과서적 경기순환 사전평균) 정상성 삼각형으로 제약되고, σ_c^2 는 역감마 사전분포를 가지며, σ_τ^2 은 유계균등 $(0, 0.01)$ 사전분포를 갖는다(의도적으로 촘촘하여, 추세가 y_t 의 저주파 움직임만을 흡수하도록 강제하고 경기순환 주파수의 움직임은 c_t 에 남겨둔다) 유계균등 사전분포는 역감마 켄레 형태가 없으므로 표준적인 켄레 갱신이 아니라 4장의 격자 기반 역CDF 방법으로 표본추출된다.

알고리즘: 산출갭모형을 위한 깃스 표본추출기

매 스왑마다:

1. 전체 추세경로 $\tau_{1:T}$ 를 그 가우스 완전조건부분포로부터 결합적으로 추출한다(정밀도 표본추출기, H_2 연산자),^a 매끄러운-추세 사전분포를 $y_t - \tau_t = c_t$ 에 대한 AR(2) 함의 우도와 결합한다.
2. 함의된 순환 $c_t = y_t - \tau_t$ 가 주어졌을 때 (ϕ_1, ϕ_2) 를 그 정규 완전조건부분포에서 추출하되, (약간 축소된) 정상성 삼각형 $\phi_1 + \phi_2 < 0.99$, $\phi_2 - \phi_1 < 0.99$, $\phi_2 > -0.99$ 밖의 표본은 기각하고 다시 추출한다.
3. AR(2) 잔차가 주어졌을 때 σ_c^2 를 그 역감마 완전조건부분포에서 추출한다.
4. σ_τ^2 를 그 유계균등 완전조건부분포에 대한 500점 격자 근사로부터 추출한다(4장의 역CDF 방법).
5. 초기조건 (τ_0, τ_{-1}) 을 그 가우스 완전조건부분포에서 추출한다.

연쇄는 600스왑의 번인 이후 2,000스왑에 대해 실행된다. 정상성-기각 단계는 제안된 (ϕ_1, ϕ_2) 표본의 98.1%를 수락하는데, 이는 이 사후분포에서 그 제약 영역이 거의 구속력을 갖지 않음을 나타낸다.

^a역시 Chan and Jeliazkov (2009)다: $H_2'H_2/\sigma_\tau^2$ 와 $H_\phi'H_\phi/\sigma_c^2$ 모두 락 행렬이라 그 합도 락 구조를 유지하고, 결합 추출 비용은 희소 출레스키 분해 한 번이다 (UC_output_gap.m).

유도: 산출갭모형의 다섯 가지 완전조건부분포

아래의 다섯 블록 각각은 이 노트 다른 곳에서 이미 온전히 수행된 유도를 재사용한다. 이어지는 내용은 단순히 유추만으로 결과를 주장하는 대신, 이 모형의 구체적인 대상들을 각각에 대입하여

커널-매칭 단계를 명시적으로 다시 수행한다.

1. **추세** $\tau_{1:T}$. 매끄러운-추세 제약을 $H_2\tau = b + u$, $u \sim N(0, \sigma_\tau^2 I_T)$ 로 쓰면(H_2 는 이차차분 연산자, b 는 (τ_0, τ_{-1}) 을 흡수), 상태방정식 사전분포 커널은 위의 국소수준모형 증명상자에서 $H \rightarrow H_2, \omega^2 \rightarrow \sigma_\tau^2$ 로 바꾼 것과 정확히 같다,

$$p(\tau) \propto \exp\left\{-\frac{1}{2}(\tau - H_2^{-1}b)'(\sigma_\tau^{-2}H_2'H_2)(\tau - H_2^{-1}b)\right\}.$$

측정 쪽은, 현재의 순환 표본 $c = y - \tau$ 가 주어졌을 때, 우도 커널 $\exp\{-\frac{1}{2}\sigma_c^{-2}(y - \tau)'(y - \tau)\}$ 을 기여하는데, 이는 정말로 $\sigma_c^{-2}I_T$ 와 평균 y 를 갖는 τ 에 대한 가우스분포다. 두 커널을 곱하고 τ 에 대한 이차항과 일차항을 모으면, 이전과 정확히 같은 방식으로 $\omega^{-2}H'H \rightarrow \sigma_\tau^{-2}H_2'H_2$ 이고 $\sigma^{-2} \rightarrow \sigma_c^{-2}$ 일 때:

$$p(\tau \mid \sigma_c^2, \sigma_\tau^2, c) \propto \exp\left\{-\frac{1}{2}\left[\tau'(\sigma_\tau^{-2}H_2'H_2 + \sigma_c^{-2}I_T)\tau - 2\tau'(\sigma_\tau^{-2}H_2'b + \sigma_c^{-2}y)\right]\right\}$$

다음의 커널이다:

$$\begin{aligned}\tau \mid \sigma_c^2, \sigma_\tau^2, c &\sim N(\hat{\tau}, K_\tau), \\ K_\tau &= \sigma_\tau^{-2}H_2'H_2 + \sigma_c^{-2}I_T, \\ \hat{\tau} &= K_\tau^{-1}(\sigma_\tau^{-2}H_2'b + \sigma_c^{-2}y)\end{aligned}$$

2. **AR(2) 계수** (ϕ_1, ϕ_2) . 함의된 순환 $c_t = y_t - \tau_t$ 가 주어졌을 때, 재귀 $c_t = \phi_1 c_{t-1} + \phi_2 c_{t-2} + \varepsilon_t$ 는 기지의 오차분산 σ_c^2 를 갖는 c_t 의 (c_{t-1}, c_{t-2}) 에 대한 평범한 이변량 회귀다. $\phi = (\phi_1, \phi_2)'$, X_c 를 행이 (c_{t-1}, c_{t-2}) 인 쌓인 설계행렬, 그리고 정규 사전분포 $\phi \sim N(\phi_0, V_{0,\phi})$, $\phi_0 = (1.3, -0.7)'$ 라 하면, 6.2절의 $\beta \mid \sigma^2, y$ 완전제곱 논증이 $X \rightarrow X_c, y \rightarrow c, b_0 \rightarrow \phi_0, V_0 \rightarrow V_{0,\phi}$ 로 적용된다:

$$\begin{aligned}p(c \mid \phi, \sigma_c^2) &\propto \exp\left\{-\frac{1}{2\sigma_c^2}(c - X_c\phi)'(c - X_c\phi)\right\}, \\ p(\phi) &\propto \exp\left\{-\frac{1}{2}(\phi - \phi_0)'V_{0,\phi}^{-1}(\phi - \phi_0)\right\}.\end{aligned}$$

6.2절과 정확히 같은 방식으로 곱하고 ϕ 에 대한 이차항과 일차항을 모으면:

$$p(\phi \mid \sigma_c^2, c) \propto \exp\left\{-\frac{1}{2}\left[\phi'(V_{0,\phi}^{-1} + \sigma_c^{-2}X_c'X_c)\phi - 2\phi'(V_{0,\phi}^{-1}\phi_0 + \sigma_c^{-2}X_c'c)\right]\right\}$$

다음의 무절단 커널이다:

$$\begin{aligned}\phi \mid \sigma_c^2, c &\sim N(\bar{\phi}, \bar{V}_\phi), \\ \bar{V}_\phi &= (V_{0,\phi}^{-1} + \sigma_c^{-2}X_c'X_c)^{-1}, \\ \bar{\phi} &= \bar{V}_\phi(V_{0,\phi}^{-1}\phi_0 + \sigma_c^{-2}X_c'c)\end{aligned}$$

정상성 제약은 (진짜 완전조건부분포가 요구할, 그리고 7장/9장의 자료증강 문제가 일방 문턱에 대해 그렇게 했던 것처럼) 절단정규 커널을 다시 유도하는 방식이 아니라 기각추출로 부과된다: 무절단 $N(\bar{\phi}, \bar{V}_\phi)$ 에서 반복 추출하여 정상성 삼각형 밖의 표본을 버리는 것은 절단분포를 표본추출하는 유효한 방법인데, 이는 어떤 가측집합 A 로 제한했을 때 $\mathbb{K}_A$ 로 재정규화된 정

규밀도가 바로 무제약 정규분포에서 A 에 도달하는 조건부로 기각추출한 것과 정확히 같은 것을 산출하기 때문이다.

3. $\sigma_c^2 \mid c$. AR(2) 오차분산 사전분포를 $IG(a_{0c}/2, d_{0c}/2)$ (6.2절 표기법)로, 잔차를 $\varepsilon_t = c_t - \phi_1 c_{t-1} - \phi_2 c_{t-2}$, $t = 1, \dots, T_c$ 로 나타내자(여기서 T_c 는 적합한 AR(2) 잔차의 개수다). $e \rightarrow \varepsilon$ 인 6.2절의 $\sigma^2 \mid \beta, y$ 논증과 정확히 같다:

$$p(c \mid \phi, \sigma_c^2) = (2\pi\sigma_c^2)^{-T_c/2} \exp\left\{-\frac{\varepsilon'\varepsilon}{2\sigma_c^2}\right\}, \quad p(\sigma_c^2) \propto (\sigma_c^2)^{-(a_{0c}/2+1)} \exp\left\{-\frac{d_{0c}}{2\sigma_c^2}\right\}.$$

6.2절과 정확히 같은 방식으로 곱하고 σ_c^2 의 거듭제곱을 모으면:

$$p(\sigma_c^2 \mid c) \propto (\sigma_c^2)^{-\left(\frac{a_{0c}+T_c}{2}+1\right)} \exp\left\{-\frac{d_{0c} + \varepsilon'\varepsilon}{2\sigma_c^2}\right\}$$

다음의 커널이다:

$$\sigma_c^2 \mid c \sim IG\left(\frac{a_{0c} + T_c}{2}, \frac{d_{0c} + \varepsilon'\varepsilon}{2}\right)$$

여기서 $\varepsilon'\varepsilon = \sum_t \varepsilon_t^2$ 가 $e'e$ 의 역할을, T_c 가 T 의 역할을 한다.

4. σ_τ^2 . $u = H_2\tau - b$ 가 추세 자신의 이차차분 $\eta_t = \Delta\tau_t - \Delta\tau_{t-1}$, $t = 1, \dots, T$ 를 모으므로, σ_τ^2 에 대한 τ 의 우도 기여는

$$p(\tau \mid \sigma_\tau^2) = (2\pi\sigma_\tau^2)^{-T/2} \exp\left\{-\frac{1}{2\sigma_\tau^2} \sum_{t=1}^T \eta_t^2\right\}, \quad \eta_t = \Delta\tau_t - \Delta\tau_{t-1},$$

그리고 균등(0, 0.01) 사전분포는 지시함수 $\mathbb{I}\{0 < \sigma_\tau^2 < 0.01\}$ 만을 기여한다(형태/척도 항 없음). 둘을 곱하면:

$$p(\sigma_\tau^2 \mid \tau) \propto (\sigma_\tau^2)^{-T/2} \exp\left\{-\frac{\sum_t \eta_t^2}{2\sigma_\tau^2}\right\} \times \mathbb{I}\{0 < \sigma_\tau^2 < 0.01\}$$

이는 (0, 0.01)로 제한된, 알아볼 수 있는 다음의 커널이다:

$$\sigma_\tau^2 \mid \tau \sim IG\left(\frac{T-2}{2}, \frac{\sum_t \eta_t^2}{2}\right)$$

(거듭제곱 대응: $-T/2 = -(\alpha+1)$ 이면 $\alpha = (T-2)/2$). 이 절단된 역감마 커널은 직접 표본 추출에 편리한 닫힌 형태의 정규화상수가 없는데, 이것이 바로 알고리즘이 교과서적 쿨레 추출 대신 4장의 격자 역CDF 방법(위 커널을 (0, 0.01)에 걸친 촘촘한 격자에서 평가하고 수치적으로 정규화한 뒤 그 결과인 이산 CDF를 역변환)에 의존하는 이유다.

5. **초기조건** (τ_0, τ_{-1}). 이것들은 $H_2\tau = b + u$ 의 처음 두 행의 일차항 b 를 통해서만 들어오는데, 이는 H_2 의 i 번째 행이 $\tau_i, \tau_{i-1}, \tau_{i-2}$ 를 참조하고 $t = 1$ 이전으로 거슬러 올라가는 것은 오직 $i = 1, 2$ 행뿐이기 때문이다. $b = R\gamma$ 로 쓰되 R 은 고정된 $T \times 2$ 선택행렬(오직 1-2행에서만

비영)이고 $\gamma = (\tau_0, \tau_{-1})'$, 확산적 이변량 정규 사전분포 $\gamma \sim N(g_0, G_0)$ 라 하면:

$$p(\tau | \gamma, \sigma_\tau^2) \propto \exp \left\{ -\frac{1}{2\sigma_\tau^2} (H_2\tau - R\gamma)' (H_2\tau - R\gamma) \right\},$$

$$p(\gamma) \propto \exp \left\{ -\frac{1}{2} (\gamma - g_0)' G_0^{-1} (\gamma - g_0) \right\}.$$

첫 이차형식을 γ 에 대해 전개하고 사전분포를 곱하면, 6.2절의 $\beta | \sigma^2, y$ 논증에서 $X \rightarrow R$, $y \rightarrow H_2\tau$, $b_0 \rightarrow g_0$, $V_0 \rightarrow G_0$, $\sigma^2 \rightarrow \sigma_\tau^2$ 로 바꾼 것과 정확히 같다:

$$p(\gamma | \tau, \sigma_\tau^2) \propto \exp \left\{ -\frac{1}{2} \left[\gamma' (G_0^{-1} + \sigma_\tau^{-2} R' R) \gamma - 2\gamma' (G_0^{-1} g_0 + \sigma_\tau^{-2} R' H_2\tau) \right] \right\}$$

다음의 커널이다:

$$\gamma | \tau, \sigma_\tau^2 \sim N(\bar{\gamma}, \bar{G}),$$

$$\bar{G} = (G_0^{-1} + \sigma_\tau^{-2} R' R)^{-1},$$

$$\bar{\gamma} = \bar{G} (G_0^{-1} g_0 + \sigma_\tau^{-2} R' H_2\tau)$$

실증 예제: 실증 결과: 잠재산출과 산출갭

이 모형을 분기별 실질 GDP, 1947Q1-2015Q4 ($T = 276$)에 적합하면 사후평균 $\hat{\phi}_1 = 1.308$ (95% 신용구간 $[1.192, 1.427]$), $\hat{\phi}_2 = -0.372$ (95% 신용구간 $[-0.481, -0.260]$), $\hat{\sigma}_c^2 = 0.734$, 그리고 $\hat{\sigma}_\tau^2 = 0.0034$ 를 주는데 $-\sigma_c^2$ 보다 세 자릿수 더 작아, 그림 66(a)의 추세가 구성상 원계열보다 훨씬 매끄러움을 확인해준다. 추정된 산출갭(그림 66(b))은 표준편차 2.39%, 1949Q4에 표본 최솟값 -7.20% (1948-49년 전후 침체의 골), 1953Q1에 표본 최댓값 4.95% (한국전쟁 생산호황, 1953-54년 하강 직전)를 가지며, 2015Q4 표본 끝에서는 -0.09% 로 — 사실상 잠재수준에서 마무리된다. 잠재산출 자체의 성장률은 표본 시작 시점의 3.90% 에서 표본 끝의 1.72% 로 하락하는데, 이는 이 기간에 걸쳐 잘 문서화된 미국 추세 GDP 성장의 둔화와 일치한다.

동일한 $100 \times \log$ 실질 GDP 계열에 적용한 단순 HP 필터 ($\lambda = 1600$)와 대비하면, 두 산출갭 추정치는 양의 상관관계를 가지지만(상관계수 0.84) HP 필터의 알려진 약점이 예측하는 바로 그 방식으로 진폭과 시점 모두에서 다르다. 전체 표본에 걸쳐 상태공간모형의 순환은 표준편차 2.39%인 반면 HP 순환은 1.62%다: 상태공간모형은 계열의 움직임 중 눈에 띄게 더 많은 부분을 추세가 아니라 순환에 귀속시킨다. 2008-09년 저점에서 상태공간모형의 갭은 2009Q3에 -3.30% 로 바닥을 치는데, 이는 HP 갭의 2009Q2 -2.89% 보다 더 깊고 한 분기 늦다. 더 날카로운 발산은 표본의 끝에서 나타난다: 2014Q3까지 HP 필터는 이미 $+0.60\%$ 의 양의 산출갭(산출이 잠재수준 위)을 보이는 반면, 상태공간모형은 여전히 경제가 잠재수준보다 -0.41% 아래에 있다고 보고하며, 상태공간모형의 갭은 표본의 마지막 몇 분기까지 양수로 전환하지 않는다. 이는 교과서적인 HP 말단점 문제다: 표본의 경계에서는 필터가 평활화할 미래 자료가 남아 있지 않으므로, 그 추세는 가장 최근 관측치에 밀착하도록 요동치며 추정된 갭을 조기에 닫아버리는데, 반면 상태공간모형의 추세에 대한 곡률 사전분포 (σ_τ^2 가 $(0, 0.01)$ 로 제한됨)는 표본 내부에서든 경계에서든 동일하게 제약을 가한다. 그림 66(c)는 이 발산을 직접 눈으로 확인할 수 있도록 2005-2016을 확대한다.




Figure 66: (a) $100 \times \log$ 실질 GDP(회색) 대 추정된 매끄러운 추세/잠재산출(파선) 대 단순 HP 필터 추세($\lambda = 1600$, 점선); (b) 추정된 산출갭, 상태공간(실선) 대 HP 필터(파선), 경기침체 저점과 호황 정점이 드러난다; (c) 확대, 2005-2016, HP 필터의 표본 끝 편향을 상태공간 갭과 대비

참고: 정밀도-표본추출 기법이 단순한 HP 필터보다 나은 점은 무엇인가?

이 장의 두 실증 예제는 모두 가장 단순한 기성품 추세추출 대안인, 관행적인 분기별 평활화 모수 $\lambda = 1600$ 을 갖는 HP 필터를 동일한 원자료에 적용하여 대조되었다. 두 방법은 대체로 상당히 가깝게 일치하는데(위에서 보고된 PCE 추세와 GDP 순환 모두에서 상관계수가 0.8을 넘는다)이 자체가 시사적이다: 평범한 분기의 평범한 자료에 대해서는 일반적인 HP 필터와 이 장의 완전한 베이저안 상태공간모형이 크게 다투지 않는다. 두 접근법은 정확히 두 지점에서 갈라서는데, 둘 다 위에서 예시되었다. 첫째는 진정한 지속적인 단절의 크기다: PCE 성장률 추세에서, HP 필터의 고정된 벌점은 기저 이행이 아무리 지속적이든 추정된 추세가 몇 분기에 걸쳐 얼마나 멀리 움직일 수 있는지를 제한하여, 추세 소비 성장률의 2008-09년의 급락을 두 퍼센트포인트 이상 과소평가한다. 반면 상태공간모형은 자신의 평활화 강도(σ^2, ω^2)를 자료로부터 추정하여 충분히 크고 충분히 지속적인 충격이 이를 극복하도록 둔다. 둘째는 표본 경계다: HP 필터는 표본의 양 끝을 제외한 모든 곳에서는 대칭적인 양방향 필터이지만, 그 끝에서는 평활화할 미래 관측치가 남아 있지 않아 그 추세가 가장 최근 자료 쪽으로 요동친다 — 잘 문서화된 “말단점 문제”로, 이는 2014-15년 미국 산출갭 추정치를 상태공간모형의 곡률-제약된 추세보다 훨씬 일찍 단아버린다. 어느 문제도

이 특정한 λ 선택에 특유한 결함이 아니다(다른 평활화 모수는 한 편향을 다른 편향과 맞바꿀 뿐이다). 둘 다 표본 전체에 걸쳐 균일하게 적용되는 어떤 고정-평활화모수 필터의 구조적 특징이며, 이는 정확히 이 장의 모형기반 접근법이, 표본의 경계 바로 그곳에서조차, 얼마나 많은 평활화가 정당한지를 자료가 알려주도록 함으로써 완화하는 제약이다.

참고: 여기에 잘 식별된 경기순환 주기가 존재하는가?

AR(2) 순환 $c_t = \phi_1 c_{t-1} + \phi_2 c_{t-2} + \varepsilon_t$ 은 $\phi_1^2 + 4\phi_2 < 0$ 일 때만 진동적이다(복소 특성근을 가지며, 따라서 합의된 순환 주기를 갖는다). 이를 사후평균 계수만이 아니라 사후 표본마다 점검하면(서로 다른 각도의 복소근을 갖는 표본들을 평균하면 실근을 갖는 평균점을 낼 수 있으므로) 2,000개의 사후 표본 중 겨우 2.95%만이 이를 만족함을 보여준다. 여기서의 진정한 발견은 이 모형의 순환이 깔끔한 주기정보보다는 지속성과 감쇠에 의해 지배된다는 것이다: 사후질량의 대다수에서 (ϕ_1, ϕ_2) 는 두 개의 실수 자기회귀근을 함의하는데(지속적이지만 진동하지 않는 순환), 이는 교과서적인 감쇠 사인파가 아니다. 복소근을 함의하는 소수의 표본 중에서는, 합의된 순환 길이가 평균 13.3년(중앙값 10.1)이지만, 이를 만족하는 표본이 너무 적어 이 수치는 “미국의” 경기순환 길이에 대한 신뢰할 만한 요약이 아니며 여기서는 투명성을 위해서만 보고될 뿐, 대표 결과로서가 아니다 — 이 사후분포로부터 단일한 확신에 찬 순환길이 추정치를 억지로 끌어내는 것은 자료와 모형이 실제로 식별하는 바를 과장하는 것이다.

15.4 Clark (1987)

위의 모형 2는 GDP를 매끄러운 추세와 순환으로 가정에 의해 분해했다. 그 추세에는 수준 충격이 전혀 허용되지 않았으므로, 분기별 잔물결은 모두 순환으로 밀려 들어갔다. 이 절이 재현하는 논문은 바로 그 가정이 건너뛴 질문을 던졌다. Clark (1987), “The Cyclical Component of U.S. Economic Activity”(Quarterly Journal of Economics 102(4))는 $y_t = 100 \ln(\text{실질 GNP})$, 1947Q1–1985Q4를 두 종류의 충격을 모두 갖는 추세와 정상 AR(2) 순환으로 분해한다.

$$y_t = \tau_t + c_t, \quad \tau_t = g_{t-1} + \tau_{t-1} + v_t, \quad g_t = g_{t-1} + w_t, \quad c_t = \phi_1 c_{t-1} + \phi_2 c_{t-2} + e_t,$$

세 교란항은 상호 독립이다 — Clark의 식별 가정이다. 이 설계는 결정론적 선형추세($\sigma_v = \sigma_w = 0$)부터 모형 2의 매끄러운 추세($\sigma_v = 0$), 넬슨-플로셔식 랜덤워크(큰 σ_v , 작은 순환)까지를 모두 포괄하며, 선택은 자료에 맡긴다. 당시를 지배하던 Nelson and Plosser (1982)의 해석(GNP는 본질적으로 랜덤워크이며 순환이 설 자리는 거의 없다는 것)에 맞서, Clark의 답은 GNP의 분기별 혁신 중 적어도 절반이 오 년까지 지속되는 정상 순환성분의 몫이라는 것이었다. Clark은 칼만 필터를 통한 최우추정으로 모형을 추정했다. 재현은 대신 이 장의 정밀도 샘플러 장치를 재사용하며, 모형 2를 위해 이미 구축된 산출갭 샘플러에 드리프트 경로 $g_{1:T}$ 를 위한 깃스 블록 하나($\tau_{1:T}$ 블록과 구조적으로 동일한 두 번째 희소 가우시안 추출)를 더할 뿐이다.⁴

⁴즉 UC_clark1987.m의 매 스윕은 Chan–Jeliazkov (2009) 희소 가우시안 경로 추출 두 번($\tau_{1:T}$ 와 $g_{1:T}$) 더하기 표준 컬레 블록들로 이루어진다.

실증 예제: 원표본 1947Q1-1985Q4

사후평균(표준편차)을 Clark의 Table I 최우추정값(여기서 사용하는 $100 \times \log$ 스케일로 환산)과 비교하면 다음과 같다.

	사후분포	Clark (1987)
ϕ_1	1.46 (0.11)	1.53
ϕ_2	-0.58 (0.10)	-0.59
σ_v (추세 수준)	0.71	0.64
σ_w (추세 성장률)	0.08	0.01
σ_e (순환)	0.73	0.74

논문의 결론이 사는 곳은 순환이며, 그곳은 거의 정확하게 재현된다. 순환 혁신의 표준편차는 소수 둘째 자리까지 일치하고, AR(2) 계수는 사후 표준편차 하나 이내이며, 헤드라인 산술도 그대로 살아남는다 — 분기별 혁신 분산 전체에서 순환의 몫은 51.6%, Clark의 “적어도 절반”이다. 사후평균 순환 경로(그림 67 가운데 패널)는 -5.1에서 +3.4퍼센트 사이를 오가며 표본 안의 모든 NBER 침체에서 저점을 찍고, 사후평균 AR(2)는 약 22분기(오 년 반)의 확률적 주기를 갖는 복소근을 함의한다. Clark의 점추정에서 떨어져 앓은 것은 작은 추세 성장률 분산뿐인데, 그 간극은 문제라기보다 유익한 정보이다. Clark 자신의 Table I은 추세에 대한 네 가지 서로 다른 제약(그의 최우추정, 드리프트 딸린 랜덤워크, 모형 2의 매끄러운 추세, 심지어 선형추세)이 $2 \times \log$ 우도 4.3점 이내에서 적합함을 보여주고, 그의 우도 지도는 정확히 (σ_v, σ_w) 평면에 길고 평평한 능선을 그린다. 최우추정값은 그 능선 위의 한 점이다. 사후분포는 그 능선 전체에 대해 적분하며, 능선을 따라 조금 다른 곳에 내려앉은 것이다. 아래 패널은 랜덤워크 드리프트가 무엇을 더해 주는지 보여준다. 연율화된 추세 성장률이 1960년대 중반 4.3%까지 올랐다가 1985년까지 3%를 향해 내려가는 — Clark으로 하여금 상수 성장률을 미리 부과하지 않게 만든 생산성 둔화의 프로파일이다.




Figure 67: Clark (1987) 재현: 사후평균 추세와 HP($\lambda = 1600$) 추세를 겹친 $100 \times$ 로그 실질 GNP(위), 68% 구간과 HP 순환을 겹친 순환성분(가운데), 연율화 추세 성장률 $4g_t$ (아래), 원표본

참고: HP 필터 위에 모형이 더해 주는 것, 한 번 더

동일한 계열에 돌린 HP 벤치마크는 일들이 언제 일어났는가에 관해서는 Clark의 순환과 합의한다(두 순환 경로의 상관은 0.94이다) 그리고 이는 민망한 일이 아니라 안심되는 일이다. 둘 다, 느슨하게 말해, 같은 계열의 평활기이기 때문이다. 차이는 정확히 이 장의 앞선 예제들이 기록한 것들이며, 이제 창시 응용 위에서 눈에 보인다. HP 순환은 더 잘게 된다(팔 분기 자기상관이 Clark 순환의 -0.14 에 맞서 -0.32). $\lambda = 1600$ 은 고정된 평활 상수인 반면 Clark 추세의 유연성은 자료로부터 추정되기 때문이다. HP 필터는 불확실성 구간을 보고하지 않지만 UC 모형의 순환은 사후 분포를 지니고 온다. 그리고 HP 필터에는 추세 성장률이라는 개념 자체가 없으므로, 그림 67과 68의 아래 패널(아마도 이 모형의 가장 경제학적으로 흥미로운 산출물)에는 HP 대응물이 아예 존재하지 않는다.

실증 예제: 전체표본 1947Q1-2026Q1

동일한 모형을 2026Q1까지 연장하면 모형의 세 가지 이야기가 모두 경제적으로 읽기 쉬운 방식으로 달라진다(그림 68). 순환은 줄어든다. 사후평균 표준편차가 1.82에서 1.21로 떨어지고 1984년 이후의 안정화가 가운데 패널에서 뚜렷하게 보이며, 분기별 혁신 분산에서 순환의 몫은 51.6%에서 42.5%로 내려간다 — 더 긴 표본에서는 GNP의 분기별 변동 중 좀 더 많은 부분이 영구적인 것으로 읽히는 것이다. 추세 성장률은 Clark이 드리프트 랜덤워크를 만들어 넣은 이유를 계속 수행

한다. 표본 초의 3.7%에서 1990년대의 고원을 거쳐 2010년 이후 약 2.3%까지 내려가 거기 머무는 — 상수 드리프트 설정이었다면 통째로 놓쳤을 장기 하락의 프로파일이다. 그리고 COVID 분기는 그림 안에서 두 분해 사이의 통제된 실험을 연출한다. 추세가 충분히 빨리 휘지 못하는 HP 필터는 2020Q2의 붕괴를 거의 전부 순환으로 보내지만(−10퍼센트에 가까운 저점), Clark의 2충격 추세는 그 대략 절반을 영구적인 수준 충격으로 흡수하여 순환 저점을 −4.5에 남긴다 — 두 순환 추정치의 상관은 0.90으로 내려가고, HP 순환은 이제 모형 기반 순환보다 33% 더 변동적이다. 어느 배분이 옳은가는 진정으로 열린 질문이다 — 그러나 둘 중 하나의 방법만이 그 판정을 고정된 평활 상수가 아니라 자료에 맡긴다.




Figure 68: 2026Q1까지 추정된 동일한 UC 모형: 순환은 1984년 이후 안정화되고, 추세 성장률은 약 2.3%까지 장기 하락하며, 2020Q2의 붕괴는 HP 필터가 전부 순환으로 밀어넣는 것과 달리 추세와 순환으로 나뉜다

16. 확률적 변동성을 갖는 VAR

로드맵

앞선 세 장은 각각 이 장의 문제를 한 조각씩 따로 해결했다: 11장은 변동성을 고정한 채 VAR의 계수를 추정했고, 14장은 하나의 방정식의 변동성이 움직이도록 두었지만 이를 담을 시스템이 없었으며, 15장은 전체 잠재경로를 하나의 선형 해법으로 추출하는 기법을 구축했다. 이 장의 진정한 내용은 그 조립이다: 삼각분해가 하나의 어려운 다변량 변동성 문제를 15장의 단변량 문제를 n 개

따로 복제한 것으로 바꾸며, 여기에 새로운 조각 하나, 즉 로그제곱 잔차를 정밀도-표본추출 기법이 적용될 만큼 충분히 가우스처럼 보이게 만드는 Kim-Shephard-Chib 기법이 더해진다. 여기서 처음부터 새로 작성되는 표본추출기는 없다. 모든 것이 재사용되며, 이것이 바로 이 장의 요점이다.

11장의 VAR는 오차항 공분산 Σ 를 전체 표본에 걸쳐 고정했다. 14장은 하나의 방정식의 분산이 시간에 걸쳐 움직이도록 두었지만 방정식 시스템에 대해서는 아무것도 말하지 않았다. 15장은 잠재상태가 매끄럽게 진화하도록 두었지만 전체에 걸쳐 상수분산 혁신을 가정했다. 이 장은 이 세 가지 발상을 하나의 모형으로 결합한다: 계수는 여전히 상수이지만 충격 공분산이 다변량 확률적 변동성 과정을 통해 시간에 걸쳐 진화하는 VAR다 — 정확히 14장과 15장의 KSC(Kim, Shephard and Chib, 1998) 혼합-표본추출기와 정밀도-표본추출 기법을, 이제 VAR의 모든 방정식에 동시에 적용한 것이다. 이는 뒤이어 나올 완전한 시변 시스템(17장의 TVP-VAR)으로 가는 표준적인 첫 걸음이다.

확률적 변동성을 갖는 VAR(VAR-SV) n 개 변수 VAR(p)에 대해, 축약형을 다음과 같이 쓴다:

$$y_t = \Phi_1 y_{t-1} + \cdots + \Phi_p y_{t-p} + c + u_t, \quad u_t \sim N(0, \Sigma_t),$$

여기서 11장과 달리 Σ_t 는 이제 t 에 따라 변한다. Σ_t 를 직접 모형화하는 대신, VAR-SV는 삼각(“구조적”) 분해를 통해 이를 모형화한다: L 을 자유로운 부대각 원소 $a = (a_{21}, a_{31}, a_{32}, \dots)$ 를 갖는 하부단위삼각행렬이라 하고, $\varepsilon_t = L u_t$ 를 직교화된(구조적) 충격이라 하자. 각 직교화된 충격은 자신만의 독립적인 확률적 변동성 과정을 가지며, 이는 로그분산에서의 순수 임의보행이다:

$$\varepsilon_{i,t} \sim N(0, e^{h_{i,t}}), \quad h_{i,t} = h_{i,t-1} + \eta_{i,t}, \quad \eta_{i,t} \sim N(0, \sigma_{h,i}^2),$$

$h_{i,0} \sim N(1, 10)$ 과 함께. $u_t = L^{-1} \varepsilon_t$ 이므로, 이는 $\Sigma_t = L^{-1} \text{diag}(e^{h_{1,t}}, \dots, e^{h_{n,t}}) L^{-\prime}$ 를 함의한다: L 은 시간에 걸쳐 상수인 교차방정식 공분산 부분을 포착하고, $h_{i,t}$ 경로들은 각 직교화된 충격 자신의 척도가 독립적으로 팽창하거나 수축하도록 하며, 이 둘의 결합은 L 자체는 변하지 않더라도 축약형 충격 사이의 상관관계가 시간에 걸쳐 이동하도록 한다.

그림 69는 다섯 가지 블록 유형이 서로 어떻게 맞물리는지를 배치한다. 혼합지표 $\kappa_{1:T}$ 는 이 장이 도입하는 진정으로 새로운 유일한 블록으로, 변동성 경로와 자료 사이에 위치한다.




Figure 69: VAR-SV 표본추출기의 의존 구조: 실선/양방향 화살표는 각 스왑의 직접 갱신($\beta, L \leftrightarrow \kappa_{1:T} \leftrightarrow h_{1:T}$)이고, 점선 화살표는 더 먼 거리의 유일한 연결이다($h_{1:T}$ 는 β, L 단계에서 사용되는 정밀도 가중치도 설정한다) 그리고 σ_h^2 는 변동성 경로 자신의 혁신분산에 대한 순환을 담는다

알고리즘: VAR-SV를 위한 김스 표본추출기

(Φ, c) 에 대해 11장의 VAR 사전분포(기울기 계수에 정밀도 1, 절편에 1/10)를 반영한 사전분포, L 의 자유원소에 대한 독립 $N(0, 1)$ 사전분포, 그리고 각 $\sigma_{h,i}^2$ 에 대한 $IG(3, 0.01)$ 사전분포와 함께:

1. **계수.** 쌓인 VAR 계수벡터를 그 정규 완전조건부분포로부터 결합적으로 추출하는데, 이는 각 관측치를 자신의 시점- t 정밀도 $\Sigma_t^{-1} = L' \text{diag}(e^{-h_{1,t}}, \dots, e^{-h_{n,t}}) L$ 로 가중하는 일반화최소 제곱(GLS) 갱신이다 — 이는 14장의 GARCH 우도와 6장의 베이저안 회귀를 직접 다변량으로 일반화한 것으로, 매 기간 변하는 정밀도행렬을 갖는다.
2. **로그변동성.** 현재의 잔차로부터 함의된 구조적 충격 $s_t = Lu_t$ 를 복구하고, $y_t^* = \log(s_t^2 + 0.0001)$ 을 형성한 뒤, 각 방정식 i 에 대해 이 노트 어디에도 아직 등장하지 않았지만 모든 SV 모형에 암묵적으로 깔려 있는 동일한 Kim-Shephard-Chib 보조혼합 표본추출기를 적용한다: 다루기 힘든 $\log \chi_1^2$ 관측밀도를 7개 성분 정규혼합으로 근사하고, 각 t 를 한 성분으로 분류한 다음, 전체 경로 $h_{i,1:T}$ 를 정확히 15장의 대역 일차차분 정밀도-표본추출 구성을 통해 그 가우스 완전조건부분포로부터 결합적으로 추출한다 — 임의보행 상태방정식 $h_{i,t} = h_{i,t-1} + \eta_{i,t}$ 는 15장의 국소수준 추세 τ_t 와 구조적으로 동일하며, 여기서는 단지 성장을 대신 로그분산에 적용될 뿐이다.
3. **동시적 적재값.** 각 축약형 잔차를 선행하는 잔차들의 음수값에 대해 회귀한 것으로부터 L 의 자유원소를 추출하되, $e^{-h_{i,t}}$ 로 정밀도-가중한다 — 이는 12장의 SVAR 식별 단계의 다변량 유사물이지만, 이제 시변 가중치를 갖는다.
4. **상태분산과 초기상태.** $h_{i,1:T}$ 경로의 일차차분이 주어졌을 때 각 $\sigma_{h,i}^2$ 를 그 역감마 완전조건부분포로부터 추출하고, 각 $h_{i,0}$ 을 $h_{i,1}$ 이 주어졌을 때 그 정규 완전조건부분포로부터 추출한다.

16.1 사후분포 유도

유도: $\beta \mid \Sigma_{1:T}, y$ (시변 정밀도 아래에서의 계수)

VAR를 10.2절과 정확히 같은 SUR/축적 형태 $y_t = Z_t\beta + u_t, u_t \sim N(0, \Sigma_t)$ 로 쓰면, β 에 대한 사후분포 커널은

$$p(\beta \mid \Sigma_{1:T}, y) \propto \exp \left\{ -\frac{1}{2} \left[\sum_t (y_t - Z_t\beta)' \Sigma_t^{-1} (y_t - Z_t\beta) + (\beta - b_0)' B_0^{-1} (\beta - b_0) \right] \right\}$$

10.2절의 완전제곱식 논증은 합 안의 가중행렬이 모든 t 에서 동일한 행렬이라는 가정을 전혀 사용하지 않았다. 그것은 단지 어떤 양의 정부호 가중치가 각 $(y_t - Z_t\beta)$ 이차형식을 항이 t 에 대해 합해지기 전에 곱한다는 사실만을 사용했다. Σ_t 가 t 첨자를 갖도록 허용해도 그 논증에는 아무런 변화가 없으므로, 이전과 정확히 같은 방식으로 전개하고 항을 모으면:

$$\begin{aligned} \beta \mid \Sigma_{1:T}, y &\sim N(\bar{\beta}, \bar{B}), \\ \bar{B} &= \left(B_0^{-1} + \sum_t Z_t' \Sigma_t^{-1} Z_t \right)^{-1}, \\ \bar{\beta} &= \bar{B} \left(B_0^{-1} b_0 + \sum_t Z_t' \Sigma_t^{-1} y_t \right) \end{aligned}$$

이는 6.2절의 스칼라 σ^{-2} -가중 결과와 10.2절의 상수- Σ^{-1} -가중 결과를 직접 다변량, 시변정밀도로 일반화한 것이다: 합 안의 가중행렬이 단지 기간마다 바뀔 뿐, 앞으로 뿔쳐 나오지는 않는다.

유도: $h_{i,1:T}$ 에 대한 KSC 보조혼합 표현

방정식 i 를 고정하고 첨자를 생략한다. 구조적 충격 $\varepsilon_t \sim N(0, e^{h_t})$ 는 $\varepsilon_t = e^{h_t/2} \xi_t, \xi_t \sim N(0, 1)$ 로 쓸 수 있으므로, $\varepsilon_t^2 = e^{h_t} \xi_t^2$ 이고, 로그를 취하면 관측방정식은 다음이 된다:

$$y_t^* \equiv \log(\varepsilon_t^2 + 0.0001) \approx \log \varepsilon_t^2 = h_t + \log \xi_t^2$$

이는 h_t 에 대해 선형인 관측방정식이지만 비가우스 오차 $\log \xi_t^2 \sim \log \chi_1^2$ ($\xi_t^2 \sim \chi_1^2$ 이므로)를 가지며, 이것이 바로 로그변동성 경로가 있는 그대로는 15장의 정밀도 표본추출기로 직접 추출될 수 없는 이유다: 그 구성은 가우스 관측방정식을 요구한다. Kim, Shephard and Chib (1998)의 장치는 각 t 에 대해 이산 보조혼합성분지표 $\kappa_t \in \{1, \dots, 7\}$ 과, (오프라인에서 한 번, 적률을 맞추어 선택된) 7개 성분 정규혼합 $\{\pi_k, m_k, v_k^2\}_{k=1}^7$ 을 도입하여 $\sum_k \pi_k N(m_k, v_k^2)$ 가 $\log \chi_1^2$ 밀도를 밀접하게 근사하도록 하는 것이다. $\kappa_t = k$ 가 주어지면, 이는 h_t 에 대해 정확히 가우스인 관측방정식이 된다:

$$y_t^* \mid h_t, \kappa_t = k \sim N(h_t + m_k, v_k^2)$$

두 번의 추출로 이 단계가 완성된다:

1. **성분지표.** 현재의 h_t 가 주어졌을 때, κ_t 에 대한 사후분포는 유한혼합에 적용된 베이즈 규칙에 의해(이는 8장의 γ_j 단계와 동일한 이산사후분포 논증을 두 성분에서 일곱 성분으로 일반화한 것이다)

$$P(\kappa_t = k \mid y_t^*, h_t) \propto \pi_k N(y_t^* \mid h_t + m_k, v_k^2), \quad k = 1, \dots, 7,$$

k 에 대해 합이 1이 되도록 정규화되고 t 마다 단일 범주형 표본으로 추출된다.

2. **로그변동성 경로.** $\kappa_{1:T}$ 가 주어지면, 관측방정식 $y_t^* - m_{\kappa_t} = h_t + \xi_t^*$, $\xi_t^* \sim N(0, v_{\kappa_t}^2)$ 는 임의 보행 상태방정식 $h_t = h_{t-1} + \eta_t$, $\eta_t \sim N(0, \sigma_h^2)$ 와 함께, 이제 정확히 15장의 국소수준 구성이다($\tau_t \rightarrow h_t$, $y_t \rightarrow y_t^* - m_{\kappa_t}$, $\sigma^2 \rightarrow v_{\kappa_t}^2$, 여기서는 상수가 아니라 t 에 걸쳐 대각이지만 이분산적인데, 이는 그곳의 완전제곱식 논증이 이미 항별로 수용하는 것이다). 따라서 전체 경로 $h_{1:T}$ 는 다음으로부터 결합적으로 추출된다:

$$h_{1:T} \mid \kappa_{1:T}, y^*, \sigma_h^2 \sim N(\hat{h}, K_h^{-1}), \quad K_h = \sigma_h^{-2} H' H + \text{diag}(v_{\kappa_t}^{-2}),$$

이는 15장의 증명상자와 동일한 대역-정밀도 콜레스키 구성이며, 거기서의 상수 $\sigma^{-2} I_T$ 가 여기서 (여전히 대각이지만 이제 t 에 따라 변하는) $\text{diag}(v_{\kappa_t}^{-2})$ 로 대체된 것만 다르다.^a

이것이 바로 KSC 단계가, 이 노트를 위한 진정으로 새로운 기법임에도 불구하고, 새로운 표본추출 원리가 아니라 보조 표현으로 도입되는 이유다: 일단 혼합지표가 관측방정식을 선형화하고 가우스화하면, 실제 경로 추출은 아무 수정 없이 15장의 유도를 재사용한다.

^a즉 혼합 지시변수가 주어지면 모형은 선형 가우스 상태공간이 되고, 로그변동성 경로 전체가 15장과 똑같이 Chan and Jeliazkov (2009)의 정밀도 표본추출기로 추출된다. 복제 킷의 SVRW.m이 바로 이 블록이다.

유도: 동시적 적재값 a 와 나머지 상태 모수

L 이 하부단위삼각행렬이므로, $Lu_t = \varepsilon_t$ 의 i 번째 행은 $u_{i,t} + \sum_{j < i} a_{ij} u_{j,t} = \varepsilon_{i,t}$ 로 읽히며, 즉

$$u_{i,t} = - \sum_{j < i} a_{ij} u_{j,t} + \varepsilon_{i,t}, \quad \varepsilon_{i,t} \sim N(0, e^{h_{i,t}}),$$

이는 기지의, 시변인 오차분산 $e^{h_{i,t}}$ 를 갖고 $u_{i,t}$ 를 선행 방정식들의 동시적 잔차의 음수값에 대해 회귀한 것이다. 이 블록은 세 개의 뚜렷한 하위결과를 가지며, 단순히 인용만으로도 아니라 아래에서 차례로 도출된다.

1. **적재값** $a_{i,\cdot} \mid u, h_i$. $u_{-i,t} = (u_{1,t}, \dots, u_{i-1,t})'$ 와 $a_{i,\cdot} = (a_{i1}, \dots, a_{i,i-1})$ 에 대한 명시된 $N(0, I)$ 사전분포를 가지고,

$$p(u_i \mid a_{i,\cdot}, h_i) \propto \exp \left\{ -\frac{1}{2} \sum_t e^{-h_{i,t}} (u_{i,t} + u'_{-i,t} a_{i,\cdot})^2 \right\}, \quad p(a_{i,\cdot}) \propto \exp \left\{ -\frac{1}{2} a'_{i,\cdot} a_{i,\cdot} \right\}$$

이는 위 첫 증명상자에서 유도된 시변정밀도 GLS 회귀의 스칼라 가중치 사례이며, $Z_t \rightarrow -u_{-i,t}$, $y_t \rightarrow u_{i,t}$, $\Sigma_t^{-1} \rightarrow e^{-h_{i,t}}$, $b_0 \rightarrow 0$, $B_0^{-1} \rightarrow I$ 다. 거기서와 정확히 같은 방식으로 $a_{i,\cdot}$ 에 대한 이차형식을 곱하고 전개하면:

$$p(a_{i,\cdot} \mid u, h_i) \propto \exp \left\{ -\frac{1}{2} \left[a'_{i,\cdot} \left(I + \sum_t e^{-h_{i,t}} u_{-i,t} u'_{-i,t} \right) a_{i,\cdot} + 2 a'_{i,\cdot} \sum_t e^{-h_{i,t}} u_{-i,t} u_{i,t} \right] \right\},$$

다음의 커널이다: $a_{i,\cdot} \mid u, h_i \sim N(\bar{a}_{i,\cdot}, \bar{V}_{a_i})$,

$$\bar{V}_{a_i} = \left(I + \sum_t e^{-h_{i,t}} u_{-i,t} u'_{-i,t} \right)^{-1},$$

$$\bar{a}_{i,\cdot} = -\bar{V}_{a_i} \sum_t e^{-h_{i,t}} u_{-i,t} u_{i,t}.$$

2. $\sigma_{h,i}^2 \mid h_{i,1:T}$. $t = 1, \dots, T$ 에 대한 $\eta_{i,t} = h_{i,t} - h_{i,t-1}$ 과 알고리즘 상자의 $IG(3, 0.01)$ 사전분포(이 노트 전체에서 사후분포에 사용되는 형태/척도 관례)를 가지고,

$$p(h_i \mid \sigma_{h,i}^2) = (2\pi\sigma_{h,i}^2)^{-T/2} \exp\left\{-\frac{1}{2\sigma_{h,i}^2} \sum_{t=1}^T \eta_{i,t}^2\right\}, \quad p(\sigma_{h,i}^2) \propto (\sigma_{h,i}^2)^{-4} \exp\left\{-\frac{0.01}{\sigma_{h,i}^2}\right\}$$

정확히 15장의 $\omega^2 \mid \tau$ 논증에서 $\tau_t - \tau_{t-1} \rightarrow \eta_{i,t}$ 로 바꾼 것이다. 곱하고 $\sigma_{h,i}^2$ 의 거듭제곱을 모으면:

$$p(\sigma_{h,i}^2 \mid h_i) \propto (\sigma_{h,i}^2)^{-(3+T/2+1)} \exp\left\{-\frac{0.01 + \frac{1}{2} \sum_t \eta_{i,t}^2}{\sigma_{h,i}^2}\right\},$$

$$\sigma_{h,i}^2 \mid h_i \sim IG\left(3 + \frac{T}{2}, 0.01 + \frac{1}{2} \sum_t \eta_{i,t}^2\right).$$

3. $h_{i,0} \mid h_{i,1}, \sigma_{h,i}^2$. $h_{i,1} = h_{i,0} + \eta_{i,1}$, $\eta_{i,1} \sim N(0, \sigma_{h,i}^2)$ 과 사전분포 $h_{i,0} \sim N(1, 10)$ 을 가지고, 이는 단일 “회귀변수” $x = 1$, 결과 $y = h_{i,1}$, 사전평균 $b_0 = 1$, 사전분산 $V_0 = 10$ 을 갖는 6.2절의 $\beta \mid \sigma^2, y$ 논증의 스칼라 사례다:

$$p(h_{i,1} \mid h_{i,0}, \sigma_{h,i}^2) \propto \exp\left\{-\frac{(h_{i,1} - h_{i,0})^2}{2\sigma_{h,i}^2}\right\}, \quad p(h_{i,0}) \propto \exp\left\{-\frac{(h_{i,0} - 1)^2}{20}\right\}$$

6.2절과 정확히 같은 방식으로 곱하고 $h_{i,0}$ 에 대해 완전제곱하면:

$$p(h_{i,0} \mid h_{i,1}, \sigma_{h,i}^2) \propto \exp\left\{-\frac{1}{2} \left[h_{i,0}^2 \left(\frac{1}{10} + \frac{1}{\sigma_{h,i}^2} \right) - 2h_{i,0} \left(\frac{1}{10} + \frac{h_{i,1}}{\sigma_{h,i}^2} \right) \right] \right\},$$

$\bar{v}_{i,0} = (1/10 + 1/\sigma_{h,i}^2)^{-1}$ 과 $\bar{h}_{i,0} = \bar{v}_{i,0}(1/10 + h_{i,1}/\sigma_{h,i}^2)$ 를 갖는 $h_{i,0} \mid h_{i,1}, \sigma_{h,i}^2 \sim N(\bar{h}_{i,0}, \bar{v}_{i,0})$ 의 커널이다.

16.2 실증 예제: 25개 변수 LBVAR-SV, 1979–2026

실증 예제: 대규모 패널로의 확장: 삼각구조라는 요령

위 알고리즘은 일반적인 n 에 대해 서술되었지만, β 를 추출하는 결합 단계(전체 쌓인 계수벡터(차원 nk)를, t 에 걸쳐 $n \times n$ 외적을 합산하여 만든 정밀도행렬로부터 단일 정규분포로 한 번에 추출하는 단계)는 n 이 커지면 계산적으로 감당할 수 없게 된다: 이 노트 자체의 25변수 분기 패널(1978Q2–2026Q1, 이번 판에서 13장이 BGR의 월별 자료로 전환하기 전까지 13장이 사용 하던 패널)은 $p = 4$ 시차로 방정식당 $k = 101$ 개의 회귀변수를 가지므로, 결합벡터의 차원은 $nk = 2,525$ 이며, 매 깃스 스위치마다 $2,525 \times 2,525$ 정밀도행렬을 분해하는 것은 반복 가능한 작업이 아니다. 이는 정확히 13장이 서두에서 다룬 대규모 BVAR의 차원의 저주가 이제 변동성 쪽에서 재등장한 것이다. Carriero, Chan, Clark and Marcellino의 (2021) 대규모 BVAR-SV 논문에 대한 정오표가 그 해법을 제공하며, 이는 13장이 위계적 사전분포에서 이미 사용한 것과 같은 삼각 발상이다: L 이 하부단위삼각행렬이므로, 구조적 시스템의 i 번째 행은 $u_{i,t} + \sum_{j < i} a_{ij}u_{j,t} = \varepsilon_{i,t}$ 로 읽히고, 따라서 방정식 i 의 구조적 충격은 오직 변수 $1, \dots, i$ 에만 의존하며 그 이후 순서의 어떤 변수에도 의존하지 않는다. $(\beta_i, a_{i,\cdot})$ 를 방정식별로, 각각 다른 방정식에 조건부로 추출하면, 하나의

$nk \times nk$ 분해가 n 개의 별도 분해로 대체되며 각각의 크기는 $(k+i-1) \times (k+i-1)$, 여기서는 최대 $k+n-1=125$ 로 2,525가 아니다 — 이는 다루기 힘든 결합문제를 n 개의 평범한 회귀로 바꾸는 것이며, 정확히 13장 자신의 위계적 사전분포 표본추출기가 이미 평균방정식을 추출하는 방식이다. 변동성 쪽은 전혀 새로운 발상이 필요 없다: (β, a) 가 주어졌을 때 방정식들이 조건부로 독립이므로, 각 $h_{i,1:T}$ 는 여전히 15장의 평범한 단변량 임의보행 평활기일 뿐이며, $n=3$ 이 아니라 $n=25$ 번 실행될 뿐이다. 13장의 삼각 위계적-카파 사전분포(동일한 $\kappa_1, \dots, \kappa_4$ 강도 초모수; 다만 여기서는 이 분기 패널의 균일한 $\delta_i = 0.5$ 자기시차 사전평균과 강한 정상성 기각추출을 사용하는데, 이 패널이 BGR의 수준 자료와 달리 정상화 변환된 성장률로 들어오기 때문에 둘 다 실행 가능하다)를 이 장의 임의보행 로그변동성 기법과 방정식별로 결합하면, 상수변동성 위계적 표본추출기와 스위프당 거의 동일한 비용으로 25변수 전체 패널까지 확장되는 LBVAR-SV를 얻는다. 상수변동성 (“CV”)과 확률적변동성 (“SV”) 두 버전 모두를 이 25변수 분기 패널, $p=4$ 시차, 500개 표본의 번인 이후 1,500개 사후표본으로 적합했으며, 패널의 1978Q2 시작점에서 $p=4$ 개 시차가 소모된 이후 이용 가능한 전체 1979Q2–2026Q1 구간 ($T=188$)에 대해 추정했다.

실증 예제: 25개 변수에 걸친 시변 변동성

그림 70는 이전과 동일한 세 개의 서사적 변수(GDP 성장률, CPI 인플레이션, 실업률)에 대한 사후 평균 구조적 충격 표준편차 $e^{h_{i,t}/2}$ 를, 이제 3변수 시스템이 아니라 25변수 전체 시스템 내에서 결합적으로 추정하여 그리며, 볼커 디스인플레이션, 2008-09년 침체, 2020년 코로나19 침체를 음영으로 표시한다. 1960년이 아니라 1979년에 표본을 시작하면 1960-70년대의 대인플레이션기를 잃는 대신 볼커 시기 자체를 얻는다.

GDP-성장률 충격 변동성은 연준의 디스인플레이션이 연이은 침체를 촉발하는 1979-1983년 동안 이미 높은 수준(3.2–4.9)이며, 대안정기를 거치며 1990년대 중반에는 1–2 범위로 하락하고, 2008-09년 무렵 완만하게 상승한 뒤(2008Q4 근방 3.1에서 정점), **2020Q3에 14.19**로 정점을 찍어 이전의 모든 시기를 압도한다 — 볼커 시기 최고치의 네 배 이상이다. 실업-충격 변동성도 다른 규모에서 같은 패턴을 보인다: 침체기 밖에서는 사실상 평탄하고 낮으며(0.1–0.3), 금융위기 때 완만하게 상승했다가, **2020Q2에 2.65**로 날카롭고 좁게 치솟은 뒤 일 년 안에 다시 가라앉는다. CPI-인플레이션 충격 변동성은 다른 이야기를 들려준다: 이 구간에서 최고치는 **1980Q2의 1.97**로, 볼커 디스인플레이션의 정점이며 코로나나 2021-22년 인플레이션 급등 시기가 아니다. 이제 패널의 공동변동을 설명하는 부담을 23개의 다른 변수와 나누어 지므로, 3변수 소규모 시스템에서보다 2021-22년 구간에서 CPI 자체의 분기별 변동 중 설명되지 않고 남는 부분이 더 적다 — 이는 변수의 추정된 충격 변동성이 변수 하나만이 아니라 모형에 무엇이 함께 들어있는지에 달려 있음을 일깨운다. 소규모 시스템에서와 마찬가지로, “가장 변동성이 컸던 시기”라는 단일한 표제는 세 변수 모두에 들어맞지 않는다: 산출과 실업은 2020Q2–Q3에 명백한 최악의 순간을 갖는 반면, 인플레이션은 여전히 사십 년 전인 1980년이다.




Figure 70: 25변수 LBVAR-SV, 1979Q2–2026Q1 내에서 결합적으로 추정된 사후평균 구조적 충격 변동성, GDP 성장률, CPI 인플레이션, 실업률; 음영 구간은 볼커 디스인플레이션(1979-83), 2008-09년 침체, 2020년 코로나19 침체

실증 예제: 함의된 시변 상관관계와 오쿤의 법칙

그림 71는 GDP-성장률과 실업률 축약형 충격 사이의 함의된 상관관계 $\Sigma_t[\text{GDP}, \text{UEMP}] / \sqrt{\Sigma_t[\text{GDP}, \text{GDP}] \Sigma_t[\text{UEMP}, \text{UEMP}]}$ 를 그리며, 이는 다시 오쿤의 법칙의 충격 수준 대응물이다. 표본 전체에 걸쳐 음(-)이며, **2000Q1**의 가장 강한(가장 밀접한 연계의) 음수값 **-0.73**부터(이는 이 구간의 두 주요 위기 중 어느 쪽도 아닌 닷컴 붕괴 직전이다) **2020Q2**, 즉 코로나 4개 분기의 가장 약한(가장 느슨한 연계의) 음수값 **-0.19**까지 걸쳐 있다. 코로나 시기의 약화는 소규모 3변수 시스템에서의 발견을 반복한다: 2020년의 실업률 급등은 통상적인 수요 측 경로가 아니라 기계적이고 정책에 의해 강제된 섀다운에서 비롯되었으므로, 성장과 실업이 동시에 가장 극단적이었던 바로 그 시점에 충격 수준의 동조성은 이례적으로 느슨했다(구간 평균 -0.23). 볼커 구간(1979-83)은 비교적 밀접한 평균 -0.59 를 보이고, 2008-09년 금융위기는 -0.43 , 평온했던 2015-19년 시기는 -0.34 다. 이전과 마찬가지로, 전체 표본에서 가장 강한 단일 연계는 유명한 위기 시기의 분기가 아니라 그 외의 특별할 것 없는 분기이며, 이는 “상관관계는 크고 유명한 위기 동안 가장 강했다”는 직관적인 기본값을 이 25변수 시스템 역시 확인해주지 않는다는 사실을 재확인해준다.




Figure 71: GDP-성장률과 실업률 축약형 충격 사이의 사후평균 함의된 시변 상관관계, 25변수 LBVAR-SV, 1979Q2-2026Q1

16.3 LBVAR 대 LBVAR-SV: 점 예측과 밀도 예측

실증 예제: 첫 번째 시도: 위기 이전 단일 시점에서의 예측

25변수 BVAR에 확률적 변동성을 추가하는 것은 13장의 상수변동성 위계적 표본추출기보다 상당히 더 비싸다(여기서는 스왑당 대략 60% 더 많은 시간이 걸리며, 대부분은 $n = 25$ 개의 임의보행 평활기 호출에서 비롯된다) 따라서 이 비용이 실제로 무언가를 사주는지 직접 물어볼 가치가 있다. 첫 번째 시도로, 위의 CV 모형과 SV 모형 모두를 2007Q4까지만(금융위기 이전 마지막 평온한 분기) 적합하고, 2008-09년 위기와 그 여파로 $h = 1, 4, 8, 16, 24, 32$ 분기를 예측하는 데 사용하여 (i) 각 모형 자신의 축약형 예측경로에 대한 사후표본별 평균인 점 예측과, (ii) 각 모형 자신의 1,500개 사후표본 예측 혼합분포 아래에서 실제 결과의 로그 예측점수를 logsumexp를 통해 수 준공간에서 평균한 밀도 예측을 비교한다. SV의 경우, 각 사후표본 자신의 미래 로그변동성 경로 자체가 임의보행 법칙 $h_{T_0+s} = h_{T_0+s-1} + \eta_s$ 을 통해 표본 내 마지막 상태에서부터 앞으로 시뮬레이션되므로, 한 표본의 예측오차 공분산은 그 표본 자신의 미래 변동성에 대한 불확실성을 반영한다. 표 2와 그림 72가 그 결과를 보고하는데, SV 예측 문헌에 익숙한 독자가 기대할 만한 결과가 아니다. 점 예측(GDP 성장률의 절대예측오차)은 모든 시계(horizon)에서 CV와 SV 사이에 거의 동일하며, 이는 확률적 변동성이 예측의 중심경향이 아니라 그 주변의 불확실성에 대한 모형의 평가를 바꾼다는 것을 확인해준다. 그러나 밀도 예측에서는 SV가 교과서적 직관처럼 위기 근처에서 그냥 이기는 것이 아니라 — 정확히 이겨야 할 곳에서 크게 진다: $h = 4$ 와 $h = 8$ (2008년 4분기 2009년 4분기, 위기의 최악의 순간)에서 SV의 로그점수는 CV보다 각각 65.2점, 8.8점 낮다(25개 변수 전체 합산). $h = 24-32$ (위기 이후 6-8년)에 이르러서야 SV가 앞서 나가는데, 그마저도 소폭이다(+3.8, +2.7). 이 표를 액면 그대로 받아들이면 확률적 변동성이 예측자가 가장 도움을 원할 바로 그 순간에 오히려 해롭다는 뜻이 되는데, 이는 확률적 변동성 자체보다는 이 분석 설계를 의심해야 한다는 신호다.

Table 2: LBVAR 대 LBVAR-SV, 25변수 패널, 2007년 4분기까지만 훈련, 2008-09년 위기와 그 여파로 예측: 25개 단변량 개별 로그 예측점수의 합, 그리고 SV-CV 차이(양수면 SV 선호)

h (분기)	LPS, CV	LPS, SV	차이 (SV-CV)
1	-56.4	-59.1	-2.7
4	-195.8	-261.1	-65.2
8	-81.1	-89.9	-8.8
16	-78.0	-78.5	-0.5
24	-71.5	-67.7	+3.8
32	-72.3	-69.7	+2.7

LBVAR vs LBVAR-SV, 25-Variable Panel, Trained Through 2007Q4, Forecasting Into the 2008-09 Crisis




Figure 72: 왼쪽: GDP 성장률의 절대 점예측오차, LBVAR(CV) 대 LBVAR-SV, 시계별(거의 동일함. 오른쪽: SV에서 CV를 뺀 로그 예측점수(25개 변수 전체 합산), 시계별) 2007년 4분기 단일 시점 기준, 충격 근처에서는 비용이 들고 몇 년 후에야 소폭 유리해짐

실증 예제: 왜 SV는 이겨야 할 곳에서 지는가?

범인은 모형 설계의 오류가 아니라 예측 기준시점으로 선택된 바로 그 분기다. 2007Q4는 2000년대 중반의 이례적으로 잠잠했던 구간인 “대안정기(Great Moderation)”의 저점에 위치한다. 그래서 바로 그 분기의 SV 변동성 상태는 비정상적으로 낮은 수준으로 적응해 있다. 반면 CV는 1978-2007년 전체표본 평균과 같은 하나의 상수분산을 쓰는데, 여기에는 이미 볼커 디스인플레이션, 1990-91년 침체, 2001년 침체가 다 녹아들어 있다. 예측 기준시점에서 두 모형이 내재하는 분산의 사후평균을 비교하면 그 격차가 구체적으로 드러난다:

변수	CV 분산(전체표본 평균)	SV 분산(2007년 4분기)
GDP 성장률	5.17	2.92
CPI 인플레이션	1.41	0.13
실업률	0.029	0.017

CPI의 경우 CV의 무조건부 분산이 예측 기준시점의 SV 상태보다 11배 이상 크다. 로그변동성 과정이 평균회귀 없는 순수 임의보행이므로(16.1절), 아직 관측하지 못한 충격을 예상할 수 없고, 각

방정식 고유의 작은 혁신분산 σ_{η}^2 가 정하는 속도로만 천천히 넓어진다. 전례 없는 충격 직전의 이례적으로 조용한 분기가 우연히 기준시점으로 주어지면, SV는(기계적으로, 예측 가능하게) 과거 변동성 국면들이 이미 평균에 반영된 상수분산 모형보다 더 과신하게 된다. 이는 표본추출기의 버그가 아니라 기억없는 확률적 변동성의 진짜 속성이다: 이미 넓은 쪽(여기서는 CV)에 보상을 주고, 적응적이지만 평온한 상태에서 출발한 쪽(여기서는 SV)에는 불리하다. $h = 24$ -32에 이르면 임의보행이 충분히 확산되어 추가적인 폭을 확보하고 SV가 앞서지만, 이는 느리고 기계적인 따라잡기일 뿐 SV가 무언가를 학습했다는 증거는 아니다.

실증 예제: 진짜 검증: 롤링(rolling) 기준시점 비교

응용 문헌(Clark, 2011; Carriero, Clark and Marcellino)은 SV의 밀도 예측 우위를 위기 이전 단일 고정 시점에서 보여주지 않는다. 표본이 늘어남에 따라 여러 시점에서 순차적으로 재추정하는 롤링 혹은 확장표본(expanding-window) 설계를 쓰며, 이는 변동성 상태가 위기가 실제로 전개되는 것과 거의 실시간으로 갱신될 수 있게 한다. 위기를 가로지르는 다섯 개의 기준시점 — 2007Q4, 2008Q2, 2008Q4, 2009Q2, 2009Q4 (각각 독립적으로 재추정, 번인 300 + 보존표본 700개) — 에서 위 분석을 반복하고 각 시점에서 $h = 1, 4, 8, 16$ 분기를 평가하면 전혀 다른 그림이 나온다.

표 3와 그림 73은 3변수(GDP, CPI, 실업률) 결합 로그점수 격차(SV에서 CV를 뺀 값)를 기준시점과 시계별로 보여준다. $h = 4$ 에서 격차는 -10.5 (2007년 4분기, 위에서 본 것과 동일하게 잘못 보정된 결과)로 시작해 -5.7 (2008년 2분기), -1.3 (2008년 4분기)로 개선되다가, 마침내 2009Q2(추정표본에 실제 2008-09년 변동성이 이미 포함된 첫 시점)에서 양수인 $+0.2$ 로 전환된다. $h = 8$ 행도 같은 단조로운 상승을 보인다: $-7.3 \rightarrow -1.7 \rightarrow +0.9 \rightarrow +1.1$ 이며, 위기 자체가 사실상 끝나고 두 모형 모두 비슷한 위험 평가로 수렴하는 2009Q4에서만 0 쪽으로 되돌아간다. 이는 정확히 교과서적인 결과다(SV의 단기 밀도 예측은 모형이 변동성이 쌓이는 것을 볼 수 있게 되는 순간 CV를 앞지른다) 그리고 그 우위가 보이는지 여부를 결정하는 것은 모형이 아니라 기준시점 선택이다. 다섯 시점 전체를 동일 가중으로 단순 평균(pool)하면 $h = 4$ 와 $h = 8$ 격차는 여전히 음수다(-3.5 , -1.4): 다섯 시점 중 세 시점이 개별적으로는 SV를 선호함에도, 위기 이전 두 시점의 크기가 평균을 끌어내리기에 충분하기 때문이다. 이는 더 유용한 결과를 평균으로 지워버리기 쉽다는 점에서 분명히 짚어둘 만하다: 시점별 진행 양상(SV가 충격 초기부터 명백한 패배에서 명백한 승리로 옮겨가는 것) 자체가 발견이지, 어느 하나의 평균값이 발견은 아니다.

Table 3: 롤링 기준시점 비교: SV–CV 3변수(GDP, CPI, 실업률) 결합 로그점수 격차, 기준시점 및 시계별(양수면 SV 선호)

기준시점	$h = 1$	$h = 4$	$h = 8$	$h = 16$
2007Q4	-0.15	-10.49	-7.28	-1.76
2008Q2	-0.35	-5.70	-1.74	-0.47
2008Q4	-1.25	-1.34	+0.85	+0.52
2009Q2	-0.08	+0.21	+1.06	+0.12
2009Q4	+0.04	-0.15	-0.06	-0.09
평균(pooled)	-0.36	-3.49	-1.43	-0.33




Figure 73: 롤링 기준시점 SV-CV 로그점수 격차. 왼쪽: 기준시점이 위기를 관통해 이동함에 따른 시계별 변화 — SV의 단기 열위가 추정표본이 새로 나타나는 변동성을 흡수함에 따라 줄어들다가 역전됨. 오른쪽: 같은 자료를 시계별로 묶어 각 기준시점의 기여를 보여줌

참고: 진짜 교훈: SV의 우위는 모형이 이미 무엇을 보았는지에 달려 있다

단일 기준시점 표는 확률적 변동성이 위기 동안 오히려 해로운 것처럼 보이게 했다. 롤링 기준시점 표는 그 반대를 보여준다 — 추정표본에 충격의 초기 부분이 포함되는 즉시 SV가 단기 시계에서 CV를 앞지른다. 두 표 모두 올바르게 계산되었으며, 다만 서로 다른 질문에 답할 뿐이다. 위기 이전 단일 고정 시점은 “SV가 한 번도 본 적 없는 위기를 예상할 수 있는가”를 묻고, 정직한 답은 상수분산 모형보다 나을 것이 없다는 것이다. 롤링 기준시점은 “위기가 진행 중일 때 SV의 변동성 상태가 그것을 추적하는가”를 묻고, 여기서의 답은 충격 발생 후 두세 분기 이내에 확실히 그렇다는 것이다. 이는 응용 문헌의 실시간 예측 평가가 단일 분할이 아니라 거의 항상 롤링 혹은 확장표본을 사용하는 이유이기도 하다: 단일 기준시점은 “모형이 이미 얼마나 보았는가”라는 시나리오 분포에서 뽑은 하나의 표본일 뿐이며, 그 하나의 표본이 멀쩡한 모형을 임의로 더 좋게도 더 나쁘게도 보이게 할 수 있다. SV가 정확히 사주는 것은 충격이 시작된 것을 관측한 조건에서의 적응이지, 예지력도 아니고 평온한 상태에서 위기가 시작되는 순간 공짜로 얻는 승리도 아니다. 이 장이 변동성을 도입하기도 전에 13장이 먼저 자신의 조건에서 위계적 사전분포를 제시한 이유가 바로 여기에 있다: 평균방정식을 제대로 잡는 것은 확률적 변동성이 도움이 될 때 그 위에서 도움을 주는 모형으로 남는다.

17. 시변모수 VAR (Time-Varying Parameter VAR, TVP-VAR)

로드맵

제15장과 제16장은 각각 하나의 잠재 대상이 시간에 따라 변동하도록 하였다. 제15장에서는 단일 스칼라 추세, 제16장에서는 n 개의 독립적인 로그변동성이 그 대상이었다. 두 경우 모두 선형 가우스 상태공간 재귀식이라는 동일한 도구로 다루어졌다. 이 장은 바로 그 도구를 실무자들이 흔히 “시변(time-varying)”이라고 부르는 대상, 즉 VAR의 계수 자체(총 $m = n(np + 1)$ 개의 계수가 함께 변동하는 경우)에 적용한다. 여기서 새롭게 유도되는 내용은 없다. 모든 단계는 제6.2절의 켄레 정규분포 업데이트를 매 시점마다 한 번씩 반복 적용하는 것이며, 진정으로 새로운 부분은 상태의 커진 차원을 정리하고 재귀식을 순방향, 이어서 역방향으로 실행하는 작업뿐이다.

제16장은 VAR의 계수 Φ 를 고정한 채 오차 공분산만 변동하도록 하였다. 이 장은 그 반대이면서 한 걸

을 더 나아간다. 시변모수 VAR(time-varying-parameter VAR, TVP-VAR)은 전체 계수벡터 Φ_t 가 계수별로 독립적인 확률보행(random walk)을 따라 변동하도록 하면서, 잔차 공분산 Σ 는 상수로 고정한다. 이제 추적하는 상태는 더 이상 단일 스칼라 로그분산(제14장)도, 저차원의 추세-순환 쌍(제15장)도, n 개의 독립적인 로그변동성(제16장)도 아니다. 이는 차원이 $m = n(np + 1)$ 인 전체 결합 VAR 계수벡터가 함께 변동하는 것이다. 그럼에도 김스 샘플러는 제15장과 제16장 전체에서 사용된 것과 동일한 국소수준(local-level) 기법을, 스칼라 또는 대각 상태에서 진정한 벡터값 상태로 일반화한 것에 지나지 않는다. 즉 순방향 칼만 필터에 이어 역방향 시뮬레이션 평활기를 적용하는 방식으로, 이는 앞의 두 장에서 사용한 밴드형 정밀도 샘플러와 수학적으로 동등하지만, 상태 차원($m = 21$, 아래 참조)이 시점별 행렬 연산을 저렴하게 만들어주므로 여기서는 고전적 재귀식을 통해 구현한다.

시변모수 VAR (TVP-VAR) n 개 변수의 VAR(p)에 대해, 시변계수를 갖는 축약형(reduced form)을 다음과 같이 쓴다.

$$y_t = \Phi_{1,t}y_{t-1} + \cdots + \Phi_{p,t}y_{t-p} + c_t + u_t, \quad u_t \sim N(0, \Sigma),$$

그리고 시점 t 의 $n(np+1)$ 개 계수 전부를 β_t 로 쌓으면 $y_t = Z_t\beta_t + u_t$ 이며, 여기서 $Z_t = I_n \otimes x_t'$ 이고 $x_t = (1, y'_{t-1}, \dots, y'_{t-p})'$ 이다. 제11장의 상수 Φ 와 달리, 여기서는 β_t 의 모든 원소가 각자 독립적으로 표류 없는 (driftless) 확률보행을 따른다.

$$\begin{aligned} \beta_t &= \beta_{t-1} + \eta_t, \\ \eta_t &\sim N(0, Q), \\ Q &= \text{diag}(q_1, \dots, q_m), \\ \beta_0 &\sim N(a_0, B_0), \end{aligned}$$

이때 Σ 자체는 상수로 고정되는데, 이는 Φ 를 고정한 채 Σ_t 가 변동하도록 한 제16장의 모형과 대비된다. β_t 와 Σ_t 가 모두 시변하는 TVP-VAR (Primiceri, 2005)은 이 장과 앞 장을 자연스럽게 결합한 모형이지만, 여기서는 추정하지 않는다.

그림 74는 전체 경로 $\beta_{0:T}$ 를 추출하는 이중 경로(two-pass) 구조를 보여준다. 오직 과거 방향만을 참조하는 순방향 스윕(실선 화살표)에 이어, 각 시점을 역순으로 다시 방문하면서 바로 다음 시점에서 방금 추출된 값을 이용하는 역방향 스윕(점선 화살표)이 뒤따른다.




Figure 74: 순방향 필터링, 역방향 샘플링(forward-filtering, backward-sampling, FFBS): 순방향 경로(실선)는 왼쪽에서 오른쪽으로 이동하며 각 y_t 를 필터링된 상태 $\beta_{t|t}$ 에 반영하고, 역방향 경로(점선)는 오른쪽에서 왼쪽으로 이동하며 $\beta_T, \beta_{T-1}, \dots, \beta_0$ 를 추출하는데, 각 추출값은 바로 한 단계 앞서 추출된 값에 조건부로 결정된다

알고리즘: TVP-VAR를 위한 깃스 샘플러

제11장의 VAR 사전분포를 초기 상태에 그대로 반영한 사전분포(기울기 계수에는 정밀도 1, 절편에는 $1/10$ 을 적용하여 β_0 의 사전분포 B_0 을 구성), Σ 에 대한 역위샤트(inverse-Wishart)($n + 3, I_n$) 사전분포, 그리고 각 상태분산 q_j 에 대한 독립적인 역감마(Inverse-Gamma) 사전분포(기울기 혁신에는 형상모수 3, 척도모수 0.01^2 를, 절편 혁신에는 척도모수 0.1^2 를 적용하여 절편이 다소 더 자유롭게 변동하도록 허용)를 사용할 때:

1. **계수 경로.** 순방향 칼만 필터($Z_t'\Sigma^{-1}Z_t$ 와 $Z_t'\Sigma^{-1}y_t$ 로 구성된 정밀도가중 업데이트를 사용하며, 이는 제15장과 제16장의 정밀도 샘플러에 등장한 스칼라 항들을 벡터로 그대로 일반화한 것이다)를 실행한 뒤 역방향 시뮬레이션 평활기를 적용하여 전체 경로 $\beta_{1:T}$ 를 함께 추출한다. 이는 고전적인 Carter-Kohn/Frühwirth-Schnatter 순방향 필터링, 역방향 샘플링(FFBS) 알고리즘으로,^a 제15-16장과 수학적으로 동일한 재귀적 국소수준 구성을 스칼라나 스칼라 집합이 아니라 차원 $m = n(np + 1)$ 의 벡터 상태에 대해 수행하는 것이다.
2. **공분산.** 추출된 경로 전체에 걸쳐 계산된 잔차 $u_t = y_t - Z_t\beta_t$ 가 주어졌을 때, Σ 를 그 역위샤트 완전조건부분포에서 추출한다. 이는 제6장의 켈레 회귀-분산 업데이트를 고정계수 하나의 적합이 아니라 잔차의 경로 전체에 적용한 다변량 일반화이다.
3. **상태분산.** $\beta_{1:T}$ 의 일계차분($\beta_1 - \beta_0$ 포함) 제곱합이 주어졌을 때, 각 q_j 를 그 역감마 완전조건부분포에서 추출한다. 이는 구조적으로 제15장의 σ_τ^2 업데이트 및 제16장의 $\sigma_{h,i}^2$ 업데이트와 동일하며, 다만 여기서는 1개의 추세나 n 개의 로그변동성이 아니라 $m = 21$ 개의 계수 각각에 독립적으로 적용된다.
4. **초기 상태.** β_1, Q , 그리고 사전분포 $N(a_0, B_0)$ 이 주어졌을 때, β_0 을 그 (대각행렬이므로 원소별인) 정규 완전조건부분포에서 추출한다.

^aCarter and Kohn (1994); Frühwirth-Schnatter (1994). FFBS와 제15-16장의 Chan-Jeliazkov (2009) 정밀도 표본추출기는 동일한 결합 가우스 완전조건부분포에서 추출하며, 때 구조 선형계를 전진-후진 재귀로 푸느냐 희소 콜레스키 분해 한 번으로 푸느냐만 다르다. 복제 킷에서 Launch_ch17_cs2001.m은 FFBS 형태를, VAR_TVP.m은 정밀도 형태를 구현한다.

17.1 사후분포 유도: 순방향 필터링, 역방향 샘플링

이제 상태 β_t 는 벡터값을 가지며 시간에 따라 변동하므로, 제6장의 단일 고정계수 업데이트도, 제15장의 밴드형 정밀도 결합추출도 정확히 맞는 형태로 서술되어 있지 않다. 여기서 $\beta_{1:T}$ 를 추출하는 고전적인 방법은 아래의 이중 경로 Carter-Kohn 알고리즘이다. 두 경로 모두 결국 제6.2절에서 처음 유도된 동일한 켈레 정규분포 완전제곱식 논증을, 전체 표본에 대해 한 번이 아니라 매 시점마다 한 번씩 반복 적용한 것에 지나지 않는다.

유도: 순방향 필터: $\beta_t \mid y_{1:t}$

$\beta_{t-1} \mid y_{1:t-1} \sim N(\beta_{t-1|t-1}, P_{t-1|t-1})$ 이라고 가정하자($t = 1$ 일 때는 사전분포 $\beta_0 \sim N(a_0, B_0)$ 에 의해 성립한다). 두 단계를 거쳐 이를 시점 t 로 업데이트한다.

예측(Prediction). $\beta_t = \beta_{t-1} + \eta_t$ 이고 $\eta_t \sim N(0, Q)$ 가 $y_{1:t-1}$ 과 독립이므로, $\beta_t \mid y_{1:t-1}$ 은 두 독립 정규분포의 합이 되어 다음과 같은 정규분포를 따른다.

$$\beta_{t|t-1} = \beta_{t-1|t-1}, \quad P_{t|t-1} = P_{t-1|t-1} + Q.$$

업데이트(Update). 예측사전분포 $\beta_t \mid y_{1:t-1} \sim N(\beta_{t|t-1}, P_{t|t-1})$ 과 새로운 관측치 하나 $y_t = Z_t \beta_t + u_t, u_t \sim N(0, \Sigma)$ 가 주어졌을 때, 사후커널은

$$p(\beta_t \mid y_{1:t}) \propto N(y_t \mid Z_t \beta_t, \Sigma) N(\beta_t \mid \beta_{t|t-1}, P_{t|t-1})$$

이는 정확히 제6.2절의 $\beta \mid \sigma^2, y$ 커널에서 $(b_0, B_0) \rightarrow (\beta_{t|t-1}, P_{t|t-1}), X \rightarrow Z_t, \sigma^{-2} \rightarrow \Sigma^{-1}$ 로 치환하고, 전체 표본 대신 단 하나의 “관측치” y_t 를 사용한 것이다. 그곳에서와 정확히 동일하게 완전제곱식을 적용하면 다음을 얻는다:

$$\begin{aligned} \beta_t \mid y_{1:t} &\sim N(\beta_{t|t}, P_{t|t}), \\ P_{t|t} &= (P_{t|t-1}^{-1} + Z_t' \Sigma^{-1} Z_t)^{-1}, \\ \beta_{t|t} &= P_{t|t} (P_{t|t-1}^{-1} \beta_{t|t-1} + Z_t' \Sigma^{-1} y_t) \end{aligned}$$

^a $t = 1, \dots, T$ 에 대해 예측 다음 업데이트를 반복하는 것이 바로 순방향 칼만 필터이다. 이는 새로운 유도 기법이 아니라 제6.2절의 일회성 켄레 업데이트를 매 시점마다 재귀적으로 적용한 것으로, (예측 단계가 그 시점의 과정잡음 Q 를 반영한 뒤) 각 시점의 사후분포가 다음 시점의 사전분포가 된다.

^a 위 공식은 $T = 263$ 개 시점 각각에서 $m \times m$ 행렬($m = 21$)의 역행렬을 계산하는 것처럼 보여 비용이 커 보이지만, 실제로는 $m \times m$ 역행렬 계산이 전혀 필요하지 않다. 우드베리(Woodbury) 항등식을 이용하면 $(P_{t|t-1}^{-1} + Z_t' \Sigma^{-1} Z_t)^{-1}$ 을 $n \times n$ 행렬($n = 3$)의 역행렬만으로 다시 쓸 수 있는데, 이는 $Z_t' \Sigma^{-1} Z_t$ 의 계수(rank)가 최대 n 이기 때문이며, $Z_t = I_n \otimes x_t'$ 가 매 시점 항상 n 개 행 만큼의 새로운 정보만을 담고 있기 때문이다. 크고 조밀한 역행렬 계산을 작은 것으로 바꾸는 이 방법 덕분에, 변수와 시차의 수에 따라 m 이 커지더라도 필터는 빠르게 유지된다.

유도: 역방향 샘플링: $\beta_t \mid \beta_{t+1}, y_{1:t}$

상태방정식에 의해 β_{t+1} 은 β_t 가 주어지면 $y_{1:t}$ 와 조건부 독립이다 (모형의 마르코프 구조: $y_{1:t}$ 가 β_{t+1} 에 대해 담고 있는 모든 정보는 β_t 를 거쳐 전달된다). 따라서 베이즈 법칙에 의해 사후커널은

$$\begin{aligned} p(\beta_t \mid \beta_{t+1}, y_{1:t}) &\propto p(\beta_{t+1} \mid \beta_t) p(\beta_t \mid y_{1:t}) \\ &= N(\beta_{t+1} \mid \beta_t, Q) N(\beta_t \mid \beta_{t|t}, P_{t|t}) \end{aligned}$$

이는 다시 정확히 제6.2절의 켄레 정규분포 커널 형태이며, 이번에는 이미 추출된 미래 상태 β_{t+1} 을 β_t 에 대한 “오차공분산” Q 를 갖는 단위설계행렬 “관측치”로 취급하고, 순방향 필터의 $N(\beta_{t|t}, P_{t|t})$ 를 사전분포로 취급한다. 완전제곱식을 적용하면 다음을 얻는다:

$$\begin{aligned} \beta_t \mid \beta_{t+1}, y_{1:t} &\sim N(\beta_{t|t,t+1}, P_{t|t,t+1}), \\ P_{t|t,t+1} &= (P_{t|t}^{-1} + Q^{-1})^{-1}, \\ \beta_{t|t,t+1} &= P_{t|t,t+1} (P_{t|t}^{-1} \beta_{t|t} + Q^{-1} \beta_{t+1}) \end{aligned}$$

전체 경로는 먼저 $\beta_T \sim N(\beta_{T|T}, P_{T|T})$ 를 추출한 뒤(순방향 필터 자체의 최종 출력이며, β_{T+1} 이 존재하지 않으므로 추가 조건이 필요 없다), 위 재귀식으로 부터 $\beta_{T-1}, \dots, \beta_0$ 을 역순으로 추출함으로써 얻어지며, 각 추출값은 바로 다음 시점 β_{t+1} 에 대해 방금 추출된 값에 조건부로 결정된다. 이 이중 경로의 순방향 필터/역방향 샘플링 절차는 $p(\beta_{0:T} \mid \cdot) = p(\beta_T \mid \cdot) \prod_{t=0}^{T-1} p(\beta_t \mid \beta_{t+1}, y_{1:t})$ 라는, 임의의 선형 가우스 상태공간 모형에서 역방향 샘플링을 정당화하는 데 사용되는 것과 동일

한 연쇄법칙 논증에 의해 $p(\beta_{0:T} | \Sigma, Q, y)$ 로부터 $\beta_{0:T}$ 의 정확한 결합추출을 제공한다.

유도: $\Sigma | \beta_{1:T}, y, q_j | \beta_{1:T}$, 그리고 $\beta_0 | \beta_1$

아래의 세 결과는 각각 이 장에 특유한 양들을, 이 노트의 다른 곳에서 이미 완전하게 수행된 커널 매칭(kernel-matching) 논증에 대입하여, 그 결과로 나오는 커널을 명시적으로 다시 유도한 것이다.

1. $\Sigma | \beta_{1:T}, y$. 전체 경로 $\beta_{1:T}$ 가 주어지면, $u_t = y_t - Z_t \beta_t, t = 1, \dots, T$ 는 SUR/VAR의 경우와 정확히 동일한 완성된 잔차 계열이 되며, U 를 u'_t 를 쌓은 $T \times n$ 행렬이라 하면 $U'U = \sum_t u_t u'_t$ 이다. 제10.2절의 $\Sigma | \beta, y$ 유도 상자에서와 정확히 동일하게 대각합 항등식 $u'_t \Sigma^{-1} u_t = \text{tr}(\Sigma^{-1} u_t u'_t)$ 을 사용하되, $e_t \rightarrow u_t, E \rightarrow U, M \rightarrow n$ 으로 치환하면:

$$p(y | \beta_{1:T}, \Sigma) = |\Sigma|^{-T/2} \exp \left\{ -\frac{1}{2} \sum_t u'_t \Sigma^{-1} u_t \right\} = |\Sigma|^{-T/2} \exp \left\{ -\frac{1}{2} \text{tr}(\Sigma^{-1} U'U) \right\},$$

$$p(\Sigma) \propto |\Sigma|^{-(\nu_0+n+1)/2} \exp \left\{ -\frac{1}{2} \text{tr}(\Sigma^{-1} S_0) \right\}.$$

두 식을 곱하고, 제10.2절에서와 정확히 동일하게 $\text{tr}(\Sigma^{-1} S_0) + \text{tr}(\Sigma^{-1} U'U) = \text{tr}(\Sigma^{-1} (S_0 + U'U))$ 을 이용하면:

$$p(\Sigma | \beta_{1:T}, y) \propto |\Sigma|^{-(T+\nu_0+n+1)/2} \exp \left\{ -\frac{1}{2} \text{tr}(\Sigma^{-1} (S_0 + U'U)) \right\},$$

$$\Sigma | \beta_{1:T}, y \sim IW(S_0 + U'U, \nu_0 + T).$$

2. $q_j | \beta_{1:T}$. 각 상태분산 q_j 는 오직 j 번째 좌표의 일계차분 $\Delta \beta_{j,t} = \beta_{j,t} - \beta_{j,t-1} \sim N(0, q_j)$, $t = 1, \dots, T$ ($\Delta \beta_{j,1} = \beta_{j,1} - \beta_{j,0}$ 포함)에만 의존한다. 사전분포 $q_j \sim IG(a_{0,j}/2, d_{0,j}/2)$ 하에서,

$$p(\beta_{1:T} | q_j) = (2\pi q_j)^{-T/2} \exp \left\{ -\frac{1}{2q_j} \sum_{t=1}^T \Delta \beta_{j,t}^2 \right\}, \quad p(q_j) \propto q_j^{-(a_{0,j}/2+1)} \exp \left\{ -\frac{d_{0,j}}{2q_j} \right\}$$

이는 정확히 제15장의 $\omega^2 | \tau$ 논증에서 $\tau_t - \tau_{t-1} \rightarrow \Delta \beta_{j,t}, \omega^2 \rightarrow q_j$ 로 치환하여 $j = 1, \dots, m$ 에 대해 좌표별로 적용한 것이다. 곱한 뒤 q_j 의 거듭제곱을 정리하면:

$$p(q_j | \beta_{1:T}) \propto q_j^{-\left(\frac{a_{0,j}+T}{2}+1\right)} \exp \left\{ -\frac{d_{0,j} + \sum_t \Delta \beta_{j,t}^2}{2q_j} \right\},$$

$$q_j | \beta_{1:T} \sim IG \left(\frac{a_{0,j} + T}{2}, \frac{d_{0,j} + \sum_t \Delta \beta_{j,t}^2}{2} \right).$$

3. $\beta_0 | \beta_1$. $\beta_1 = \beta_0 + \eta_1$ 이고 $\eta_1 \sim N(0, Q)$ 이며 사전분포가 $\beta_0 \sim N(a_0, B_0)$ 이므로, 이는 위에서 유도한 역방향 샘플링 커널에서 $(\beta_{t|t}, P_{t|t}) \rightarrow (a_0, B_0), \beta_{t+1} \rightarrow \beta_1$ 로 치환한 $t = 0$ 인 경우와 정확히 같다:

$$p(\beta_1 | \beta_0) p(\beta_0) = N(\beta_1 | \beta_0, Q) N(\beta_0 | a_0, B_0)$$

위의 역방향 샘플링 유도에서와 정확히 동일하게 완전제곱식을 적용하면:

$$\begin{aligned}\beta_0 | \beta_1 &\sim N(\beta_{0|0,1}, P_{0|0,1}), \\ P_{0|0,1} &= (B_0^{-1} + Q^{-1})^{-1}, \\ \beta_{0|0,1} &= P_{0|0,1}(B_0^{-1}a_0 + Q^{-1}\beta_1).\end{aligned}$$

17.2 실증 예제: 통화정책의 전달은 변했는가

실증 예제: 자료와 질문

이 절의 모형(확률보행하는 계수와 상수 잔차공분산을 가진 VAR)은 Cogley and Sargent(2001, “Evolving Post-World War II U.S. Inflation Dynamics,” NBER Macroeconomics Annual)가 미국 인플레이션의 지속성, 그리고 그것을 둘러싼 민간부문과 연준의 행태가 전후(戰後) 시기에 걸쳐 어떻게 변화했는지를 연구하기 위해 도입한 바로 그 설정이다. 이들의 원 논문 역시 같은 취지로 인플레이션, 실업률, 단기금리라는 동일한 세 변수를 사용하며, 아래에서 쓰는 것과 동일한 칼만필터 전진 패스와 역방향 시뮬레이션 스무더로 추정한다. 표류하는 계수 위에 확률변동성을 얹은 것은 이들의 2005년 후속 논문인 “Drifts and Volatilities”에서 처음 등장하며, 이는 위 수식상자가 “프리미체리(Primiceri, 2005)의 결합모형”이라고 부른 바로 그 논문이다 — 그 확장은 여기서서는 추정하지 않는다.

아래의 실증 분석은 미국 분기별 실업률, 소비자물가지수(CPI) 인플레이션, 실효 연방기금금리에 TVP-VAR(2)를 적합한다. 표본기간은 1960Q3–2026Q1($T = 263$, 제11장이 사용한 것과 동일한 출처 계열이되, 이 노트의 자료 확장 이전에 사용하던 2008년 이전 구간이 아니라 전체 표본을 사용한다). 원래의 절단은 그 뒤에 이어진 제로금리하한(zero lower bound)을 피하기 위해 2008Q2에서 멈췄는데, 확률보행 계수 모형은 연방기금금리가 영 근방에서 제약되는 상황을 특별히 다루지 못한다는 것이 그 근거였다. 그러나 그 우려는 보기보다 중요하지 않은 것으로 드러났다: β_t 는 정책금리 자체의 구조모형이 아니라 계수 공간에서의 확률보행이므로, 제로금리하한에 머문 기간(2009–2015년, 그리고 2020년에 다시 짧게)도 다른 어떤 느린 국면전환과 마찬가지로 (y_t 에 하한을 부과하는 방식이 아니라 계수가 표류하도록 허용하는 방식으로) 흡수된다. 전체 표본을 사용하면 코로나19 이후 금리인상 국면 내부에 세 번째 스냅샷 시점을 추가할 수 있다.

1,000회의 번인(burn-in) 이후 3,000회의 사후번인 값스 추출값은, 분기당 표준편차 0.62(실업률), 1.65(CPI 인플레이션), 0.21퍼센트포인트(연방기금금리)의 상수 잔차공분산과, 실업률 충격과 인플레이션 충격 간의 -0.35 수준의 중간 정도 음의 상관을 복원한다. 이 세 수치 중 둘은 확장 이전 추정치(0.18, 0.94, 0.27)에서 크게 움직였다: 실업률의 충격 크기는 거의 전적으로 2020Q2 실업률 급등의 힘으로 세 배 넘게 커진 반면, 연방기금금리의 충격 크기는 오히려 약간 줄어들었는데, 이는 확장된 표본이 이전에는 아예 제외되었던 제로금리하한 시기의, 사실상 평탄하고 분산이 작은 정책금리 분기들을 이제 다수 포함하기 때문이다. 이는 Σ 를 상수로 두는 것(이 장의 모형이 그러하며, 위에서 언급했지만 여기서서는 추정하지 않는 프리미체리(Primiceri, 2005)의 결합모형만이 이를 시간에 따라 움직이게 한다)의 직접적이고 눈에 보이는 대가이다: 이제 하나의 전역적 잔차공분산이 평온했던 시기와 2020Q2를 동시에 요약해야 한다.

이 모형이 답하고자 하는 질문은 그래서 “통화정책의 평균적 효과는 무엇인가”(이는 이미 제11장이 답한다)가 아니라 “통화정책의 효과가 변화하였는가”이다. 아래의 세 스냅샷은 표본 내 세 시점에서의 계수와 그에 함의되는 충격반응을 비교한다.

실증 예제: 세 스냅샷: 1975Q3, 2005Q3, 2022Q3

그림 75는 동일한 100베이시스포인트 연방기금금리 충격에 대한 세 변수 전체의 사후평균 충격 반응을, 세 시점 — **1975Q3**(볼커 시대의 디스인플레이션이 다가오던 시기), **2005Q3**(2000년대 중반 대안정기), 그리고 새로 추가된 코로나 시기 스냅샷인 **2022Q3**(코로나 이후 금리인상 국면의 한가운데) — 의 계수벡터 β_t 를 이용하여 비교한다. 연방기금금리 자체의 지속성은 세 시점에 걸쳐 단조롭게 상승한다 — 0.711(1975Q3), 0.805(2005Q3), 0.846(2022Q3) — 이는 정책금리를 보다 점진적이고 완만하게 조정하는 쪽으로 이동했다는 널리 알려진 사실과 부합한다. 그러나 2022Q3에 이르면 이 지속성이 국지적 체계를 안정성의 경계에 충분히 가깝게 밀어붙여, 충격 반응의 형태 자체가 크기뿐 아니라 질적으로 달라진다.

1975Q3과 2005Q3에서는 세 반응 모두 20분기 시계에 걸쳐 정상적으로 소멸한다. 2022Q3에서는 초기의 험프(인플레이션은 이전 두 시점과 비슷하게 2분기 후 0.70으로 정점을 찍는다) 이후, 세 반응 모두 시계의 후반부에서 오히려 재가속하여 20분기 시계가 끝날 때까지도 수평을 찾지 못한다. 실업률의 반응은 여전히 하락하는 중이며 -0.95에 이른다: 긴축적 충격이 계수경로가 20년 가까이 흐른 뒤에는 오히려 실업률을 끌어내리는 결과로 귀결되는 것으로, 제12.5절의 부호제약이 가정한 방향과도, 교과서적인 긴축 충격의 반응과도 반대이다. 반면 인플레이션과 연방기금금리 자체 충격에 대한 자체 반응은 여전히 상승 중이며 각각 1.84와 5.98에 이른다. 이 세 수치는 모두, 세 계열이 아직 꺾이지 않았으므로, 통상적 의미의 정점이 아니다.

이는 진정한, 다만 다소 불편한 발견이다: 표본에서 가장 빠르고 공격적이었던 긴축 국면이 안정성의 경계에 바로 걸쳐 있는 국지적 동학을 함의하는 계수 스냅샷과 일치하며, 아래의 절은 이 불안정성이 그리 정밀하게 추정되지는 않음을 보여준다. 물가퍼즐 (price puzzle)(긴축적 정책 충격 직후 CPI 인플레이션이 하락이 아니라 상승하는 현상으로, 이러한 방식으로 식별된 통화정책 VAR에서 잘 알려진 이례현상이다)은 세 시점 모두에서 나타나지만 2005Q3에서 가장 작고(초기 정점 0.74), 재가속을 포함하면 2022Q3에서 큰 차이로 가장 크다.

실업률 자체의 지속성은 앞선 두 시점에 걸쳐 이미 나타난 하락세를 이어간다: 0.746(1975Q3) → 0.699(2005Q3) → 0.591(2022Q3). 이는 연방기금금리 자체의 지속성과 정반대 방향으로, “체계 전체가 점점 더 지속적이 되고 있다”는 명제가 방정식마다 성립하는 것은 아니라는 점을 일깨워준다.




Figure 75: 100bp 연방기금금리 충격에 대한 일반화 충격반응, 1975Q3, 2005Q3, 2022Q3에서 평균 사후평균 계수경로

실증 예제: 이 차이는 얼마나 확신할 수 있는가?

그림 76는 2022Q3 충격반응과 2005Q3 충격반응 간의 사후평균 차이(코로나 이후 금리인상 국면과 위기 이전 대안정기 기준점의 비교)를, 3,000개의 사후변인 추출값으로부터 직접 계산한 90% 사후구간과 함께 나타낸다. 시점별 차이는 절대적 크기로 볼 때 크다: 20분기째 기준으로 연방기금금리 자체 반응이 3.98포인트, 인플레이션이 1.39포인트, 실업률이 0.47포인트이며, 모두 위에서 설명한 2022Q3 스냅샷의 재가속에서 비롯된다. 그러나 이 크기에도 불구하고 90% 사후구간은 세 변수 모두에서 모든 시계에 걸쳐 영(0)을 포함한다 — 확장 이전의 2005Q3 대 1975Q3 비교는 초기 몇몇 시계에서 영을 배제했던 것과 달리, 이번 새 비교는 20분기 시계 어디에서도 정밀하게 추정되지 않는다. 이 자체가 시사하는 바가 있다: 2022Q3는 263분기짜리 표본의 끝에서 불과 몇 분기 떨어져 있으므로, 순방향 필터링-역방향 표본추출 알고리즘이 2022Q3 이후로 남겨진 자료가 매우 적어 국지적 계수경로를 단단히 고정하지 못하며, 확률보행 상태방정식은 그 불확실성 내에서 β_t 가 상당히 표류하도록 허용한다. 정직하게 요약하면, 이 모형은 코로나 이후 긴축 국면을 둘러싼 통화정책 파급경로의 변화(더 강해진 물가퍼즐, 경계에 걸친 국지적 동학)에 대해 크고 경제적으로 눈에 띄는 점추정치를 찾아내지만, 그 추정치는 표본 끝에 너무 가까이 있다는 바로 그 이유로 상당한 사후 불확실성을 동반하므로, 이는 앞서 이 노트에서 다룬 더 잘 식별된 1975Q3 대 2005Q3 변화와 달리 정밀하게 확정된 변화라기보다는 시사적인 신호로 읽어야 한다.




Figure 76: 충격반응의 사후평균 차이(2022Q3 코로나 이후 금리인상 국면에서 2005Q3 대안정기를 뺀 값)와 90% 사후구간

17.3 Cogley and Sargent (2001)

위의 예제는 이 장의 질문을 이 노트 자신의 자료로 물었다. 이 절은 그 질문을 처음 던진 논문을 재현한다. Cogley and Sargent (2001, 이하 CS), “Evolving Post-World War II U.S. Inflation Dynamics”(NBER Macroeconomics Annual)는 정확히 이 모형(랜덤워크 계수와 상수 교란항 공분산을 갖는 VAR(2))을 세워, 미국 인플레이션의 상승과 하락이 고정된 준칙에 나쁜 운이 겹친 결과가 아니라 통화정책의 체계적 변화(Sargent (1999)의 The Conquest of American Inflation이 그린 학습과 이탈의 서사)를 반영한다고 주장했다. 세 변수는 CPI-U 인플레이션, 민간 실업률의 로짓(시뮬레이션된 실업률이 (0, 100) 경계를 지키도록), 그리고 사후적 실질금리, 즉 분기 첫 달의 3개월 T-bill 금리에서 동분기 인플레이션을 뺀 것이다. 논문을 규정하는 설계는 두 가지다. 첫째, 사전분포를 훈련표본으로 보정한다. 1948Q1–1958Q4에 추정한 시불변 VAR(2)가 초기 계수벡터의 사전평균(그 OLS 추정값 $\bar{\theta}$), 상수 Σ 의 사전 스케일(훈련 잔차 공분산), 그리고 표류 공분산의 사전 스케일 $Q = (0.01)^2 \bar{P}$ ($\bar{P}$ 는 OLS 점근 공분산)를 공급한다 — 시간 변동이 처음에는 각 계수 표준편차의 1퍼센트만 차지한다는 믿음이다. 둘째, 관심 대상은 계수 자체가 아니라 매 시점 θ_t 로부터 계산되는 두 개의 장기 예측(그들의 식 3.2)이다. 인플레이션의 120분기 앞 예측(core inflation)과 실업률의 그것(자연실업률)이며, 지속성의 척도인 주파수 0에서의 인플레이션 스펙트럼이 이를 보완한다. 추정은 1959Q1부터, 이 장의 FFBS 기계를 그대로 사용한다.⁵

실증 예제: 원표본, 추정 1959Q1–2000Q4

그림 77는 CS Figure 1의 재현이며, 그림 위의 모든 특징적 지점이 논문이 놓아둔 자리에 내려앉는다. core inflation의 중앙값은 1965년 말 2.7%(CS: 1960년대 말 1.75–4% 사이)에서 1970년대 내내 올라 1979Q2에 9.4%로 정점을 찍고(CS: 1979–80년에 대략 8%), 1980년대 초에 무너

⁵CS 대비 두 가지 단순화를 밝혀 둔다. 표류 공분산 Q 는 대각행렬로 두고 원소별 역감마로 갱신하되 사전평균을 CS의 $(0.01)^2 \text{diag}(\bar{P})$ 에 정보성 있는 가중으로 고정했다(CS는 역위사트를 사용한다). 또 국소 안정성을 시점별로 선별하여 불안정한 추출(추출-시점 쌍의 약 1–2%)을 예측 계산에서 제외했는데, CS는 계수 경로 전체에 안정성 사전분포를 부과한다.

저 1985년 3.5%가 되며, 표본 끝 2000Q4에서 2.83%로 마감한다 — CS 자신이 그림을 읽어낸 표현이 2000년 말 core inflation “3% 바로 아래”였다. 자연실업률 추정치도 같은 궤적을 그린다. 1965년 4.3%, 1980Q4 정점 8.7%, 2000년 4.2%로 회귀. 아래 패널은 논문의 지속성 발견을 재생한다. 인플레이션의 영주파수 스펙트럼은 1960년대 말부터 1980년까지 높은 고원에 앉아 있다가 붕괴하여 1990년대에는 1970년대 수준의 대략 삼분의 일이 된다 — 높은 core inflation의 시대와 지속적이고 예측 가능한 인플레이션의 시대가 같은 시대라는 것, 정확히 Sargent (1999)의 학습 모형이 예측하는 동반 이동이다.




Figure 77: CS (2001) Figure 1 재현: 실현 인플레이션에 겹친 core inflation 중앙값(120분기 앞 예측, 68% 구간)(위), 실현 실업률에 겹친 자연실업률(가운데), 인플레이션의 로그 영주파수 스펙트럼(아래)

실증 예제: 전체표본, 추정 1959Q1-2026Q1

사반세기의 추가 자료는 표류 계수 모형에 Volcker 디스인플레이션 이후 가장 흥미로운 시험을 부과하며, 결과는 1970년대의 거울상으로 읽힌다 (그림 78). core inflation은 1985-2019년 전 구간을 2.2-4.2% 사이에 못박힌 채 보낸다(두 차례의 경기침체, 십사 년의 영 하한, 양적완화를 통과하면서도) 그리고 실현 인플레이션이 9%를 찍은 2021-22년 급등도 core inflation 중앙값을 2022Q4의 3.8%까지만 밀어올린 뒤 2026Q1에는 3.2%로 가라앉는다. 지속성 패널이 이 숫자가 왜 중요한지 설명해 준다. 2022년 정점에서 영주파수 스펙트럼은 1.8인데, 같은 추정에서 1970Q4의 값은 7.6이다 — 모형은 최근의 급등을 여전히 앵커링된 인플레이션 과정을 때린 크지만 일시적인 충격으로 읽고, 1970년대는 과정 자체의 표류로 읽었던 것이다. 자연실업률 패널은

같은 논점을 다른 변수로 말한다. 1970년대에 실현 실업률이 올라갈 때 자연실업률 추정치는 그것을 따라 8.5%까지 올라갔지만, 2020Q2에 실업률이 13%로 치솟았을 때 자연실업률은 5%에서 거의 움직이지 않았다 — 아무리 거대해도 한 분기짜리 스파이크는 120분기 예측에 거의 신호를 실지 못하기 때문이다. 2021년 이후의 들쭉임 — 표본 끝에서 core 3.2%, 지속성은 여전히 오르는 중 — 이 느린 닛 풀림의 시작인지 이미 마무리된 일회성 급등인지는, 새 분기가 도착할 때마다 계속 묻도록 이 모형이 만들어진 바로 그 종류의 질문이다.




Figure 78: 2026Q1까지 추정된 동일 체계: core inflation은 ZLB 시대 내내 앵커링을 유지하고 2021-22년 급등에도 3.8%까지만 오르며, 자연실업률은 한 분기짜리 COVID 실업률 스파이크를 무시하고, 지속성은 1970년대 고원에 한참 못 미친다

참고: Q 의 사전분포는 실질적인 가정이다

이 재현은 처음에 표류 공분산 Q 에 무정보에 가까운 사전분포($\nu_0 = 3$, CS의 $(0.01)^2 \bar{P}$ 는 스케일 로만 사용)를 두었는데, 그 결과가 보고할 가치가 있을 만큼 교훈적이었다. 같은 샘플러가 같은 자료에서 1981년에 25% 근처에서 정점을 찍는 core inflation 경로를 낳은 것이다 — 논문 수치의 세 배다. 깃스 샘플러가 Q 를 부풀려 계수들이 1970년대 인플레이션의 잔물결 하나하나를 뒤쫓게 만들었고, 그 결과 국소 동학이 장기 예측이 폭발하는 단위근 경계 쪽으로 밀려났기 때문이다. CS는 정확히 이 위험을 각주에서 경고한다. “깃스 샘플러는 체계에 시간 변동을 금방 더해 넣는다.” Q 의 사전평균을 그들의 보정값에 정보성 있는 가중($\nu_0 = 20$)으로 다시 고정하면 정점은 9.4%로 내려오고 앵커링 시대의 추정치들은 사실상 그대로 남는다. 일반적 교훈은 13장의 계층적 사전분포 논의와 맞닿아 있다. 잠재 대상이 얼마나 움직이도록 허용되는지를 분산 모수가 통제하는 모형

에서, 그 분산의 사전분포는 성가신 설정값이 아니라 경제학의 일부다 — 전후 미국 자료에서 정책 표류를 얼마나 발견하는가는, 피할 수 없이, 표류를 얼마나 믿을 준비가 되어 있었는가에 달려 있다. 두 번째 실질적 가정은 CS의 토론자들이 곧바로 지적인 상수 Σ 다: Sims (2001)와 Stock (2001)은 등분산 TVP-VAR가 계수 표류로 귀속시키는 것이 실은 무시된 충격 변동성의 변화일 수 있다고 주장했다 — 1970년대가 달라 보이는 이유는 전달 계수가 움직여서가 아니라 충격이 더 컸기 때문일 수 있다는 것이다. Cogley와 Sargent 자신의 후속 연구가 바로 이 이유로 확률적 변동성을 추가했고(16장의 장치가 그 도구다), 여기의 재현은 의도적으로 2001년 명세를 유지하므로 그 표류 추정치는 이 유보를 붙여 읽어야 한다.

18. 마르코프 국면전환 모형 (Markov-Switching Regime Model)

로드맵

제14장 이후의 모든 모형은 어떤 대상이 얼마나 매끄럽게 변동하는지를 다루어 왔다. GARCH 분산, 확률보행 추세, 변동성 경로, 계수벡터가 그 예이다. 이 장은 질문 자체를 바꾼다. 매끄러운 변동 대신, 세상이 소수의 반복되는 상태들 사이를 오가며 뛰어넘는 것은 아닌가? 그 방법론은 결국 제17장의 직계 친척임이 드러난다 — 순방향 필터에 이어 역방향 샘플러가 오는 구조로서, 모든 연속적인 가우스 단계가 이산적인 두 상태짜리 대응물로 치환될 뿐이다. 그러한 평행 관계야말로 이 모형을 모수적 장들의 마지막에 배치한 이유이다. 이 장에 이르면, 제6장, 제8장, 제15장, 제17장을 따라온 독자는 이 모형에 필요한 모든 개별 조각을 이미 갖추고 있는 셈이다.

제14장 이후의 모든 모형은 자료생성과정의 일부가 시간에 따라 매끄럽게 변동하도록 하였다. GARCH 분산 재귀식, 확률보행 추세, n 개의 독립적인 로그변동성 경로, 또는 전체 확률보행 계수벡터가 그것이다. 이 장은 그 근저의 논리를 완전히 바꾼다. 매끄러운 연속적 변동 대신, 과정이 소수의 이산적이고 반복되는 국면(regime)(여기서는 “경기침체” 상태와 “확장” 상태) 사이를 은닉 마르코프 연쇄(hidden Markov chain)에 의해 뛰어넘도록 허용한다. 이는 Hamilton(1989)의 국면전환 틀을, Albert and Chib(1993)과 Chib(1996)에 의한 베이저안 깃스 샘플러 형태로 구현한 것이다. 국면계열 $S_{1:T}$ 는 국면별 계수 및 분산과 함께 추출해야 할 또 하나의 미지수 집합으로 취급된다.

마르코프 국면전환 AR(1) 모형 y_t 가 절편, 기울기, 잔차분산 모두가 관측되지 않는 이산 상태 $S_t \in \{1, 2\}$ 에 의존하는 AR(1) 과정을 따른다고 하자.

$$y_t = \beta_{0,S_t} + \beta_{1,S_t} y_{t-1} + e_t, \quad e_t \sim N(0, \sigma_{S_t}^2),$$

여기서 S_t 는 다음 전이확률을 갖는 1차, 2상태 마르코프 연쇄를 따른다.

$$P = \begin{pmatrix} p_{11} & 1 - p_{11} \\ 1 - p_{22} & p_{22} \end{pmatrix}, \quad p_{11} = \Pr(S_t = 1 \mid S_{t-1} = 1), \quad p_{22} = \Pr(S_t = 2 \mid S_{t-1} = 2).$$

상태 1은 $\beta_{0,1} < \beta_{0,2}$ 을 부과함으로써 저(低)평균성장(“경기침체”) 국면으로 식별된다(이러한 제약이 없으면 두 라벨은 서로 교환 가능하며 사후분포는 그에 대해 대칭이다 — 이는 이 노트의 다른 어디에서도 쓰이지 않는 순서제약의 이산상태 버전이지만, 개념적으로는 제12장 SVAR의 부호제약과 동일한 식별 문제이다). 이는 Hamilton(1989) 자신의 식별 장치를 분산이 아니라 절편에 적용한 것이다. 경기침체/확장의 구분은 근본적으로 평균 성장률에 관한 주장이므로, 라벨링 제약을 그곳에 직접 부과하는 것이다. 제14–17장과 달리 여기서의 잠재 대상(S_t)은 연속형이 아니라 이산형이며, 자연스러운 필터링 재귀식은 칼만 필터나 정밀도 샘플러가 아니라 해밀턴 필터(Hamilton filter)이다.

그림 79는 제17장 그림 74와 동일한 이중 경로 형태를, 연속상태 β_t 를 이산국면 S_t 로 치환하여 나타낸 것이다.




Figure 79: 해밀턴 필터 / Chib 역방향 샘플러: 순방향 해밀턴 필터(실선)는 왼쪽에서 오른쪽으로 이동하며 각 y_t 를 반영하여 필터링된 확률 $\xi_{t|t}$ 를 계산하고, Chib(1996)의 역방향 다중이동(multi-move) 샘플러(점선)는 오른쪽에서 왼쪽으로 이동하며 $S_T, S_{T-1}, \dots, S_1$ 을 추출한다 — 제17장 그림 74의 이산상태 쌍둥이이다

알고리즘: 마르코프 국면전환 모형을 위한 깁스 샘플러

각 국면의 (β_0, β_1) 에 대한 확산(diffuse) $N(0, \text{diag}(9, 0.5))$ 사전분포, 각 σ_j^2 에 대한 확산 역감마 $(1.5, 1.5)$ 사전분포, 그리고 전이확률에 대한 비대칭적 베타 사전분포(p_{11} 에는 베타(10, 30), p_{22} 에는 베타(30, 10))를 사용하여, 경기침체는 일반적으로 단기간 지속되는 반면 확장은 일반적으로 오래 지속된다는 믿음을 반영한다:

1. **국면별 계수.** 현재의 국면경로 $S_{1:T}$ 가 주어지면, 표본을 두 국면별 부표본으로 분할하고, $(\beta_{0,1}, \beta_{1,1})$ 과 $(\beta_{0,2}, \beta_{1,2})$ 각각을 통상적인 켈레 베이저안 회귀 완전조건부분포로 부터 제안한다(이는 정확히 제6장의 기법을 두 개의 서로소인 부표본에 두 번 적용한 것이다) 그런 다음 $\beta_{0,1} < \beta_{0,2}$ 일 때만 이 쌍을 수락하고, 그렇지 않으면 직전 스왑의 값을 유지한다. 이것이 체인 전반에 걸쳐 라벨링 제약을 강제하는 메커니즘이다.
2. **국면별 분산.** 각 국면의 잔차가 주어졌을 때, σ_1^2 과 σ_2^2 을 그 켈레 역감마 완전조건부분포에서

추출한다. 여기서는 기각 단계가 필요 없다. 라벨링 제약은 이미 단계 1에서 전적으로 처리되기 때문이다.

3. **국면경로.** 해밀턴 필터를 표본 전체에 걸쳐 순방향으로 실행하여 매 시점 t 의 필터링된 확률 $\Pr(S_t | y_{1:t})$ 를 얻은 다음, Chib(1996)의 역방향 다중이동 샘플러를 통해 전체 경로 $S_{1:T}$ 를 함께 추출한다. S_T 를 그 필터링된 분포에서 추출하고, $t = T - 1, \dots, 1$ 에 대해 $\Pr(S_t | S_{t+1}, y_{1:t}) \propto \Pr(S_t | y_{1:t}) P(S_t, S_{t+1})$ 로부터 S_t 를 추출한다 — 이는 제15–17장에서 연속상태에 사용된 역방향 시뮬레이션 평활기의 이산상태 버전이다.
4. **전이확률.** 추출된 경로 $S_{1:T}$ 에서 실현된 전이 횟수를 세고, p_{11} 과 p_{22} 각각을 그 켤레 베타 완전조건분포(사전 횟수에 실현된 전이 횟수를 더한 것)에서 추출한다.

18.1 사후분포 유도

유도: 국면별 계수와 분산

국면경로 $S_{1:T}$ 가 주어지면, 표본을 $S_t = 1$ 인 부표본과 $S_t = 2$ 인 부표본으로 분할한다. 국면 j 내에서, $S_t = j$ 인 모든 관측치는 $y_t = \beta_{0,j} + \beta_{1,j}y_{t-1} + e_t$, $e_t \sim N(0, \sigma_j^2)$ 을 따른다 — 이는 그 부표본만을 대상으로 한 통상적인 선형회귀이다. 이것이 타당한 이유는, $S_{1:T}$ 가 주어지면 두 부표본의 관측치들이 완전히 별개인 두 모수집합에 의해 지배되는 독립적인 정규 추출값이 되어, 마치 두 개의 별개의 회귀 데이터셋인 것과 정확히 같기 때문이다:

$$(\beta_{0,j}, \beta_{1,j}) | S_{1:T}, \sigma_j^2, y \sim N(\bar{\beta}_j, \bar{V}_j)$$

이는 제6.2절의 완전제곱식 결과를, $S_t = j$ 인 행들로 X 와 y 를 제한하여 적용한 것이며, 그리고

$$\sigma_j^2 | S_{1:T}, \beta_j, y \sim IG\left(\frac{a_0 + T_j}{2}, \frac{d_0 + \sum_{t:S_t=j} (y_t - \beta_{0,j} - \beta_{1,j}y_{t-1})^2}{2}\right)$$

는 동일한 제한된 부표본에 적용한 제6.2절의 지수매칭 결과에 의한 것이다. 여기서 T_j 는 국면 j 에 배정된 기간의 수이고, $\bar{\beta}_j, \bar{V}_j$ 는 국면- j 설계행렬과 종속변수에 대해 계산한 제6.2절의 $\bar{\beta}, \bar{V}$ 공식이다. 두 식 모두 새로운 유도가 필요하지 않다. 제6.2절의 논증을 적용하기에 앞서 S_t 로 표본을 분할하는 것은 공식에 들어가는 X 와 y 의 행만을 바꿀 뿐이다.

$\beta_{0,1} < \beta_{0,2}$ 라는 라벨링 제약은, 제15장의 정상성 삼각형(stationarity triangle)에서와 같은 방식으로 부과된다. 위의 두 절단되지 않은 정규 완전조건부분포로부터 쌍 (β_1, β_2) 을 추출한 뒤, 순서가 위반될 때마다 둘 다 기각하고 다시 추출하며, 대신 직전 스왑의 값을 유지한다. 이것이 타당한 이유는, 결합분포를 어떤 부분집합으로 제한하고 재정규화하는 것이 바로 그 부분집합으로의 수락에 조건화하는 것과 정확히 같은 결과를 낳기 때문이다. 변동성 국면 모형의 분산순서 제약과 달리, 여기서는 두 절편만 확인하면 되므로 β_1 과 β_2 는 쌍으로 함께 수락되거나 기각되며, σ_1^2, σ_2^2 에는 별도의 제약이 부과되지 않는다.

유도: 해밀턴 필터: $S_t | y_{1:t}$

$\xi_{t|t-1}(j) = \Pr(S_t = j | y_{1:t-1})$, $\xi_{t|t}(j) = \Pr(S_t = j | y_{1:t})$ 라 하고, $f_j(y_t) = N(y_t; \beta_{0,j} + \beta_{1,j}y_{t-1}, \sigma_j^2)$ 을 현재의 계수 및 분산 추출값이 주어졌을 때 현재 관측치에 대한 국면 j 의 조건부 밀도라 하자.

1. **예측(Prediction).** S_t 의 마르코프 성질과 전체확률의 법칙에 의해,

$$\xi_{t|t-1}(j) = \Pr(S_t = j \mid y_{1:t-1}) = \sum_{i=1}^2 \Pr(S_t = j \mid S_{t-1} = i) \Pr(S_{t-1} = i \mid y_{1:t-1})$$

그리고 방금 곱한 두 항을 전이행렬 및 필터링된확률 표기로 바꾸어 쓰면,

$$= \sum_i P(i, j) \xi_{t-1|t-1}(i).$$

이는 제17장의 연속형 예측단계 $\beta_{t|t-1} = \beta_{t-1|t-1}$ 의 이산상태 버전이다. 그곳에서는 단일한 결정론적 확률보행 평균이었던 것이, 여기서는 두 가능한 선행상태에 대한 가중평균으로, 전이확률로 가중된다.

2. **업데이트(Update).** 베이즈 법칙에 의해, 제8장의 이산 $\gamma_j \mid \beta_j, \dots$ 사후분포와 제16장의 혼합성분 지시변수 사후분포에서와 정확히 동일하게,

$$\xi_{t|t}(j) = \Pr(S_t = j \mid y_{1:t}) \propto f_j(y_t) \xi_{t|t-1}(j), \quad j = 1, 2,$$

$j = 1, 2$ 에 대해 합이 1이 되도록 재정규화한다.

$t = 1, \dots, T$ 에 대해 예측 다음 업데이트를 반복하면(초기값 $\xi_{1|0}$, 예컨대 P 가 함의하는 연쇄의 정상분포에서 시작하여) 필터링된 확률의 전체 수열 $\xi_{t|t}$ 가 생성되며, 이는 제17장의 순방향 칼만 필터와 정확히 평행을 이루되, 연속적인 가우스 재귀식이 이산적인 두 점(two-point) 재귀식으로 치환된 것이다.

유도: Chib의 역방향 다중이동 샘플러: $S_{1:T} \mid y_{1:T}$

제17장의 연속형 역방향 샘플러에서와 마찬가지로, 모형의 마르코프 구조에 의해 S_{t+1} 은 S_t 가 주어지면 $y_{1:t}$ 와 조건부 독립이다. 따라서 베이즈 법칙에 의해,

$$\Pr(S_t = k \mid S_{t+1}, y_{1:t}) \propto \Pr(S_{t+1} \mid S_t = k) \Pr(S_t = k \mid y_{1:t})$$

그리고 전이확률과 필터링된 확률질량을 위에서 이미 고정한 표기로 쓰면,

$$= P(k, S_{t+1}) \xi_{t|t}(k), \quad k = 1, 2,$$

k 에 대해 재정규화한다. 이는 제17장의 가우스 역방향 샘플링 커널 $N(\beta_{t+1} \mid \beta_t, Q) N(\beta_t \mid \beta_{t|t}, P_{t|t})$ 의 이산상태 대응물이다. 가우스 전이밀도 $N(\cdot \mid \beta_t, Q)$ 는 이산 전이확률 $P(k, S_{t+1})$ 로, 가우스 필터링밀도 $N(\cdot \mid \beta_{t|t}, P_{t|t})$ 는 필터링된 확률질량 $\xi_{t|t}(k)$ 로 치환된다.

$S_T \sim \xi_{T|T}$ 을 추출한 뒤 이 커널로부터 $S_{T-1}, \dots, S_1$ 을 역순으로 추출하면, 제17장의 연속형 역방향 샘플러를 정당화하는 데 사용된 것과 동일한 연쇄법칙 분해 논증 $p(S_{1:T} \mid y) = p(S_T \mid$

$y_{1:T}) \prod_{t=1}^{T-1} p(S_t | S_{t+1}, y_{1:t})$ 에 의해 $p(S_{1:T} | y_{1:T})$ 로부터의 정확한 결합추출을 얻는다.

유도: $p_{11} | S_{1:T}$ 와 $p_{22} | S_{1:T}$

추출된 경로 $S_{1:T}$ 가 주어졌을 때,^a n_{11} 을 전이 $S_{t-1} = 1 \rightarrow S_t = 1$ 의 횟수, n_{12} 를 전이 $S_{t-1} = 1 \rightarrow S_t = 2$ 의 횟수라 하자(따라서 $T_1 - 1 \leq n_{11} + n_{12} \leq T_1$ 이며, 이는 국면 1을 벗어난 기간의 수이다). 이러한 각 전이는 성공확률 p_{11} (“국면 1에 머무름”)을 갖는 독립적인 베르누이 시행이므로, p_{11} 에 대한 우도 기여분은 p_{11} 에 대한 이항 커널이다. 커널이 $p_{11}^9(1 - p_{11})^{29}$ 인 Beta(10, 30) 사전분포하에서, 그 곱은

$$p(p_{11} | S_{1:T}) \propto \underbrace{p_{11}^{n_{11}}(1 - p_{11})^{n_{12}}}_{\text{우도}} \times \underbrace{p_{11}^9(1 - p_{11})^{29}}_{\text{사전분포}}$$

그리고 p_{11} 과 $1 - p_{11}$ 각각의 지수를 더하면,

$$= p_{11}^{9+n_{11}}(1 - p_{11})^{29+n_{12}},$$

이는 관찰만으로 정확히 Beta($10 + n_{11}$, $30 + n_{12}$) 커널임을 알 수 있다 — 이는 제8장의 $p | \gamma$ 우도와 동일한 베타-베르누이 컬레스성 논증으로, 국면전이 지시변수 $\mathbb{I}\{S_t = 1\}$ ($S_{t-1} = 1$ 인 기간 중)에서이 그곳에서 포함지시변수 γ_j 가 하던 역할을 대신한다. 사전분포가 Beta(30, 10)인 국면 2에서의 전이에 동일한 논증을 적용하면 $p_{22} | S_{1:T} \sim \text{Beta}(30 + n_{22}, 10 + n_{21})$ 을 얻는데, 여기서 n_{22} 는 $S_{t-1} = 2 \rightarrow S_t = 2$ 전이의 횟수, n_{21} 은 $S_{t-1} = 2 \rightarrow S_t = 1$ 전이의 횟수이다.

^a비록 $S_{1:T}$ 는 단일한 종속적 연쇄이지만, 그 우도는 출발상태별로 깔끔하게 인수분해된다. 국면 1에서 나가는 모든 전이는 오직 p_{11} 만을 포함하고, 국면 2에서 나가는 모든 전이는 오직 p_{22} 만을 포함하므로, 전체 경로의 우도는 P 의 각 행에 하나씩, 두 개의 독립적인 이항형(Binomial-style) 곱으로 분해된다. 바로 이 행별 분해가 하나의 결합경로를 아래의 두 개의 별개의, 통상적인 베타-이항 컬레스 업데이트로 바꾸어 주며, 2×2 행렬 P 전체를 다룰 필요가 없게 해 준다.

18.2 실증 예제: 미국 GDP 성장률의 경기침체 및 확장 국면, 1959–2026년

실증 예제: 자료와 추정된 국면

이 장은 주식수익률 계열 대신, 미국 분기별 실질 GDP 성장률(연율 %) — 제4–6장, 제11–13장, 제19장에서 계속 사용해 온 거시경제 예제와 동일한 data_Q 패널, 이제 코로나19 팬데믹과 그 이후의 회복기까지 포함하도록 확장되어 $T = 266$ 개의 사용 가능한 분기(1959Q4–2026Q1) — 예 모형을 적합한다. 이는 또한 역사적으로, 자산수익률 계열의 변동성 국면이 아니라 실질 산출성장률의 반복되는 경기침체 및 확장 국면이라는, Hamilton(1989)이 이 모형을 만든 원래의 적용 대상이기도 하다. 1,500회의 번인 이후 5,000회의 사후번인 Gibbs 추출값(라벨링 제약이 부과된 계수 추출의 수락률 $\approx 75\%$ — 코로나 분기의 극단적 값들로 인해 확장 표본에서는 절편 순서 위반이 더 자주 발생한다)을 이용하면, 뚜렷이 구분되는 두 국면이 나타난다. 경기침체 국면은 이제 평균성장률($\hat{\beta}_{0,1} = 0.476$)이 이전보다 낮고, AR(1) 계수는 부호가 뒤집혀 $\hat{\beta}_{1,1} = -0.283$ 이 되었으며, 잔차분산은 $\hat{\sigma}_1^2 = 96.00$ 으로 이전 표본(1959–2013)의 23.73에서 네 배 가까이 커졌다. 확장 국면은 상당히 더 높은 평균성장률($\hat{\beta}_{0,2} = 2.298$, $\hat{\beta}_{1,2} = 0.295$)을 가지며, 잔차분산 $\hat{\sigma}_2^2 = 5.52$ 는 거의 변하지 않았다. 경기침체 국면의 극적인 변화는 온전히 2020년 코로나 충격 때문이다: 2020Q2의 -28.0% 급락과 그 직후인 2020Q3의 $+34.9\%$ 반등이 모두 경기침체 국면으로 분류되면서, 그 국면의 분산을 지배하고 AR(1) 계수의 부호까지 뒤집었다 — 평범한 침체 분기 이후에는 성장률이

계속 낮게 유지되는 경향(양의 AR(1) 계수)이 있는 반면, 코로나 이후에는 극단적인 마이너스 분기 다음에 극단적인 플러스 반등이 뒤따랐고, 이는 단순한 2상태, 평균만 다른(mean-only) 설계로는 음(-)의 자기상관으로만 수용될 수 있기 때문이다. 이는 산출성장률이 침체기에 확장기보다 평균이 낮을 뿐 아니라 변동성도 훨씬 더 크다는 표준적인 경기순환 정형화 사실을 한층 더 극명하게 보여준다 — 코로나를 포함하면, 경기침체는 단순히 확장을 거꾸로 돌린 것이 아니라 질적으로 다른, 훨씬 더 소란스러운 국면임이 분명해진다.

실증 예제: 국면 지속성과 기간

추정된 전이확률은 사전분포가 인코딩한 방향으로 여전히 강하게 비대칭적이다. $\hat{p}_{11} = 0.295$ (경기침체 국면) 대 $\hat{p}_{22} = 0.889$ (확장 국면)이며, 이는 경기침체 국면 지속에 대해 $1/(1 - \hat{p}_{11}) \approx 1.4$ 분기(변화 없음), 확장 국면 지속에 대해 $1/(1 - \hat{p}_{22}) \approx 9.0$ 분기(2년 이상)라는 기대 국면기간으로 환산된다 — 확장 국면의 기대 지속기간이 이전 표본의 약 4.0분기에서 두 배 넘게 늘어난 것은, 2009년부터 2020년 초까지 이어진 미국 역사상 가장 긴 경기확장이 코로나 이전 표본에 새로 편입되었기 때문이다. 전체 표본에서 경기침체 국면에 있을 사후평균 확률은 평균 11.8%로 이전보다 낮아졌으며(확장 국면 편입 효과), 266개 분기 중 19개 분기가 0.5를 넘는 사후 경기침체국면 확률을 가지며, 이는 13개의 서로 구별되는 사건(episode)으로 정리된다. 그림 80은 전체 사후확률 경로를, 그로부터 국면을 추론해 낸 GDP 성장률 계열과 함께 나타낸다. 2020년 초의 확률 급등은 그래프에서 다른 모든 사건을 왜소하게 만들 정도로 거의 수직에 가깝다.




Figure 80: 저성장(경기침체) 국면의 사후확률, 전체 표본, 미국 분기별 GDP 성장률과의 비교

실증 예제: 식별된 사건들은 NBER 경기침체 연대기와 일치하는가?

이제 식별된 가장 긴 경기침체 사건은 큰 차이로 **2020Q1–2020Q4**(4개 연속 분기)이며, NBER이 지정한 2020년 2월–4월의 코로나19 경기침체(NBER 자체 연대기 기준 역대 가장 짧은 침체)를 정확히 포함한다. 이 모형이 가장 확신을 갖는 사건이 바로 이 가장 짧은 침체라는 점은 짚어볼

가치가 있다. 그 메커니즘은 다음과 같다: 2020Q2의 -28.0% 급락은 의심의 여지 없이 국면 1로 분류되지만, 2020Q3의 $+34.9\%$ 반등도 마찬가지로 국면 1로 분류된다 — 언뜻 보면 확장 국면에 속할 것처럼 보이는데도 그렇다. 그 이유는 여기서의 분류가 성장률의 수준이 아니라 AR(1) 동학에 좌우되기 때문이다: $y_{t-1} = -28.0\%$ 일 때, 국면 1의 음(-)의 AR(1) 계수는 2020Q3의 평균을 $0.48 + (-0.28)(-28.0) \approx 8.4\%$ 로 예측하며, 이는 실제 실현값 34.9% 보다 국면 1 표준편차 약 2.7배 낮은 값에 불과하다. 반면 국면 2의 양(+)의 계수는 $2.30 + 0.29(-28.0) \approx -5.7\%$ 를 예측하는데, 이는 실제로 일어난 일과 국면 2 표준편차 약 17배나 떨어져 있다. 성장률의 수준만 보는 모형이라면 2020Q3을 확장 국면으로 판단했겠지만, 성장률이 직전 분기 대비 어떻게 움직이는지를 추적하는 이 모형은 극단적인 반등을 여전히 동일한 극단적 사건의 일부로 올바르게 인식한다. 코로나 사건 다음으로 긴 사건들은 각각 2개 분기로, **1960Q1–1960Q2**(1960년 아이젠하워 경기침체), **1970Q4–1971Q1**(1969–70년 경기침체의 꼬리 부분), **1981Q4–1982Q1**(1981–82년 경기침체 내부)이다. 단일분기 사건 중에서는 1974Q1, 1974Q3, 1975Q1이 NBER이 지정한 1973–75년 오일쇼크 경기침체 내부에 위치하고, 1980Q2는 짧았던 1980년 경기침체 내부에, 1981Q2는 1981–82년 내부에 위치한다. 그리고 여전히 -8.70% 였던^a 2008Q4는 2007–09년 금융위기 내부에 위치한다. 식별된 두 분기, 1965Q1과 1978Q2는 어떤 NBER 경기침체에도 대응하지 않는다 — 확장 이전 표본에서도 나타났던 것과 동일한 종류의 오탐(false positive)으로, GDP 성장률만 보고 NBER 연대기 위원회가 고려하는 구조적 계기는 전혀 알지 못하는 축약형 분류기가 치르는 대가이다. 이제 표본 구간에 포함된 9개의 NBER 경기침체 중 7개가 적어도 하나의 일치하는 분기로 식별된다. 흥미롭게도, 확장된 표본에서 넓어진 경기침체 국면의 분산이 오히려 이전 표본에서는 잡아냈던 두 건의 일치를 놓치게 만든다 — 1990–91년과 2001년 경기침체는 이제 0.5를 넘는 사후확률을 가진 분기를 하나도 만들어내지 못하는데, 이는 2020Q2를 수용하도록 어느 정도 맞춰진 국면의 분산에 비하면 평범한 크기의 침체가 이제 상대적으로 작아 보이기 때문이다. 이것이 표본을 코로나 시기까지 확장하는 데서 얻는 핵심 교훈이다: 충분히 극단적인 관측치 하나가 추가되면 단순히 사건 하나가 새로 식별되는 데서 그치지 않고, 전후 미국 역사상 가장 급격했던 수축을 수용하기 위해 분산이 재조정되면서 다른 모든 사건에 대한 모형의 민감도를 조용히 떨어뜨릴 수 있다. 2상태, 평균만 다른 (mean-only) 단순 설계는 국면당 분산 모수를 단 하나만 가지므로, 평범한 침체와 전후 최악의 수축을 동시에 기술해야 하기 때문이다. 그림 81는 세 구간(1973–75년 오일쇼크 경기침체, 2007–09년 금융위기, 2020년 코로나19 경기침체)을 확대하여, 성장률이 음(-)으로 전환됨에 따라 사후확률이 급격히 상승하고 각 사건이 끝남에 따라 다시 하락하는 모습을 보여준다. 코로나 구간의 거의 수직에 가까운 0.99 이상으로의 확률 급등은 다른 두 구간에서는 볼 수 없는 시각적 특징이다.

^a경기침체 국면의 평균인 $\hat{\beta}_{0,1} = 0.48$ 은 온건한 침체 분기와 코로나 극단값을 포함한 침체로 분류된 모든 분기에 대한 평균임에 유의하라. 개별 침체 분기는 이보다 훨씬 낮을 수 있고 실제로도 그러하다 — -8.70% 의 2008Q4는 코로나 이전 표본에서는 여전히 최악의 단일 분기이다.




Figure 81: 경기침체 국면의 사후확률(왼쪽 축, 남색)과 GDP 성장률(오른쪽 축, 점선)의 비교, 1973-75년 오일쇼크 경기침체, 2007-09년 글로벌 금융위기, 2020년 코로나19 경기침체 기간

18.3 Hamilton (1989)

위의 실증 예제는 이 장의 일반형인 절편 전환 AR(1)을 사용했다. 이 절은 이 틀 전체의 출발점이 된 논문을 그 논문 자신의 자료에서 재현한다. Hamilton (1989), “A New Approach to the Economic Analysis of Nonstationary Time Series and the Business Cycle”(Econometrica 57(2))는 미국 분기 실질 GNP 성장률 $y_t = 100\Delta \ln \text{GNP}_t$, 1951Q2-1984Q4를, 평균만 두 상태 마르코프 연쇄를 따라 전환되고 나머지는 두 국면에 공통인 AR(4)로 모형화했다.

$$(y_t - \mu_{S_t}) = \sum_{i=1}^4 \phi_i (y_{t-i} - \mu_{S_{t-i}}) + e_t, \quad e_t \sim N(0, \sigma^2).$$

논문의 유명한 발견은 두 갈래이다. 추정된 두 평균이 진정으로 음(-)인 침체 성장률($\hat{\mu}_0 = -0.36$, 분기당)과 $+1.16$ 의 확장 성장률로 갈린다는 것(침체는 성장의 둔화가 아니라 수준의 하락이라는 것) 그리고 GNP 성장률 하나만으로 추론된 모형의 침체확률이 NBER의 판단적 경기순환 연대기를 거의 국면 하나하나까지 재생한다는 것이다.

이 설정은 이 장 앞의 예제와 두 가지 점에서 다르며, 둘 다 샘플러에 영향을 준다. 첫째, 전환되는 대상이 절편이 아니라 평균 μ_{S_t} 이므로, 네 개의 시차 상태 $S_{t-1}, \dots, S_{t-4}$ 가 S_t 와 함께 t 기 조건부 평균에 들어간다. 앞 예제의 1단계 마르코프 구조 위에 세워진 칩의 multi-move 후방 샘플러는 따라서 더 이상 직접 적용되지 않으며, 국면 경로는 상태를 하나씩 갱신한다 — 각 S_t 를 이웃 상태들, 두 개의 전이 항, 그리고 S_t 가 건드리는 (최대) 다섯 개의 우도 항 $y_t, \dots, y_{t+4}$ 가 주어진 완전조건부분포에서 다시 추출하는 single-move 스위치이다. 이는 정확히 Albert and Chib (1993)의 샘플러인데, 그 논문 자신의 실증 응용이 바로 이 자료에 대한 이 모형이었다. 둘째, 약하게 정보적인 사전분포가 여기서는 실질적인 일을 한다. Kim and Nelson (1999) 류의 지속성 사전분포($p \sim \text{Beta}(9, 1)$, $q \sim \text{Beta}(8, 2)$)와 ± 1 에 중심을 둔 국면 평균 사전분포는, 두 “국면”이 분기별 잡음을 뒤쫓으며 거의 매 분기 전환되는 잘 알려진 허위 모드로 single-move 연쇄가 빠지지 않게 붙들어 준다. 평탄한 Beta(2, 2) 사전분포 아래에서

는 이 샘플러가 정확히 그 잡음 추종 모드에 안착한다.⁶

실증 예제: 원표본 1951Q2-1984Q4

번인 이후 10,000개의 추출로 얻은 사후평균(표준편차)을 Hamilton의 Table I 최우추정값과 비교하면 다음과 같다.

	사후분포	Hamilton (1989)
μ_0 (침체)	-0.44 (0.57)	-0.36
μ_1 (확장)	1.14 (0.20)	1.16
p (확장 지속)	0.91 (0.06)	0.90
q (침체 지속)	0.71 (0.12)	0.76

기대 지속기간으로는 침체 3.4분기, 확장 11.4분기로, Hamilton의 4.1과 10.5에 대응한다 — 논문의 중심 추정값들이 사후 표준편차 하나 이내에서 재생된 것이다.^a 135개 분기 중 16개가 침체 확률 0.5를 넘으며, 그림 82은 이들이 정확히 있어야 할 자리에 온다는 것을 보여준다. 1953-54, 1957-58, 1960-61, 1970, 1974-75, 1980, 1981-82 — 표본 안의 NBER 침체 하나마다 뚜렷한 군집 하나씩이다. 성장을 자료 하나만으로 복원된, 이 논문을 유명하게 만든 바로 그 그림이다.




Figure 82: Hamilton (1989) 재현: 침체국면의 사후확률(실선, 왼쪽 축)과 분기 실질 GNP 성장률(점선, 오른쪽 축), 원표본

^aAR 계수와 교란항 분산은 Table I에서 더 멀리 떨어진다($\hat{\phi}_1 = 0.24$ 대 0.014; $\hat{\sigma}^2 = 0.84$ 대 0.59). 이유는 이제 익숙한 두 가지이다. 실질 GNP는 Hamilton이 사용한 1984년 빈티지 이후 여러 차례 전면 개정되었고, 여기의 값은 최우추정 점추정값이 아니라 약하게 정보적인 사전분포 아래의 사후평균이다 — 7장의 EM(1998)에서 지적한 것과 같은 단서이다.

실증 예제: 2019Q4까지의 전체표본: 대안정기가 두 국면을 모두 바꾼다

동일한 모형을 2019Q4까지(코로나19 직전에서 의도적으로 멈춘 것인데, 그 이유는 다음 예제가 생생하게 보여준다) 연장해 추정하면 두 국면 모두 Hamilton 이후 문헌이 기록한 방향으로

⁶이 장 앞의 예제에 이런 조심이 필요 없었던 것은 분산까지 함께 전환되어 두 국면이 훨씬 뚜렷이 분리되기 때문이다. Hamilton의 공통 σ^2 설계에서는 두 국면을 구별하는 것이 평균뿐이다.

달라진다. 확장 평균은 1.14에서 0.88로 내려가고(추세 성장의 둔화), 확장은 극적으로 길어진다. $\hat{p} = 0.96$, 기대 지속기간 25분기로, 1991–2001년과 2009–2019년의 길고 끊기지 않은 확장을 반영한다. 침체국면은 더 깊고 더 짧아진다($\hat{\mu}_0 = -1.15$, 기대 지속기간 2.3분기). 대안정기의 산출 변동성 하락(McConnell and Perez-Quiros, 2000)과 함께, 한때 일 년짜리 NBER 침체를 서술하던 국면이 갈수록 가장 급격한 수축 분기들만을 전담하게 되는 것이다 — 그림 83에서 1957–58년, 1980–82년, 그리고 무엇보다 2008–09년이 도드라지는 반면, 온건했던 1990–91년과 2001년 침체는 거의 등록되지 않는다. Kim and Nelson (1999)은 전환 모형 그 자체에서 정확히 이 구조 변화를 기록했다. 재현은 Hamilton의 표본을 늘리는 것만으로 그들의 결론을 복원한다.





Figure 83: 2019Q4까지 추정된 동일 모형: 확장은 길어지고, 침체국면은 날카로워지며, 대안정기 이후의 온건한 침체들은 희미해진다

실증 예제: 코로나19를 더하면: 한 분기가 침체국면을 독차지한다

2026Q1까지(추가되는 육 년 중 단 한 분기만이 이례적인 자료를) 추정하면 국면 하나가 더해지는 것이 아니라 침체국면이 무엇인지 자체가 바뀐다. 침체 평균은 $\hat{\mu}_0 = -4.4$ 로 무너지고, 확장국면은 99%의 지속성($\hat{p} = 0.99$)을 흡수하며, 칠십오 년 중 침체로 분류되는 분기는 단 세 개뿐이다. 이 국면은 경기순환의 하강을 서술하기를 멈추고 2020Q2의 붕괴에 맞춰진 희귀 재난(rare-disaster) 상태가 된 것이다(그림 84). 코로나 이전 적합이 선명하게 식별했던 2008–09년을 포함해 모든 평범한 침체는 확장국면의 잡음으로 재분류된다. -4.4% 의 국면 평균에 견주면 -2% 짜리 분기는 더 이상 침체처럼 보이지 않기 때문이다. 이는 이 장 자신의 코로나 논의가 다른 방향에서 도달한 것과 같은 교훈이며, 국면전환 모형에 국한된 것도 아니다. Lenza and Primiceri (2022)는 VAR에서 유사한 왜곡을 기록하고 명시적인 이상치 처리를 제안했으며, 16장의 확률적 변동성 장치는 같은 문제에 대한 이 노트 자신의 답이다. 분산 하나와 평균 둘을 가진 두 상태 모형에는 백 년에 한 번 나올 관측치에 붙일 세 번째 이름표가 없다 — 그래서 가진 둘 중 하나를 그 관측치에 써 버리는 것이다.



19. 비모수 모형: 회귀나무와 BART (Bayesian Additive Regression Trees)

로드맵

이 노트의 지금까지의 모든 모형은 먼저 함수형태를 고정한 다음 그 모수에 사전분포를 부여하였다. 제6장의 선형, 제7장의 프로빗 연결함수, 제14~17장의 로그선형 변동성 재귀식이 그것이다. 이들 중 가장 유연한 제8장의 SSVS조차도 오직 어떤 선형 항을 남길지만을 결정할 뿐이다. 이 장은 함수형태 자체를 완화한다. 베이저안 가법회귀나무(Bayesian Additive Regression Trees, BART; Chipman, George and McCulloch, 2010)는 계단함수(step function)들의 공간(회귀나무들의 합)에 직접 사전분포를 부여하고, 분석자가 미리 추측해야만 반영할 수 있었던 꺾임, 임계값, 상호작용을 포함하여 자료가 그 형태를 결정하도록 한다. 추정 기법은 다시 한 번 깃스형 순환이다. 깃스 스위치 안에 메트로폴리스-헤이스팅스 단계가 내장된 구조로, 제14장의 맞춤형 M-H와 제18장의 이산상태 샘플러가 이미 사용한 것과 정확히 동일한 조합이다. 이는 의도적으로 다른 방식으로 이 노트를 마무리하는 것이다. 다른 모든 장이 “이 방정식의 모수를 어떻게 추정할 것인가”를 물었다면, 이 장은 “방정식 자체를 쓰지 않기로 한다면 어떻게 할 것인가”를 묻는다.

나무 기반 회귀모형은 단일한 전역적 함수형태를, 공변량 공간을 직사각형 영역들로 분할하고 각 영역마다 고유한 상수예측값을 부여하는 방식으로 대체한다. 나무 하나만으로는 조악하고 분산이 큰 근사기에 지나지 않는다(이는 잎(leaf)의 개수만큼의 서로 다른 값만을 갖는 계단함수이다) 하지만 각각이 단순하게 유지되도록 개별적으로 정규화된 여러 얇은 나무의 합은, 훨씬 더 정교한 비모수적 방법에 필적하는 정확도로 매끄럽거나 꺾인 반응 표면을 근사할 수 있으며, 동시에 완전히 베이저안적인 성격을 유지한다. 모든 나무, 모든 잎 평균, 그리고 잔차분산 모두가 명시적인 사후분포를 갖는다.

나무합 모형 (Sum-of-Trees Model) 단일 회귀나무 j 는 순서쌍 (T_j, M_j) 이다. T_j 는 축에 정렬된 분할 $\{x_{\cdot,k} \leq c\}$ 로 이루어진 이진분할 구조이고, $M_j = \{\mu_{j,1}, \dots, \mu_{j,b_j}\}$ 는 잎(terminal-node) 평균들의 집합으로, 잎마다 하나씩 존재한다. x 가 도달하는 잎 평균을 $g(x; T_j, M_j)$ 로 쓰면, BART는 다음을 모형화한다.

$$y_i = f(x_i) + \varepsilon_i, \quad f(x) = \sum_{j=1}^m g(x; T_j, M_j), \quad \varepsilon_i \sim N(0, \sigma^2),$$

즉 m 개 나무(전형적으로 $m = 50-200$)의 합이다. 세 개의 사전분포가 이 합을 정규화하여, 어느 한 나무도 지배적이지 않고 앙상블이 m 개의 독립적으로 과적합된 나무가 아니라 약한 학습기 (weak-learner)들의 평균처럼 행동하도록 한다.

$$\begin{aligned} \Pr(\text{깊이 } d \text{에서 노드가 분할될 확률}) &= \alpha(1+d)^{-\beta}, \\ \mu_{j,l} &\sim N(0, \sigma_\mu^2), \\ \sigma^2 &\sim IG\left(\frac{\nu}{2}, \frac{\nu\lambda}{2}\right), \end{aligned}$$

여기서 Chipman-George-McCulloch(2010)의 기본값은 $\alpha = 0.95$, $\beta = 2$ (가파르게 감소하는 분할확률 — 대부분의 나무는 2-3단계 깊이에만 머무른다), y 를 $[-0.5, 0.5]$ 로 재척도화한 뒤 $k = 2$ 를 적용한 $\sigma_\mu = 0.5/(k\sqrt{m})$ (따라서 $f(x)$ 의 사전 95% 범위가 재척도화된 자료를 대략 포괄하도록 함), 그리고 $q = 0.9$ 에 대해 $\Pr(\sigma^2 < \hat{\sigma}_{OLS}^2) = q$ 가 되도록 선택된 λ, ν ($\nu = 3$)이다. 새로운 노드에서의 분할변수는 p 개의 예측변수 중에서 균등하게 추출되며, 분할값은 해당 노드에서 실제로 관측된 그 예측변수의 값들 중에서 균등하게 추출된다.

그림 85는 그러한 합에서 나온 나무 하나를 보여준다. 소수의 분할들이 각각 자신만의 상수예측값 μ_l 을 갖는 직사각형 공변량 영역을 잘라낸다. 개별적으로는 이렇게 단순한 나무 쉰 개의 합이, 이 장의 실증 예제에서 나타나는 유연하고 비가법적인 반응 표면을 만들어낸다.




Figure 85: 나무합 앙상블에서 나온 나무 하나 (T_j, M_j) : 두 번의 분할이 공변량 공간을 세 개의 잎으로 나누며, 각 잎은 고유한 상수예측값 μ_l 을 갖는다

유도: 리프 주변우도와 생성/소멸 수락비율

(T_j, M_j) 를 직접 추출하는 것은 T_j 가 이산적이고 차원이 가변적인 대상이기 때문에 다루기 어렵다. 표준적인 방법(Chipman, George and McCulloch, 1998)은 나무 구조에 대해서만 메트로폴리스-헤이스팅스를 적용하는 것으로, 잎 평균 M_j 는 수락비율에서 해석적으로 적분하여 제거한 다음, 이후 그 정확한 조건부분포에서 다시 추출한다 — 이는 제8장의 Chib 방법 유도 상자가 β 에

대해 사용한 것과 동일한 '적분 후 재추출' 논리를, 연속형이 아닌 이산형 성가신모수(nuisance parameter)에 적용한 것이다. 현재 나무의 부분잔차 $r_i = y_i - \sum_{k \neq j} g(x_i; T_k, M_k)$ (다른 모든 나무의 기여분을 뺀 뒤 나무 j 가 설명해야 할 목표값으로, 정확히 제8장에서 배피팅(backfitting)에 쓰인 잔차의 역할과 같다)와 현재의 σ^2 를 고정한다.

n 개의 관측치가 도달하고 잔차합이 $R = \sum_{i \in \text{leaf}} r_i$ 인 앞에 대해, 정규우도로부터 $\mu \sim N(0, \sigma_\mu^2)$ 를 적분하여 제거한다. 정규우도와 정규사전분포 커널을 명시적으로 쓰고, 우도 지수 안의 제곱항을 전개하면,

$$\int \prod_{i \in \text{leaf}} N(r_i; \mu, \sigma^2) N(\mu; 0, \sigma_\mu^2) d\mu = \int (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2} \sum_{i \in \text{leaf}} (r_i - \mu)^2\right) \times (2\pi\sigma_\mu^2)^{-1/2} \exp\left(-\frac{\mu^2}{2\sigma_\mu^2}\right) d\mu$$

$\sum_{i \in \text{leaf}} (r_i - \mu)^2 = \sum_i r_i^2 - 2\mu R + n\mu^2$ 로 전개하고, μ 와 무관한 인자 $(2\pi\sigma^2)^{-n/2} \exp(-\sum r_i^2/2\sigma^2)$ 를 적분 바깥으로 빼내면, 지수 안에는 μ 에 의존하는 항만 남는다:

$$= (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\sum r_i^2}{2\sigma^2}\right) (2\pi\sigma_\mu^2)^{-1/2} \times \int \exp\left(-\frac{1}{2} \left[\left(\frac{n}{\sigma^2} + \frac{1}{\sigma_\mu^2}\right)\mu^2 - \frac{2R}{\sigma^2}\mu\right]\right) d\mu$$

$A \equiv n/\sigma^2 + 1/\sigma_\mu^2$, $c \equiv R/\sigma^2$ 를 μ 에 대한 이차항 및 일차항 계수로 두고 완전제곱식을 적용하면 $A\mu^2 - 2c\mu = A(\mu - c/A)^2 - c^2/A$ 이므로, 지수는 μ 와 무관한 부분과 μ 에 대한 가우스 커널로 나뉜다:

$$= (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\sum r_i^2}{2\sigma^2}\right) (2\pi\sigma_\mu^2)^{-1/2} \exp\left(\frac{c^2}{2A}\right) \times \int \exp\left(-\frac{A}{2}(\mu - c/A)^2\right) d\mu$$

남은 적분은 이제 μ 에 대한 (비정규화된) 가우스 적분으로, $\sqrt{2\pi/A}$ 로 계산된다:

$$= (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\sum r_i^2}{2\sigma^2}\right) \sqrt{\frac{1}{A\sigma_\mu^2}} \exp\left(\frac{c^2}{2A}\right)$$

$A = n/\sigma^2 + 1/\sigma_\mu^2 = (\sigma^2 + n\sigma_\mu^2)/(\sigma^2\sigma_\mu^2)$ 를 다시 대입하면 $1/(A\sigma_\mu^2) = \sigma^2/(\sigma^2 + n\sigma_\mu^2)$ 이고 $c^2/(2A) = \sigma_\mu^2 R^2/[2\sigma^2(\sigma^2 + n\sigma_\mu^2)]$ 이므로, 이는 다음과 같이 단순화된다:

$$= (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\sum r_i^2}{2\sigma^2}\right) \times \sqrt{\frac{\sigma^2}{\sigma^2 + n\sigma_\mu^2}} \exp\left(\frac{\sigma_\mu^2 R^2}{2\sigma^2(\sigma^2 + n\sigma_\mu^2)}\right)$$

선행 인자 $(2\pi\sigma^2)^{-n/2} \exp(-\sum r_i^2/2\sigma^2)$ 는 앞이 분할되든 되지 않든 동일하다(분할은 동일한 관측치들을 다시 나눌 뿐이므로, 노드 전체에 대한 n 과 $\sum r_i^2$ 는 보존된다). 따라서 아래의 모든 비율에서 이는 소거되므로, 이를 제거하면:

$$\propto \sqrt{\frac{\sigma^2}{\sigma^2 + n\sigma_\mu^2}} \exp\left(\frac{\sigma_\mu^2 R^2}{2\sigma^2(\sigma^2 + n\sigma_\mu^2)}\right).$$

생성(birth) 이동은 현재의 잎, 예측변수, 사용 가능한 분할값을 각각 무작위로 선택하여, 그 잎 (n 개 관측치, 합 R)을 두 개의 새로운 잎(n_L, n_R 개 관측치, 합 R_L, R_R)으로 바꾼다.

이 닫힌 형태의 잎 주변우도는 나무구조 수락비율을 명시적인 계산으로 바꾸어 준다. 제14장의 맞춤형 독립 유도 상자에 나온 일반적인 메트로폴리스-헤이스팅스 유도에서와 마찬가지로, 현재 나무 T 에 대한 제안 나무 T' (여기서는 선택된 잎이 분할된 나무)의 수락비율은 $\alpha_{\text{birth}} = \min(1, \pi(T' | y) q(T | T') / [\pi(T | y) q(T' | T)])$ 이며, 사후커널 $\pi(T | y) \propto p(T) p(y | T)$ 는 나무사전분포와 잎별로 주변화된 우도 $p(y | T) = \prod_{l \in \text{leaves}(T)} (\text{잎 } l \text{에서의 잎 주변우도})$ 의 곱으로 인수분해된다. 깊이 d 에서 방금 유도한 잎 주변우도의 로그를 $L(n, R)$ 로 쓰면,

$$\frac{\pi(T' | y) q(T | T')}{\pi(T | y) q(T' | T)} = \frac{p(T')}{p(T)} \cdot \frac{p(y | T')}{p(y | T)} \cdot \frac{q(T | T')}{q(T' | T)}$$

T' 과 T 는 분할된 잎에서만 차이가 난다. 다른 모든 잎의 주변우도 인자는 $p(y | T') = \prod_l(\cdot)$ 와 $p(y | T) = \prod_l(\cdot)$ 에 공통으로 존재하여 소거되고, 분할된 잎의 인자와 그 두 자식의 인자만 남는다:

$$\frac{p(y | T')}{p(y | T)} = \exp [L(n_L, R_L) + L(n_R, R_R) - L(n, R)]$$

마찬가지로 T' 과 T 는, 새로 분할된 잎 자체(깊이 d, T 하의 잎으로서의 사전확률 질량 $1 - \alpha(1+d)^{-\beta}$ 대 T' 하의 내부노드로서의 $\alpha(1+d)^{-\beta}$)와 그 두 개의 새로운 잎 자식(깊이 $d+1, T'$ 하에서 각각 $1 - \alpha(2+d)^{-\beta}$ 를 기여하고 T 하에서는 아무 인자도 기여하지 않음)을 제외한 모든 노드의 분할/무분할 상태에서 일치한다. 다른 모든 노드의 인자는 $p(T)$ 와 $p(T')$ 에 공통으로 존재하여 소거된다:

$$\frac{p(T')}{p(T)} = \frac{\alpha(1+d)^{-\beta} [1 - \alpha(2+d)^{-\beta}]^2}{1 - \alpha(1+d)^{-\beta}}$$

생성 이동과 소멸 이동이 동일한 확률로 제안된다고 하면, $q(T' | T) = \frac{1}{2} \cdot \frac{1}{n_{\text{leaves}} p n_{\text{cand}}}$ (생성을 제안한 다음, n_{leaves} 개의 잎, p 개의 예측변수, n_{cand} 개의 후보 분할값 중에서 각각 균등하게 잎, 예측변수, 분할값을 선택)이고 $q(T | T') = \frac{1}{2} \cdot \frac{1}{n'_{\text{nog}}}$ (소멸을 제안한 다음, T' 에서 가지치기가 가능한 n'_{nog} 개의 “자손없는(no-grandchildren)” 노드 중에서 균등하게 선택)이다. $\frac{1}{2}$ 인자는 소거되어,

$$\frac{q(T | T')}{q(T' | T)} = \frac{n_{\text{leaves}} p n_{\text{cand}}}{n'_{\text{nog}}}$$

세 비율을 곱하고 로그를 취하면 앞서 제시한 수락비율을 다시 얻는다:

$$\log \alpha_{\text{birth}} = \underbrace{L(n_L, R_L) + L(n_R, R_R) - L(n, R)}_{\text{우도비}} + \underbrace{\log \frac{\alpha(1+d)^{-\beta} [1 - \alpha(2+d)^{-\beta}]^2}{1 - \alpha(1+d)^{-\beta}}}_{\text{나무사전분포비}} + \underbrace{\log \frac{n_{\text{leaves}} p n_{\text{cand}}}{n'_{\text{nog}}}}_{\text{전이비}},$$

여기서 n_{leaves} 는 생성 이전의 잎의 수, n_{cand} 는 선택된 잎에서 유효한 분할값의 수, n'_{nog} 는 생성 이후의 “자손없는” 노드(잎 자식 두 개를 가진 내부노드 — 이후의 소멸 이동이 가지치기할 수 있는 노드)의 수이다. 소멸 이동은 정확히 그 역단계이므로, 그 수락비율은 분자와 분모가 뒤바뀐 동일한 세 부분으로 이루어진다. n'_{nog} 를 정확히 계산하는 데에는 두 가지 세부사항이 중요하다. 새로 분할된 잎은 항상 자손없는 노드가 되지만, 만약 그 잎 자신의 부모가 분할 이전에 자손없는 노드였다면(그 형제도 잎이었던 경우), 그 부모는 더 이상 자손없는 노드가 아니게 된다 — 이 두 효과가 서로 상쇄될 수 있다.

알고리즘: 베이저안 배피팅(Backfitting) MCMC

모든 m 개의 나무를 $\mu = 0$ 인 단일잎 뿌리로 초기화하고, $\sigma^2 = \hat{\sigma}_{\text{OLS}}^2$ 로 설정한다. 매 스왑마다:

1. **각 나무** $j = 1, \dots, m$ 에 대해: 부분잔차 $r_i = y_i - \sum_{k \neq j} g(x_i; T_k, M_k)$ 를 구성한다. 생성 또는 소멸 이동을 제안하고(동일 확률, 소멸 이동이 불가능하면 생성이 강제됨) 위 유도 상자의 확률로 이를 수락한다. 그런 다음 (경우에 따라 갱신된) 나무구조를 고정한 채, 모든 잎 평균을 그 정확한 컬레 정규 조건부분포 $\mu_l | r, \sigma^2 \sim N(V_l R_l / \sigma^2, V_l)$, $V_l = (n_l / \sigma^2 + 1 / \sigma_\mu^2)^{-1}$ 에서 다시 추출한다.
2. **잔차분산**: $e_i = y_i - \sum_{j=1}^m g(x_i; T_j, M_j)$ 일 때, $\sigma^2 | \cdot \sim IG(\frac{\nu+T}{2}, \frac{\nu\lambda + \sum_i e_i^2}{2})$ 를 추출한다.

이 스왑을 반복하는 것이 베이저안 배피팅이다. 각 나무는 차례로 앙상블의 나머지 부분이 아직 설명하지 못한 것에 적합되는데, 이는 가우스-자이델(Gauss-Seidel)식 좌표 업데이트와 동일한 부분잔차 논리를 적절한 깁스 순환 안에 감싼 것이다. σ^2 과 모든 잎 평균이 전 과정에 걸쳐 정확한 조건부분포에서 추출되기 때문이다.

참고: 단순화, 튜닝, 그리고 더 넓은 베이저안 비모수 지형

완전한 Chipman-George-McCulloch(2010) 알고리즘에 비해 두 가지 단순화가 있음을 분명히 짚어둘 필요가 있다. 첫째, 여기서는 생성과 소멸 이동만을 사용한다. 완전한 알고리즘은 추가적인 혼합을 위해 변경(change) (노드의 분할을 다시 추출) 이동과 교환(swap)(부모와 자식 사이에 분할을 교환) 이동도 포함하는데, 실무에서 지배적인 조합인 생성/소멸만으로도 이 노트에서 사용하는 표본크기에서는 엄밀히 필요하지 않다. 둘째, 후보 분할값은 매 제안마다 다시 계산되는 노드국소적 격자가 아니라, 고정된 전역적, 예측변수별 격자(한 번 계산된 분위수)에서 해당 노드에 실제로 도달하는 값들로 제한하여 추출한다. 이는 목표 사후분포를 변화시키지 않는 표준적인 구현상의 지름길이다. 튜닝에 관해 말하자면, 폭넓은 응용범위에 걸쳐 BART의 대표적인 실증적 특성은, 위의 기본값 $(\alpha, \beta, k, m) = (0.95, 2, 2, 50-200)$ 설정이 자료셋별 조정 없이도 경쟁력 있는 성능을 낸다는 점이다. 이는 예컨대 명시적인 보정이 필요했던 이 노트의 미네소타 사전분포 λ_1, λ_2 (제13.2절)와는 대조적이다. BART는 이 노트이 그 밖에는 다루지 않은 훨씬 더 큰 베이

지만 비모수 도구상자의 한 구성원에 불과하다. 가우스 과정(Gaussian process) 사전분포는 나무의 합이 아니라 회귀함수의 공분산 구조에 직접 사전분포를 부여하여, $O(T^3)$ 의 계산량을 대가로 매끄러운(계단함수가 아닌) 사후추출값을 제공한다. 디리클레 과정 혼합(Dirichlet process mixture)은 조건부평균이 아니라 자료생성밀도 자체에 비모수 사전분포를 부여하여, 혼합성분의 수를 고정하지 않고 추론되도록 한다 — 이는 제18장의 고정된 2상태 국면모형을 무한개의 잠재 상태로 직접 일반화한 것이다. 둘 다 유한한 모수벡터가 아니라 함수나 분포에 사전분포를 부여한다는 이 장의 핵심 발상을 공유하는, 여기서부터의 자연스러운 다음 단계이다.

실증 예제: 제로금리하한 꺾임을 갖는 테일러 준칙(Taylor Rule)

이번 판 전체에서 사용하는 확장된 분기별 패널(1959Q3–2026Q1)에는 연방기금금리가 제로금리하한(zero lower bound, ZLB)에 머무는 국면이 이제 두 번 나타난다. 금융위기 이후의 긴 국면인 2009Q1–2016Q4(32개 분기)와, 팬데믹 시기의 짧은 국면인 2020Q2–2022Q1(8개 분기)로, 합쳐서 40개의 ZLB 분기이다 — 원래 표본에서 존재했던 단일한 20개 분기짜리 국면(2009–13년)의 두 배이다. 이 분기들에서 연방기금금리는 0.06%에서 0.45% 사이에 있으며, 테일러 준칙이라면 반응했을 분기별 인플레이션과 GDP 성장률 수치와 무관하게 사실상 고정되어 있다. 동일한 자료(동시기 CPI 인플레이션과 GDP 성장률에 대한 연방기금금리, $T = 267$ 개 분기, 다른 전처리 없음)에 BART($m = 50$ 개 나무)와 통상적인 베이지안 선형회귀를 적합하면, 전체 표본 표본내(in-sample) RMSE는 BART가 2.16퍼센트포인트, 선형적합이 2.81퍼센트포인트이다. 계단함수의 합과 선형 준칙 모두 팬데믹의 급격한 성장률 요동까지 수용해야 하지만, 그럼에도 BART가 선형 벤치마크에 대해 갖는 우위는 더 길고 더 까다로워진 표본에서도 그대로 유지된다. 더 뚜렷한 대조는 여전히 ZLB 분기들에서 나타나며, 이는 그림 86에 그려져 있다. 실제 평균 연방기금금리는 0.15%인데, 그 구간에서 BART의 적합값 평균은 2.78%(개별 분기별로 1.12%에서 7.05%까지 분포), 선형회귀의 평균은 3.74%(개별 분기별로 0.12%에서 8.73%까지 분포)이다 — BART가 완벽에 가까운 것은 아니다(예측변수가 단 두 개뿐이고, 실제 테일러 준칙 명세가 추가했을 법한 금리평탄화 시차항 i_{t-1} 이 없으므로, 두 모형 모두 인플레이션과 성장률만으로는 ZLB 국면을 완전히 식별할 수 없다. 1970 80년대의 일부 분기가 비슷하게 낮은 수치를 보이면서도 대신 두 자릿수의 연방기금금리를 가졌기 때문이며, 특히 팬데믹 시기의 ZLB 분기들은 유난히 낮은 인플레이션과 역사적으로 극단적인 성장률 요동을 함께 보여 분기마다 적합값을 서로 반대 방향으로 끌어당긴다), 그러나 계단함수 앙상블이라는 그 구조는 ZLB의 존재를 알려주지 않고서도, 평균적으로 제약 없는 선형 준칙보다 눈에 띄게 바닥에 더 가깝게 움직인다. 두 모형 모두 ZLB 분기에서 음(-)의 금리를 적합하는 일은 전혀 없는데, 그 이유는 서로 다르다. BART의 leaf 예측값은 관측된 y 값들의 평균(모든 적합값이 표본에서 실제로 관측된 연방기금금리들의 볼록결합이고, 그 최솟값이 0.06%다) 이므로 BART는 어디에서도 음의 금리를 적합할 수 없고, 선형 준칙은 구조적으로는 음의 금리를 예측할 수 있음에도 이 특정 공변량 값들에서는 그렇게 되지 않을 뿐이다.




Figure 86: 실제값 대 적합값 연방기금금리, 확장된 전체 표본(1959Q3–2026Q1); 음영대는 첫 번째 ZLB 분기부터 마지막 ZLB 분기까지(2009Q1부터 2022Q1까지)를 표시하므로, 두 ZLB 국면 사이에 있는 2017–2019년 구간(연방기금금리가 0.5%를 넘었던 시기)도 함께 포함된다




Figure 87: 40개 제로금리 하한 분기에서의 표본내 적합값: 실제 평균(0.15%) 대 BART(2.78%)와 선형 준칙(3.74%); 수직선은 ZLB 분기 전체에 걸친 각 모형 적합값의 최솟값과 최댓값 범위

참고문헌

- Albert, J. H., and Chib, S. (1993). “Bayesian Analysis of Binary and Polychotomous Response Data.” *Journal of the American Statistical Association*, 88(422), 669–679.
- Albert, J. H., and Chib, S. (1993). “Bayes Inference via Gibbs Sampling of Autoregressive Time Series Subject to Markov Mean and Variance Shifts.” *Journal of Business &*

Economic Statistics, 11(1), 1–15.

- Arias, J. E., Rubio-Ramírez, J. F., and Waggoner, D. F. (2018). “Inference Based on Structural Vector Autoregressions Identified with Sign and Zero Restrictions: Theory and Applications.” *Econometrica*, 86(2), 685–720.
- Bańbura, M., Giannone, D., and Reichlin, L. (2010). “Large Bayesian Vector Auto Regressions.” *Journal of Applied Econometrics*, 25(1), 71–92.
- Baumeister, C., and Hamilton, J. D. (2015). “Sign Restrictions, Structural Vector Autoregressions, and Useful Prior Information.” *Econometrica*, 83(5), 1963–1999.
- Boivin, J., and Giannoni, M. P. (2006). “Has Monetary Policy Become More Effective?” *Review of Economics and Statistics*, 88(3), 445–462. (Earlier version: 2002, FRBNY Economic Policy Review, 8(1), 97–111.)
- Boivin, J., Kiley, M. T., and Mishkin, F. S. (2010). “How Has the Monetary Transmission Mechanism Evolved Over Time?” In *Handbook of Monetary Economics*, Vol. 3A, eds. B. M. Friedman and M. Woodford, 369–422. Amsterdam: Elsevier.
- Bollerslev, T. (1986). “Generalized Autoregressive Conditional Heteroskedasticity.” *Journal of Econometrics*, 31(3), 307–327.
- Carriero, A., Clark, T. E., and Marcellino, M. (2019). “Large Bayesian Vector Autoregressions with Stochastic Volatility and Non-Conjugate Priors.” *Journal of Econometrics*, 212(1), 137–154.
- Carriero, A., Chan, J. C. C., Clark, T. E., and Marcellino, M. (2021). “Corrigendum to ‘Large Bayesian Vector Autoregressions with Stochastic Volatility and Non-Conjugate Priors.’” *Journal of Econometrics*, posted correction, Elsevier.
- Carter, C. K., and Kohn, R. (1994). “On Gibbs Sampling for State Space Models.” *Biometrika*, 81(3), 541–553.
- Carvalho, C. M., Polson, N. G., and Scott, J. G. (2010). “The Horseshoe Estimator for Sparse Signals.” *Biometrika*, 97(2), 465–480.
- Chan, J. C. C. (2017). Notes on Bayesian Macroeconometrics. Lecture notes, Purdue University / Australian National University.
- Chan, J. C. C., and Jeliazkov, I. (2009). “Efficient Simulation and Integrated Likelihood Estimation in State Space Models.” *International Journal of Mathematical Modelling and Numerical Optimisation*, 1(1–2), 101–120.
- Chan, J. C. C. (2020). “Large Bayesian Vector Autoregressions.” In *Macroeconomic Forecasting in the Era of Big Data*, ed. P. Fuleky, *Advanced Studies in Theoretical and Applied Econometrics*, Vol. 52, 95–125. Cham: Springer.
- Chan, J. C. C. (2021). “Minnesota-Type Adaptive Hierarchical Priors for Large Bayesian VARs.” *International Journal of Forecasting*, 37(3), 1212–1226.

- Chib, S. (1995). "Marginal Likelihood from the Gibbs Output." *Journal of the American Statistical Association*, 90(432), 1313–1321.
- Chib, S. (1996). "Calculating Posterior Distributions and Modal Estimates in Markov Mixture Models." *Journal of Econometrics*, 75(1), 79–97.
- Chib, S., and Greenberg, E. (1995). "Understanding the Metropolis–Hastings Algorithm." *The American Statistician*, 49(4), 327–335.
- Chib, S., and Jeliazkov, I. (2001). "Marginal Likelihood from the Metropolis–Hastings Output." *Journal of the American Statistical Association*, 96(453), 270–281.
- Chipman, H. A., George, E. I., and McCulloch, R. E. (1998). "Bayesian CART Model Search." *Journal of the American Statistical Association*, 93(443), 935–948.
- Chipman, H. A., George, E. I., and McCulloch, R. E. (2010). "BART: Bayesian Additive Regression Trees." *Annals of Applied Statistics*, 4(1), 266–298.
- Christiano, L. J., Eichenbaum, M., and Evans, C. L. (1996). "The Effects of Monetary Policy Shocks: Evidence from the Flow of Funds." *Review of Economics and Statistics*, 78(1), 16–34.
- Christiano, L. J., Eichenbaum, M., and Evans, C. L. (1999). "Monetary Policy Shocks: What Have We Learned and to What End?" In *Handbook of Macroeconomics*, Vol. 1A, eds. J. B. Taylor and M. Woodford, 65–148. Amsterdam: Elsevier.
- Clark, T. E. (2011). "Real-Time Density Forecasts from Bayesian Vector Autoregressions with Stochastic Volatility." *Journal of Business & Economic Statistics*, 29(3), 327–341.
- Clark, P. K. (1987). "The Cyclical Component of U.S. Economic Activity." *Quarterly Journal of Economics*, 102(4), 797–814.
- Cogley, T., and Sargent, T. J. (2001). "Evolving Post-World War II U.S. Inflation Dynamics." *NBER Macroeconomics Annual*, 16, 331–373.
- Doan, T., Litterman, R., and Sims, C. (1984). "Forecasting and Conditional Projection Using Realistic Prior Distributions." *Econometric Reviews*, 3(1), 1–100.
- De Mol, C., Giannone, D., and Reichlin, L. (2008). "Forecasting Using a Large Number of Predictors: Is Bayesian Shrinkage a Valid Alternative to Principal Components?" *Journal of Econometrics*, 146(2), 318–328.
- Eichenbaum, M. (1992). "Comment on 'Interpreting the Macroeconomic Time Series Facts: The Effects of Monetary Policy' by Christopher Sims." *European Economic Review*, 36(5), 1001–1011.
- Engle, R. F. (1982). "Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation." *Econometrica*, 50(4), 987–1007.
- Engle, R. F., and Kraft, D. (1983). "Multi-period Forecast Error Variances of Inflation Es-

timated from ARCH Models.” In *Applied Time Series Analysis of Economic Data*, ed. A. Zellner, 293–302. Washington, DC: Bureau of the Census.

- Estrella, A. (1998). “A New Measure of Fit for Equations with Dichotomous Dependent Variables.” *Journal of Business & Economic Statistics*, 16(2), 198–205. (First circulated in 1995 as a Federal Reserve Bank of New York research paper.)
- Estrella, A., and Mishkin, F. S. (1998). “Predicting U.S. Recessions: Financial Variables as Leading Indicators.” *Review of Economics and Statistics*, 80(1), 45–61.
- Frühwirth-Schnatter, S. (1994). “Data Augmentation and Dynamic Linear Models.” *Journal of Time Series Analysis*, 15(2), 183–202.
- Faust, J. (1998). “The Robustness of Identified VAR Conclusions About Money.” *Carnegie-Rochester Conference Series on Public Policy*, 49, 207–244.
- Gelfand, A. E., and Smith, A. F. M. (1990). “Sampling-Based Approaches to Calculating Marginal Densities.” *Journal of the American Statistical Association*, 85(410), 398–409.
- Gelman, A., and Rubin, D. B. (1992). “Inference from Iterative Simulation Using Multiple Sequences.” *Statistical Science*, 7(4), 457–472.
- George, E. I., and McCulloch, R. E. (1993). “Variable Selection via Gibbs Sampling.” *Journal of the American Statistical Association*, 88(423), 881–889.
- Geman, S., and Geman, D. (1984). “Stochastic Relaxation, Gibbs Distributions, and the Bayesian Restoration of Images.” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 6(6), 721–741.
- Geweke, J. (1992). “Evaluating the Accuracy of Sampling-Based Approaches to the Calculation of Posterior Moments.” In *Bayesian Statistics 4*, eds. J. M. Bernardo, J. O. Berger, A. P. Dawid, and A. F. M. Smith, 169–193. Oxford: Oxford University Press.
- Giannone, D., Lenza, M., and Primiceri, G. E. (2015). “Prior Selection for Vector Autoregressions.” *Review of Economics and Statistics*, 97(2), 436–451.
- Hamilton, J. D. (1989). “A New Approach to the Economic Analysis of Nonstationary Time Series and the Business Cycle.” *Econometrica*, 57(2), 357–384.
- Harvey, A. C. (1985). “Trends and Cycles in Macroeconomic Time Series.” *Journal of Business & Economic Statistics*, 3(3), 216–227.
- Hastings, W. K. (1970). “Monte Carlo Sampling Methods Using Markov Chains and Their Applications.” *Biometrika*, 57(1), 97–109.
- Kadiyala, K. R., and Karlsson, S. (1997). “Numerical Methods for Estimation and Inference in Bayesian VAR-Models.” *Journal of Applied Econometrics*, 12(2), 99–132.
- Kalman, R. E. (1960). “A New Approach to Linear Filtering and Prediction Problems.” *Journal of Basic Engineering*, 82(1), 35–45.

- Kass, R. E., and Raftery, A. E. (1995). “Bayes Factors.” *Journal of the American Statistical Association*, 90(430), 773–795.
- Kim, C.-J., and Nelson, C. R. (1999). *State-Space Models with Regime Switching: Classical and Gibbs-Sampling Approaches with Applications*. Cambridge, MA: MIT Press.
- Kim, S., Shephard, N., and Chib, S. (1998). “Stochastic Volatility: Likelihood Inference and Comparison with ARCH Models.” *Review of Economic Studies*, 65(3), 361–393.
- Laubach, T., and Williams, J. C. (2003). “Measuring the Natural Rate of Interest.” *Review of Economics and Statistics*, 85(4), 1063–1070.
- Lenza, M., and Primiceri, G. E. (2022). “How to Estimate a Vector Autoregression after March 2020.” *Journal of Applied Econometrics*, 37(4), 688–699.
- McConnell, M. M., and Perez-Quiros, G. (2000). “Output Fluctuations in the United States: What Has Changed Since the Early 1980’s?” *American Economic Review*, 90(5), 1464–1476.
- Link, W. A., and Eaton, M. J. (2012). “On Thinning of Chains in MCMC.” *Methods in Ecology and Evolution*, 3(1), 112–115.
- Koop, G. (2013). “Forecasting with Medium and Large Bayesian VARs.” *Journal of Applied Econometrics*, 28(2), 177–203.
- Litterman, R. B. (1986). “Forecasting with Bayesian Vector Autoregressions: Five Years of Experience.” *Journal of Business & Economic Statistics*, 4(1), 25–38.
- Makalic, E., and Schmidt, D. F. (2016). “A Simple Sampler for the Horseshoe Estimator.” *IEEE Signal Processing Letters*, 23(1), 179–182.
- Metropolis, N., Rosenbluth, A. W., Rosenbluth, M. N., Teller, A. H., and Teller, E. (1953). “Equation of State Calculations by Fast Computing Machines.” *Journal of Chemical Physics*, 21(6), 1087–1092.
- Nelson, C. R., and Plosser, C. I. (1982). “Trends and Random Walks in Macroeconomic Time Series: Some Evidence and Implications.” *Journal of Monetary Economics*, 10(2), 139–162.
- Primiceri, G. E. (2005). “Time Varying Structural Vector Autoregressions and Monetary Policy.” *Review of Economic Studies*, 72(3), 821–852.
- Roberts, G. O., and Rosenthal, J. S. (2001). “Optimal Scaling for Various Metropolis–Hastings Algorithms.” *Statistical Science*, 16(4), 351–367.
- Rossi, B., and Sekhposyan, T. (2010). “Have Economic Models’ Forecasting Performance for US Output Growth and Inflation Changed Over Time, and When?” *Journal of Applied Econometrics*, 25(4), 808–835.
- Rudebusch, G. D., and Svensson, L. E. O. (1999). “Policy Rules for Inflation Targeting.”

In Monetary Policy Rules, ed. J. B. Taylor, 203–246. Chicago: University of Chicago Press.

- Ramey, V. A. (2016). “Macroeconomic Shocks and Their Propagation.” In Handbook of Macroeconomics, Vol. 2, 71–162. Amsterdam: Elsevier.
- Rubio-Ramírez, J. F., Waggoner, D. F., and Zha, T. (2010). “Structural Vector Autoregressions: Theory of Identification and Algorithms for Inference.” Review of Economic Studies, 77(2), 665–696.
- Sargent, T. J. (1999). The Conquest of American Inflation. Princeton, NJ: Princeton University Press.
- Sims, C. A. (1980). “Macroeconomics and Reality.” Econometrica, 48(1), 1–48.
- Sims, C. A. (1992). “Interpreting the Macroeconomic Time Series Facts: The Effects of Monetary Policy.” European Economic Review, 36(5), 975–1000.
- Sims, C. A. (2001). “Comment on Sargent and Cogley’s ‘Evolving Post-World War II U.S. Inflation Dynamics.’” NBER Macroeconomics Annual, 16, 373–379.
- Sims, C. A., and Zha, T. (1998). “Bayesian Methods for Dynamic Multivariate Models.” International Economic Review, 39(4), 949–968.
- Song, J., and Kang, K. H. (2025). “Stochastic Volatility Selection in Bayesian VARs.” Working paper, Department of Economics, Korea University.
- Stewart, G. W. (1980). “The Efficient Generation of Random Orthogonal Matrices with an Application to Condition Estimators.” SIAM Journal on Numerical Analysis, 17(3), 403–409.
- Stock, J. H. (2001). “Comment on Cogley and Sargent’s ‘Evolving Post-World War II U.S. Inflation Dynamics.’” NBER Macroeconomics Annual, 16, 379–387.
- Stock, J. H., and Watson, M. W. (2001). “Vector Autoregressions.” Journal of Economic Perspectives, 15(4), 101–115.
- Stock, J. H., and Watson, M. W. (2005). “Implications of Dynamic Factor Models for VAR Analysis.” NBER Working Paper No. 11467.
- Watson, M. W. (1986). “Univariate Detrending Methods with Stochastic Trends.” Journal of Monetary Economics, 18(1), 49–75.
- Wu, J. C., and Xia, F. D. (2016). “Measuring the Macroeconomic Impact of Monetary Policy at the Zero Lower Bound.” Journal of Money, Credit and Banking, 48(2–3), 253–291.
- Tierney, L. (1994). “Markov Chains for Exploring Posterior Distributions.” Annals of Statistics, 22(4), 1701–1728.

- Tobin, J. (1958). "Estimation of Relationships for Limited Dependent Variables." *Econometrica*, 26(1), 24–36.
- Uhlig, H. (2005). "What Are the Effects of Monetary Policy on Output? Results from an Agnostic Identification Procedure." *Journal of Monetary Economics*, 52(2), 381–419.
- Zellner, A. (1962). "An Efficient Method of Estimating Seemingly Unrelated Regressions and Tests for Aggregation Bias." *Journal of the American Statistical Association*, 57(298), 348–368.